

7.1 引言

主讲： 施明辉

厦门大学

函数逼近与函数插值

- 函数逼近与函数插值既有相同点，又有不同点。
- 相同点：
 - 二者都是对于实际中的复杂函数，构造一个既能反映函数本身的特性又便于计算的简单函数，近似代替原来的函数。
- 不同点：
 - 函数插值是对于一组离散点 $(x_i, f(x_i)), (i = 0, 1, 2, \dots, n)$ ，选定一个便于计算的简单函数形式 $p(x)$ ，要求简单函数 $p(x)$ 满足 $p(x_i) = f(x_i), (i = 0, 1, 2, \dots, n)$ 。由此确定函数 $p(x)$ 作为 $f(x)$ 的近似函数。
 - 函数逼近是对于实际中的复杂函数 $f(x)$ ，构造一个简单函数 $p(x)$ ，要求其误差整体上在某种度量意义下最小。

函数逼近的含义

- 函数逼近是指：


“对函数类A中给定的函数 $f(x)$ ，记作 $f(x) \in A$ ，要求在另一类简单的便于计算的函数类B中求函数 $P(x) \in B$ ，使 $P(x)$ 与 $f(x)$ 的误差在某种度量下最小”

- 说明：

- 函数类A中给定的函数 $f(x)$ 通常是区间 $[a, b]$ 上的连续函数(也可以是用(离散的)点表示)
- 函数类B中的函数 $P(x)$ 通常是代数多项式，三角多项式，有理函数或分段低次多项式等。

函数逼近的基本问题

1. “函数类”如何描述？
2. 如何度量函数间的误差？



向量空间（线性空间）的定义与性质

定义 设 V 是一个非空集合, $\mathbf{R}$ 为实数域,如果对于任意两个元素 $\alpha, \beta \in V$, 总有唯一的一个元素 $\gamma \in V$ 与之对应, 称为 α 与 β 的和, 记作 $\gamma = \alpha + \beta$; 又对于任一数 $\lambda \in \mathbf{R}$ 与任意元素 $\alpha \in V$, 总有唯一的一个元素 $\delta \in V$ 与之对应, 称为 λ 与 α 的积, 记作 $\delta = \lambda \alpha$;

且这两种运算满足以下八条运算规律(设 $\alpha, \beta, \gamma \in V$; $\lambda, \mu \in \mathbf{R}$):

$$(i) \alpha + \beta = \beta + \alpha$$

$$(ii) (\alpha + \beta) + \gamma = \alpha + (\beta + \gamma)$$

(iii) 在 V 中存在零元素 0 , 对任何 $\alpha \in V$, 都有 $\alpha + 0 = \alpha$;

(iv) 对任何 $\alpha \in V$, 都有 α 的负元素 $\beta \in V$, 使 $\alpha + \beta = 0$;

(v) $1\alpha = \alpha$

(vi) $\lambda(\mu\alpha) = (\lambda\mu)\alpha$

(vii) $(\lambda + \mu)\alpha = \lambda\alpha + \mu\alpha$

(viii) $\lambda(\alpha + \beta) = \lambda\alpha + \lambda\beta$

那么, V 就称为(实数域 $\mathbb{R}$ 上的)向量空间(或线性空间), V 中的元素无论其本来的性质如何, 称为(实)向量.

简言之, 凡是满足八条规律的加法及乘数运算, 就称为线性运算; 凡定义了线性运算的集合, 就称为向量空间.

例 证明**次数不超过** n 的多项式全体, 记作 $P[x]_n$, 即
$$P[x]_n = \{a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0 \mid a_0, \cdots, a_n \in R\}$$

对于通常的多项式**加法**、数乘多项式的**乘法**构成向量空间。

证明: 多项式加法、数乘两种运算显然满足线性运算规律, 故只要证 $P[x]_n$ 对两种运算封闭: 事实上

$$\begin{aligned} & (a_n x^n + \cdots + a_1 x + a_0) + (b_n x^n + \cdots + b_1 x + b_0) \\ &= (a_n + b_n) x^n + \cdots + (a_1 + b_1) x + (a_0 + b_0) \in P[x]_n \end{aligned}$$

$$\begin{aligned} & \lambda(a_n x^n + \cdots + a_1 x + a_0) \\ &= (\lambda a_n) x^n + \cdots + (\lambda a_1) x + (\lambda a_0) \in P[x]_n \end{aligned}$$

所以 $P[x]_n$ 是一个向量空间.

[注] 1) 这个向量空间的零元素为0;

2) $\sum_{k=0}^n a_k x^k$ 的负元素为 $\sum_{k=0}^n (-a_k) x^k$

线性组合

设 V 是数域 P 上的一个线性空间, $\alpha_1, \alpha_2, \dots, \alpha_r$ ($r \geq 1$) 是一组向量, $k_1, k_2, \dots, k_r$ 是数域 P 中的数, 那么向量 α

$$\alpha = k_1\alpha_1 + k_2\alpha_2 + \dots + k_r\alpha_r$$

称为 向量组 $\alpha_1, \alpha_2, \dots, \alpha_r$ 的一个线性组合, 有时也说向量 α 可以用向量组线性表出.

线性相关

- **定义** 设集合 S 是数域 P 上的线性空间，元素 $x_1, x_2, \dots, x_n \in S$ ，如果存在不全为零的数 $a_1, a_2, \dots, a_n \in P$ ，使得

$$a_1 x_1 + a_2 x_2 + \dots + a_n x_n = 0, \quad (1)$$

则称 $x_1, x_2, \dots, x_n$ **线性相关**。

否则，称 $x_1, x_2, \dots, x_n$ **线性无关**。

基 如果在线性空间 V 中有 n 个线性无关的向量 $\alpha_1, \alpha_2, \dots, \alpha_n$, 且 V 中任一向量都可以用它们线性表示, 那么

$\alpha_1, \alpha_2, \dots, \alpha_n$ 就是线性空间的一组基.

例 在线性空间 $P[x]_n$ 中, $1, x, x^2, \dots, x^{n-1}, x^n$ 是线性无关的向量, 而且每一个**次数不大于** n 的数域 R 上的多项式都可以被它们线性表示, 所以 $1, x, x^2, \dots, x^{n-1}, x^n$ 就是 $P[x]_n$ 的一组基.



在 n 维空间 R^n 中，显然

$$\begin{cases} \varepsilon_1 = (1, 0, \dots, 0), \\ \varepsilon_2 = (0, 1, \dots, 0), \\ \dots\dots\dots \\ \varepsilon_n = (0, 0, \dots, 1) \end{cases}$$

是一组基. 对于每一个向量 $\alpha = (a_1, a_2, \dots, a_n)$, 都有

$$\alpha = a_1 \varepsilon_1 + a_2 \varepsilon_2 + \dots + a_n \varepsilon_n$$

$(a_1, a_2, \dots, a_n)$ 就是向量 α 在这组基下的坐标.

- 现在，线性空间可用它的基来描述。
- $S = \text{span}\{x_1, x_2, \dots, x_n\}$ 表示 S 是由 $x_1, x_2, \dots, x_n$ 生成的，其中 $x_1, x_2, \dots, x_n$ 线性无关。

再看 函数逼近问题

一般情形

- **函数逼近问题**就是对 $\forall f(x) \in C[a, b]$, 在子空间 $\Phi = \text{Span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_m(x)\}$ 中找一个元素 $\varphi^*(x)$, 使得 $f(x) - \varphi^*(x)$ 在**某种意义**下最小.

范数与赋范线性空间

• **定义** 设 S 为线性空间, $x \in S$, 若存在实函数 $||\cdot||$ 满足条件:

(1) $||x|| \geq 0$, 当且仅当 $x=0$ 时 $||x||=0$; (正定性)

(2) $||\alpha x|| = |\alpha| ||x||$, $\alpha \in P$; (齐次性)

(3) $||x+y|| \leq ||x|| + ||y||$, $\forall x, y \in S$. (三角不等式)

则称 $||\cdot||$ 为线性空间 S 上**范数**, S 与 $||\cdot||$ 一起称为**赋范线性空间**, 记为 X .

三种常用范数

在 R^n 上的向量

$$x = (x_1, x_2, \dots, x_n)^T \in R^n$$

$$\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i|,$$

$$\|x\|_1 = \sum_{i=1}^n |x_i|,$$

$$\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2},$$

对连续函数空间

$$C[a, b], f \in C[a, b]$$

$$\|f\|_{\infty} = \max_{a \leq x \leq b} |f(x)|, \quad \text{称为}\infty\text{-范数};$$

$$\|f\|_1 = \int_a^b |f(x)| dx, \quad \text{称为}1\text{-范数};$$

$$\|f\|_2 = \sqrt{\int_a^b f^2(x) dx}, \quad \text{称为}2\text{-范数}.$$

内积与内积空间

- **定义3** 设 X 为数域 K ($\mathbb{R}$ 或 $\mathbb{C}$)上的线性空间, 对 $\forall u, v \in X$, 有 K 中一个数与之对应, 记为 (u, v) , 它满足以下条件:
 - (1) $(u, v) = \overline{(v, u)}, \forall u, v \in X;$ 共轭对称性
 - (2) $(\alpha u, v) = \alpha(u, v) = (u, \alpha v), \forall \alpha \in K, \forall u, v \in X;$ 线性性
 - (3) $(u + v, w) = (u, w) + (v, w), \forall u, v, w \in X;$
 - (4) $(u, u) \geq 0$, and $(u, u) = 0$ iff $u = 0$. 非负性
- 则称 (u, v) 为 X 上 u 与 v 的**内积**. 定义了内积的线性空间称为**内积空间**.
- 特别地, $(u, \mathbf{0}) = 0, \forall u \in X$.
- 若 $(u, v) = 0$, 则称 u 与 v **正交**.

例1 实数域向量的内积

$\mathbf{R}^n$ 的内积.

设 $x, y \in \mathbf{R}^n$, $x = (x_1, \cdots, x_n)^T$, $y = (y_1, \cdots, y_n)^T$,

$$(x, y) = \sum_{i=1}^n x_i y_i$$

例2 实数域带权内积

若给定实数 $\omega_i > 0 (i = 1, 2, \dots, n)$, 称 $\{\omega_i\}$ 为权系数,
 $\mathbf{R}^n$ 上的加权内积为

$$(x, y) = \sum_{i=1}^n \omega_i x_i y_i$$

当 $\omega_i = 1 (i = 1, 2, \dots, n)$ 时, 就是前面定义的内积.

例3 复数域带权内积

如果 $x, y \in C^n$, 带权内积定义为

$$(x, y) = \sum_{i=1}^n \omega_i x_i \overline{y_i} \quad (1.14)$$

这里 $\{\omega_i\}$ 仍为正实数序列, $\overline{y_i}$ 为 y_i 的共轭.

例4 函数的内积

$$(f(x), g(x)) = \int_a^b f(x)g(x)dx.$$

例4 函数的带权内积

设 $f(x), g(x) \in C[a, b]$, $\rho(x)$ 是 $[a, b]$ 上给定的权函数
则可定义内积

$$(f(x), g(x)) = \int_a^b \rho(x) f(x) g(x) dx.$$

称为**带权 $\rho(x)$ 的内积**.

权函数 $\rho(x)$ 是满足一定条件的函数,
其作用相当于给每个点赋予相应的
权重, 用以表示其重要性。

权函数

设 $[a, b]$ 是有限或无限区间, 在 $[a, b]$ 上的非负函数 $\rho(x)$ 满足条件:

(1) $\int_a^b x^k \rho(x) dx$ 存在且为有限值 ($k = 0, 1, \dots$),

(2) 对 $[a, b]$ 上的非负连续函数 $g(x)$,

如果 $\int_a^b g(x) \rho(x) dx = 0$, 则 $g(x) \equiv 0$.

则称 $\rho(x)$ 为 $[a, b]$ 上的一个权函数.

常见的权函数：

$$\textcircled{1} \quad \rho(x) = 1. (-1 \leq x \leq 1)$$

$$\textcircled{2} \quad \rho(x) = \frac{1}{\sqrt{1-x^2}}. x \in [-1, 1]$$

$$\textcircled{3} \quad \rho(x) = e^{-x}. (0 < x < +\infty)$$

$$\textcircled{4} \quad \rho(x) = e^{-x^2}. (-\infty < x < +\infty)$$

通过内积定义导出的范数

- 内积空间X中可以通过内积, 导出一种范数:

$$\|u\| = \sqrt{(u, u)} \quad (1.10)$$

可以用范数的定义来验证。

- 范数的定义:

(1) $\|x\| \geq 0$, 当且仅当 $x=0$ 时 $\|x\|=0$; (正定性)

(2) $\|\alpha x\| = |\alpha| \|x\|$, $\alpha \in \mathbb{P}$; (齐次性)

(3) $\|x + y\| \leq \|x\| + \|y\|$, $\forall x, y \in S$. (三角不等式)

通过内积定义导出的范数

例1

$\mathbf{R}^n$ 的内积.

设 $x, y \in \mathbf{R}^n$, $x = (x_1, \dots, x_n)^T$, $y = (y_1, \dots, y_n)^T$,

$$(x, y) = \sum_{i=1}^n x_i y_i$$

向量的2-范数为

$$\|x\|_2 = (x, x)^{\frac{1}{2}} = \left(\sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}}$$

通过内积定义导出的范数

例2

若给定实数 $\omega_i > 0 (i = 1, 2, \dots, n)$, 称 $\{\omega_i\}$ 为权系数,

$\mathbb{R}^n$ 上的加权内积为

$$(x, y) = \sum_{i=1}^n \omega_i x_i y_i$$

相应的范数为

$$\|x\|_2 = \left(\sum_{i=1}^n \omega_i x_i^2 \right)^{\frac{1}{2}}.$$

例3

$C[a, b]$ 上的内积.

设 $f(x), g(x) \in C[a, b]$, $\rho(x)$ 是 $[a, b]$ 上给定的权函数

则可定义内积

$$(f(x), g(x)) = \int_a^b \rho(x) f(x) g(x) dx.$$

由此内积导出的范数为

$$\|f(x)\|_2 = (f(x), f(x))^{\frac{1}{2}} = \left[\int_a^b \rho(x) f^2(x) dx \right]^{\frac{1}{2}}$$

称为**带权 $\rho(x)$ 的范数**.

常用的是 $\rho(x) \equiv 1$ 的情形, 即

$$(f(x), g(x)) = \int_a^b f(x)g(x)dx.$$

$$\|f(x)\|_2 = \left[\int_a^b f^2(x)dx \right]^{\frac{1}{2}}$$

再看 函数逼近问题

一般情形

- **函数逼近问题**就是对 $\forall f(x) \in C[a, b]$, 在子空间 $\Phi = \text{Span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_m(x)\}$, 中找一个元素 $\varphi^*(x)$, 使得 $f(x) - \varphi^*(x)$ 在**某种意义**下最小.

度量标准常用的有两种: **∞ -范数, 2-范数**

• 度量标准

– 1 $\|f(x)-P(x)\|_{\infty}=\max_{a\leq x\leq b}|f(x)-P(x)|.$

- 在这种度量(一致范数)意义下的函数逼近称为一致逼近或均匀逼近;

– 2 $\|f(x)-P(x)\|_2=\sqrt{\int_a^b\rho(x)(f(x)-P(x))^2dx}.$

- 用这种度量(欧氏范数)的函数逼近称为均方逼近或平方逼近.

最佳一致逼近问题或切比雪夫问题

- 固定 n , 在 $G_n = \text{span}\{1, x, \dots, x^n\}$ 中求 $P_n^*(x)$ 逼近 $f(x) \in C[a, b]$, 使其误差

$$\|f(x) - P_n^*(x)\|_\infty = \min_{P_n(x) \in G_n} \|f(x) - P_n(x)\|_\infty$$

- 这是所谓最佳一致逼近问题或切比雪夫 (有的书中译成“契比晓夫”) 问题.

最佳平方逼近问题

连续情形

- 对于被逼近函数 $f(x) \in C[a, b]$, 在某函数类 Φ_n 中, 寻求一个逼近函数 $P^*(x)$ 使得

$$\|f - P^*\|_2 = \min_{P \in \Phi_n} \|f - P\|_2$$

其中逼近函数 $P^*(x)$ 称为 $f(x)$ 在 $[a, b]$ 上的最佳平方逼近函数, 或称 $P^*(x)$ 为 Φ_n 对 $[a, b]$ 上的 $f(x)$ 的最佳平方逼近函数.

这里, $\Phi_n = \text{Span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)\}$.

最佳平方逼近问题

离散情形：曲线拟合问题

- **离散情形：曲线拟合问题：**
- 对于给定的数据， $(x_i, y_i)(i = 1, 2, \dots, N)$
- 要求在函数类 $\Phi = \text{span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)\}$
- 中找一个函数， $\varphi^*(x) = a_0^* \varphi_0(x) + a_1^* \varphi_1(x) + \dots + a_n^* \varphi_n(x) (n < N)$
- 使其与给定的数据拟合的程度是该函数类中最好的。

函数与给定数据

拟合程度的常用度量方法

1. 使偏差绝对值之和最小

$$\min_{\varphi} \sum_{i=1}^m |\delta_i| = \sum_{i=1}^m |\varphi(x_i) - y_i|$$

2. 使偏差绝对值最大的最小

$$\min_{\varphi} \max_i |\delta_i| = \min_{\varphi} \max_i |\varphi(x_i) - y_i|$$

3. 使偏差平方和最小

$$\min_{\varphi} \sum_{i=1}^m \delta_i^2 = \sum_{i=1}^m (\varphi(x_i) - y_i)^2$$

按偏差平方和最小的原则选取拟合曲线，称为最小二乘法。

- End.