

期末复习

- 基础
- 存储与管理
- 处理与分析

大数据基础

- 第1章 概述
- 第2章 大数据处理架构Hadoop

第1章 大数据概述

■ 大数据的概念

- 4V：数据量大、数据类型繁多、处理速度快、价值密度低。


■ 大数据的影响

- 对科学研究的影响
 - 实验→理论→计算→数据密集型
- 对思维方式的影响
 - 全样、效率、相关

第1章 大数据概述

■ 云计算

■ 概念




第1章 大数据概述

■ 云计算

■ 关键技术


■ 虚拟化、分布式存储、分布式计算、多租户等



第1章 大数据概述

■ 物联网

■ 概念



第1章 大数据概述

■ 物联网

- 技术：识别和感知技术（二维码、RFID、传感器等）、网络与通信技术、数据挖掘与融合技术等




图1-10 矩阵式二维码



图1-11 采用RFID芯片的公交卡



(a)温湿度传感器



(b)压力传感器

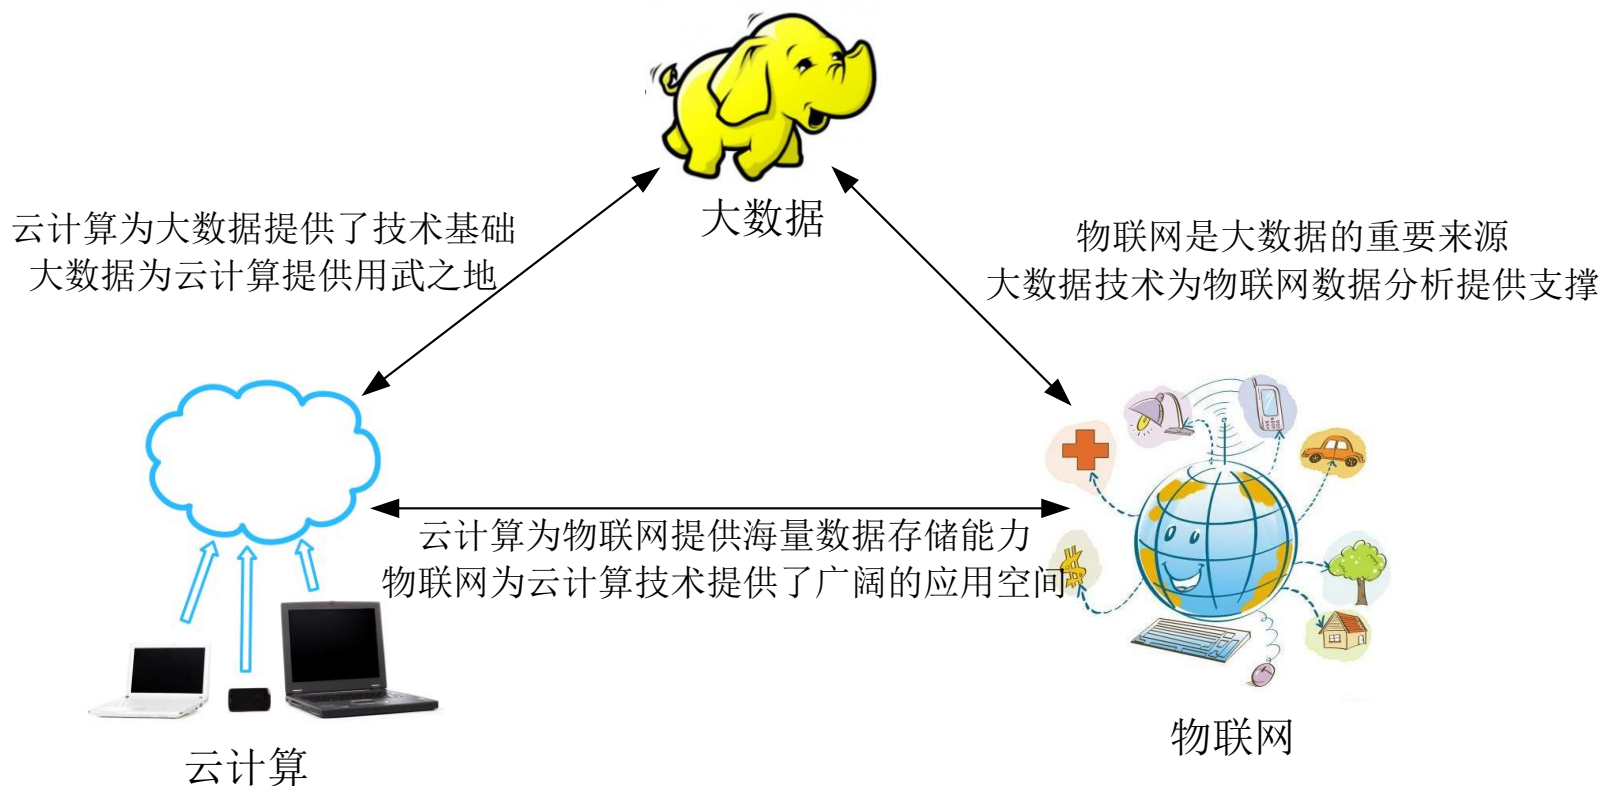


(c)烟雾传感器

图1-12 不同类型的传感器

第1章 大数据概述

■ 大数据、云计算、物联网



第2章 大数据处理架构Hadoop

■ 特性


- 高可靠性、高效性、高可扩展性、高容错性、成本低、支持多种编程语言

■ 生态系统

组件	功能
HDFS	分布式文件系统
MapReduce	分布式并行编程模型
YARN	资源管理和调度器
Tez	运行在YARN之上的下一代Hadoop查询处理框架
Hive	Hadoop上的数据仓库
HBase	Hadoop上的非关系型的分布式数据库
Pig	一个基于Hadoop的大规模数据分析平台，提供类似SQL的查询语言Pig Latin
Sqoop	用于在Hadoop与传统数据库之间进行数据传递
Oozie	Hadoop上的工作流管理系统
Zookeeper	提供分布式协调一致性服务
Storm	流计算框架
Flume	一个高可用的，高可靠的，分布式的海量日志采集、聚合和传输的系统
Ambari	Hadoop快速部署工具，支持Apache Hadoop集群的供应、管理和监控
Kafka	一种高吞吐量的分布式发布订阅消息系统，可以处理消费者规模的网站中的所有动作流数据
Spark	类似于Hadoop MapReduce的通用并行框架

第2章 大数据处理架构Hadoop

■ 生态系统



第2章 大数据处理架构Hadoop

■ 计算机集群结构

- 分布式文件系统把文件分布存储到多个计算机节点上，成千上万的计算机节点构成计算机集群





图3-1 计算机集群的基本架构

第2章 大数据处理架构Hadoop

■ 计算机集群结构

- 普通的Hadoop集群结构由一个两阶网络构成
- 每个机架（Rack）有30-40个服务器，配置一个1GB的交换机，并向上传输到一个核心交换机或者路由器（1GB或以上）
- 在相同的机架中的节点间的带宽的总和，要大于不同机架间的节点间的带宽总和




大数据存储与管理

- 第3章 分布式文件系统HDFS
- 第4章 分布式数据库HBase
- 第5章 NoSQL数据库
- 第6章 云数据库

第3章 分布式文件系统HDFS

■ 分布式文件系统



第3章 分布式文件系统HDFS

■ 相关概念

- 块、名称节点、数据节点、第二名称节点


■ 名称节点的数据结构

- FsImage

- EditLog


■ 数据节点

- 负责数据的存储和读取
- 向名称节点定期发送自己所存储的块的列表




第3章 分布式文件系统HDFS

■ 第二名称节点的工作情况



第3章 分布式文件系统HDFS

■ 体系结构



第3章 分布式文件系统HDFS

■ 1.0和2.0的区别

■ 2.0高可用（HA）的作用

■ 多副本存取策略

■ 容错性

■ 名称节点出错

■ 数据节点出错


■ 数据出错

第3章 分布式文件系统HDFS

——读数据的过程

```
import org.apache.hadoop.fs.FileSystem
Configuration conf = new Configuration();
FileSystem fs = FileSystem.get(conf);
FSDataInputStream in = fs.open(new Path(uri));
```


通过ClientProtocol.getBlockLocations()
远程调用名称节点，获得文件开始部分数据块的位置
对于该数据块，名称节点返回保存该数据块
的所有数据节点的地址
并根据距离客户端远近进行排序



第3章 分布式文件系统HDFS


——写数据的过程

```
import org.apache.hadoop.fs.FileSystem
Configuration conf = new Configuration();
FileSystem fs = FileSystem.get(conf);
FSDataOutputStream out = fs.create(new Path(uri));
```



第4章 分布式数据库HBase

■ 数据模型



第4章 分布式数据库HBase

■ 数据模型

■ 数据坐标




第4章 分布式数据库HBase

■ 三个功能组件

■ 库函数、Master、Region

■ 三层结构



第4章 分布式数据库HBase

■ 三层结构


层次	名称	作用
第一层	Zookeeper文件	记录了-RROOT-表的位置信息
第二层	-ROOT-表	记录了.META.表的Region位置信息 -ROOT-表只能有一个Region。通过-RROOT-表，就可以访问.META.表中的数据
第三层	.META.表	记录了用户数据表的Region位置信息， .META.表可以有多个Region，保存了HBase中所有用户数据表的Region位置信息

■ Region数目的计算

■ 三级寻址


第4章 分布式数据库HBase

■ 系统架构



第4章 分布式数据库HBase

■ Region服务器工作原理




1. 用户读写数据过程
2. 缓存的刷新
3. **StoreFile**的合并

第4章 分布式数据库HBase

■ StoreFile的工作原理

■ 合并与分裂



■ Log工作原理

■ HBase系统为每个Region服务器配置了一个HLog

文件

■ 容错

第5章 NoSQL

- 概念
- 四大类型
- 三大基石
 - CAP
- **BASE**和**ACID**的区别与联系
- 最终一致性

第6章 云数据库

- 概念
- 优点


大数据处理与分析

- 第7章 MapReduce
- 第9章 Spark
- 第10章 流计算

第7章 MapReduce


■ 体系结构

■ Client、JobTracker、TaskTracker、Task




第7章 MapReduce

■ 工作流程



第7章 MapReduce

■ 具体执行阶段



第7章 MapReduce

■ Shuffle过程

- Map端和Reduce端

■ 实例——WordCount

- 输入和输出
- 计算逻辑

第9章 Spark

■ 概念与特点

■ 生态系统


应用场景	时间跨度	其他框架	Spark生态系统中的组件
复杂的批量数据处理	小时级	MapReduce、Hive	Spark
基于历史数据的交互式查询	分钟级、秒级	Impala、Dremel、Drill	Spark SQL
基于实时数据流的数据处理	毫秒、秒级	Storm、S4	Spark Streaming
基于历史数据的数据挖掘	-	Mahout	MLlib
图结构数据的处理	-	Pregel、Hama	GraphX

第9章 Spark

■ 与MapReduce的区别


■ 运行架构

- 基本概念：RDD、DAG、Executor、Task、Job、Stage




第9章 Spark

■ 运行基本流程



第9章 Spark

■ 运行基本流程




■ 动作

■ 转换


第9章 Spark

■ 阶段的划分：宽依赖、窄依赖



第10章 流计算

- 概念：流数据、流计算
- 数据处理流程
 - 与传统数据处理流程的区别




第10章 流计算

■ Storm

- 概念、特点
- Streams、Tuple、Spouts、Bolts、Topology和 Stream Groupings
- Stream Groupings: 分组方式


第10章 流计算

■ Storm设计框架




第10章 流计算

■ Storm设计框架




第10章 流计算

■ Storm工作流程



第10章 流计算

■ Spark Streaming



■ Spark Streaming与Storm的区别