



数据挖掘综合实验报告

使用 SQL Server Business Intelligence Development Studionachos 建立决策树

姓 名：田佳铭
学 号：22920172204211
院 系：信息学院人工智能系
专 业：智能科学与技术
年 级：2017 级

2019 年 12 月 17 日

一、实验目的

1.实验要求

使用 SQL Server Business Intelligence Development Studio 对上述数据建立数据立方体，并进行数据挖掘分析，挖掘的知识类型不限，将挖掘过程和结果形成实验报告。

实验报告内容必须至少包含：

- 对选择出的数据，如何构建数据立方体
- 选择挖掘的知识类型的原因，及挖掘出来的结果
- 对挖掘出来的知识的分析，及根据这个分析可以做出的决策。

2.使用数据

使用“数据挖掘数据.xls”中的数据，该数据包含 6 个属性：编号、高中类型、大学考试成绩、是否录取、高中平均成绩及性别。

二、实验思路

1.实验所需工具

使用的主要软件有两个：

第一个是“Microsoft SQL Server Management Studio”，主要的作用是生成数据库，供数据挖掘软件使用。

第二个是“Microsoft Visual Studio”，我们使用其中的“Analysis Services 多维和数据挖掘项目”功能，里面集成了很多数据挖掘的工具和方法，且有较为友好的视图。参考“SQL Server 2008——Data Mining.pdf”文件就可以基本掌握其中基本功能的使用。

2.数据分析

实验提供的数据包含 6 个属性：编号、高中类型、大学考试成绩、是否录取、高中平均成绩及性别。

分析数据可以看到，（如果导入数据库后）编号是这些数据的主码，一般不使用这个属性进行数据挖掘。

结合理论课知识，考虑比较简单的数据挖掘策略，即建立一颗决策树。

在数据包含的 6 个属性中，性别类似于人的自然属性，一般不用来作为决策时的要预测的变量。因为要做预测，一般是要遵循时间上的逻辑，所以用和高中有关的属性去预测大学是合适的，而“是否录取”属性值是离散的且只有两个值，更适合用于作为要预测的变量。

本实验使用“是否录取”属性作为要预测的变量。

在男女平等的社会，我们认为性别与“是否录取”没有直接和必然的联系，这样，自变量就只剩下三个属性：高中类型、大学考试成绩和高中平均成绩。

三、实验步骤

1. 构建数据立方体

1.1 导入数据，建立数据库

要想进行数据挖掘，首先要将 Excel 的数据导入到数据库中。因为一共有一千条记录，手工输入和编写 SQL 语句都不太现实，这里直接使用 SQL Server 自带的数据库导入方法，先建立一个新的数据库，然后如图所示，找到导入数据选项：



图 1 导入数据

完成后，查看数据是否导入成功：




图 2 检查数据

可见，数据已经成功导入数据库。

1.2 建立 Analysis Services 多维和数据挖掘项目并连接数据库

先在 Virtual Studio 中安装相应的工具，创建空白的项目。

要想进行数据挖掘，还需要让项目连接到 SQL Server 中的数据库。

先在 SQL Server 中创建一个新的登录名，以给予 Analysis Services 项目以权限，如图所示（SQL Server 要有相关功能支持）：




图 3 新建登录名

选择“用户映射”，勾选刚刚导入数据的数据库（我的为“University”），并给予数据库角色成员“db_datareader”和“db_datawriter”身份：




图 4 用户映射

这样，之后的操作才可以进行。

1.3 新建数据源、数据源视图、维

根据文档的步骤新建数据源、数据源视图、维，因为只有一个表，操作比较简单，有如下一些图：

data\$
编号
高中类型
大学考试成绩
是否录取
高中平均成绩
性别

图 5 新建数据源视图

可以看到，整个数据库只有一个表，没有任何外键连接。

Attributes
Data
编号
大学考试成绩
高中类型
高中平均成绩
是否录取
性别

图 6 新建维

1.4 建立数据立方体

因为只有一个表，它就作为唯一的事实表。度量值组表等选项全选即可。

2.数据挖掘工作——建立决策树流程

新建挖掘结构，选择之前已经选好的数据源。

在数据挖掘技术中选择决策树，根据实验思路，这里分开两组：

（1）用高中类型、大学考成绩和高中平均成绩预测“是否录取”，有如下选择：

Mining model structure:				
☐	Tables/Columns	Key	☐ Input	☐ Predict...
-	data\$			
☒	编号	☒	☐	☐
☒	大学考成绩	☐	☒	☐
☒	高中类型	☐	☒	☐
☒	高中平均成绩	☐	☒	☐
☒	是否录取	☐	☐	☒
☐	性别	☐	☐	☐

图 7 决策树策略（1）

（2）用高中类型和高中平均成绩预测“是否录取”，有如下选择：

Mining model structure:				
☐	Tables/Columns	Key	☐ Input	☐ Predict...
-	data\$			
☒	编号	☒	☐	☐
☒	大学考成绩	☐	☐	☐
☒	高中类型	☐	☒	☐
☒	高中平均成绩	☐	☒	☐
☒	是否录取	☐	☐	☒
☐	性别	☐	☐	☐

图 8 决策树策略（2）

其他保持默认配置，可以看出，默认决策树建立的一些规则：

- （1）使用 30%的数据作为测试集
- （2）不限制最大案例数

四、结果分析

运行项目，可以得到结果。

1.用高中类型、大学考成绩和高中平均成绩预测“是否录取”

运行结果如下：




图9 决策树（1）

其中，蓝色条代表“未录取大学”，红色条代表“录取大学”。如果将每个叶子节点中类别稍多的类作为此叶子节点的类别（下面的决策时也采用这种策略），将决策树翻译成如下分类规则（进行一定的合并）：

If 大学考试成绩<87.410 Then 是否录取=“未录取大学”

If 大学考试成绩>=87.410 Then 是否录取=“录取大学”

如果只关照叶子节点，那么，只提取比较纯的两个叶子节点，可以翻译出如下分类规则：

If 大学考试成绩>=87.410 Then 是否录取=“录取大学”

If 大学考试成绩<81.550 and 高中类型=“普通高中” Then 是否录取=“未录取大学”

2.用高中类型和高中平均成绩预测“是否录取”

运行结果如下：




图10 决策树（2）

将决策树翻译成如下分类规则（进行一定的合并）：

If 高中平均成绩<2.940 Then 是否录取=“未录取大学”

If 高中平均成绩>=2.940 Then 是否录取=“录取大学”

同样的，只关照叶子节点且提取比较纯的三个叶子节点，可以翻译出如下分类规则：

If 高中平均成绩<-2.7 Then 是否录取=“未录取大学”

If 高中平均成绩>=5.760 Then 是否录取=“录取大学”

If 高中平均成绩>=-2.7 and 高中平均成绩<-1.008 Then 是否录取=“未录取大学”

可以看出，相较于决策树（1），决策树（2）的叶子节点更纯一些。

3.结果对比分析

当我们使用高中类型、大学考试成绩和高中平均成绩这三个属性来预测“是否录取”时，对决策树起分支起作用的主要是大学考试成绩一项，这说明大学考试成绩与是否录取有着更强的关系，从分类规则也可以看出，大学考试成绩越高，被录取的几率越大。虽然高中类型也对决策树的分支有所帮助，但是影响是很小的。

当排除掉大学考试成绩的因素，用高中类型和高中平均成绩这两个属性来预测“是否录取”时，只有高中平均成绩对决策树的分支产生影响，高中平均成绩是主要因素。

对比两颗决策树可以看出，在不考虑性别的前提下，决定一个学生是否能被大学录取，最直接的影响因素是大学考试成绩，如果不考虑大学考试成绩，最重要的影响因素是高中平均成绩，而与高中类型关系不大。

这符合实际情况。不管是在普通高中还是在实验高中，高中平均成绩都是衡量一个学生能力的较为客观的表述，也会影响大学考试成绩，最终影响录取情况（虽然没有从高中平均成绩出发对大学考试成绩做出预测，但得出这个结论也是符合现实的）。成绩、分数仍然是高中生的主线。

五、实验总结

本次实验内容比较简单，因为实验平台的功能比较强大，直接使用工具就可以很快地得出结果。但是在一些准备工作和配置方面花掉了很大的精力，要连接数据库需要准备很多东西，这个问题最终在朋友们的共同讨论下得到解决。

通过实验，我不仅深入理解了数据挖掘的一些基本知识，而且，通过建立决策树的方法，在老师提供的数据集中挖掘出了实际的知识，真正体会到数据挖掘是有一定的实际意义的。