

# 期末复习

- 基础
- 存储与管理
- 处理与分析

# 大数据基础

- 第1章 概述
- 第2章 大数据处理架构Hadoop

# 第1章 大数据概述

## ■ 大数据的概念

- 4V：数据量大、数据类型繁多、处理速度快、价值密度低。

## ■ 大数据的影响

### ■ 对科学研究的影响

- 实验→理论→计算→数据密集型


### ■ 对思维方式的影响

- 全样、效率、相关

# 第1章 大数据概述

## ■ 云计算

### ■ 概念




# 第1章 大数据概述

## ■ 云计算

### ■ 关键技术


■ 虚拟化、分布式存储、分布式计算、多租户等



# 第1章 大数据概述


## ■ 物联网

### ■ 概念



# 第1章 大数据概述

## ■ 大数据、云计算、物联网



# 第2章 大数据处理架构Hadoop

## ■ 特性

- 高可靠性、高效性、高可扩展性、高容错性、成本低、支持多种编程语言


## ■ 生态系统

| 组件        | 功能                                         |
|-----------|--------------------------------------------|
| HDFS      | 分布式文件系统                                    |
| MapReduce | 分布式并行编程模型                                  |
| YARN      | 资源管理和调度器                                   |
| Tez       | 运行在YARN之上的下一代Hadoop查询处理框架                  |
| Hive      | Hadoop上的数据仓库                               |
| HBase     | Hadoop上的非关系型的分布式数据库                        |
| Pig       | 一个基于Hadoop的大规模数据分析平台，提供类似SQL的查询语言Pig Latin |
| Sqoop     | 用于在Hadoop与传统数据库之间进行数据传递                    |
| Oozie     | Hadoop上的工作流管理系统                            |
| Zookeeper | 提供分布式协调一致性服务                               |
| Storm     | 流计算框架                                      |
| Flume     | 一个高可用的，高可靠的，分布式的海量日志采集、聚合和传输的系统            |
| Ambari    | Hadoop快速部署工具，支持Apache Hadoop集群的供应、管理和监控    |
| Kafka     | 一种高吞吐量的分布式发布订阅消息系统，可以处理消费者规模的网站中的所有动作流数据   |
| Spark     | 类似于Hadoop MapReduce的通用并行框架                 |



# 第2章 大数据处理架构Hadoop

## ■ 生态系统



## 第2章 大数据处理架构Hadoop

### ■ 计算机集群结构

- 分布式文件系统把文件分布存储到多个计算机节点上，成千上万的计算机节点构成计算机集群





图3-1 计算机集群的基本架构

## 第2章 大数据处理架构Hadoop

### ■ 计算机集群结构

- 普通的Hadoop集群结构由一个两阶网络构成
- 每个机架（Rack）有30-40个服务器，配置一个1GB的交换机，并向上传输到一个核心交换机或者路由器（1GB或以上）
- 在相同的机架中的节点间的带宽的总和，要大于不同机架间的节点间的带宽总和




# 大数据存储与管理

- 第3章 分布式文件系统HDFS
- 第4章 分布式数据库HBase
- 第5章 NoSQL数据库
- 第6章 云数据库

# 第3章 分布式文件系统HDFS

## ■ 分布式文件系统



# 第3章 分布式文件系统HDFS

## ■ 相关概念

- 块、名称节点、数据节点、第二名称节点


## ■ 名称节点的数据结构

- FsImage

- EditLog


## ■ 数据节点

- 负责数据的存储和读取
- 向名称节点定期发送自己所存储的块的列表




# 第3章 分布式文件系统HDFS

## ■ 第二名称节点的工作情况



# 第3章 分布式文件系统HDFS

## ■ 体系结构





# 第3章 分布式文件系统HDFS

## ■ 1.0和2.0的区别

### ■ 2.0高可用（HA）的作用

## ■ 多副本存取策略

## ■ 容错性

### ■ 名称节点出错

### ■ 数据节点出错


### ■ 数据出错

# 第3章 分布式文件系统HDFS

## ——读数据的过程

```
import org.apache.hadoop.fs.FileSystem
Configuration conf = new Configuration();
FileSystem fs = FileSystem.get(conf);
FSDataInputStream in = fs.open(new Path(uri));
```


通过`ClientProtocol.getBlockLocations()`  
远程调用名称节点，获得文件开始部分数据块的位置  
对于该数据块，名称节点返回保存该数据块  
的所有数据节点的地址  
并根据距离客户端远近进行排序



# 第3章 分布式文件系统HDFS


## ——写数据的过程

```
import org.apache.hadoop.fs.FileSystem
Configuration conf = new Configuration();
FileSystem fs = FileSystem.get(conf);
FSDataOutputStream out = fs.create(new Path(uri));
```



# 第4章 分布式数据库HBase


## ■ 数据模型



# 第4章 分布式数据库HBase

## ■ 数据模型

## ■ 数据坐标




# 第4章 分布式数据库HBase

## ■ 三个功能组件

### ■ 库函数、Master、Region

## ■ 三层结构



# 第4章 分布式数据库HBase

## ■ 三层结构


| 层次  | 名称          | 作用                                                                      |
|-----|-------------|-------------------------------------------------------------------------|
| 第一层 | Zookeeper文件 | 记录了-RROOT-表的位置信息                                                        |
| 第二层 | -ROOT-表     | 记录了.META.表的Region位置信息<br>-ROOT-表只能有一个Region。通过-RROOT-表，就可以访问.META.表中的数据 |
| 第三层 | .META.表     | 记录了用户数据表的Region位置信息，<br>.META.表可以有多个Region，保存了HBase中所有用户数据表的Region位置信息  |

## ■ Region数目的计算

## ■ 三级寻址

# 第4章 分布式数据库HBase


## ■ 系统架构





# 第4章 分布式数据库HBase

## ■ Region服务器工作原理




1. 用户读写数据过程
2. 缓存的刷新
3. **StoreFile**的合并

# 第4章 分布式数据库HBase

## ■ StoreFile的工作原理

### ■ 合并与分裂



### ■ Log工作原理

### ■ HBase系统为每个Region服务器配置了一个HLog文件

### ■ 容错

# 第5章 NoSQL

- 概念
- 四大类型
- 三大基石
  - CAP
- **BASE**和**ACID**的区别与联系
- 最终一致性

# 第6章 云数据库

- 概念
- 优点


# 大数据处理与分析

- **第7章 MapReduce**
- **第9章 Spark**
- **第10章 流计算**

# 第7章 MapReduce


## ■ 体系结构

### ■ Client、JobTracker、TaskTracker、Task




# 第7章 MapReduce

## ■ 工作流程



# 第7章 MapReduce

## ■ 具体执行阶段





# 第7章 MapReduce

## ■ Shuffle过程

### ■ Map端和Reduce端

## ■ 实例——WordCount

### ■ 输入和输出

### ■ 计算逻辑

# 第9章 Spark

## ■ 概念与特点

## ■ 生态系统


| 应用场景         | 时间跨度   | 其他框架                | Spark生态系统中的组件   |
|--------------|--------|---------------------|-----------------|
| 复杂的批量数据处理    | 小时级    | MapReduce、Hive      | Spark           |
| 基于历史数据的交互式查询 | 分钟级、秒级 | Impala、Dremel、Drill | Spark SQL       |
| 基于实时数据流的数据处理 | 毫秒、秒级  | Storm、S4            | Spark Streaming |
| 基于历史数据的数据挖掘  | -      | Mahout              | MLlib           |
| 图结构数据的处理     | -      | Pregel、Hama         | GraphX          |

# 第9章 Spark

## ■ 与MapReduce的区别


## ■ 运行架构

- 基本概念：RDD、DAG、Executor、Task、Job、Stage




# 第9章 Spark

## ■ 运行基本流程



# 第9章 Spark

## ■ 运行基本流程




■ 动作

■ 转换


# 第9章 Spark

## ■ 阶段的划分：宽依赖、窄依赖



# 第10章 流计算

- 概念：流数据、流计算
- 数据处理流程
  - 与传统数据处理流程的区别



# 第10章 流计算


## ■ Storm

- 概念、特点
- Streams、Tuple、Spouts、Bolts、Topology和  
Stream Groupings
- Stream Groupings: 分组方式




# 第10章 流计算

## ■ Storm设计框架




# 第10章 流计算

## ■ Storm设计框架




# 第10章 流计算

## ■ Storm工作流程



# 第10章 流计算

## ■ Spark Streaming



## ■ Spark Streaming与Storm的区别