

机器人高级控制

神经网络控制系统

晁飞

单 位：厦门大学

fchao@xmu.edu.cn



廈門大學
XIAMEN UNIVERSITY

第一节 引言

模糊控制

机器模拟人脑的感知、推理等智能行为

人工神经网络

人工模拟人脑的工作机理
(人脑的生理学和心理学)

人工神经网络的定义

人工神经网络就是模拟人脑细胞的分布式工作特点和自组织功能实现并行处理、自学习和非线性映射等能力。因此是一种典型的智能控制方法。

神经网络与控制

■ 神经网络对控制领域的吸引力

- 较强的非线性逼近能力
- 信息的并行分布处理与储存
- 多输入多输出
- 易于集成电路实现
- 自学习，自适应

神经网络在控制领域的应用

■ 基于神经网络的系统辨识：

- 建立被控对象模型

■ 神经网络控制器

- 控制器的直接使用

■ 神经网络与其他算法结合

- 神经网络与模糊逻辑

神经网络控制系统


- 神经网络控制就是将神经网络在相应的控制结构中作控制器与辨识器。主要是为了解决复杂的非线性，不确定性系统，在不确定的环境中使控制系统稳定，鲁棒性好。

神经网络控制系统组成

■ 与计算机控制系统相同：由硬件和软件两部分

- 硬件部分：连续被控对象，驱动装置或执行机构
- 神经控制器：输入输出是数字量，由计算机实现
- 模拟输入通道：AD转换器
- 模拟输出通道：DA转换器
- 传感器：系统反馈

硬件部分框图



系统辨识System Identification

- 根据系统的输入输出时间函数来确定描述系统行为的数学模型。现代控制理论中的一个分支。通过辨识建立数学模型的目的是估计表征系统行为的重要参数，建立一个能模仿真实系统行为的模型，用当前可测量的系统的输入和输出预测系统输出的未来演变，以及设计控制器。
- 对系统进行分析的主要问题是根据输入时间函数和系统的特性来确定输出信号。对系统进行控制的主要问题是根据系统的特性设计控制输入，使输出满足预先规定的要求。

系统辨识

- 而系统辨识所研究的问题恰好是这些问题的逆问题。通常，预先给定一个模型类 $\mu = \{M\}$ （即给定一类已知结构的模型），一类输入信号 u 和等价准则 $J = L(y, y_M)$ ；然后选择使误差函数 J 达到最小的模型，作为辨识所要求的结果。
- 系统辨识包括两个方面：结构辨识和参数估计。在实际的辨识过程中，随着使用的方法不同，结构辨识和参数估计这两个方面并不是截然分开的，而是可以交织在一起进行的。

系统辨识应用

□ 系统辨识在工业方面的应用，归结为以下几方面。

(1) 控制系统的分析和设计

由辨识所得对象模型，用于分析控制系统作为改进的依据；也可用于控制系统的设计。

(2) 在实时控制系统中，系统辨识器做为对象的模型，由其调整控制器参数，获得较好的控制效果。

(3) 有的控制结构，用系统的逆模型做控制器，故需建立逆模型，并对其进行辨识。

(4) 预测、预报

在模型结构确定情况下，建立时变模型，预测其参数，以实现系统参数的预测、预报。

(5) 监视系统运行状态，进行故障诊断

由系统运行的状态信息，推测系统特性的变化，判断运行是否正常，若有故障，则判断故障位置、状况等。

应用存在的问题

- 以往对线性，非时变具有不确定参数的系统进行辨识的研究已经取得了很大进展，但被辨识系统模型结构的选择是建立在线性系统之上的，对于复杂的非线性系统的辨识一直未能很好的解决。
- 神经网络具有非线性的特性，正好弥补了这个问题

基于神经网络的系统辨识

- 基于神经网络的系统辨识，就是用神经网络作为被辨识系统的正逆模型，预测模型，因此，也可称之为神经网络建模。它们可实现对线性与非线性系统，静态与动态系统进行离线或在线辨识。
- NNI

神经网络与系统辨识

- 神经网络的非线性特性、学习能力：
为解决复杂的非线性、不确定、不确定系统与逆系统的辨识问题，开辟了有效的途径。
- 神经网络系统辨识：
用神经网络作为被辨识系统的正与逆模型、预测模型——神经网络建模。
- 可实现对线性与非线性、静态与动态系统，进行离线或在线辨识。

基本原理

■ L. A. Zadeh为系统辨识做出的定义为：辨识是在输入和输出数据的基础上，从一组给定的模型类中确定一个与所测系统等价的模型。

■ 辨识的三要素

- 数据：能观测到被辨识系统的输入输出数据。
- 模型类：要寻找的模型类别，即所考虑的模型结构
- 等价准则：辨识的优化目标，用来衡量接近系统的标准。

$$J = \|e\|$$

要素补充

- 由于观测的数据一般都有噪声，因此辨识建模是一种实验统计方法，是对系统输入输出的一种近似描述。
- 辨识的目的是根据系统提供的测量信息，在某种准则意义下，估计出系统的结构和未知参数。

简单数学描述

■ 设 P 表示被辨识系统， U ， Y 分别是输入输出空间，则 $P: U \rightarrow Y$ 。可将 P 看做是从输入空间到输出空间的算子。它以输入输出对 $\{u, y\}$ 的形式隐含定义系统。

■ $\hat{P}$


举例讨论基本原理

以单输入单输出（SISO）动态系统为例，设 $\{u(kT), y(kT)\}$ 是被辨识系统 P 经采样得到的输入输出时间序列， T 是采样周期。

在 $\{u(kT), y(kT)\}$ 中确定 P 的模型 $\hat{P}$ ，准则函数最小：

$$J = \|z(k) - \hat{y}(k)\| = \|e\| < \varepsilon$$

系统辨识原理图



P : 被辨识系统

$\hat{P}$: 被辨识系统的模型

$u(k)$: 输入数据序列

$y(k)$: 不含噪声的系统输出数据序列

$z(k)$: 含有噪声的系统输出数据序列

$\hat{y}(k)$: 模型输出数据序列

$v(k)$: 作用于系统输出端的噪声

- 准则函数通常是非线性的，辨识问题也可归结为优化问题

等价准则


- 也称为误差准则，或者损失函数，衡量模型接近实际系统的标准

$$J = \sum_{k=0}^L E(k) = \sum_{k=0}^L \frac{1}{2} e^2(k)$$

- $e(k)$ 为定义在 $[0, L]$ 上的误差函数。可以理解为模型与实际系统的误差，可以是输出误差，输入误差或者广义误差


输出误差：实际系统输出
与模型输出误差

$$e(k) = z(k) - \hat{y}(k)$$




输入误差

$$e(k) = u(k) - \hat{u}(k) = u(k) - \hat{P}^{-1}[z(k)]$$



广义误差：

$$e(k) = \hat{P}_2^{-1}[z(k)] - \hat{P}_1[u(k)]$$



辨识精度

- 基于输入输出数据，利用辨识方法得到模型必定有误差。
 - 假定的模型结构只是实际系统的一种近似
 - 数据受污染
 - 数据长度不够
 - 未能将一些模式激活
- 要对精度进行评价，如果不达要求，可以考虑改变模型结构，采样周期等。

辨识的步骤

- 1, 实验设计
- 2, 模型的机构辨识
- 3, 模型的参数辨识
- 4, 模型检验

辨识的步骤

■ 1, 实验设计

- 实验设计的目的是使采集到的输入输出数据序列尽可能多的包含系统特性的内在信息。
- 实验设计需要确定输入信号，采样周期，辨识时间，离线和在线等。
- 具体要求有：
 - 在辨识时间内，系统的动态必须被充分激活
 - 激励时间要充分长
 - 输入信号有良好的质量

■ 2, 模型的辨识结构:

- 确定模式类, 利用已有的知识进行分析, 确定模型的结构,
- 应该尽可能简单的模型来描述辨识的系统

■ 3, 模型参数辨识

- 在结构确定的基础上进行参数辨识, 使得误差准则最小。

-
- 4，模型检验：可以通过对待辨识系统的继续采样得到的数据进行检验。
 - 在辨识前掌握辨识系统的一些先验知识是有必要的，对1,2步起到很重要的作用。


基于神经网络的系统辨识原理

- 基于神经网络的辨识是选择适当的神经网络作为辨识系统 P 的模型 $\hat{p}$ ，逆模型 $\hat{p}^{-1}$ ，也就是用神经网络来逼近实际的系统或者逆。
- 辨识过程是：当选定网络结构后，在给定的被辨识系统输入输出数据的情况下，网络通过学习，不断的调整权值，使得准则函数最优而得到网络，既是被辨识系统的模型 $\hat{p}$ ，逆模型 $\hat{p}^{-1}$ 。

模型辨识结构

一、正模型


通过选择与系统相同的输入 / 输出数据作为训练用样本，对神经网络进行训练，其目的是为了使得网络的输入 / 输出能够与系统的输入 / 输出完全一致。



二、逆模型—直接逆系统建模法


将系统输出作为网络的输入，将网络输出与其期望输出即系统输入进行比较得到的误差作为神经网络训练的信号。但是这种逆模型建模方法在实用上并不理想。

- 1) 学习过程不一定是目标最优的。因为神经网络无法完全表示整个非线性系统的特性（样本无法无限地取得）因此只是局部的逼近。
- 2) 一旦非线性系统的对应关系不是一对一的，那么不准确的逆模型可能会被建立。




二、逆模型—对象—逆系统建模法

直接利用逆系统神经网络设定的输入和未知被控对象的实际输出之差来调节逆系统神经网络的加权系数。**最大的缺点是**，在整体误差的基础上调节网络加权系数时，必须知道对象的模型，但由于被控对象的模型实际上未知，所以实现有一定困难。




二、逆模型—正模型—逆系统建模法

为了克服被控对象模型未知这一缺陷，首先建立未知被控对象的正模型，然后利用送到逆系统神经网络的给定输入和被控对象正模型输出之间的差来调节逆系统神经网络的加权系数。因为逆系统模型的最终准确程度直接与所建立的正模型的精度有关，真正的被控对象没有加入到逆系统网络参数的学习过程中，因而用此方法建立的逆模型精度得不到保证。




二、逆模型—对象—正模型—逆系统建模法

直接利用逆模型设定的输入与被控对象的输出之差来调节网络的加权系数。在调节过程中要用的未知被控对象则用正模型网络来代替。正模型神经网络所起的作用只是误差反向传递作用，即使有一点误差也不会影响很大。这种建模方法将真正的被控对象信息加入到逆系统网络参数的学习当中，逆模型的精度可以得到保证。



二、逆模型—逆—逆系统建模法

此方法由两个逆系统模型和未知对象一起构成学习回路。主通道上是神经网络控制器，用它来控制未知对象。引入未知对象的另一个逆模型的目的是用它来计算未知对象应得输入的估计值与控制器实际输出的控制信号之间的偏差，用这个偏差来调整控制器网络的加权系数，消除网络实际给出的控制信号和未知对象应得的控制信号之间的误差。



在线辨识与离线辨识

- 神经网络可以实现在线学习与离线学习
- 问题：什么是在线和离线？


在线辨识与离线辨识

- 神经网络可以实现在线学习与离线学习
- 在线辨识是在实际运行中完成的，辨识过程要求具有实时性，即必须在一个采样周期的时间间隔内产生一次模型参数估计的调整值。
- 离线辨识是在取得系统输入输出序列并储存后再辨识，因此辨识过程与系统是分离的，无实时性要求。

改进离线辨识

- 离线辨识能使网络在系统工作前预先完成学习过程，但因输入输出训练集很难覆盖系统所有可能的工作范围，因此，先进行离线学习，得到网络的权值，再进行在线学习，使之前得到权值，作为在线学习的初始值，加快在线学习的速度。

石灰窑炉是一个长长的金属圆柱体，其轴线与水平面稍作倾斜，并能绕轴线旋转，所以又名回转窑。含有大约30%水分的碳酸钙泥浆由左端输入回转窑。由于窑炉的坡度和旋转作用，泥浆在炉内从左向右慢慢下滑，而燃料油和空气由右端上方喷入窑内燃烧，形成热气流由右向左流动，以使泥浆干燥、加热，并发生分解反应。回转炉从左到右可分为干燥段、加热段、煅烧段和冷却段。最终生成的石灰由右端下方输出，而废气由左端下方排出。



石灰窑炉生产流程示意图

石灰窑的神经网络模型

控制量有：燃料流速 u_1 ，风量流速 u_2 。

受控量有：窑炉的热端温度 y_1 ，冷端温度 y_2 ，因为这两点的温度决定了炉内的温度分布曲线，而温度曲线又是影响产品质量和能耗的关键因素。

从实现的角度看，这四个变量是容易实时测量的。因此，石灰窑可近似为一个二输入二输出的非线性动态系统。系统模型为：

$$y^p(k) = f[y^p(k-1), \dots, y^p(k-n); u(k-1), \dots, u(k-m)]$$

$$y(k) = [y_1(k), y_2(k)]^T$$

$$u(k) = [u_1(k), u_2(k)]^T$$

采样周期为1.125min，根据经验和实验结果，选择 $n=m=2$ ，就能足够精确地描述系统的动态特性，神经网络模型表示为：

$$y^M(k) = f[y^P(k-1), y^P(k-2); u(k-1), u(k-2)]$$


定义系统输出误差与模型输出误差为：

$$e(k, \theta) = y^P(k) - y^M(k, \theta)$$

系统辨识的指标函数是：



$$J(\theta) = \frac{1}{2T} \sum_{k=1}^T e^T(k, \theta) e(k, \theta)$$

神经网络结构为N（8,20,10,2），隐层的节点数是根据实验确定的，隐层各神经元的激发函数均为双正切函数。




对4000组样本数据进行归一化，并用BP算法训练神经网络，直至均方根差 $RMS < 0.01$ 。对这组样本训练迭代261382次达到 $RMS = 0.009$ 。用另外4000组样本作为检验集，得到 $RMS = 0.0065$ ，这说明神经网络具有良好的泛化能力。

辨识结果



逆模型结构为 $N(8,20,12,2)$ ，激发函数为 $\tanh(x)$ ，学习算法与训练正模型时相同。

逆模型的训练结果比正模型差，它对4000组样本迭代了719914次（正模型为261382次）才使RMS达到0.0338（正模型0.0090），对校验样本的RMS为0.0262（正模型为0.0065）。



用间接法训练石灰窑炉的逆模型

神经网络控制理论

- 传统的基于模型的控制方式，根据被控对象的数学模型及对控制系统要求的性能指标来设计控制器，并对控制规律加以数学解析描述；
- 模糊控制基于专家经验和领域知识的总结出若干条模糊控制规则，构成描述具有不确定性复杂对象的模糊关系，通过被控系统输出误差，误差变化及模糊关系的推理合成获得控制量。从而对系统进行控制。

传统的基于模型
的控制方式

→ 是根据被控对象的数学模型及对控制系统要求的性能指标来设计控制器，并对控制规律加以数学解析描述。

模糊控制

→ 基于专家经验和领域知识总结出若干条模糊控制规则，构成描述具有不确定性、复杂对象的模糊关系，通过被控系统输出误差及误差变化和模糊关系的推理合成获得控制量，从而对系统进行控制。

神经网络控制

→ 具有很强的逼近非线性函数的能力，即非线性映射能力，神经网络用于控制正是利用这个独特的优点。

-
- 前面两种控制方式都具有显式表达知识的特点，而神经网络不善于显式表达知识。
 - 问题：那是怎么表达知识？

神经网络在控制中的作用有以下几种：

1. 在传统的控制系统中用以动态系统建模，充当对象模型；
2. 在反馈控制系统中直接充当控制器的作用；
3. 在传统控制系统中起优化计算作用；
4. 与其他智能控制方法如模糊逻辑、遗传算法、专家控制等相融合。

神经网络控制器的目的：是设计出一个神经网络去代替传统控制器的作用，使得系统的输出跟随系统的期望输出。神经网络控制器的学习就是寻找一种有效的途径进行网络连接权阵或网络结构的修改，从而使网络控制器输出的控制信号能够保证系统输出跟随系统的期望输出。

神经网络控制器的学习规则与辨识器（建模）的学习规则比较：

神经网络辨识器的期望输出值应该是系统的实际输出值，辨识器的样本信息是已知的；

神经网络控制器的样本信息应该是系统的最佳控制量，一般说来往往预先是无法知道的，尤其在被控系统模型未知的情况下。

神经网络控制分类



■ 一些典型的神经网络的控制结构和学习方式可归结为七类：

- 导师指导下的控制器
- 逆控制器
- 自适应网络控制器
- 神经内模控制结构
- 前馈控制结构
- 自适应评价函数
- 混合控制系统

神经网络控制的基本原理

- 控制的目的在于通过确定适当的控制输入，使系统获得期望输出特性。

神经网络控制的基本原理



简单的数学表述

设被控制对象的输入 u 和系统输出 y 之间满足如下非线性关系：

$$y = g(u)$$

控制的目的是确定最佳的控制量输入 u ，使系统的实际输出 y 等于期望的输出 y_d ，

$$u = f(y_d)$$

为了使系统输出 y 等于期望输出 y_d ，可得

$$y = g[f(y_d)]$$


简单的数学表述

- 显然，当 $f(\cdot) = g^{-1}(\cdot)$ 时，满足 $y = y_d$ 的要求。
- 由于采用神经网络控制的被控对象的非线性函数很难建立，神经网络的系统辨识，就是建立这一个被控对象的模拟。因此这个神经网络控制器就是系统的一个逆模型。

导师指导下的控制器


NN监督控制

- 1、神经网络监督控制实际就是建立人工控制器的正向模型。
- 2、经过训练，神经网络将记忆该控制器的动态特性，并且接受传感信息输入，最后输出与人工控制器（导师）相似的控制作用。
- 3、缺乏视觉反馈，由此构成的控制系统实际是一个开环系统，这就使其稳定性和鲁棒性均得不到保证。



直接（逆模型）逆控制

直接逆控制




在神经网络直接逆模控制方案中，神经网络学习对象的逆特性，并作为控制器直接与被控对象连结。控制器在期望信号的作用下产生控制量，使得对象输出 $Y \cong Y_{sp}$ 。


这种控制方式能否成功运行，很大程度上取决于网络的泛化特性。所以在实际应用中，**适用场合是**学习专家或操作人员的丰富经验从而替代人工操作，而不是通过直接求解对象的逆动态模型实现控制。

神经网络内模控制


神经网络模型与被控对象/模型是并立的，主要作用是辅助建立对象的逆模型；神经网络模型输出与实际对象输出的偏差与期望信号进行比较后，进入神经网络控制器。



内模控制与常规反馈控制



(a)



(b)

常规反馈与内模

常规反馈控制器 G 是由内模控制器 C 与被控对象的模型 M 通过反馈连接而构成的,因此 G 可以由下式

$$G = \frac{C}{1 - CM}$$


求得。同样,我们也可以由常规反馈控制器 G 求出等效的内模控制器 C ,即

$$C = \frac{G}{1 + GM}$$

由此可见,内模控制与常规反馈控制在结构上是可以互相转换的,


直接模型参考自适应控制

由于过程对象位于神经网络控制器与输出误差之间，
在对象的模型未辨识之前无法计算系统的雅可比矩阵。



间接模型参考自适应控制


首先进行对象辨识，然后利用辨识模型得到误差函数对控制器进行在线调整，以满足对象特性变化的场合。这种方法与逆模型间接控制方法相比，优点是能够解决过程对象逆模型为病态的情况。



神经网络自校正（自整定）


神经网络自校正控制

分为间接与直接控制，它们的根本区别在于前者使用常规控制器，离线辨识的神经网络估计器需要具有足够高的建模精度；而后者则同时使用神经网络控制器和神经网络估计器，其中估计器可进行在线修正。神经网络间接自校正控制的结构框图如下：





神经网络预测控制

非线性模型预测控制一般是指系统模型、性能指标或者约束条件具有非线性特性。因此，神经网络因其良好的非线性逼近能力通常被引入作为模型辨识器，对系统输出进行 k 步预测得到 $y(t+k)$ ，进一步实现对目标函数的优化和控制量的计算。**适用网络有：**前馈网络、递归网络、模糊神经网络和小波神经网络等。



神经网络前馈控制结构

- 单纯的求逆控制结构不能很好地起到抗干扰能力，因此结合反馈控制的思想组成前馈补偿器的网络控制结构。



自学习与自适应

- 自学习控制(self-learning control):当被控系统及其环境的特性未知但时不变时,设计一种学习方法来修正控制器的结构与参数,使控制系统的某个指标函数达到最优。自学习控制可以离线进行,也可以在线进行。自学习之前控制器未定,自学习之后控制器被确定,并且在控制过程中不再改变。
- 自适应控制(adaptive control):当被控系统及其环境的特性随时间变化时,设计一种自适应算法来随时修正控制器的结构与参数,使控制系统的某个指标函数总是达到最优。自适应控制必须在线进行。自适应之前控制器未定或已定,在自适应过程中将随时间变化。

- 前面介绍的控制结构大多适用于自学习，理论上也适合自适应，但是要求自适应算法能收敛，并且收敛速度要快于系统的时变速度。

举例1-直接逆控制的实现


例1: 考虑被控系统

$$y(k+1) = \frac{y(k)y(k-1)y(k-2)u(k-1)[y(k-1)-1] + u(k)}{1 + y^2(k-1) + y^2(k-2)}$$

根据控制性能的要求，选目标函数为

$$E = \sum E_p = \frac{1}{2} \sum [y_d(k) - y(k)]^2$$

其系统的控制结构如下图所示：



举例1-直接逆控制的实现


例1：考虑被控系统

$$y(k+1) = \frac{y(k)y(k-1)y(k-2)u(k-1)[y(k-1)-1] + u(k)}{1 + y^2(k-1) + y^2(k-2)}$$

根据控制性能的要求，选目标函数为

$$E = \sum E_p = \frac{1}{2} \sum [y_d(k) - y(k)]^2$$

其系统的控制结构如下图所示：



神经网络模型选用四层前向传播神经网络，并假设输出单元层的神经元为线性单元，其余层的神经元为Sigmoid激励元，则其学习规则可归结为

$$\omega_{pj}(k+1) = \omega_{pj}(k) - \eta \delta_{pj} o_{pj}$$

$$\delta_{pj} = [y_d(k) - y(k)] \frac{dy(k)}{du(k-1)} = [y_d(k) - y(k)] \frac{1}{1 + y^2(k-2) + y^2(k-3)}$$

取神经网络结构为 $\Pi_{5,25,12,1}$ 。 $\eta = 0.05$ 。

期望输出为 $y_d(k) = \sin \frac{2\pi k}{100} + 0.2 \sin \frac{6\pi k}{100}$

经过100次的在线学习和训练后，其均方误差已经小于0.005。此法虽然解决了神经控制网络的学习问题，对系统的自适应能力、自学习能力有显著的提高。但是，它需要系统的Jacobian矩阵 dy/du 。显然，这一要求对大多数复杂系统、未知系统而言是无法满足的。

为了克服这一缺陷，许多专家学者提出了各种不同的方法。归结起来，主要有以下四种解决措施。

①**摄动法**：用 $\frac{\Delta y_i}{\Delta u_i}$ 来代替 $\frac{\partial y_i}{\partial u_i}$ 。这虽然是一种近似的计算方法，但一般说来，在采用间隔比较短的情况下还是可行的。

②**符号函数法**：简单地采用符号函数 $\text{sgn}(\frac{y_i}{u_i})$ 来代替 $\frac{\partial y_i}{\partial u_i}$ 。这种方法比较摄动法更为简单且实用。因为，对于大多数系统而言系统的输出变化随输入变化的趋势是容易知道的。简单地采用符号函数代替Jacobian矩阵函数既能保证神经网络学习算法的稳定性，又具有计算简单，在已知条件较少的情况下系统也能控制的优点。

③前向神经网络仿真模型法：采用另一神经网络模型来仿真系统的动力学模型，并利用它来得到系统的Jacobian矩阵 dy/du 信息，从而实现神经网络控制的学习。

④多网络自学习控制法：采用神经网络的系统逆动力学模型来产生系统的期望控制信号，从而解决神经网络控制器的导师信号问题，实现了网络控制器学习。

举例 2：小脑模型神经逆模型控制

小脑是控制运动的，小脑模型神经网络（CMAC）一开始是应用于机器人控制中，有多种控制形式。本节介绍CMAC的三种控制结构：

1. CMAC直接逆运动控制
2. CMAC前馈控制
3. CMAC反馈控制


中的CMAC直接逆运动控制

小脑模型神经网络

小脑模型神经网络（**CMAC**）是模拟人的小脑的一种学习结构，是基于表格查询式输入输出的局部网络模型，提供了一种从输入至输出的多维非线性映射能力。

CMAC的结构及工作原理

CMAC是前馈网，结构见图，由两个基本映射，表示输入输出之间的非线性关系。



CMAC结构

CMAC直接逆运动控制

CMAC 用于逆运动控制例——机械手控制问题。

机械手末端的运动轨迹定为 $\mathbf{x}=[x, y, z]$ ，

机械手运动通过各关节转动角度来实现，转角 $\theta=[\theta_1, \theta_2, \dots, \theta_n]$ 。


若已知： $\mathbf{x} = f(\theta)$ 求 θ ： $\theta = f^{-1}(\mathbf{x})$

为逆运动学计算，或称机械手位置逆运动学模型辨识，
可由 CMAC 实现。


机械手位置逆运动学模型辨识，见图4-8-1：

若已知： $\mathbf{x} = f(\theta)$ 求 θ ： $\theta = f^{-1}(\mathbf{x})$

二关节机械手，在平面上运动，见图4-8-2。



逆运动辨识



两关节机械手

二关节机械手，在平面上的逆运动控制，由CMAC实现见图4-8-3。





图4-8-3 逆运动控制

举例3：石灰窑炉的内膜控制

石灰窑炉是一个长长的金属圆柱体，其轴线与水平面稍作倾斜，并能绕轴线旋转，所以又名回转窑。含有大约30%水分的碳酸钙泥浆由左端输入回转窑。由于窑炉的坡度和旋转作用，泥浆在炉内从左向右慢慢下滑，而燃料油和空气由右端上方喷入窑内燃烧，形成热气流由右向左流动，以使泥浆干燥、加热，并发生分解反应。回转炉从左到右可分为干燥段、加热段、煅烧段和冷却段。最终生成的石灰由右端下方输出，而废气由左端下方排出。



石灰窑炉生产流程示意图

石灰窑的神经网络模型

控制量有：燃料流速 u_1 ，风量流速 u_2 。

受控量有：窑炉的热端温度 y_1 ，冷端温度 y_2 ，因为这两点的温度决定了炉内的温度分布曲线，而温度曲线又是影响产品质量和能耗的关键因素。

从实现的角度看，这四个变量是容易实时测量的。因此，石灰窑可近似为一个二输入二输出的非线性动态系统。系统模型为：

$$y^p(k) = f[y^p(k-1), \dots, y^p(k-n); u(k-1), \dots, u(k-m)]$$

$$y(k) = [y_1(k), y_2(k)]^T$$

$$u(k) = [u_1(k), u_2(k)]^T$$

采样周期为1.125min，根据经验和实验结果，选择 $n=m=2$ ，就能足够精确地描述系统的动态特性，神经网络模型表示为：

$$y^M(k) = f[y^P(k-1), y^P(k-2); u(k-1), u(k-2)]$$


定义系统输出误差与模型输出误差为：

$$e(k, \theta) = y^P(k) - y^M(k, \theta)$$

系统辨识的指标函数是：

$$J(\theta) = \frac{1}{2T} \sum_{k=1}^T e^T(k, \theta) e(k, \theta)$$

神经网络结构为N（8,20,10,2），隐层的节点数是根据实验确定的，隐层各神经元的激发函数均为双正切函数。



对4000组样本数据进行归一化，并用BP算法训练神经网络，直至均方根差 $\text{RMS} < 0.01$ 。对这组样本训练迭代261382次达到 $\text{RMS} = 0.009$ 。用另外4000组样本作为检验集，得到 $\text{RMS} = 0.0065$ ，这说明神经网络具有良好的泛化能力。

石灰窑的内膜控制

石灰窑的非线性动态系统方程描述为：

$$y^p(k) = f[y^p(k-1), y^p(k-2); u(k-1), u(k-2)]$$


石灰窑炉的逆模型可描述如下：

$$u(k) = f^{-1}[r(k+1); y^M(k), y^M(k-1); u(k-1)]$$

这里用 $r(k+1)$ 来代替 $y^M(k+1)$ ，因为 $y^M(k+1)$ 是 $u(k)$ 的作用结果，在 k 时刻尚不知道。


逆模型结构为N(8,20,12,2)，激发函数为 $\tanh(x)$ ，学习算法与训练正模型时相同。

逆模型的训练结果比正模型差，它对4000组样本迭代了719914次（正模型为261382次）才使RMS达到0.0338（正模型0.0090），对校验样本的RMS为0.0262（正模型为0.0065）。



用间接法训练石灰窑炉的逆模型

图中 NN_C 是神经网络逆模型，作为控制器， NN_M 是神经网络正模型。这里 F 设计为 $2/(1-Z^{-1})$ ，它是一个积分器，目的在于消除静态误差。控制系统的跟踪仿真实验和抗干扰仿真实验结构表明，本神经内膜控制系统具有良好的跟踪性能和抗干扰性能。



石灰窑炉内模控制系统框图