

移动机器人

移动机器人基础知识

温程璐

厦门大学人工智能系


2023 年9月



部分课件内容参考：
浙江大学熊蓉老师



移动机器人框架

- 移动机器人的运动学、规划、定位和地图构建等问题都围绕移动机器人的“**状态**”展开
- 状态是什么？
 - 对移动机器人自身信息的抽象描述
 - **运动**是对状态的改变
 - **观测**是对状态的测量



随机性

- 机器人在实际世界中运行时，机器人通过传感器（人的五官）感知实际世界
- 人的感官一定是客观且正确的吗？
- 同样，传感器必存在随机噪声，需要用**概率理论**描述状态和传感
 - 如，通过温度传感器测量机器人当前的温度
 - 如，通过测距传感器测量和障碍物的距离





概率论 (复习)

- **随机事件 e** : 可能出现或不出现的随机试验结果, 如: 传感器测量机器人过热, 距离障碍物10cm以上等
- **样本空间 S** : 随机试验所有可能的结果的集合, 如: 机器人测温的样本空间 $S = \{\text{正常}, \text{过热}\}$
- **随机变量 X** : 从样本空间到实数的映射, $X(e) = x, e \in S$



如: 记录温度“正常”为0, “过热”为1, 将机器人测温的结果建模为随机变量 X , 注意这里的实数 x , **不一定可比**

- 样本为过热, 映射为 $X = 1$
- 样本为正常, 映射为 $X = 0$



离散随机变量概率

- **概率：**描述一个随机事件（如是否过热）发生的频率，记为 $Pr(e)$
- 概率有两个特性
 - 对任意随机事件 e ，均有 $Pr(e) \in [0,1]$ ；
 - 随机事件总频率 $\sum_{e \in S} Pr(e) = 1$
- 如测温可以定义概率 $Pr(X = 0) = 0.99$ ， $Pr(X = 1) = 0.01$




连续随机变量概率

- 对于连续变量，无法用每个事件的概率去描述，通常采用**概率分布函数**和**密度函数**进行描述
- 连续随机变量可用**累计分布函数** $F(x)$ ，定义为 $F(x) \triangleq Pr(X \leq x)$
 - $F(x)$ 是单调非减的，因为概率的取值非负
 - $\lim_{x \rightarrow \infty} F(x) = 1$;
 - $\lim_{x \rightarrow -\infty} F(x) = 0$;
- 注意离散随机变量的 x 不一定可比
- 连续随机变量的 x 一般可比

连续随机变量概率

- 将连续随机变量的事件转化为区间，借助随机变量的概率分布函数对累计分补函数进行定义
- 如，将测距的定位误差定义为连续随机变量 X ，结果值直接作为 x
- 障碍物测距的分布函数 $F(x)$ 解释为
 - $F(5) \triangleq \Pr(X \leq 5)$ 表示：测距结果小于5cm的概率
 - $F(10) \triangleq \Pr(X \leq 10)$ 表示：测距结果小于5cm和5cm到10cm间的概率
 - 考虑到分布函数单调非减，可以导出 $\Pr(5 \leq X \leq 10) = F(10) - F(5)$ ，解释为测距结果在5cm-10cm之间的概率



连续随机变量概率

- 当 x 是连续时，基于分布函数，定义为概率密度函数

$$p(x) = \frac{dF(x)}{dx}$$

- 概率密度函数满足如下的性质：

- $p(x) \geq 0$

- $\int_{-\infty}^{\infty} p(x)dx = 1$

- $\int_a^b p(x)dx = Pr(a \leq X \leq b)$

- 许多典型的概率分布经常采用概率密度函数进行描述
- 机器人系统的误差多是连续随机变量，适合采用概率密度函数分析

$$\int_{3.1}^{5.8} p(x)dx: \text{定位误差在3.1-5.8cm之间的概率}$$

期望和方差

- 估计一个事件的概率可重复对离散随机变量测量，并计算频率获得
- 连续随机变量取值有无穷多个，按照此方法无法计算概率
- 因此，可对随机变量的一些特殊参数进行估计，如：

- 期望：描述平均水平，定义为

$$E\{X\} = \int x p(x) dx$$

- 协方差矩阵：描述与均值的偏差水平，定义为

$$Cov\{X\} = \int (x - E\{X\})(x - E\{X\})^T p(x) dx$$

描述了随机变量的离散程度，其中对角元素为随机变量每个元素的方差

高斯分布

- 在移动机器人领域，很多问题都采用连续随机变量建模
- 最常见的连续随机变量的概率分布是高斯分布
- 高斯分布的概率密度函数定义为



$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^N |\boldsymbol{\Sigma}|}} \exp\left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)$$

了解它们就大约够了



- 随机变量 X 服从高斯分布，记为 $X \sim N(\boldsymbol{\mu}(\text{期望}), \boldsymbol{\Sigma}(\text{协方差矩阵}))$
- $X \sim N(\mathbf{0}, I)$ 为标准高斯分布， I 为 $N \times N$ 单位矩阵
- 变量 x 也可以是向量，能够更方便的描述处在二维或三维环境中的机器人的状态

高斯分布

- 对于符合高斯分布的二维随机变量，可以通过椭圆进行描述
- 椭圆的中心为**期望**，椭圆的长短轴表示二维向量两个元素各自的**方差**，椭圆的旋转程度则反映两个元素的**相关性**



标准高斯分布



方差主对角线为**1**，非对
角线**0.3**

多变量概率分布

- 机器人应用中关心多个随机变量，常需要利用容易测到的随机变量，对不容易测到的随机变量进行估计

如用激光雷达间接得到定位信息，此时测距结果是一个随机变量，机器人的定位信息是另一个无法直接测量的随机变量，需要用测距结果进行推断

- 此时就需要多变量概率分布，如变量X和Y
- 联合分布函数

$$F(x, y) \triangleq \Pr(X \leq x, Y \leq y)$$

- 联合密度函数

$$p(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$$

$$\int_{-\infty}^{\infty} p(x) dx = 1$$

激光雷达测距精度X和Y，定位精度在5cm范围内的概率为：

$$\Pr(X \leq 5) = \Pr(X \leq 5, Y \leq \infty) = F(5, \infty)$$

多变量概率分布

- 机器人应用中不止关心一个随机变量，多需要利用容易测到的随机变量，对不容易测到的随机变量进行估计

如用激光雷达间接得到定位信息，此时测距结果是一个随机变量，机器人的定位信息是另一个无法直接测量的随机变量，需要用测距结果推断定位信息

- 此时需要多变量概率分布，如变量X和Y
- 联合分布函数

$$F(x, y) \triangleq \Pr(X \leq x, Y \leq y)$$

- 联合密度函数

$$p(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$$

$$\int_{-\infty}^{\infty} p(x) dx = 1$$

如，激光雷达测距精度X和Y，定位精度在5cm范围内的概率为：

$$\Pr(X \leq 5) = \Pr(X \leq 5, Y \leq \infty) = F(5, \infty)$$

多变量概率分布

边际分布和条件分布

- **边际概率密度函数**: 给定多变量的联合密度函数, 可以计算单变量的概率密度

$$p(x) = \int_{-\infty}^{\infty} p(x, y) dy \quad p(y) = \int_{-\infty}^{\infty} p(x, y) dx$$

- **条件概率密度函数**: 基于联合分布中一个变量的测量值, 可根据多变量关系推断另一个变量


$$p(x|Y \in A) = \frac{p(x, Y \in A)}{p(Y \in A)} = \frac{\int_A p(x, y) dy}{\int_A p(y) dy} = \frac{\int_A p(x, y) dy}{\int_A \int_{-\infty}^{\infty} p(x, y) dx dy}$$

描述一个变量满足某个条件 A (如距离测量50cm, 或温度范围36-38度) 时, 推断另一个变量的分布

多变量概率分布


条件分布案例

- 假设一个激光传感器测量结果 Y ，定位精度 X
- 建模随机变量， $Y=1$ 表示50cm内(蓝块)， $Y=2$ 为大于50cm(黄块)，误差建模为 X
- 测量50cm内的物体时(1)，测量误差的方差较小，定位精度概率密度为 $p(x|Y < 50)$
- 测量50cm外的物体时(2)，测量误差的方差较大，定位精度概率密度为 $p(x|Y > 50)$
- 激光雷达对近距离测距的定位平均性能比远距离好，原因可能是远距离测量误差 Y 较大



三维动态系统

- 平坦平面上移动的机器人可用二维空间描述
- 而对于飞行、水下等机器人，有复杂运动，需要在三维空间描述
- 三维空间中点的运动，可以采用质点方式描述
- 机器人是刚体，在三维空间中的运动可以用位置和姿态描述




三维动态系统-位移、旋转和位姿

- 首先假定机器人坐标系：**B**，静止的参考世界坐标系：**W**
- 设三维空间中一个质点用三维向量描述如下

$$\mathbf{p} \triangleq (x, y, z)^T \in \mathcal{R}^3$$

- x, y, z 分别表示 $\mathbf{p}$ 在空间坐标系B中的坐标
- $\mathbf{p}^{\mathbb{B}}$ 为该点在机器人坐标系下的表示
- $\mathbf{p}^{\mathbb{W}}$ 表示定义在世界坐标系




三维动态系统-位移、旋转和位姿

- 机器人运动时，其坐标系与世界坐标系发生相对运动
- **平移** $t_{\mathbb{B}}^{\mathbb{W}}$ ：相对于世界坐标系平动，表示从 $\mathbb{W}$ 的原点到 $\mathbb{B}$ 原点的向量，表示在 $\mathbb{W}$ 坐标系下存在

$$\mathbf{p}^{\mathbb{W}} = \mathbf{p}^{\mathbb{B}} + \mathbf{t}_{\mathbb{B}}^{\mathbb{W}}$$

- 当机器人相对世界坐标系**旋转**时，定义 $\mathbb{B}$ 坐标系的三轴向量在 $\mathbb{W}$ 下的坐标为 $\mathbf{x}_{\mathbb{B}}^{\mathbb{W}}$ ， $\mathbf{y}_{\mathbb{B}}^{\mathbb{W}}$ 和 $\mathbf{z}_{\mathbb{B}}^{\mathbb{W}}$
- 则刚体上的点 $\mathbf{p}$ 在 $\mathbb{W}$ 中的位置为


$$\mathbf{p}^{\mathbb{W}} = (\mathbf{x}_{\mathbb{B}}^{\mathbb{W}} \quad \mathbf{y}_{\mathbb{B}}^{\mathbb{W}} \quad \mathbf{z}_{\mathbb{B}}^{\mathbb{W}}) \mathbf{p}^{\mathbb{B}} + \mathbf{t}_{\mathbb{B}}^{\mathbb{W}}$$



三维动态系统-位移、旋转和位姿

- 旋转矩阵 $R_{\mathbb{B}}^{\mathbb{W}}$: B坐标系三轴所定义的矩阵（下标相对上标的转动）
- 表示机器人坐标系相对于世界的旋转
- 其三个列向量两两互相垂直，为正交阵
- 其三个列向量模长为1
- 其三个列向量满足笛卡尔坐标系右手定则， $|R_{\mathbb{B}}^{\mathbb{W}}| = 1$

$$R_{\mathbb{B}}^{\mathbb{W}} \triangleq (\mathbf{x}_{\mathbb{B}}^{\mathbb{W}} \quad \mathbf{y}_{\mathbb{B}}^{\mathbb{W}} \quad \mathbf{z}_{\mathbb{B}}^{\mathbb{W}})$$



三维动态系统-位移、旋转和位姿

- 如果B相对W，只有一个轴的旋转，可以导出三个旋转矩阵

$$\mathbf{R}_x(\theta_x) \triangleq \begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos(\theta_x) & -\sin(\theta_x) \\ 0 & \sin(\theta_x) & \cos(\theta_x) \end{pmatrix} \quad \mathbf{R}_y(\theta_y) \triangleq \begin{pmatrix} \cos(\theta_y) & 0 & \sin(\theta_y) \\ 0 & 1 & 0 \\ -\sin(\theta_y) & 0 & \cos(\theta_y) \end{pmatrix} \quad \mathbf{R}_z(\theta_z) \triangleq \begin{pmatrix} \cos(\theta_z) & -\sin(\theta_z) & 0 \\ \sin(\theta_z) & \cos(\theta_z) & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

翻滚角

俯仰角

航向角

- 那么，三轴的旋转可以通过对单轴的旋转逐次得到，因此存在

$$\mathbf{p}^W = \mathbf{R}_z(\theta_z)\mathbf{R}_y(\theta_y)\mathbf{R}_x(\theta_x)\mathbf{p}^B + \mathbf{t}_B^W$$


$$\mathbf{R}_B^W = \mathbf{R}_z(\theta_z)\mathbf{R}_y(\theta_y)\mathbf{R}_x(\theta_x)$$

三个旋转矩阵相乘

三维动态系统-位移、旋转和位姿

- 将这个分解一般化：机器人可以通过任意多次三轴旋转得到新的三轴旋转
- 更进一步，可以用多次位移和旋转的连乘，获得连续运动中刚体上一点的位置

$$p^W = R_B^W (R_{B_1}^B p^{B_1} + t_{B_1}^B) + t_B^W$$



三维动态系统-位移、旋转和位姿

- B和W之间的相对关系（即机器人相对于世界的位置和旋转），可以通过旋转 $R_{\mathbb{B}}^{\mathbb{W}}$ 和平移 $t_{\mathbb{B}}^{\mathbb{W}}$ 定义，将两者表示在一起，形成位姿矩阵

$$T = \begin{pmatrix} R & t \\ 0 & 1 \end{pmatrix}$$

- 可以用连乘表示点的连续运动变换

$$\begin{pmatrix} p \\ 1 \end{pmatrix}^{\mathbb{W}} = T_{\mathbb{B}}^{\mathbb{W}} T_{\mathbb{B}_1}^{\mathbb{B}} \begin{pmatrix} p \\ 1 \end{pmatrix}^{\mathbb{B}_1} = T_{\mathbb{B}_1}^{\mathbb{W}} \begin{pmatrix} p \\ 1 \end{pmatrix}^{\mathbb{B}_1}$$

三维动态系统-位移、旋转和位姿


- 除了刚体上的点，静态世界中的点也需要表示到移动机器人自身的坐标系下
- 这个操作因为位姿矩阵非奇异，存在逆，可以这么定义

$$\begin{pmatrix} l^W \\ 1 \end{pmatrix} = T_{\mathbb{B}}^W \begin{pmatrix} l^{\mathbb{B}} \\ 1 \end{pmatrix}$$

$$\begin{pmatrix} l^{\mathbb{B}} \\ 1 \end{pmatrix} = T_{\mathbb{B}}^{W,-1} \begin{pmatrix} l^W \\ 1 \end{pmatrix}$$

- 也可以推广到连乘

$$\begin{pmatrix} l^{\mathbb{B}} \\ 1 \end{pmatrix} = T_{\mathbb{B}_{\mathbb{B}_1}}^{\mathbb{B}} T_{\mathbb{B}_1}^{W,-1} \begin{pmatrix} l^W \\ 1 \end{pmatrix}$$



三维动态系统-位移、旋转和位姿

位姿其他问题

- 旋转矩阵是正交阵，位姿矩阵是非奇异阵
- 位姿矩阵的求逆，对应到旋转矩阵的部分是转置
- 位姿矩阵和旋转矩阵的连乘，都满足矩阵的乘法，因此
 - 满足矩阵乘法的结合律
 - 但不满足交换律，交换旋转的顺序，得不到相同的变换结果

三维动态世界-状态系统建模-速度与角速度

- 速度与角速度的变换要考虑其坐标系和运动的相对关系
- 不同于位置，其坐标系变换仅和旋转有关，B相对于W转动，在W下测量的角速度和速度为：

$$\omega_{BW}^W = R_B^W \omega_{BW}^B \quad v_{BW}^W = R_B^W v_{BW}^B$$

- 速度角速度通过位姿和旋转微分导出，旋转矩阵的导数定义如下

$$\frac{dR_B^W}{dt} = \omega_{BW}^W \times R_B^W$$

- 可以理解为B坐标系每个坐标轴因旋转形成的线速度

三维动态世界-状态系统建模-刚体运动

- 针对刚体上一点 $\mathbf{p}^{\mathbb{W}}$ ，可以用位姿联系其不同坐标系的表示

$$\mathbf{p}^{\mathbb{W}} = \mathbf{R}_{\mathbb{B}}^{\mathbb{W}} \mathbf{p}^{\mathbb{B}} + \mathbf{t}_{\mathbb{B}}^{\mathbb{W}}$$

下标 $\mathbf{B}$ 相对上标 $\mathbf{W}$ 的转动

- 对上式做微分，得到刚体上一点速度和角速度的关系

$$\frac{d\mathbf{p}^{\mathbb{W}}}{dt} = \frac{d\mathbf{R}_{\mathbb{B}}^{\mathbb{W}}}{dt} \mathbf{p}^{\mathbb{B}} + \frac{d\mathbf{t}_{\mathbb{B}}^{\mathbb{W}}}{dt}$$

$$\mathbf{v}_{\mathbf{p}^{\mathbb{W}}}^{\mathbb{W}} = \boldsymbol{\omega}_{\mathbb{B}\mathbb{W}}^{\mathbb{W}} \times \mathbf{R}_{\mathbb{B}}^{\mathbb{W}} \mathbf{p}^{\mathbb{B}} + \mathbf{v}_{\mathbb{B}\mathbb{W}}^{\mathbb{W}}$$

- 引入反对称矩阵表示叉乘

$$\mathbf{k}_{\times} \triangleq \begin{pmatrix} 0 & -k_z & k_y \\ k_z & 0 & -k_x \\ -k_y & k_x & 0 \end{pmatrix}$$

- 刚体上点的运动可进一步写为

$$\mathbf{v}_{\mathbf{p}^{\mathbb{W}}}^{\mathbb{W}} = \boldsymbol{\omega}_{\mathbb{B}\mathbb{W},\times}^{\mathbb{W}} \mathbf{R}_{\mathbb{B}}^{\mathbb{W}} \mathbf{p}^{\mathbb{B}} + \mathbf{v}_{\mathbb{B}\mathbb{W}}^{\mathbb{W}}$$

三维动态世界-状态系统建模-刚体运动


- 进一步微分，可以得到加速度的关系
(叉乘写成矩阵乘法的形式)

$$\frac{d\mathbf{v}_{p^W}^W}{dt} = \frac{d\boldsymbol{\omega}_{BW,\times}^W}{dt} \mathbf{R}_B^W \mathbf{p}^B + \boldsymbol{\omega}_{BW,\times}^W \boldsymbol{\omega}_{BW,\times}^W \mathbf{R}_B^W \mathbf{p}^B + \frac{d\mathbf{v}_{BW}^W}{dt}$$

- 由此得出：机器人上一点的加速度和机器人自身角速度、角加速度、线加速度均有关系
- 位置，速度和加速度之间的关系，构建机器人运动的状态系统

三维动态世界-状态系统建模-状态空间系统方程


- 机器人的状态空间系统方程：位置、速度和加速度之间的关系方程，是移动机器人运动的微分方程
- u ：机器人的可控量，如速度、加速度、角速度； f ：以上运动学模型
- x ：一般化状态量，可以是静态或非静态测量状态，如位姿、速度或仅仅姿态
- y ：一般外部观测； h ：观测方程



- 如当移动机器人是一辆汽车时
 - u 是油门和方向盘， x 是位姿和速度， f 是之前导出的刚体上一点的运动方程
 - h 是观测方程，比如机器人看见一个路标
 - y 是传感器测量的机器人相对路标的距离

三维动态世界-旋转的线性化

- 由于旋转的存在，机器人的系统方程通常是非线性的
- 非线性系统分析的重要方法是将系统方程线性化
- 在介绍旋转的线性化前，首先介绍**罗德里格斯公式**



- 给定一个W中的单位旋转轴 $\frac{\theta}{|\theta|}$ 和其旋转角度 $|\theta|$ ，可以表示任意旋转运动
- 观察旋转前后刚体上一点r的位置变化，分解出相对旋转轴的为垂直 $r_{\perp}$ 和平行分量 $r_{||}$
- 由于 $\frac{\theta}{|\theta|} \times (\frac{\theta}{|\theta|} \times r) = r_{\perp}$

罗德里格斯公式

$$R_{\mathbb{B}}^{\mathbb{W}} = I + (1 - \cos|\theta|) \frac{\theta}{|\theta|} \times \frac{\theta}{|\theta|} + \sin|\theta| \frac{\theta}{|\theta|} \times$$

旋转矩阵可以认为是由三自由度参数 θ 作为自变量，因变量为矩阵的函数 $R(\theta)$

三维动态世界-旋转的线性化

- 可以分解为两个矩阵相乘 $R(\theta) = R(\bar{\theta})R(\delta\theta)$
- 当旋转角度 θ 很小时，基于罗德里格斯公式舍弃二次以上项，可得

$$\lim_{\delta\theta \rightarrow 0} R(\delta\theta) \approx I + \delta\theta_{\times}$$

- 得到旋转的线性化如下

$$R(\theta) = R(\bar{\theta})R(\delta\theta) \approx R(\bar{\theta})(I + \delta\theta_{\times}) = R(\bar{\theta}) + R(\bar{\theta})\delta\theta_{\times}$$

- 当W中的静态点被在原点的机器人观测时，存在

$$p^{\mathbb{B}} = R_{\mathbb{W}}^{\mathbb{B}} p^{\mathbb{W}}$$

- 在 $R(\bar{\theta}) = \bar{R}$ 处对旋转做线性化，此时相对于 $\delta\theta$ ， $p^{\mathbb{B}}$ 由一个线性函数导出

$$p^{\mathbb{B}} \approx \bar{R}_{\mathbb{W}}^{\mathbb{B}} p^{\mathbb{W}} + \bar{R}_{\mathbb{W}}^{\mathbb{B}} \delta\theta_{\times} p^{\mathbb{W}} = \bar{R}_{\mathbb{W}}^{\mathbb{B}} p^{\mathbb{W}} - \bar{R}_{\mathbb{W}}^{\mathbb{B}} p_{\times}^{\mathbb{W}} \delta\theta$$

$\bar{R}_{\mathbb{W}}^{\mathbb{B}}$ 是线性化点
生成的旋转矩阵

由此旋转表示被表达为关于 $\delta\theta$ 的线性问题，非线性系统求解被简化

三维动态世界-旋转的概率表达

- 基于旋转线性化的概念，进一步引入旋转作为随机变量的概率分布

$$p(\mathbf{R}) = \frac{1}{\sqrt{(2\pi)^3 |\boldsymbol{\Sigma}|}} \exp\left(-\frac{1}{2} g(\bar{\mathbf{R}}^T \mathbf{R})^T \boldsymbol{\Sigma}^{-1} g(\bar{\mathbf{R}}^T \mathbf{R})\right)$$

- 其中 g 表示将旋转矩阵 $\bar{\mathbf{R}}^T \mathbf{R}$ 换算到旋转角度 $\delta\theta$
- 该分布建立在 $\delta\theta$ 较小，也就是线性化点较为准确的时候成立
- 移动机器人的方程是非线性模型，主要原因是表示姿态的旋转量并不是实数空间中的元素
- 对旋转量定义随机分布，并将线性化技术建立在旋转矩阵上，可以方便未来在分析中采用实数空间中常用手段进行处理

机器人运动小结

- 机器人的运动可以利用刚体上点的运动进行描述
- 机器人的状态通常被建模成位姿和速度，由于旋转的存在，机器人的运动和观测都是非线性模型
- 通过引入旋转的线性化，可以将非线性模型线性化
- 同时引入旋转的概率密度函数，使旋转的随机性可以用概率理论描述
- 至此，有了完整的机器人状态系统建模，有了对状态的线性化方法，以及用概率描述因传感噪声导致的系统随机性

概率理论估计方法

- 基于以上的系统方程和随机理解，机器人系统可以建模为随机系统方程
- 基于随机系统方程，可以采用概率分布对位姿和观测进行描述，也可以引入概率理论中的估计方法对状态进行估计
- 基于机器人的动态特性，估计方法可以分成以下两类：
 - ✓ 批处理类型：可以对过去状态进行修正，但计算量增加
 - ✓ 迭代类型：保证每个步骤计算时间一致，但只是估计当前状态

概率理论估计方法-概率状态系统

- 相比于状态空间系统，随机系统利用噪声将随机性引入到方程中

$$\begin{cases} \frac{dx}{dt} = f(x, u) \\ y = h(x) \end{cases} \quad \Rightarrow \quad \begin{cases} \frac{dx}{dt} = f(x, u, \boxed{n_f}) \\ y = h(x, \boxed{n_h}) \end{cases}$$

- 如此建模方式可将运动和观测方程中没有建模的部分一并考虑
- 定义积分后的系统为（t为时刻）：
$$\begin{cases} x_{t+1} = F(x_t, u_t, n_{F,t}) \\ y_t = h(x_t, n_h) \end{cases}$$
 离散随机系统，符合机器人数据采集形式
- 引入条件概率密度对离散后的随机系统进行描述，形成对机器人包含随机性的状态空间建模：
$$\begin{cases} p(x_{t+1} | x_t, u_t) \\ p(y_t | x_t) \end{cases}$$

由于存在噪声，状态量和观测量变成了随机变量的概率分布，从而把确定性系统分析转化为概率分布分析范围，概率估计工具就可以用于机器人问题

概率理论估计方法-概率状态系统

马尔科夫过程建模

- 基于概率分布表征的随机系统，可将机器人在一个序列的运动过程中所有传感器和控制信息考虑到一起，以马尔卡夫过程的形式建模
- 机器人0-t时刻的状态和所收集的数据的整体联合概率分布：

$$\begin{cases} p(\mathbf{X}_t | \mathbf{U}_{t-1}) = p(\mathbf{x}_0) p(\mathbf{x}_1 | \mathbf{x}_0, \mathbf{u}_0) p(\mathbf{x}_2 | \mathbf{x}_1, \mathbf{u}_1) \dots \\ p(\mathbf{Y}_t | \mathbf{X}_t) = p(\mathbf{y}_0 | \mathbf{x}_0) p(\mathbf{y}_1 | \mathbf{x}_1) \dots \end{cases}$$

- 其中 $\mathbf{X}_t \triangleq \{\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_t\}$, $\mathbf{Y}_t \triangleq \{\mathbf{y}_0, \mathbf{y}_1, \dots, \mathbf{y}_t\}$, $\mathbf{U}_t \triangleq \{\mathbf{u}_0, \mathbf{u}_1, \dots, \mathbf{u}_t\}$ 。上式的推导采用了条件独立性质：

$$p(\mathbf{x}_{t+1} | \mathbf{X}_t) = p(\mathbf{x}_{t+1} | \mathbf{x}_t) \quad p(\mathbf{y}_t | \mathbf{X}_t) = p(\mathbf{y}_t | \mathbf{x}_t)$$

即系统的递推关系：给定 $\mathbf{x}_t$ 可以推导出 $\mathbf{x}_{t+1}$ ，不需要和其他过去时刻的状态产生关联。

概率理论估计方法-概率状态系统

- 基于上述推导，将从0~t时刻所有状态和传感器数据 Y 和 U 关联在一起，形成联合分布，使得给定传感器数据下的分布能够推导。
- 即采用马尔科夫模型，将传感器测量状态的过程，构造成概率推断问题
- 具体而言，已知传感器观测 Y_t 和控制信息 U_t ，推断机器人的状态 X_t
- 用统计学语言来描述，就是随机变量的估计问题
- 下面介绍两种估计方法
 - 最大后验估计 MAP (Maximum a posteriori estimation)
 - 滤波估计器 Filter

概率理论估计方法-最大后验估计

- 最大后验概率估计MAP：指取后验分布中使得概率最大的那组状态
- 这里后验分布指给定 U_{t-1} 和 Y_t 情况下， X_t 的分布

$$p(X_t|Y_t, U_{t-1}) = \frac{p(Y_t, X_t|U_{t-1})}{\int p(Y_t, X_t|U_{t-1})dX_t} = \frac{p(Y_t|X_t)p(X_t|U_{t-1})}{\int p(Y_t|X_t)p(X_t|U_{t-1})dX_t}$$

- 对其取最大，并对数变换可得

$$\hat{X}_t = \operatorname{argmax} \frac{p(Y_t|X_t)p(X_t|U_{t-1})}{\int p(Y_t|X_t)p(X_t|U_{t-1})dX_t} = \operatorname{argmax} p(Y_t|X_t)p(X_t|U_{t-1})$$

$$\hat{X}_t = \operatorname{argmin} -\log p(Y_t|X_t) - \log p(X_t|U_{t-1})$$

$\hat{X}_t$ 指的是对 X_t 的估计。使用 $\log$ 运算可以将概率密度函数中的指数去除，同时转为最优化问题

概率理论估计方法-最大后验估计

- 对于大多数非线性系统和概率分布，上式无法在可行时间内求解
- 为了导出可行的求解形式，可采用高斯分布建模加性噪声

$$\begin{cases} p(\mathbf{x}_{t+1}|\mathbf{x}_t, \mathbf{u}_t) = \beta_x \exp(-\frac{1}{2}(\mathbf{x}_{t+1} - \mathbf{F}(\mathbf{x}_t, \mathbf{u}_t, 0))^T \Sigma_x^{-1}(\mathbf{x}_{t+1} - \mathbf{F}(\mathbf{x}_t, \mathbf{u}_t, 0))) \\ p(\mathbf{y}_t|\mathbf{x}_t) = \beta_y \exp(-\frac{1}{2}(\mathbf{y}_t - \mathbf{h}(\mathbf{x}_t, 0))^T \Sigma_y^{-1}(\mathbf{y}_t - \mathbf{h}(\mathbf{x}_t, 0))) \end{cases}$$

- 其中
$$\begin{cases} \mathbf{F}(\mathbf{x}_t, \mathbf{u}_t, \mathbf{n}_{F,t}) = \mathbf{F}(\mathbf{x}_t, \mathbf{u}_t, 0) + \mathbf{n}_{F,t} \triangleq \mathbf{F}_t + \mathbf{n}_F \\ \mathbf{h}(\mathbf{x}_t, \mathbf{n}_h) = \mathbf{h}(\mathbf{x}_t, 0) + \mathbf{n}_h \triangleq \mathbf{h}_t + \mathbf{n}_h \end{cases}$$

- 回代到MAP的公式，可以得到具体形式

$$\begin{cases} \log p(\mathbf{X}_t|\mathbf{U}_{t-1}) = -\frac{1}{2}(\mathbf{x}_0^T \Sigma_x^{-1} \mathbf{x}_0 + \sum_t (\mathbf{x}_t - \mathbf{F}_{t-1})^T \Sigma_x^{-1} (\mathbf{x}_t - \mathbf{F}_{t-1})) + c_1 \\ \log p(\mathbf{Y}_t|\mathbf{X}_t) = -\frac{1}{2} \sum_t (\mathbf{y}_t - \mathbf{h}_t)^T \Sigma_y^{-1} (\mathbf{y}_t - \mathbf{h}_t) + c_2 \end{cases}$$

- C为高斯分布中的常数项取对数，当做MAP时，常数项对结果没影响，可忽略

概率理论估计方法-最大后验估计

- 由于是最小化运算，移除常数项，导出MAP的最终形式为

$$\hat{X}_t = \operatorname{argmin} x_0^T \Sigma_x^{-1} x_0 + \sum_t (y_t - h_t)^T \Sigma_y^{-1} (y_t - h_t) + (x_t - F_{t-1})^T \Sigma_x^{-1} (x_t - F_{t-1})$$

- 当系统噪声满足高斯分布式，等价于求解一个非线性方程方程组，通常称为“最小二乘法”
- 当h和f为线性函数时，高斯系统的最大后验估计由线性最小二乘求解
- 当h和f为非线性函数时，高斯系统的最大后验估计由非线性最小二乘求解

概率理论估计方法-最大后验估计

求解非线性最小二乘-高斯牛顿迭代法

- 简化起见，写成矩阵形式 $\hat{\mathbf{X}}_t = \operatorname{argmin} \begin{pmatrix} \mathbf{x}_0 \\ \mathbf{h} \\ \mathbf{F} \end{pmatrix}^T \begin{pmatrix} \Sigma_{\mathbf{x}}^{-1} & 0 & 0 \\ 0 & \Sigma_{\mathbf{y}}^{-1} & 0 \\ 0 & 0 & \Sigma_{\mathbf{x}}^{-1} \end{pmatrix} \begin{pmatrix} \mathbf{x}_0 \\ \mathbf{h} \\ \mathbf{F} \end{pmatrix}$

- 给定线性化点 $\tilde{\mathbf{x}}_t$ ，可以对系统进行线性化
- 对移动机器人而言，就是对位移、旋转进行线性化

$$\mathbf{y}_t - \mathbf{h}_t \approx \mathbf{y}_t - \mathbf{h}(\tilde{\mathbf{x}}_t, 0) - \frac{\partial \mathbf{h}}{\partial \mathbf{x}_t} (\mathbf{x}_t - \tilde{\mathbf{x}}_t) \triangleq \mathbf{e}_{h_t} - \mathbf{J}_{h_t} \delta \mathbf{x}_t$$

$$\mathbf{x}_t - \mathbf{F}_{t-1} \approx \tilde{\mathbf{x}}_t + \mathbf{x}_t - \tilde{\mathbf{x}}_t - \mathbf{F}(\tilde{\mathbf{x}}_{t-1}, 0) - \frac{\partial \mathbf{F}}{\partial \mathbf{x}_{t-1}} (\tilde{\mathbf{x}}_{t-1} - \mathbf{x}_{t-1}) \triangleq \mathbf{e}_{F_t} - \begin{pmatrix} -\mathbf{I} \\ \mathbf{J}_{F_{t-1}} \end{pmatrix}^T \begin{pmatrix} \delta \mathbf{x}_t \\ \delta \mathbf{x}_{t-1} \end{pmatrix}$$

- 写为矩阵形式 $\mathbf{h} \approx \mathbf{e}_h - \mathbf{J}_h \delta \mathbf{X}_t$ $\mathbf{F} \approx \mathbf{e}_F - \mathbf{J}_F \delta \mathbf{X}_t$
雅可比矩阵 雅可比矩阵

概率理论估计方法-最大后验估计

求解非线性最小二乘-高斯牛顿迭代法

- 转化MAP为对线性化点和真值点间偏差量的线性最小二乘

目标函数 $\hat{X}_t = \operatorname{argmin} \begin{pmatrix} x_0 \\ h \\ F \end{pmatrix}^T \begin{pmatrix} \Sigma_x^{-1} & 0 & 0 \\ 0 & \Sigma_y^{-1} & 0 \\ 0 & 0 & \Sigma_x^{-1} \end{pmatrix} \begin{pmatrix} x_0 \\ h \\ F \end{pmatrix}$



$$\delta \hat{X}_t \approx \operatorname{argmin} \begin{pmatrix} -\check{x}_0 - J_0 \delta X_t \\ e_h - J_h \delta X_t \\ e_F - J_F \delta X_t \end{pmatrix}^T \begin{pmatrix} \Sigma_x^{-1} & 0 & 0 \\ 0 & \Sigma_y^{-1} & 0 \\ 0 & 0 & \Sigma_x^{-1} \end{pmatrix} \begin{pmatrix} -\check{x}_0 - J_0 \delta X_t \\ e_h - J_h \delta X_t \\ e_F - J_F \delta X_t \end{pmatrix}$$

矩阵简写



转化为线性最小二乘形式

$$\delta \hat{X}_t \approx \operatorname{argmin} (b - A \delta X_t) W^{-1} (b - A \delta X_t)$$

- 迭代法**：通过不断变更待求变量 X_t ，实现该函数最小化
- 核心思想：用一个二次函数对当前目标函数进行拟合，认为二次函数的最小值点为最优解
- 不断迭代，实现目标函数不断下降，达到局部最优解


概率理论估计方法-最大后验估计-非线性最小二乘

- 偏差量 $\delta\widehat{X}_t$ 可通过求解线性最小二乘得到

$$\delta\widehat{X}_t = (A^T W^{-1} A)^{-1} A^T W^{-1} b$$

- 在线性化点上增加偏差量，获得对状态的估计的更新 $\check{X}_t$

$$\check{X}_t = \check{X}_t + \delta\widehat{X}_t$$



- 可以保证局部范围目标函数下降
- $\check{X}_t$ 越接近局部最优解， $\delta\widehat{X}_t$ 趋于0，收敛

- 线性化点如何获得？


- 随机，全0，离真值点较远时结果很差
- 其他取得初值的手段，比如先解控制量部分的方程

- 线性化点一次迭代后是否真的是真值？

- 不是，因为非线性方程线性化只是局部的近似
- 可以用更新后的点，作为新的初始化点，重新进行上述步骤，迭代

概率理论估计方法-最大后验估计-非线性最小二乘

- 高斯-牛顿最小二乘求解法
- 通过不断的用二次函数拟合线性化点附近的误差曲面，逐渐逼近解
- 但只能保证局部最优性，因此和第一个线性化点的高度相关



MAP小结

- 基于随机系统理论建模机器人的整个序列



- 将状态测量问题转化为随机变量的估计问题



- 通过加性高斯噪声假设，将MAP具体化为非线性最小二乘



- 通过线性化迭代，求解非线性最小二乘问题

还有：梯度下降、Levenberg-Marquardt算法。。。

概率理论估计方法-滤波

- 为什么要滤波？
 - MAP估计机器人在整个运行序列中的状态，意味着随着机器人运行序列变长，可能求解越来越慢，因此只适合**离线**
- 在线运行时，机器人更关心当前状态。
- 滤波**：一种不估计过去状态，只求解当前状态的在线方法
- 导出关于当前状态的**MAP**

$$p(\mathbf{X}_t | Y_t, U_{t-1}) = \frac{p(Y_t, \mathbf{X}_t | U_{t-1})}{\int p(Y_t, \mathbf{X}_t | U_{t-1}) d\mathbf{X}_t} = \frac{p(Y_t | \mathbf{X}_t) p(\mathbf{X}_t | U_{t-1})}{\int p(Y_t | \mathbf{X}_t) p(\mathbf{X}_t | U_{t-1}) d\mathbf{X}_t} \quad \text{MAP}$$

关注所有状态


$$p(\mathbf{x}_t | Y_t, U_{t-1}) = \frac{p(y_t | x_t) \int p(x_t | x_{t-1}, u_{t-1}) p(x_{t-1} | Y_{t-1}, U_{t-2}) dx_{t-1}}{\int p(y_t | x_t) \int p(x_t | x_{t-1}, u_{t-1}) p(x_{t-1} | Y_{t-1}, U_{t-2}) dx_{t-1} dx_t}$$

关注当前状态


- 与全状态的MAP相比，滤波操作更复杂，但形成了递推关系，适合在线处理

概率理论估计方法-滤波


- 由于递推，所以滤波不能像MAP只关注状态的估计值，还需要导出方差，从而满足下一个时间的计算
- 同样采用和MAP时一样的假设，即加性高斯噪声
- 首先介绍高斯分布的性质，假设 X 和 Y 为高斯随机变量，
 - 联合高斯分布 $\mathbf{X}, \mathbf{Y} \sim N\left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}\right)$
 - 存在条件分布 $p(\mathbf{x}|\mathbf{y}) \sim N(\mu_X + \Sigma_{XY}\Sigma_{YY}^{-1}(\mathbf{y} - \mu_Y), \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX})$
 - 存在边际分布 $p(\mathbf{x}) \sim N(\mu_X, \Sigma_{XX})$



联合高斯分布



后验分布



边际分布

滤波：第一个观测


- 基于上述操作，在第一个时刻机器人状态满足 $p(\mathbf{x}_0)$ ，机器人获得了第一个观测 $\mathbf{y}_0$ ，此时的滤波可以写成

$$p(\mathbf{x}_0|\mathbf{Y}_0) = \frac{p(\mathbf{y}_0|\mathbf{x}_0)p(\mathbf{x}_0)}{\int p(\mathbf{y}_0|\mathbf{x}_0)p(\mathbf{x}_0)d\mathbf{x}_0}$$

- 需要构建 $\mathbf{y}_0$ 和 $\mathbf{x}_0$ 的联合分布

- 引入线性化 $\mathbf{y}_0 \approx \mathbf{h}(\check{\mathbf{x}}_0, 0) + \frac{\partial \mathbf{h}}{\partial \mathbf{x}}(\mathbf{x}_0 - \check{\mathbf{x}}_0) + \mathbf{n}_h \triangleq \mathbf{h}_0 + \mathbf{J}_{h_0}(\mathbf{x}_0 - \check{\mathbf{x}}_0) + \mathbf{n}_h$

- 高斯分布的线性变换仍满足高斯分布



滤波：第一个观测

- 构造出联合高斯分布

$$E\left\{\begin{pmatrix} \mathbf{x}_0 \\ \mathbf{y}_0 \end{pmatrix}\right\} = \begin{pmatrix} 0 \\ \mathbf{h}_0 \end{pmatrix} \quad \text{Cov}\left\{\begin{pmatrix} \mathbf{x}_0 \\ \mathbf{y}_0 \end{pmatrix}\right\} = \begin{pmatrix} \Sigma_x & \Sigma_x \mathbf{J}_{h_0}^T \\ \mathbf{J}_{h_0} \Sigma_x & \mathbf{J}_{h_0} \Sigma_x \mathbf{J}_{h_0}^T + \Sigma_y \end{pmatrix}$$

- 利用联合高斯的条件分布公式，导出后验

$$p(\mathbf{x}_0 | \mathbf{Y}_0) \sim N(\Sigma_x \mathbf{J}_{h_0}^T (\mathbf{J}_{h_0} \Sigma_x \mathbf{J}_{h_0}^T + \Sigma_y)^{-1} (\mathbf{y}_0 - \mathbf{h}_0), \Sigma_x - \Sigma_x \mathbf{J}_{h_0}^T (\mathbf{J}_{h_0} \Sigma_x \mathbf{J}_{h_0}^T + \Sigma_y)^{-1} \mathbf{J}_{h_0} \Sigma_x)$$

- 定义 $\mathbf{K}_0 \triangleq \Sigma_x \mathbf{J}_{h_0}^T (\mathbf{J}_{h_0} \Sigma_x \mathbf{J}_{h_0}^T + \Sigma_y)^{-1}$ ，为卡尔曼增益，得到第一个观测后的后验分布

$$p(\mathbf{x}_0 | \mathbf{Y}_0) \sim N(\mathbf{K}_0 (\mathbf{y}_0 - \mathbf{h}_0), (\mathbf{I} - \mathbf{K}_0 \mathbf{J}_{h_0}) \Sigma_x)$$

- 该式为高斯分布，可以代入滤波的下一时刻，满足递推的需求

滤波：第一个运动

- 在获得第一个观测以后，机器人会进行第一个运动，到下一时刻，此时滤波为

$$p(\mathbf{x}_1 | \mathbf{Y}_1, \mathbf{U}_0) = \frac{p(\mathbf{y}_1 | \mathbf{x}_1) \int p(\mathbf{x}_1 | \mathbf{x}_0, \mathbf{u}_0) p(\mathbf{x}_0 | \mathbf{Y}_0) d\mathbf{x}_0}{\int p(\mathbf{y}_1 | \mathbf{x}_1) \int p(\mathbf{x}_1 | \mathbf{x}_0, \mathbf{u}_0) p(\mathbf{x}_0 | \mathbf{Y}_0) d\mathbf{x}_0 d\mathbf{x}_1}$$

- 运动部分 $p(\mathbf{x}_1 | \mathbf{Y}_0, \mathbf{U}_0) = \int p(\mathbf{x}_1 | \mathbf{x}_0, \mathbf{u}_0) p(\mathbf{x}_0 | \mathbf{Y}_0) d\mathbf{x}_0$
- 如果 $p(\mathbf{x}_1 | \mathbf{Y}_0, \mathbf{U}_0)$ 满足高斯并可解，则第二个观测的操作和第一个观测形式完全一致，操作方法可递归

$$p(\mathbf{x}_1 | \mathbf{Y}_1, \mathbf{U}_0) = \frac{p(\mathbf{y}_1 | \mathbf{x}_1) p(\mathbf{x}_1 | \mathbf{Y}_0, \mathbf{U}_0)}{\int p(\mathbf{y}_1 | \mathbf{x}_1) p(\mathbf{x}_1 | \mathbf{Y}_0, \mathbf{U}_0) d\mathbf{x}_1}$$

滤波：第一个运动

- 因此推导 $p(\mathbf{x}_1|Y_0, U_0)$ ，采用线性化

$$\mathbf{x}_1 \approx F(\lambda_0, \mathbf{u}_0, 0) + \frac{\partial F}{\partial \mathbf{x}}(\mathbf{x}_0 - \lambda_0) + \mathbf{n}_F \triangleq F_0 + J_{F_0}(\mathbf{x}_0 - \lambda_0) + \mathbf{n}_F$$

- 简单起见将 $p(\mathbf{x}_t|Y_t)$ 满足的高斯分布记为 $N(\lambda_t, \Phi_t)$ ，同样高斯分布的线性变换仍是高斯分布，构造联合分布

$$E \left\{ \begin{pmatrix} \mathbf{x}_0 \\ \mathbf{x}_1 \end{pmatrix} \right\} = \begin{pmatrix} \lambda_0 \\ F_0 \end{pmatrix} \quad Cov \left\{ \begin{pmatrix} \mathbf{x}_0 \\ \mathbf{x}_1 \end{pmatrix} \right\} = \begin{pmatrix} \Phi_0 & \Phi_0 J_{F_0}^T \\ J_{F_0} \Phi_0 & J_{F_0} \Phi_0 J_{F_0}^T + \Sigma_x \end{pmatrix}$$

- 根据边际分布公式，得到

$$p(\mathbf{x}_1|Y_0, U_0) \sim N(F_0, J_{F_0} \Phi_0 J_{F_0}^T + \Sigma_x)$$

滤波：下一个观测

- 显然， $p(\mathbf{x}_1|Y_0, U_0)$ 满足高斯分布，并能解析写出参数
- 根据递推形式，以及第一个观测同样的处理，再获得下一个观测以后，可得

$$p(\mathbf{x}_0|Y_0) = \frac{p(\mathbf{y}_0|\mathbf{x}_0)p(\mathbf{x}_0)}{\int p(\mathbf{y}_0|\mathbf{x}_0)p(\mathbf{x}_0)d\mathbf{x}_0}$$

$$p(\mathbf{x}_1|Y_1, U_0) = \frac{p(\mathbf{y}_1|\mathbf{x}_1)p(\mathbf{x}_1|Y_0, U_0)}{\int p(\mathbf{y}_1|\mathbf{x}_1)p(\mathbf{x}_1|Y_0, U_0)d\mathbf{x}_1}$$



$$p(\mathbf{x}_1|Y_1, U_0) \sim N(\mathbf{F}_0 + \mathbf{K}_1(\mathbf{y}_1 - \mathbf{h}_1), (\mathbf{I} - \mathbf{K}_1\mathbf{J}_{h_1})(\mathbf{J}_{F_0}\boldsymbol{\Phi}_0\mathbf{J}_{F_0}^T + \boldsymbol{\Sigma}_x))$$

卡尔曼滤波

- 通过高斯假设，可以发现滤波的每一步信息都可以导出新的高斯分布，从而使整个过程可解析计算
- 一般化的卡尔曼增益

$$K_t = (J_{F_{t-1}} \Phi_{t-1} J_{F_{t-1}}^T + \Sigma_x) J_{h_t}^T (J_{h_t} (J_{F_{t-1}} \Phi_{t-1} J_{F_{t-1}}^T + \Sigma_x) J_{h_t}^T + \Sigma_y)^{-1}$$

- 一般化的后验

$$\lambda_t = F_{t-1} + K_t(y_t - h_t)$$

$$\Phi_t = (I - K_t J_{h_t}) (J_{F_{t-1}} \Phi_{t-1} J_{F_{t-1}}^T + \Sigma_x)$$

- 这组公式被称为卡尔曼滤波

滤波小结

- 相比于MAP，滤波采用单步后验形成递推形式，从而使计算从离线变成在线，相应的也丢弃了过去的状态
- 通过假设高斯分布以及线性化后，系统的线性传递满足高斯分布，因此此时的滤波转化为高斯分布的参数递推求解问题，使得滤波过程可快速求解
- 卡尔曼滤波在非线性形式下，由于线性化误差的引入，缺少理论上的严格保证，通常比MAP的精度要低

本章小结

- 概率理论能够提供建立实际世界中随机性的理论工具
- 三维世界的运动理论提供了移动机器人运动的理论工具
- 两者结合形成了随机系统理论，能够描述在随机性实际世界中运行的移动机器人，其状态-运动-观测三者的关系
- 基于上述理论构建的系统，对状态的测量问题可以转化为随机变量的估计问题，从而可以用统计学工具求解
- 在引入高斯分布的加性噪声假设下，MAP可以转化为非线性最小二乘实现全状态估计，滤波可以转化为卡尔曼滤波求解当前状态估计