

定位与建图

温程璐

单位：厦门大学


2023 年 月




为什么需要SLAM?

- 随着机器人的工作时间越来越长，里程估计的误差会不断累积，导致对自身位姿的估计精度越来越差
- SLAM能够借助机器人在同一场景的回访，减少累积误差

回访前




回访后




SLAM系统框架

- 特征跟踪：里程估计中的前后帧特征匹配
- 闭环检测：判断是否回访同一场景
- 两者和传感器的信息模态有关，所以称为SLAM系统前端



SLAM系统框架

- 前端用于生成约束
- 后端负责求解约束构成的方程，得到优化的机器人轨迹估计
- 后端和传感器信息模态无关，所以称为SLAM系统后端



闭环检测


- 定义：基于传感器信息，判断当前所处的地点是否是过去已经访问过的地点。
- 为什么基于传感器信息，而非里程估计的定位结果？
 - 由于误差累积，即使现在和过去某个时刻处在同一个地点，现在的里程估计结果，和当时的结果也不相同。
- 如何定义回访到同一个地点？
 - 现在和过去某个时刻的传感器信息相似

闭环检测问题定义

- 给定地图数据库，存储过去所有地点的传感器信息
- 给定当前的传感器信息，从数据库中返回与当前帧传感器信息最相似的一帧数据，判断是否为同一地点
- 最相似的判断：
 - 关于图像相似度的度量，并且可快速计算，因为数据库可能很大
- 相似度的依据：
 - 在同一地点应当得到类似的传感器信息，注意不是完全相等

基于图像的闭环检测


- 构建图像特征，避免像素层面可能存在的区别
- 利用特征的欧式距离反应相似度



基于图像的闭环检测

词包模型

- 相似的图像应当可以匹配大量特征，但逐张匹配效率太低
- 采用图像中特征的频率分布描述图像，实现欧式距离匹配



基于图像的闭环检测

词包模型

- 构建训练数据集，所有图像的特征描述子 $\{\mathbf{d}_{ik}\}$ 的集合

$$\mathbf{D}_{train} = \bigcup_i \{\mathbf{d}_{ik}\}$$

- 通过K均值，将描述子空间离散化为K个中心 $\{\mathbf{c}_j\}$
- 基于K个中心，离散化特征 $l(\mathbf{d}_{ik}) = \operatorname{argmin}_j \|\mathbf{d}_{ik} - \mathbf{c}_j\|$
- 采用图像中特征出现的频次分布作为该图像的K维特征


$$\mathbf{f}_i = \left(\frac{|\{\mathbf{d}_{ik} | l(\mathbf{d}_{ik}) = 1\}|}{\sum_j |\{\mathbf{d}_{ik} | l(\mathbf{d}_{ik}) = j\}|} \quad \frac{|\{\mathbf{d}_{ik} | l(\mathbf{d}_{ik}) = 2\}|}{\sum_j |\{\mathbf{d}_{ik} | l(\mathbf{d}_{ik}) = j\}|} \quad \dots \right)$$

其他图像特征方法

- VLAD, 避免离散化损失信息, 采用描述子和中心的差向量描述图像
- DenseVLAD, 避免关键点提取损失信息, 采用每个像素的描述子, 构建VLAD
-

序列判断

- 基于特征的欧氏距离，简单阈值判定？
 - 阈值可能在不同的地点不同
- SLAM是一个序列过程，如果 t_0 地点的闭环是 $t+1$ 时刻的地点，那么 t_1 地点的闭环，不会离 $t+1$ 时刻的地点很远




闭环检测剩余问题

- 得到同一地点的传感器数据以后？
 - 问题退化为临近**图片/激光数据**的位姿估计问题
 - 和里程估计的 $t-1$ 和 t 时刻的相对位姿估计问题解法类似
- 如何解决激光的闭环检测？
 - 提取激光的特征点，采用BoW或者VLAD的思路
 - 采用所有的激光点，通过DenseVLAD的思路


SLAM后端

- 把位姿看做节点，把每个约束看做边，机器人在运行过程中能够生成一个位姿图模型
- 其中相邻节点间的边代表里程估计生成的约束
- 跨多个节点的边代表闭环检测生成的约束
- SLAM后端的任务就是求解整条轨迹，逼近所有约束方程



SLAM后端

- 为什么SLAM能够比里程估计更准确？
 - 里程估计的结果可以看做是没有闭环检测的SLAM
 - 直观理解，同样多的变量，SLAM有更多的约束方程
 - 概率统计的角度，里程估计是所有里程估计约束方程的极大后验估计（MAP），并不是所有约束的MAP，而SLAM是。



SLAM的MAP构造和求解

- 约束的概率建模

- 里程估计约束 $\mathbf{u}_t$ $p(\mathbf{x}_{t+1}|\mathbf{x}_t, \mathbf{u}_t) = N(\mathbf{F}(\mathbf{x}_t, \mathbf{u}_t), \Sigma_t)$

- 所有里程估计约束 $p(\mathbf{X}_t|\mathbf{U}_{t-1})$
 $= p(\mathbf{x}_0)p(\mathbf{x}_1|\mathbf{x}_0, \mathbf{u}_0)p(\mathbf{x}_2|\mathbf{x}_1, \mathbf{u}_1) \dots$

- 闭环检测约束 $\mathbf{y}_{t,m}$ $p(\mathbf{y}_{t,m}|\mathbf{x}_t, \mathbf{x}_m) = N(\mathbf{h}(\mathbf{x}_t, \mathbf{x}_m), \Sigma_{t,m})$

- 所有闭环检测约束 $p(\mathbf{Y}_t|\mathbf{X}_t) = \prod_{t,m \in \mathcal{E}} p(\mathbf{y}_{t,m}|\mathbf{X}_t)$
 $= \prod_{t,m \in \mathcal{E}} p(\mathbf{y}_{t,m}|\mathbf{x}_t, \mathbf{x}_m)$

SLAM的MAP构造和求解

- 极大后验估计求解所有 $\mathbf{X}_t$

$$\hat{\mathbf{X}}_t = \operatorname{argmax} p(\mathbf{Y}_t | \mathbf{X}_t) p(\mathbf{X}_t | \mathbf{U}_{t-1})$$

- SLAM的MAP可以转化为最小二乘问题，即逼近所有约束

$$\left\{ \begin{array}{l} \log p(\mathbf{X}_t | \mathbf{U}_{t-1}) = -\frac{1}{2} (\mathbf{x}_0^T \boldsymbol{\Sigma}_0^{-1} \mathbf{x}_0 + \sum_t (\mathbf{x}_t - \mathbf{F}_{t-1})^T \boldsymbol{\Sigma}_t^{-1} (\mathbf{x}_t - \mathbf{F}_{t-1})) + c \\ \log p(\mathbf{Y}_t | \mathbf{X}_t) = -\frac{1}{2} \sum_{t,m \in \mathcal{E}} (\mathbf{y}_{t,m} - \mathbf{h}_{t,m})^T \boldsymbol{\Sigma}_{t,m}^{-1} (\mathbf{y}_{t,m} - \mathbf{h}_{t,m}) + c \end{array} \right.$$

因子图

- 里程估计和闭环检测约束本质上都是一种建立在从未知变量到某个测度的函数，将其统称为因子
- SLAM问题的一般化表达可以看作因子图，而因子的值域未必需要归一化

$$\hat{\mathbf{X}}_t = \operatorname{argmax} \prod_{t,m \in \mathcal{E}} \phi(\mathbf{x}_t, \mathbf{x}_m) \phi(\mathbf{x}_0) \phi(\mathbf{x}_1, \mathbf{x}_0) \phi(\mathbf{x}_2, \mathbf{x}_1) \dots$$

- 比如此时的里程计约束可以忽略归一化因子，写为

$$\begin{aligned} & \phi(\mathbf{x}_{t+1}, \mathbf{x}_t) \\ &= \exp(-(\mathbf{x}_{t+1} - \mathbf{F}(\mathbf{x}_t, \mathbf{u}_t))^T \boldsymbol{\Sigma}_t^{-1} (\mathbf{x}_{t+1} - \mathbf{F}(\mathbf{x}_t, \mathbf{u}_t))) \end{aligned}$$

更多约束

- 可以构造GPS传感器的约束

$$\begin{aligned}\phi_{GPS}(\mathbf{x}_t) \\ = \exp(-(\mathbf{y}_{t,GPS} - \mathbf{x}_t)^T \boldsymbol{\Sigma}_t^{-1} (\mathbf{y}_{t,GPS} - \mathbf{x}_t))\end{aligned}$$


- 特征点和位姿都是变量时，可以构造视觉观测约束。比如一对闭环的位姿 $\mathbf{x}_m$ 和 $\mathbf{x}_t$ ，观测到同一个特征点 l_i

$$\phi_l(\mathbf{x}_m, l_i) = \exp(-(\mathbf{y}_{m,l_i} - \mathbf{h}(\mathbf{x}_m, l_i))^T \boldsymbol{\Sigma}_{m,i}^{-1} (\mathbf{y}_{m,l_i} - \mathbf{h}(\mathbf{x}_m, l_i)))$$

$$\phi_l(\mathbf{x}_t, l_i) = \exp(-(\mathbf{y}_{t,l_i} - \mathbf{h}(\mathbf{x}_t, l_i))^T \boldsymbol{\Sigma}_{t,i}^{-1} (\mathbf{y}_{t,l_i} - \mathbf{h}(\mathbf{x}_t, l_i)))$$

SLAM约束方程构造案例

- 多传感融合-最小二乘



$$\left\{ \begin{array}{l} \phi_{GPS}(x_2) = \exp(-(\mathbf{y}_{2,GPS} - \mathbf{x}_2)^T \Sigma_t^{-1} (\mathbf{y}_{2,GPS} - \mathbf{x}_2)) \\ \phi_l(x_0, l_0) = \exp(-(\mathbf{y}_{0,l_0} - h(\mathbf{x}_0, l_0))^T \Sigma_{0,0}^{-1} (\mathbf{y}_{0,l_0} - h(\mathbf{x}_0, l_0))) \\ \phi_l(x_1, l_0) = \exp(-(\mathbf{y}_{1,l_0} - h(\mathbf{x}_1, l_0))^T \Sigma_{1,0}^{-1} (\mathbf{y}_{1,l_0} - h(\mathbf{x}_1, l_0))) \\ \phi(x_1, x_0) = \exp(-(\mathbf{x}_1 - F(\mathbf{x}_0, \mathbf{u}_0))^T \Sigma_t^{-1} (\mathbf{x}_1 - F(\mathbf{x}_0, \mathbf{u}_0))) \\ \phi(x_2, x_1) = \exp(-(\mathbf{x}_2 - F(\mathbf{x}_1, \mathbf{u}_1))^T \Sigma_t^{-1} (\mathbf{x}_2 - F(\mathbf{x}_1, \mathbf{u}_1))) \end{array} \right.$$

SLAM的MAP小结

- 优势
 - 构造精简，可以采用最小二乘优化器进行求解
 - 精度最好，逼近所有的约束方程
- 劣势
 - 整条轨迹都是变量，运行越久，变量越多，速度越慢
 - 哪怕是在固定大小的环境中运行，复杂度仍然没有上界

SLAM的滤波构造

- 为了实现在线的SLAM，需要控制变量的规模
- 只保留当前的位姿，SLAM会退化为里程，因为过去的位姿不属于可优化变量，无法考虑闭环
- 保留过去的位姿，则无法控制变量的规模
- 将环境表示为特征的集合，放在变量中参与优化，此时闭环可以转化为当前位姿和环境特征之间的约束。
- 此时复杂度为环境的大小，如果环境固定大小，则复杂度有上界，使在线计算成为可能。

卡尔曼滤波构造

- 状态包含当前位姿和所有环境中的特征
- 构造关于环境和当前位姿的MAP，注意非整条轨迹


$$\begin{aligned} & p(\mathbf{x}_t, \mathbf{L} | \mathbf{Y}_t, \mathbf{U}_{t-1}) \\ &= \frac{p(\mathbf{y}_t | \mathbf{x}_t, \mathbf{L}) \int p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) p(\mathbf{x}_{t-1}, \mathbf{L} | \mathbf{Y}_{t-1}, \mathbf{U}_{t-2}) d\mathbf{x}_{t-1}}{\int p(\mathbf{y}_t | \mathbf{x}_t, \mathbf{L}) \int p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) p(\mathbf{x}_{t-1}, \mathbf{L} | \mathbf{Y}_{t-1}, \mathbf{U}_{t-2}) d\mathbf{x}_{t-1} d\mathbf{x}_t d\mathbf{L}} \end{aligned}$$

- 该过程和扩展卡尔曼滤波的推导一致
- 唯一的区别是从t-1到t时刻，可以忽略特征，即 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) = p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{L})$

卡尔曼滤波构造

- 原因在于特征静态，和机器人的运动无关，可构造EKF运动模型如下

$$\begin{pmatrix} \mathbf{x}_t \\ \mathbf{L} \end{pmatrix} = \begin{pmatrix} \mathbf{F}(\mathbf{x}_{t-1}, \mathbf{u}_{t-1}) + \mathbf{n}_F \\ \mathbf{L} \end{pmatrix}$$



机器人从地图原点到当前时刻，单步运动后的方差情况

卡尔曼滤波构造

- 原因在于特征静态，和机器人的运动无关，可构造EKF运动模型如下
- 在卡尔曼滤波的更新步骤以后，方程会相对运动模型的预测缩小
- 通过标准的卡尔曼滤波预测和更新公式，可以实现SLAM的滤波估计

卡尔曼滤波小结

- 卡尔曼滤波可以实现与环境规模相关的复杂度，为什么还需要SLAM的MAP构造
 - 对于非线性系统，EKF在理论上并没有最优估计的保证，这主要体现在模型线性化时，仅线性化一次。而对于MAP，整条轨迹的求解使重线性化成为可能。
 - 当求解SLAM是为了离线构建地图，则MAP是最佳选择
 - 当求解在线SLAM时，目前的前沿方法通常选择MAP和滤波的均衡，将一个窗口内的多个变量放到优化变量中提高里程的精度。同时采用另一个线程求解整个SLAM，以非实时的频率对里程进行纠正。比如ORB-SLAM等。

本章小结

- 回访触发闭环检测，使里程估计累积的误差能够减少，形成里程估计和闭环检测约束共存的SLAM问题
- MAP构造的SLAM精度好，但非实时
- EKF构造的SLAM精度差，但计算和环境大小保持一致