

Homework 6

- 1. 卷积神经网络 (19 分)
- 2. 学习理论(20分)
 - 基础概念
 - 题目
- 3. MLE/MAP(37 分)
- 4. 朴素贝叶斯(24分)
- 5. 提交格式

1. 卷积神经网络 (19 分)

1. 在这个问题中, 仅考虑 CNN 标准的卷积层。下面是我们给出的一个图像 X 和滤波器 F 。

$$X = \begin{bmatrix} 1 & 0 & -2 & 3 & 4 & 1 \\ 2 & 9 & 5 & 6 & 0 & -1 \\ 0 & -3 & 1 & 3 & 4 & 4 \\ 6 & 5 & 2 & 0 & 6 & 8 \\ -5 & 4 & -3 & 1 & 3 & -2 \\ 4 & 1 & 2 & 8 & 9 & 7 \end{bmatrix} \quad F = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix} \quad Y = \begin{bmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \\ m & n & o & p \end{bmatrix}$$

- (a) (1分)让 X 与 F 进行卷积以输出 Y , 卷积无填充且步长为 1, Y 的 j 值为多少?
- (b) (2分)假设你有一个大小 (高 $\times$ 宽) 为 6×4 的输入特征图和大小为 2×2 的滤波器, 不使用填充且步幅为 2 的卷积, 那么最终的输出大小是多少? 以 "高 $\times$ 宽" 的格式写下你的答案。
2. 参数共享对于 CNN 来说是一个非常重要的概念, 因为它大大降低了学习问题的复杂性。对于以下问题, 假设我们的卷积层中没有偏差项。
- (a) (2分)多选: 以下哪些是卷积层的参数?
- A. stride 大小
- B. padding 尺寸
- C. image 大小
- D. filter 尺寸
- E. filter 的权重
- F. 以上都不是
- (b) (2分)多选: 以下哪些是卷积的超参数?
- A. stride 大小
- B. padding 尺寸
- C. image 大小
- D. filter 尺寸
- E. filter 的权重
- F. 以上都不是
- (c) (2分)假设对于卷积层, 我们给出尺寸为 22×22 的灰度图像。使用一个步长为 2 且无填充的 4×4 滤波器, 你在这一层中学习的参数数量是多少?
- (d) (2分)在(c)的基础上, 现在假设我们不进行参数共享。也就是说, 该层的每个输出均由单独的 4×4 滤波器计算。我们再次使用步长 2 并且没有填充的滤波器。你在这一层中学习的参数数量是多少?
- (e) (2分)现在假设给你一个 40×40 的彩色图像, 它由 3 个通道组成(因此你的输入是一个 $40 \times 40 \times 3$ 张量), 每个通道代表一种原色的强度。假设你再次不进行参数共享, 对每个输出像素使用唯一的 4×4 滤波器, 步幅为 2 并且没有填充。你在这一层中学习的参数数量是多少?
- (f) (1分)用一个简洁的句子, 描述除了减少学习参数数量之外, 参数共享对于应用于图像数据的卷积层来说是一个好主意的原因。
3. 小明想要自己实现 CNN 网络。
- (a) (2分)于是他提出以下简单的想法执行:
- ```
image X has shape (H_in, W_in), and filter F has shape (K, K)
the output Y has shape (H_out, W_out)
Y = np.zeros((H_out, W_out))
for r in range(0, H_out):
 for c in range(0, W_out):
 for i in range(0, K):
 for j in range(0, K):
 Y[r, c] += X[___blank___] * F[i, j]
```

上面的空白(blank)中应该填什么才能使输出  $Y$  正确? 假设  $H_{out}$  和  $W_{out}$  是预先正确计算的。

(b) (2分)他现在想要实现网络的反向传播部分, 但被卡住了。他决定去寻求帮助。一位助教告诉他, CNN 实际上可以使用矩阵乘法来实现。他收到以下一维卷积示例:

假设你有一个输入向量  $\mathbf{x} = [x_1, x_2, x_3, x_4, x_5]^T$  和一个1D卷积滤波器  $\mathbf{w} = [w_1, w_2, w_3]^T$ 。然后, 如果输出是  $\mathbf{y} = [y_1, y_2, y_3]^T$ , 其中  $y_1 = w_1x_1 + w_2x_2 + w_3x_3$ ,  $y_2 = \dots$ ,  $y_3 = \dots$ 。如果你仔细观察, 会发现这等同于:

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \mathbf{A} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix}$$

适用于上面例子的矩阵 A 是什么?

(c) (1分)用一个简洁的句子(或一个简短的数学表达式)解释当你知道某个任意输入  $\mathbf{x}$ 、滤波器  $\mathbf{w}$ , 以及相应的 1D 卷积输出  $\mathbf{y}$  中得出的 A 如何计算  $\frac{\partial y}{\partial x}$  (A 是按照与 (b) 中相同的过程获得的), 但  $\mathbf{x}$ 、 $\mathbf{y}$  和  $\mathbf{w}$  可能与示例不同)。

## 2. 学习理论(20分)

### 基础概念

1. 基础符号:

- 概率分布 (未知):  $X \sim p^*$
- 真实函数 (未知):  $c^*: X \rightarrow Y$
- 假设空间  $\mathcal{H}$ , 以及假设  $h \in \mathcal{H}: X \rightarrow Y$
- 训练数据集  $\mathcal{D} = \{x^{(1)}, \dots, x^{(N)}\}$

2. 真实误差 (期望风险)

$$R(h) = P_{x \sim p^*(x)} (c^*(x) \neq h(x))$$

3. 训练误差 (经验风险)

$$\begin{aligned} \hat{R}(h) &= P_{x \sim \mathcal{D}} (c^*(x) \neq h(x)) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{1} (c^*(x^{(i)}) \neq h(x^{(i)})) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{1} (y^{(i)} \neq h(x^{(i)})) \end{aligned}$$

• PAC标准

PAC标准是指我们以高概率产生一个高精度的假设。更正式地表达, 该标准可以表示为:

$$P \left( \forall h \in \mathcal{H}, |R(h) - \hat{R}(h)| \leq \epsilon \right) \geq 1 - \delta$$

• 样本复杂度

样本复杂度是指为了满足给定的  $\epsilon$  和  $\delta$  下的PAC标准, 所需要的最少训练样本数  $N$ 。

注意:

- 可实现 (Realizable): 意味着  $c^*$  属于假设空间  $\mathcal{H}$ 。
- 不可知 (Agnostic): 意味着  $c^*$  可能属于或可能不属于假设空间  $\mathcal{H}$ 。

以下是4种情况下的样本复杂度:

- 可实现 (Realizable) 且有限  $|\mathcal{H}|$

定理 1:  $N \geq \frac{1}{\epsilon} \left[ \log(|\mathcal{H}|) + \log\left(\frac{1}{\delta}\right) \right]$

当概率为  $(1 - \delta)$ , 所有在  $\mathcal{H}$  中且  $\hat{R}(h) = 0$  的  $h$ , 其  $R(h) \leq \epsilon$  的标签样本数量是足够的。

- 不可知 (Agnostic) 且有限  $|\mathcal{H}|$

定理 2:  $N \geq \frac{1}{2\epsilon^2} \left[ \log(|\mathcal{H}|) + \log\left(\frac{2}{\delta}\right) \right]$

当概率为  $(1 - \delta)$ , 所有  $h \in \mathcal{H}$  都有  $|R(h) - \hat{R}(h)| \leq \epsilon$  的标签样本数量是足够的。

- 可实现 (Realizable) 且无限  $|\mathcal{H}|$

定理 3:  $N = O \left( \frac{1}{\epsilon} \left[ \text{VC}(\mathcal{H}) \log\left(\frac{1}{\epsilon}\right) + \log\left(\frac{1}{\delta}\right) \right] \right)$

当概率为  $(1 - \delta)$ , 所有在  $\mathcal{H}$  中且  $\hat{R}(h) = 0$  的  $h$ , 其  $R(h) \leq \epsilon$  的标签样本数量是足够的。

- 不可知 (Agnostic) 且无限  $|\mathcal{H}|$

定理 4:  $N = O\left(\frac{1}{\epsilon^2} \left[VC(\mathcal{H}) + \log\left(\frac{1}{\delta}\right)\right]\right)$

当概率为  $(1 - \delta)$ , 所有  $h \in \mathcal{H}$  都有  $|R(h) - \hat{R}(h)| \leq \epsilon$  的标签样本数量是足够的。

• VC维数

假设空间  $\mathcal{H}$  的VC维数, 记作  $VC(\mathcal{H})$  或  $d_{VC}(\mathcal{H})$ , 是指存在至少一个样本点排列和一个假设  $h \in \mathcal{H}$ , 该假设能与这些点的任何标记一致的点的最大数量。

• 如何证明  $VC(\mathcal{H}) = n$ :

- 1.证明存在一个大小为  $n$  的点集, 该点集可以被  $\mathcal{H}$  粉碎 (shatter) (即完美分类)。
- 2.证明  $\mathcal{H}$  不能粉碎任何大小为  $n + 1$  的点集。

题目


1. 小明需要解决一个分类任务, 他决定使用具有 2 个二进制特征  $X_1$  和  $X_2$  的决策树学习器。但你认为神经网络不应该使用决策树。相反, 你认为最好使用具有 16 个实值特征以及偏差项的逻辑回归。你想用 PAC 学习来检验你是否正确。你首先在  $N$  个示例上训练逻辑回归模型以获得训练误差  $\hat{R}$ 。
- (a) (2分)你应该将以下哪种 PAC 学习法用于逻辑回归模型?
- A. 有限且可知
  - B. 有限不可知
  - C. 无限且可知
  - D. 无限不可知
- (b) (2分)用  $\hat{R}, \delta$  和  $N$  表示的真实误差  $R$  的上限是多少? 如有必要, 你可以使用大  $O$  表示法。只写最后的答案。
- (c) (3分)单选: 你想论证你的模型, 相对于小明的模型具有更低真实误差的下界。假设你已获得足够的数据点来满足 PAC 标准, 且  $\epsilon$  和  $\delta$  与神经网络相同。以下内容哪些是对的?
- A. 小明的模型总是会更准确地对看不见的数据进行分类, 因为它只需要 2 个二进制特征, 因此更简单。
  - B. 你必须首先通过删除 14 个特征来规范你的模型才能进行比较。
  - C. 这足以表明分类器的 VC 维度高于小明的 VC 维度, 因此真实误差具有下限。
  - D. 有必要证明你实现的训练误差低于小明实现的训练误差。
2. 我们可以使用样本复杂度上界来推导出特定算法的真实误差上界。考虑无限、不可知情况下的样本复杂度上界:

$$N = O\left(\frac{1}{\epsilon^2} \left[VC(\mathcal{H}) + \log\frac{1}{\delta}\right]\right)$$

- (a) (2分)使用大  $O$  符号的定义 (即, 如果  $N = O(M)$  (对于某个值  $M$ ), 则存在一个常数  $c \in \mathbb{R}$ , 使得  $N \leq cM$ ) 来重写关于  $N$  和  $\delta$  的大  $O$  上界。
- (b) (2分)现在, 使用  $\epsilon$  的定义 (即  $|R(h) - \hat{R}(h)| \leq \epsilon$ ), 证明概率至少为  $(1 - \delta)$  时:

$$R(h) \leq \hat{R}(h) + O\left(\sqrt{\frac{1}{N} \left[VC(\mathcal{H}) + \log\frac{1}{\delta}\right]}\right)$$

3. (3分)考虑一个假设空间 $\mathcal{H}$ , 其中的函数将  $M$  个二元属性映射到二元标签。该空间中的一个函数  $f$  可以表示为  $f: \{0, 1\}^M \rightarrow \{0, 1\}$ 。小明说无论  $M$  的值如何, 这个空间中的函数总是可以分割  $2^M$  个点。小明说错了吗? 如果是, 请提供反例。如果小明对了, 请简要说明原因。
4. 考虑一个实例空间  $\mathcal{X}$ , 它是实数集合。
- (a) (3分)单选: 在假设类  $H$  中, 每个假设  $h$  的形式是 "如果  $a < x < b$  或  $c < x < d$  则  $y = 1$ ; 否则  $y = 0$ " (即,  $H$  是一个无限假设类, 其中  $a, b, c,$  和  $d$  是任意实数)。  $H$  的 VC 维数是多少?
- A. 2
  - B. 3
  - C. 4
  - D. 5
  - E. 6
- (b) (3分)给定下面  $\mathcal{X}$  中的点集, 构造某个点子集的标签, 以显示任何比  $H$  的 VC 维数大出正好 1 的维数都是不正确的 (例如, 如果  $H$  的 VC 维数是 3, 则只需填写 4 个点的答案)。在表格中每个点的对应标签中填入 0 或 1。对于您在示例中没有使用的点, 请写 N/A (不要留空答案框)。



| 点  | -3 | -2 | -1 | 0 | 1 | 2 | 3 |
|----|----|----|----|---|---|---|---|
| 标签 |    |    |    |   |   |   |   |

### 3. MLE/MAP(37 分)

1. (2分)判断: 假设你对伯努利分布放置一个 Beta 先验, 并尝试从数据中学习伯努利分布的参数  $\theta$ 。还假设一个对手为了混淆你的算法, 偷偷为你选择了不好的但数量有限的 Beta 先验超参数。随着训练样本数量趋近无穷大,  $\theta$  的最大后验(MAP)估计仍然可以收敛到  $\theta$  的最大似然估计(MLE)。

- True
- False

2. (2分)设  $\Gamma$  为随机变量, 具有以下概率密度函数:

$$f(\gamma) = \begin{cases} 2\gamma & \text{if } 0 \leq \gamma \leq 1 \\ 0 & \text{otherwise} \end{cases}$$

假设另一个随机变量  $Y$ , 在给定  $\Gamma$  的条件下, 遵循参数为  $\lambda = 3\gamma$  的指数分布。回顾一下参数为  $\lambda$  的指数分布具有以下概率密度函数:

$$f_{\text{exp}}(y) = \begin{cases} \lambda e^{-\lambda y} & \text{if } y \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

当给定  $Y = \frac{2}{3}$  被观测到时  $\gamma$  的 MAP 估计是多少?

3. (4分)小明找到了一枚神秘的硬币, 想知道抛掷该硬币出现正面的概率。他将硬币抛掷建模为从伯努利分布 ( $\theta$ ) 中采样一个值, 其中  $\theta$  是正面出现的概率。他将硬币抛掷了三次, 结果分别是正面、反面和正面。一个预知者告诉他,  $\theta \in \{0, 0.25, 0.5, 0.75, 1\}$ , 其他  $\theta$  值不应考虑在内。

求  $\theta$  的 MLE 和 MAP 估计值。使用以下先验分布进行 MAP 估计:

$$p(\theta) = \begin{cases} 0.9 & \text{if } \theta = 0 \\ 0.04 & \text{if } \theta = 0.25 \\ 0.03 & \text{if } \theta = 0.5 \\ 0.02 & \text{if } \theta = 0.75 \\ 0.01 & \text{if } \theta = 1 \end{cases}$$

注意:  $\theta \in \{0, 0.25, 0.5, 0.75, 1\}$ , 所以 MLE 和 MAP 的值也必须是其中之一。

问:  $\theta$  的 MLE 是多少?  $\theta$  的 MAP 是多少?

4. 在之前的作业中, 你已经推导出线性回归的闭式解决方案。现在, 我们回到线性回归, 将其视为统计模型, 并在接下来的问题中推导参数的最大似然估计 (MLE)和最大后验估计(MAP)。

在 MLE 中, 我们有:

$$\hat{\theta}_{MLE} = \arg \max_{\theta} P(D | \theta)$$

在 MAP 中, 我们有:

$$\hat{\theta}_{MAP} = \arg \max_{\theta} P(\theta | D)$$

假设我们有数据  $D = \{x^{(i)}, y^{(i)}\}_{i=1}^N$ , 其中  $x^{(i)} = (x_1^{(i)}, \dots, x_M^{(i)})$ 。所以我们的数据有  $N$  个实例, 每个实例有  $M$  个特征。每个  $y^{(i)}$  是由给定的  $x^{(i)}$  和噪声  $\epsilon^{(i)} \sim N(0, \sigma^2)$  所生成的: 因此, 当  $w$  是线性回归的参数向量时  $y^{(i)} = w^T x^{(i)} + \epsilon^{(i)}$ 。

(a) (3分)单选: 给定这个假设,  $y^{(i)}$  的分布是什么?

- A.  $y^{(i)} \sim \mathcal{N}(w^T x^{(i)}, \sigma^2)$
- B.  $y^{(i)} \sim \mathcal{N}(0, \sigma^2)$
- C.  $y^{(i)} \sim \text{Uniform}(w^T x^{(i)} - \sigma, w^T x^{(i)} + \sigma)$
- D. 以上都不是

(b) (3分)单选: 下一步是学习线性回归模型参数的 MLE。下面哪个表达式是给定数据的正确条件对数似然  $\ell(w)$  ?

- A.  $\sum_{i=1}^N \left[ -\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- B.  $\sum_{i=1}^N \left[ \log(\sqrt{2\pi\sigma^2}) + \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- C.  $\sum_{i=1}^N \left[ -\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)}) \right]$
- D.  $-\log(\sqrt{2\pi\sigma^2}) + \sum_{i=1}^N \left[ -\frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$

(c) (3分)多选: MLE 的参数由  $\arg \max_w \ell(w)$  给出。在给定的表达式中, 选择所有能够得出正确参数 MLE(最大似然估计)的表达式:

- A.  $\arg \max_w \sum_{i=1}^N \left[ -\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)}) \right]$
- B.  $\arg \max_w \sum_{i=1}^N \left[ -\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- C.  $\arg \max_w \sum_{i=1}^N \left[ -\frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- D.  $\arg \max_w \sum_{i=1}^N \left[ -\frac{1}{2} (y^{(i)} - w^T x^{(i)}) \right]$
- E.  $\arg \max_w \sum_{i=1}^N \left[ -\frac{1}{2} (y^{(i)} - w^T x^{(i)})^2 \right]$

F. 以上全错

5. 现在我们继续学习线性回归模型参数的 MAP估计。考虑我们在上一个问题中使用的相同数据  $D$ 。

(a) (3分)多选：下面哪个表达式是 MAP 估计试图解决的正确优化问题? D 是数据, w 是回归参数(权重)。

- A.  $w_{\text{MAP}} = \arg \max_w P(D, w)$
- B.  $w_{\text{MAP}} = \arg \max_w \frac{P(D|w)P(w)}{P(D)}$
- C.  $w_{\text{MAP}} = \arg \max_w \frac{P(D,w)}{P(w)}$
- D.  $w_{\text{MAP}} = \arg \max_w P(D | w)P(w)$
- E.  $w_{\text{MAP}} = \arg \max_w P(w | D)$
- F. 以上都不是

(b) (3分)单选：假设我们对参数向量 w 的每个元素  $w_m$  使用均值为 0 , 方差为  $\frac{1}{\lambda}$  的高斯先验分布，即  $w_m \sim \mathcal{N}(0, \frac{1}{\lambda}) (1 \leq m \leq M)$  。假设每个参数  $w_1, \dots, w_m$  都是独立的。以下哪个表达式是正确的数据和参数的对数联合概率  $\log P(D, w)$  ?

- A.  $\sum_{i=1}^N \left( -\log \left( \sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 \right) - \sum_{m=1}^M \log(\sqrt{2\pi\lambda}) - \lambda(w_m)^2$
- B.  $\sum_{i=1}^N \left( -\log \left( \sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)}) \right) + \sum_{m=1}^M -\log(\sqrt{2\pi\lambda}) - \lambda(w_m)^2$
- C.  $\sum_{i=1}^N \left( -\log \left( \sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)}) \right) - \sum_{m=1}^M \log \left( \sqrt{\frac{2\pi}{\lambda}} \right) - \frac{\lambda}{2} (w_m)^2$
- D.  $\sum_{i=1}^N \left( -\log \left( \sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 \right) + \sum_{m=1}^M -\log \left( \sqrt{\frac{2\pi}{\lambda}} \right) - \frac{\lambda}{2} (w_m)^2$

(c) (3分)单选：对于具有高斯先验的相同线性回归模型(如前一个问题中所述), 最大化对数后验概率  $\ell_{MAP}(w)$  给出了参数的最大后验估计。以下哪个是  $\max_w \ell_{MAP}(w)$  的等价定义?

- A.  $\max_w \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 + \frac{\lambda}{2} \|w\|_2^2$
- B.  $\min_w \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 + \frac{\lambda}{2} \|w\|_2^2$
- C.  $\max_w \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 + \lambda \|w\|_2^2$
- D.  $\min_w - \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 - \frac{\lambda}{2} \|w\|_2^2$

(d) (3 分)单选：你发现一个 MAP 估计器的测试误差比训练误差高得多。以下哪一项可能是解决此问题的可能方法?

- A. 增加高斯先验中使用的方差
- B. 减少高斯先验中使用的方差

6. (4分) 单选：现在假设每个数据点的加性噪声  $\epsilon$  是不同的。也就是说，每个  $y^{(i)}$  在给定  $\mathbf{x}^{(i)}$  的情况下都有加性噪声  $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma_i^2)$ ，即  $y^{(i)} = \mathbf{w}^T \mathbf{x}^{(i)} + \epsilon^{(i)}$ 。与我们到目前为止使用的标准回归模型不同，现在有一个特定于示例的方差  $\sigma_i^2$ 。最大化这个新模型的对数似然性等同于最小化加权均方误差，以下哪个是被加的权重?

- A.  $1/y^{(i)}$
- B.  $1/\sigma_i^2$
- C.  $1/\|\mathbf{x}^{(i)}\|_2^2$

7. (4分) 单选：与哪种先验的MAP估计相当于  $\ell_1$  正则化? 请在下面展示你的解答过程。

注意：

- 在  $[a, b]$  上的均匀分布的概率密度函数为  $f(x) = \frac{1}{b-a}$ ，如果  $x \in [a, b]$ ，否则为0。
- 具有比率参数  $a$  的指数分布的概率密度函数为  $f(x) = a \exp(-ax)$ ，对于  $x > 0$ 。
- 具有位置参数  $a$  和尺度参数  $b$  的拉普拉斯分布的概率密度函数为  $f(x) = \frac{1}{2b} \exp\left(\frac{-|x-a|}{b}\right)$ ，对于所有  $x \in \mathbb{R}$ 。

待选项如下：

- A.  $[-1, 1]$  上的均匀分布
- B.  $[-\mathbf{w}^T \mathbf{x}^{(i)}, \mathbf{w}^T \mathbf{x}^{(i)}]$  上的均匀分布
- C. 具有比率参数  $a = \frac{1}{2}$  的指数分布
- D. 具有比率参数  $a = \mathbf{w}^T \mathbf{x}^{(i)}$  的指数分布
- E. 具有位置参数  $a = 0$  的拉普拉斯分布
- F. 具有位置参数  $a = \mathbf{w}^T \mathbf{x}^{(i)}$  的拉普拉斯分布

## 4. 朴素贝叶斯(24分)

- (4分) 假设所有人中有 0.3%的人患有癌症。如果某人接受癌症检测，检测结果可以是阳性（癌症）或阴性（无癌症）。这项测试并不完美——在患有癌症的人中，测试结果为阳性的概率为 97%。在没有癌症的人中，测试结果为阳性的概率为 4%。对于这个问题，您应该假设测试结果彼此独立，给定真实状态（有或无癌症）。如果受试者的测试结果是阳性，那么受试者患有癌症的概率是多少？答案请保留四位小数，例如0.1234。
- 下面的数据集描述了一只独角兽的几个特征，用于说明它是否成年。

| 颜色  | 体型 | 是否成年 |
|-----|----|------|
| 彩虹色 | 小  | 否    |
| 青色  | 小  | 否    |
| 青色  | 小  | 是    |

| 颜色  | 体型 | 是否成年 |
|-----|----|------|
| 青色  | 中  | 是    |
| 彩虹色 | 中  | 否    |
| 紫红色 | 中  | 是    |
| 紫红色 | 大  | 是    |
| 青色  | 大  | 是    |

有一只独角兽叫做小壮，它是青色的，体型中等。我们想要确定它是否成年，使用朴素贝叶斯假设来估算以下概率。

- (a) (2分) 一个青色、中等大小的独角鲸已经成年了的概率是多少？答案请保留四位小数，例如0.1234。  
(b) (2分) 一个青色、中等大小的独角鲸没有成年概率是多少？答案请保留四位小数，例如0.1234。  
(c) (2分) 判断：小壮这只独角兽成年了吗？

- True
- False

3. (4分) 多选：高斯朴素贝叶斯通常可以学习非线性决策边界。考虑一个简单情况，我们只有一个实值特征  $X_1 \in \mathbb{R}$ ，我们希望从中推断标签  $Y \in \{0, 1\}$  的值。相应的生成概率是：

$$Y \sim \text{Bernoulli}(\phi)$$
$$X_1 \sim \text{Gaussian}(\mu_y, \sigma_y^2)$$

其中参数是Bernoulli参数  $\phi$  和与  $Y = 0$  和  $Y = 1$  分别对应的类条件高斯参数  $\mu_0, \sigma_0^2$  和  $\mu_1, \sigma_1^2$ 。  
在一维中，线性决策边界可以由以下形式的规则描述：

$$\text{if } X_1 > c \text{ then } Y = k, \text{ else } Y = 1 - k$$

其中  $c$  是实值阈值， $k \in \{0, 1\}$ 。注意，这里的  $X_1 > c$  表示一个通用的线性不等式。也就是说，我们可以使用  $X_1 > c$  来代替  $X_1 > c, X_1 \geq c, X_1 < c$  和  $X_1 \leq c$  中的任何一个。

在这个简单的一维情况下，是否可能构建一个高斯朴素贝叶斯分类器，其决策边界不能用上述形式的规则表示？

- A. 如果高斯分布的均值相等且方差不等，那么可以发生这种情况。  
B. 如果高斯分布的均值不等且方差相等，那么可以发生这种情况。  
C. 如果高斯分布的均值和方差都不相等，那么可以发生这种情况。  
D. 上述都不是。
4. 现在我们将扩展至2D，并推导2D高斯朴素贝叶斯的决策边界。  
(a) (4分) 显示2D高斯朴素贝叶斯分类器的决策边界是二次的。也就是说，显示  $P(Y = 1|X_1, X_2) = P(Y = 0|X_1, X_2)$  可以写成  $X_1$  和  $X_2$  的多项式函数，其中每个变量的度数最多为2。你可以将不重要的常数折叠成诸如  $C, C', C'', C'''$  的项，只要你清楚地显示每一步。  
(b) (3分) 多选：选择由高斯朴素贝叶斯分类器产生的所有可能的决策边界。阴影区域被指定为类1，未阴影区域被指定为类0。





Figure 1: Decision Boundaries

- A. (a)  
B. (b)  
C. (c)  
D. (d)  
E. 以上都不是
5. (3分) 单选：小明使用2D高斯朴素贝叶斯模型进行了二分类任务，并得到了给定的条件下的密度  $f(x_1, x_2|y = +)$  的轮廓图。你立刻注意到他犯了一个错误。为什么他的结果从理论上是不可能从高斯朴素贝叶斯模型获得的？



- A. 分布的均值应该是所有点的均值，而不仅仅是正点（+）的均值
- B. 对于离散标签（+和-）应该使用伯努利朴素贝叶斯模型
- C. 分布的协方差矩阵不是对角矩阵
- D. 以上都不是

## 5. 提交格式

将答案，整理成PDF格式，命名为 学号\_姓名\_HW6\_Answer.pdf，直接提交即可。