

Homework 6 Solutions

- 1. 卷积神经网络 (19 分)
- 2. 学习理论(20分)
 - 基础概念
 - 题目
- 3. MLE/MAP(37 分)
- 4. 朴素贝叶斯(24分)
- 5. 提交格式

1. 卷积神经网络 (19 分)

1. 在这个问题中, 仅考虑 CNN 标准的卷积层。下面是我们给出的一个图像 X 和滤波器 F 。

$$X = \begin{bmatrix} 1 & 0 & -2 & 3 & 4 & 1 \\ 2 & 9 & 5 & 6 & 0 & -1 \\ 0 & -3 & 1 & 3 & 4 & 4 \\ 6 & 5 & 2 & 0 & 6 & 8 \\ -5 & 4 & -3 & 1 & 3 & -2 \\ 4 & 1 & 2 & 8 & 9 & 7 \end{bmatrix} \quad F = \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix} \quad Y = \begin{bmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \\ m & n & o & p \end{bmatrix}$$

(a) (1分)让 X 与 F 进行卷积以输出 Y , 卷积无填充且步长为 1, Y 的 j 值为多少?

答:

故为**8**。

(b) (2分)假设你有一个大小 (高 $\times$ 宽) 为 6×4 的输入特征图和大小为 2×2 的滤波器, 不使用填充且步幅为 2 的卷积, 那么最终的输出大小是多少? 以 "高 $\times$ 宽" 的格式写下你的答案。

答:

卷积公式:

$$H_{\text{out}} = \left\lfloor \frac{H_{\text{in}} + 2 \times P_{\text{H}} - F_{\text{H}}}{S} \right\rfloor + 1$$

$$W_{\text{out}} = \left\lfloor \frac{W_{\text{in}} + 2 \times P_{\text{W}} - F_{\text{W}}}{S} \right\rfloor + 1$$

其中,

H_{in} 和 W_{in} 分别是输入特征图的高度和宽度。

F_{H} 和 F_{W} 分别是滤波器的高度和宽度。

S 是步幅。

P_{H} 和 P_{W} 分别是沿高度和宽度方向的填充。

$\lfloor \cdot \rfloor$ 表示向下取整。

现在来回答本题:

$$\text{输出高度} = \frac{6 - 2}{2} + 1 = 3$$

$$\text{输出宽度} = \frac{4 - 2}{2} + 1 = 2$$

故为 **3×2** 。

2. 参数共享对于 CNN 来说是一个非常重要的概念, 因为它大大降低了学习问题的复杂性。对于以下问题, 假设我们的卷积层中没有偏差项。

(a) (2分)单选: 以下哪些是卷积层的参数?

- A. stride 大小
- B. padding 尺寸
- C. image 大小
- D. filter 尺寸
- E. filter 的权重
- F. 以上都不是

答：

在卷积层中，学习的参数主要是滤波器的权重。步幅（stride）、填充（padding）和图像大小等不是需要学习的参数。

故为**E**。

(b) (2分)多选: 以下哪些是卷积的超参数?

- A. stride 大小
- B. padding 尺寸
- C. image 大小
- D. filter 尺寸
- E. filter 的权重
- F. 以上都不是

答：

超参数是不通过训练过程学习的，但会影响学习过程的参数。步长（stride）、填充（padding）、和滤波器尺寸（filter size）都是超参数。

故为**A, B和D**。

(c) (2分)假设对于卷积层, 我们给出尺寸为 22×22 的灰度图像。使用一个步长为 2 且无填充的 4×4 滤波器, 你在这一层中学习的参数数量是多少?

答：

因为是 4×4 的滤波器，所以一共有 $4 \times 4 = 16$ 个参数

故为**16**。

如果考虑是偏置项，结果为**17**也没算错。

(d) (2分)在(c)的基础上，现在假设我们不进行参数共享。也就是说，该层的每个输出均由单独的 4×4 滤波器计算。我们再次使用步长 2 并且没有填充的滤波器。你在这一层中学习的参数数量是多少?

答：

如果每个输出像素都由一个独立的 4×4 滤波器计算，那么对于一个 22×22 的图像和步幅为2，输出的尺寸是 $\lfloor \frac{22-4}{2} \rfloor + 1 = 10$ 。

又由于每个输出像素都需要一个独立的 4×4 滤波器，即总共 $100 \times 16 = 1600$ 个参数。

故为**1600**。

如果考虑是偏置项，结果为**1700**也没算错。

(e) (2分)现在假设给你一个 40×40 的彩色图像, 它由 3 个通道组成(因此你的输入是一个 $40 \times 40 \times 3$ 张量), 每个通道代表一种原色的强度。假设你再次不进行参数共享, 对每个输出像素使用唯一的 4×4 滤波器, 步幅为 2 并且没有填充。你在这一层中学习的参数数量是多少?

答：

对于每个像素的每个通道，都需要一个 4×4 滤波器，所以每个独立的输出像素需要 $4 \times 4 \times 3 = 48$ 个参数。

输出的尺寸为 $\lfloor \frac{40-4}{2} \rfloor + 1 = 19$ ，即 $19 \times 19 = 361$ 个输出像素。

总共需要 $361 \times 48 = 17328$ 个参数

故为 **17328**。

如果考虑是偏置项，结果为**18411**也没算错。

(f) (1分)用一个简洁的句子，描述除了减少学习参数数量之外，参数共享对于应用于图像 数据的卷积层来说是一个好主意的原因。

答：

参数共享能够增强网络的特征检测能力，减少过拟合，使权重更加稀疏，并增加平移不变性，这意味着网络能够在图像的不同位置识别相同的特征。

言之有理即可。

3. 小明想要自己实现 CNN 网络。

(a) (2分)于是他提出以下简单的想法执行：

```
# image X has shape (H_in, W_in), and filter F has shape (K, K)
# the output Y has shape (H_out, W_out)
Y = np.zeros((H_out, W_out))
for r in range(0, H_out):
    for c in range(0, W_out):
        for i in range(0, K):
            for j in range(0, K):
                Y[r, c] += X[___blank___] * F[i, j]
```

上面的空白(blank)中应该填什么才能使输出 Y 正确? 假设 H_{out} 和 W_{out} 是预先正确计算的。

答:

其计算公式为:

$$Y[r, c] = \sum_{i=0}^{K-1} \sum_{j=0}^{K-1} X[r+i, c+j] \times F[i, j]$$

故填入 $r+i, c+j$ 。

上述的答案是考虑步长为1的情况的。当然步长也可能不为1, 这时我们计算可得:

$$S_H = \left\lfloor \frac{H_{in} - K}{H_{out} - 1} \right\rfloor$$

$$S_W = \left\lfloor \frac{W_{in} - K}{W_{out} - 1} \right\rfloor$$

故填入 $r*S_H + i, c*S_W + j$ 。

两种答案均给满分。

(b) (2分)他现在想要实现网络的反向传播部分, 但被卡住了。他决定去寻求帮助。一位助教告诉他, CNN 实际上可以使用矩阵乘法来实现。他收到以下一维卷积示例:

假设你有一个输入向量 $\mathbf{x} = [x_1, x_2, x_3, x_4, x_5]^T$ 和一个1D卷积滤波器 $\mathbf{w} = [w_1, w_2, w_3]^T$ 。然后, 如果输出是 $\mathbf{y} = [y_1, y_2, y_3]^T$, 其中 $y_1 = w_1x_1 + w_2x_2 + w_3x_3$, $y_2 = \dots$, $y_3 = \dots$ 。如果你仔细观察, 会发现这等同于:

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \mathbf{A} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix}$$

适用于上面例子的矩阵 A 是什么?

答:

$$\begin{bmatrix} w_1 & w_2 & w_3 & 0 & 0 \\ 0 & w_1 & w_2 & w_3 & 0 \\ 0 & 0 & w_1 & w_2 & w_3 \end{bmatrix}$$

(c) (1分)用一个简洁的句子(或一个简短的数学表达式)解释当你知道某个任意输入 $\mathbf{x}$ 、滤波器 $\mathbf{w}$, 以及相应的 1D 卷积输出 $\mathbf{y}$ 中得出的 A 如何计算 $\frac{\partial y}{\partial x}$ (A 是按照与 (b) 中相同的过程获得的), 但 $\mathbf{x}$ 、 $\mathbf{y}$ 和 $\mathbf{w}$ 可能与示例不同)。

答:

$\mathbf{y} = \mathbf{Ax}$ 是一个线性变换, 其梯度就是 $\mathbf{A}$ 本身。

即, $\frac{\partial y}{\partial x} = \mathbf{A}$

除了 $\mathbf{A}$ 以外, 另一种答案即 $\mathbf{A}^T$ 也给满分, 因为只是分子分母布局的不同。

2. 学习理论(20分)

基础概念

1. 基础符号:

- 概率分布 (未知): $X \sim p^*$

- 真实函数（未知）： $c^* : X \rightarrow Y$
- 假设空间 $\mathcal{H}$ ，以及假设 $h \in \mathcal{H} : X \rightarrow Y$
- 训练数据集 $\mathcal{D} = \{x^{(1)}, \dots, x^{(N)}\}$

2. 真实误差（期望风险）

$$R(h) = P_{x \sim p^*(x)}(c^*(x) \neq h(x))$$

3. 训练误差（经验风险）

$$\begin{aligned}\hat{R}(h) &= P_{x \sim \mathcal{D}}(c^*(x) \neq h(x)) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{1}(c^*(x^{(i)}) \neq h(x^{(i)})) \\ &= \frac{1}{N} \sum_{i=1}^N \mathbb{1}(y^{(i)} \neq h(x^{(i)}))\end{aligned}$$

- PAC标准

PAC标准是指我们以高概率产生一个高精度的假设。更正式地表达，该标准可以表示为：

$$P\left(\forall h \in \mathcal{H}, |R(h) - \hat{R}(h)| \leq \epsilon\right) \geq 1 - \delta$$

- 样本复杂度

样本复杂度是指为了满足给定的 ϵ 和 δ 下的PAC标准，所需要的最少训练样本数 N 。

注意：

- 可实现（Realizable）：意味着 c^* 属于假设空间 $\mathcal{H}$ 。
- 不可知（Agnostic）：意味着 c^* 可能属于或可能不属于假设空间 $\mathcal{H}$ 。

以下是4种情况下的样本复杂度：

- 可实现（Realizable）且有限 $|\mathcal{H}|$
定理 1: $N \geq \frac{1}{\epsilon} \left[\log(|\mathcal{H}|) + \log\left(\frac{1}{\delta}\right) \right]$
当概率为 $(1 - \delta)$ ，所有在 $\mathcal{H}$ 中且 $\hat{R}(h) = 0$ 的 h ，其 $R(h) \leq \epsilon$ 的标签样本数量是足够的。
- 不可知（Agnostic）且有限 $|\mathcal{H}|$
定理 2: $N \geq \frac{1}{2\epsilon^2} \left[\log(|\mathcal{H}|) + \log\left(\frac{2}{\delta}\right) \right]$
当概率为 $(1 - \delta)$ ，所有 $h \in \mathcal{H}$ 都有 $|R(h) - \hat{R}(h)| \leq \epsilon$ 的标签样本数量是足够的。
- 可实现（Realizable）且无限 $|\mathcal{H}|$
定理 3: $N = O\left(\frac{1}{\epsilon} \left[\text{VC}(\mathcal{H}) \log\left(\frac{1}{\epsilon}\right) + \log\left(\frac{1}{\delta}\right) \right]\right)$
当概率为 $(1 - \delta)$ ，所有在 $\mathcal{H}$ 中且 $\hat{R}(h) = 0$ 的 h ，其 $R(h) \leq \epsilon$ 的标签样本数量是足够的。
- 不可知（Agnostic）且无限 $|\mathcal{H}|$
定理 4: $N = O\left(\frac{1}{\epsilon^2} \left[\text{VC}(\mathcal{H}) + \log\left(\frac{1}{\delta}\right) \right]\right)$
当概率为 $(1 - \delta)$ ，所有 $h \in \mathcal{H}$ 都有 $|R(h) - \hat{R}(h)| \leq \epsilon$ 的标签样本数量是足够的。
- VC维数
假设空间 $\mathcal{H}$ 的VC维数，记作 $\text{VC}(\mathcal{H})$ 或 $d_{\text{VC}}(\mathcal{H})$ ，是指存在至少一个样本点排列和一个假设 $h \in \mathcal{H}$ ，该假设能与这些点的任何标记一致的点的最大数量。
- 如何证明 $\text{VC}(\mathcal{H}) = n$:
1. 证明存在一个大小为 n 的点集，该点集可以被 $\mathcal{H}$ 粉碎（shatter）（即完美分类）。
2. 证明 $\mathcal{H}$ 不能粉碎任何大小为 $n + 1$ 的点集。

题目

- 小明需要解决一个分类任务，他决定使用具有 2 个二进制特征 X_1 和 X_2 的决策树学习器。但你认为神经网络不应该使用决策树。相反，你认为最好使用具有 16 个实值特征以及偏差项的逻辑回归。你想用 PAC 学习来检验你是否正确。你首先在 N 个示例上训练逻辑回归模型以获得训练误差 $\hat{R}$ 。
(a) (2分)你应该将以下哪种 PAC 学习法用于逻辑回归模型？
A. 有限且可知
B. 有限不可知
C. 无限且可知
D. 无限不可知

答：

1.有限或无限：

即假设空间 $\mathcal{H}$ 的大小。由于逻辑回归模型具有连续的参数空间，即其权重可以是任何实数。因此，其假设空间实际上是无限的。

2. 可知 (Realizable) 或不可知 (Agnostic) :

在实际应用中, 很少有情况下真实的分类函数 c^* 会完全在给定的假设空间 $\mathcal{H}$ 中。即使在假设空间很大或者很复杂的情况下, 由于噪声、特征选择不完全等因素, c^* 往往不属于 $\mathcal{H}$ 。因此, 在大多数情况下, 我们认为是 "不可知 (Agnostic)"。

故选 **D**。

(b) (2分) 用 $\hat{R}, \delta$ 和 N 表示的真实误差 R 的上限是多少? 如有必要, 你可以使用大 O 表示法。只写最后的答案。

答:

对于无限且不可知 (Infinite and Agnostic) 的情况, 要参考复杂度定理 (定理 4) :

$$N = O\left(\frac{1}{\epsilon^2} \left[VC(\mathcal{H}) + \log\left(\frac{1}{\delta}\right) \right]\right)$$

首先消除 O 符号:

$$N \leq \frac{c}{\epsilon^2} \left[VC(\mathcal{H}) + \log\left(\frac{1}{\delta}\right) \right]$$

然后将 $|R(h) - \hat{R}(h)| \leq \epsilon$ 代入上式。化简后可得:

$$R \leq \hat{R} + O\left(\sqrt{\frac{VC(\mathcal{H}) + \log(1/\delta)}{N}}\right)$$

(c) (3分) 单选: 你想论证你的模型, 相对于小明的模型具有更低的真实误差的下界。假设你已获得足够的数据点来满足 PAC 标准, 且 ϵ 和 δ 与神经网络相同。以下内容哪些是对的?

- A. 小明的模型总是会准确地对看不见的数据进行分类, 因为它只需要 2 个二进制特征, 因此更简单。
- B. 你必须首先通过删除 14 个特征来规范你的模型才能进行比较。
- C. 这足以表明分类器的 VC 维度高于小明的 VC 维度, 因此真实误差具有下限。
- D. 有必要证明你实现的训练误差低于小明实现的训练误差。

答:

A 错。简单性不一定意味着更高的准确性。一个模型可能过于简单而无法捕捉数据的复杂性, 导致更高的偏差。

B 对。必须要保证两个模型输入同样多的信息, 才能够进行比较。

C 错。较高的 VC 维数通常意味着模型更复杂, 有更高的方差和更低的偏差。然而, 高 VC 维数并不一定意味着模型有更低的真实误差下界。实际上, 复杂的模型可能更容易过拟合。

D 错。训练误差较低并不一定意味着真实误差也会低。一个模型可能在训练集上表现得非常好, 但在未见过的数据上表现得很差。

故选 **B**。

2. 我们可以使用样本复杂度上界来推导出特定算法的真实误差上界。考虑无限、不可知情况下的样本复杂度上界:

$$N = O\left(\frac{1}{\epsilon^2} \left[VC(\mathcal{H}) + \log\left(\frac{1}{\delta}\right) \right]\right)$$

(a) (2分) 使用大 O 符号的定义 (即, 如果 $N = O(M)$ (对于某个值 M), 则存在一个常数 $c \in \mathbb{R}$, 使得 $N \leq cM$) 来重写关于 N 和 δ 的大 O 上界。

答:

在大 O 符号的定义中, 如果 $N = O(M)$, 则存在一个常数 $c \in \mathbb{R}$ 使得 $N \leq c \cdot M$ 。

对于给出的样本复杂度上界:

$$N = O\left(\frac{1}{\epsilon^2} \left[VC(\mathcal{H}) + \log\left(\frac{1}{\delta}\right) \right]\right)$$

我们可以找到一个常数 c 使得:

$$N \leq c \left(\frac{1}{\epsilon^2} \left[VC(\mathcal{H}) + \log\left(\frac{1}{\delta}\right) \right] \right)$$

这就是使用大 O 符号定义重写的 N 和 δ 的上界。

(b) (2分) 现在, 使用 ϵ 的定义 (即 $|R(h) - \hat{R}(h)| \leq \epsilon$), 证明概率至少为 $(1 - \delta)$ 时:

$$R(h) \leq \hat{R}(h) + O\left(\sqrt{\frac{1}{N} \left[VC(\mathcal{H}) + \log\left(\frac{1}{\delta}\right) \right]}\right)$$

答：

我们知道 ϵ 是真实误差 $R(h)$ 和训练误差 $\hat{R}(h)$ 之间的差距，即 $|R(h) - \hat{R}(h)| \leq \epsilon$ 。

从 (a) 部分中的不等式，我们可以解出 ϵ 的上界：

$$\epsilon^2 \leq \frac{c}{N} \left[\text{VC}(\mathcal{H}) + \log \frac{1}{\delta} \right]$$

取平方根得到：

$$\epsilon \leq \sqrt{\frac{c}{N} \left[\text{VC}(\mathcal{H}) + \log \frac{1}{\delta} \right]}$$

由于 $\epsilon \geq |R(h) - \hat{R}(h)|$ ，我们可以得到 $R(h)$ 的上界：

$$R(h) \leq \hat{R}(h) + \sqrt{\frac{c}{N} \left[\text{VC}(\mathcal{H}) + \log \frac{1}{\delta} \right]}$$

最终，为了简化表达式，我们使用大 $\mathcal{O}$ 符号：

$$R(h) \leq \hat{R}(h) + O \left(\sqrt{\frac{1}{N} \left[\text{VC}(\mathcal{H}) + \log \frac{1}{\delta} \right]} \right)$$

3. (3分) 考虑一个假设空间 $\mathcal{H}$ ，其中的函数将 M 个二元属性映射到二元标签。该空间中的一个函数 f 可以表示为 $f: \{0, 1\}^M \rightarrow \{0, 1\}$ 。小明说无论 M 的值如何，这个空间中的函数总是可以分割 2^M 个点。小明说错了吗？如果是，请提供反例。如果小明对了，请简要说明原因。

答：

小明说错了。

此假设空间中的函数并不一定总能粉碎 2^M 个点。

粉碎 2^M 个点意味着该假设空间必须能够为这 2^M 个点的每一个可能的标签组合生成一个完美分类的函数。换言之，这就需要假设空间包含足够多的不同函数来覆盖 2^M 个点所有可能的标签组合。

以 $M = 3$ 为例，有 $2^3 = 8$ 个不同的输入点组合。为了能够粉碎这 8 个点，我们实际上需要 $2^{(2^3)} = 2^8 = 256$ 个不同的函数，来拟合这么多种不同的结果。如果假设空间中只有少于 256 个不同的函数，例如只有 100 个，那么它就不能粉碎所有 8 个点。

故只有当假设空间足够大，至少包含 $2^{(2^M)}$ 个不同的这一类函数时，才能确保能粉碎 2^M 个点。如果假设空间的大小受到限制，那么这一目标则无法实现。

包含假设空间足够大以及类似表述均可给分。

4. 考虑一个实例空间 $\mathcal{X}$ ，它是实数集合。

(a) (3分) 单选：在假设类 H 中，每个假设 h 的形式是 "如果 $a < x < b$ 或 $c < x < d$ 则 $y = 1$ ；否则 $y = 0$ "（即， H 是一个无限假设类，其中 a, b, c , 和 d 是任意实数）。 H 的 VC 维数是多少？

- A. 2
- B. 3
- C. 4
- D. 5
- E. 6

答：

我们首先要知道如何证明 $\text{VC}(\mathcal{H}) = n$ 的一般步骤：

1. 证明存在一个大小为 n 的点集，该点集可以被 $\mathcal{H}$ 粉碎 (shatter)（即完美分类）。
2. 证明 $\mathcal{H}$ 不能粉碎任何大小为 $n + 1$ 的点集。

对于本题，我们要证明两点：

1. 证明 H 能粉碎一个大小为 4 的点集：

在这个假设类 H 中，每个假设 h 可以在两个不同的区间 (a, b) 和 (c, d) 内输出 1，其他情况下输出 0。

假设我们有 4 个点 $x_1 < x_2 < x_3 < x_4$ ，比如我们可以选择 a, b, c, d 使得 $a < x_1 < b$ 和 $c < x_3 < d$ 。


这 4 个点的任何标签组合: $(1, 1, 1, 1)$, $(1, 1, 1, 0)$, $(1, 1, 0, 1)$, $(1, 1, 0, 0)$, $(1, 0, 1, 1)$, $(1, 0, 1, 0)$, $(1, 0, 0, 1)$, $(1, 0, 0, 0)$, $(0, 1, 1, 1)$, $(0, 1, 1, 0)$, $(0, 1, 0, 1)$, $(0, 1, 0, 0)$, $(0, 0, 1, 1)$, $(0, 0, 1, 0)$, $(0, 0, 0, 1)$, $(0, 0, 0, 0)$, 都可以使用该假设空间中的一些函数完美分类开来。

2.证明 H 不能粉碎大小为 5 的点集:

已知 H 最多只能在两个区间内输出 1。但假设五个点的话, 就可能会有标签为 $(1, 0, 1, 0, 1)$ 的情况。因此无法生成这样的标签组合, 也就无法完美分割大小为 5 的点集。

故选C。

(b) (3分)给定下面 $\mathcal{X}$ 中的点集, 构造某个点子集的标签, 以显示任何比 H 的 VC 维数大出正好 1 的维数都是不正确的 (例如, 如果 H 的 VC 维数是 3, 则只需填写 4 个点的答案)。在表格中每个点的对应标签中填入 0 或 1。对于您在示例中没有使用的点, 请写 N/A (不要留空答案框)。



点	-3	-2	-1	0	1	2	3
标签							

答:

从(a)中已知 VC 维数都是不正确的, 我们可以考虑下面的 5 个点, 并尝试为它们分配标签。

点	-3	-2	-1	0	1	2	3
标签	N/A	1	0	1	0	1	N/A

在这个例子中, 我们选用了中间的 5 个点, 并为它们分配了标签。由于假设空间 H 只能在两个区间内输出 1, 因此无法找到一个假设 h 来完美地分类这 5 个点。

这个例子证明了 VC 维数不能大于 4, 与我们在 (a) 部分得出的结论一致。

只要有5个点, 而且前中后有三个分类为1, 就给分。

3. MLE/MAP(37 分)

1. (2分)判断: 假设你对伯努利分布放置一个 Beta 先验, 并尝试从数据中学习伯努利分布的参数 θ 。还假设一个对手为了混淆你的算法, 偷偷为你选择了不好的但数量有限的 Beta 先验超参数。随着训练样本数量趋近无穷大, θ 的最大后验(MAP)估计仍然可以收敛到 θ 的最大似然估计(MLE)。

- True
- False

答:

当训练样本数量趋近于无穷大时, 先验的影响会减小, MAP估计会趋近于MLE估计。

故选True。

2. (2分)设 Γ 为随机变量, 具有以下概率密度函数:

$$f(\gamma) = \begin{cases} 2\gamma & \text{if } 0 \leq \gamma \leq 1 \\ 0 & \text{otherwise} \end{cases}$$

假设另一个随机变量 Y , 在给定 Γ 的条件下, 遵循参数为 $\lambda = 3\gamma$ 的指数分布。回顾一下参数为 λ 的指数分布具有以下概率密度函数:

$$f_{\text{exp}}(y) = \begin{cases} \lambda e^{-\lambda y} & \text{if } y \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

当给定 $Y = \frac{2}{3}$ 被观测到时 γ 的 MAP 估计是多少?

答:

我们要求的结果, 用贝叶斯定理在连续随机变量的情况下可以表示为:

$$P(\gamma|Y = \frac{2}{3}) = \frac{P(Y = \frac{2}{3}|\gamma) \cdot P(\gamma)}{P(Y = \frac{2}{3})}$$

首先计算似然函数 $P(Y|\gamma)$ 如下:

$$P(Y|\gamma) = 3\gamma e^{-3\gamma Y}$$

后验概率 $P(\gamma|Y = \frac{2}{3})$ 可以通过贝叶斯定理计算:

$$P(\gamma|Y = \frac{2}{3}) \begin{cases} \propto P(Y = \frac{2}{3}|\gamma) \cdot P(\gamma) = 6\gamma^2 e^{-2\gamma} \\ = 0 \end{cases}$$

现在想要找到 γ 的 MAP 估计, 我们需要找到使 $P(\gamma|Y = \frac{2}{3})$ 最大的 γ 值。这等价于找到 $6\gamma^2 e^{-2\gamma}$ 的最大值, 对其求导并置0:

$$\frac{d}{d\gamma}(6\gamma^2 e^{-2\gamma}) = 0$$

解得:

$\gamma = 0$ 或 $\gamma = 1$ 。

而最大值在 $\gamma = 1$ 时取得。

故为 **1**。

3. (4分)小明找到了一枚神秘的硬币, 想知道抛掷该硬币出现正面的概率。他将硬币抛掷建模为从伯努利分布 (θ) 中采样一个值, 其中 θ 是正面出现的概率。他将硬币抛掷了三次, 结果分别是正面、反面和正面。一个预知者告诉他, $\theta \in \{0, 0.25, 0.5, 0.75, 1\}$, 其他 θ 值不应考虑在内。

求 θ 的 MLE 和 MAP 估计值。使用以下先验分布进行 MAP 估计:

$$p(\theta) = \begin{cases} 0.9 & \text{if } \theta = 0 \\ 0.04 & \text{if } \theta = 0.25 \\ 0.03 & \text{if } \theta = 0.5 \\ 0.02 & \text{if } \theta = 0.75 \\ 0.01 & \text{if } \theta = 1 \end{cases}$$

注意: $\theta \in \{0, 0.25, 0.5, 0.75, 1\}$, 所以 MLE 和 MAP 的值也必须是其中之一。

问: θ 的 MLE 是多少? θ 的 MAP 是多少?

答:

1. θ 的 MLE: 0.75

似然函数为:

$$L(\theta) = \theta^2(1-\theta)^1 = \theta^2(1-\theta)$$

我们可以直接计算这些 θ 值对应的似然函数值:

$$L(0) = 0^2 \times (1-0) = 0$$

$$L(0.25) = 0.25^2 \times (1-0.25) = 0.25^2 \times 0.75 = 0.046875$$

$$L(0.5) = 0.5^2 \times (1-0.5) = 0.5^2 \times 0.5 = 0.125$$

$$L(0.75) = 0.75^2 \times (1-0.75) = 0.75^2 \times 0.25 = 0.140625$$

$$L(1) = 1^2 \times (1-1) = 0$$

最大值对应 **0.75**。

2. θ 的 MAP: 0.5

后验概率为:

$$P(\theta|\text{data}) \propto L(\theta) \times P(\theta)$$

于是可得:

$$L(0) \times P(0) = 0 \times 0.9 = 0$$

$$L(0.25) \times P(0.25) = 0.046875 \times 0.04 = 0.001875$$

$$L(0.5) \times P(0.5) = 0.125 \times 0.03 = 0.00375$$

$$L(0.75) \times P(0.75) = 0.140625 \times 0.02 = 0.0028125$$

$$L(1) \times P(1) = 0 \times 0.01 = 0$$

最大值对应 **0.5**。

4. 在之前的作业中, 你已经推导出线性回归的闭式解决方案。现在, 我们回到线性回归, 将其视为统计模型, 并在接下来的问题中推导参数的最大似然估计 (MLE) 和最大后验估计 (MAP)。

在 MLE 中, 我们有:

$$\hat{\theta}_{MLE} = \arg \max_{\theta} P(D | \theta)$$

在 MAP 中, 我们有:

$$\hat{\theta}_{MAP} = \arg \max_{\theta} P(\theta | D)$$

假设我们有数据 $D = \{x^{(i)}, y^{(i)}\}_{i=1}^N$ ，其中 $x^{(i)} = (x_1^{(i)}, \dots, x_M^{(i)})$ 。所以我们的数据有 N 个实例，每个实例有 M 个特征。每个 $y^{(i)}$ 是由给定的 $x^{(i)}$ 和噪声 $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$ 所生成的：因此，当 w 是线性回归的参数向量时 $y^{(i)} = w^T x^{(i)} + \epsilon^{(i)}$ 。

(a) (3分)单选：给定这个假设， $y^{(i)}$ 的分布是什么？

- A. $y^{(i)} \sim \mathcal{N}(w^T x^{(i)}, \sigma^2)$
- B. $y^{(i)} \sim \mathcal{N}(0, \sigma^2)$
- C. $y^{(i)} \sim \text{Uniform}(w^T x^{(i)} - \sigma, w^T x^{(i)} + \sigma)$
- D. 以上都不是

答：

给定 $y^{(i)} = w^T x^{(i)} + \epsilon^{(i)}$ ，其中 $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$ ，我们可以得出 $y^{(i)}$ 的分布是 $\mathcal{N}(w^T x^{(i)}, \sigma^2)$ 。

故选A。

(b) (3分)单选：下一步是学习线性回归模型参数的 MLE。下面哪个表达式是给定数据的正确条件对数似然 $\ell(w)$ ？

- A. $\sum_{i=1}^N \left[-\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- B. $\sum_{i=1}^N \left[\log(\sqrt{2\pi\sigma^2}) + \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- C. $\sum_{i=1}^N \left[-\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)}) \right]$
- D. $-\log(\sqrt{2\pi\sigma^2}) + \sum_{i=1}^N \left[-\frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$

答：

对数似然函数 $\ell(w)$ 是正态分布的对数似然，表达式为：

$$\ell(w) = \sum_{i=1}^N \left[-\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$$

故选A。

(c) (3分)多选：MLE 的参数由 $\arg \max_w \ell(w)$ 给出。在给定的表达式中，选择所有能够得出正确参数 MLE(最大似然估计)的表达式：

- A. $\arg \max_w \sum_{i=1}^N \left[-\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)}) \right]$
- B. $\arg \max_w \sum_{i=1}^N \left[-\log(\sqrt{2\pi\sigma^2}) - \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- C. $\arg \max_w \sum_{i=1}^N \left[-\frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- D. $\arg \max_w \sum_{i=1}^N \left[-\frac{1}{2} (y^{(i)} - w^T x^{(i)}) \right]$
- E. $\arg \max_w \sum_{i=1}^N \left[-\frac{1}{2} (y^{(i)} - w^T x^{(i)})^2 \right]$
- F. 以上全错

答：

由于 $-\log(\sqrt{2\pi\sigma^2})$ 是一个与 w 无关的常数，因此在最大化过程中可以忽略它。同样， $\frac{1}{2\sigma^2}$ 也是一个常数，不影响最大化过程。

故选B，C和E。

5. 现在我们继续学习线性回归模型参数的 MAP估计。考虑我们在上一个问题中使用的相同数据 D 。

(a) (3分)多选：下面哪个表达式是 MAP 估计试图解决的正确优化问题？ D 是数据， w 是回归参数(权重)。

- A. $w_{MAP} = \arg \max_w P(D, w)$
- B. $w_{MAP} = \arg \max_w \frac{P(D|w)P(w)}{P(D)}$
- C. $w_{MAP} = \arg \max_w \frac{P(D, w)}{P(w)}$
- D. $w_{MAP} = \arg \max_w P(D | w)P(w)$
- E. $w_{MAP} = \arg \max_w P(w | D)$
- F. 以上都不是

答：

在最大后验估计 (MAP) 中，我们的目标是最大化后验概率 $P(w | D)$ ，这可以通过贝叶斯定理表示为 $\frac{P(D|w)P(w)}{P(D)}$ 。故B和E是对的。

而 $P(D)$ 又是一个常数，故A和D也是等价的。

故选A，B，D和E。

(b) (3分)单选：假设我们对参数向量 w 的每个元素 w_m 使用均值为 0，方差为 $\frac{1}{\lambda}$ 的高斯先验分布，即 $w_m \sim \mathcal{N}(0, \frac{1}{\lambda}) (1 \leq m \leq M)$ 。假设每个参数 $w_1, \dots, w_m$ 都是独立的。以下哪个表达式是正确的数据和参数的对数联合概率 $\log P(D, w)$ ？

- A. $\sum_{i=1}^N \left(-\log \left(\sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 \right) - \sum_{m=1}^M \log(\sqrt{2\pi\lambda}) - \lambda(w_m)^2$
- B. $\sum_{i=1}^N \left(-\log \left(\sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 \right) + \sum_{m=1}^M -\log(\sqrt{2\pi\lambda}) - \lambda(w_m)^2$
- C. $\sum_{i=1}^N \left(-\log \left(\sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 \right) - \sum_{m=1}^M \log \left(\sqrt{\frac{2\pi}{\lambda}} \right) - \frac{\lambda}{2} (w_m)^2$
- D. $\sum_{i=1}^N \left(-\log \left(\sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 \right) + \sum_{m=1}^M -\log \left(\sqrt{\frac{2\pi}{\lambda}} \right) - \frac{\lambda}{2} (w_m)^2$

答：

我们的目标是求出此式：

$$\log(P(D, w)) = \log(P(D | w)) + \log(P(w))$$

首先解决后面的部分：

$$\log(P(w)) = \log(\prod_{m=1}^M P(w_m)) = \sum_{m=1}^M -\log \left(\sqrt{\frac{2\pi}{\lambda}} \right) - \frac{\lambda}{2} * w_m^2$$

此时分析选项，已经可选D为正确答案。

但接下来还是推导一下前半部分：

$$\begin{aligned} \log(P(D | w)) &= \log \left(\prod_{i=1}^N \left[\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2}{2\sigma^2}} \right] \right) \\ &= \sum_{i=1}^N \left[-\log \left(\sqrt{2\pi\sigma^2} \right) - \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2 \right] \end{aligned}$$

故选D。

(c) (3分)单选：对于具有高斯先验的相同线性回归模型(如前一个问题中所述)，最大化对数后验概率 $\ell_{MAP}(w)$ 给出了参数的最大后验估计。以下哪个是 $\max_w \ell_{MAP}(w)$ 的等价定义？

- A. $\max_w \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 + \frac{\lambda}{2} \|w\|_2^2$
- B. $\min_w \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 + \frac{\lambda}{2} \|w\|_2^2$
- C. $\max_w \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 + \lambda \|w\|_2^2$
- D. $\min_w \sum_{i=1}^N \frac{1}{2\sigma^2} (y^{(i)} - w^T x^{(i)})^2 - \frac{\lambda}{2} \|w\|_2^2$

答：

希望最大化对数后验概率，等价于最大化上一题中的 $\log P(D, w)$ 。我们将上一题结果中，不需要优化的常数项全部去掉即可。而且还要注意去掉负号之后，就是最小化了。所以正确答案选B，注意不要错选了D。

故选B。

(d) (3 分)单选：你发现一个 MAP 估计器的测试误差比训练误差高得多。以下哪一项可能是解决此问题的可能方法？

- A. 增加高斯先验中使用的方差
- B. 减少高斯先验中使用的方差

答：

已知 $w_m \sim \mathcal{N}(0, \frac{1}{\lambda}) (1 \leq m \leq M)$ 。而本题干中，测试误差远大于训练误差就意味着出现了过拟合。

较小的方差：这意味着我们认为权重应该集中在0附近，这是一种强正则化。模型的权重将受到严格的限制，导致模型更简单，泛化能力可能更好。

较大的方差：这意味着我们认为权重可以在更大的范围内变化，这是一种弱正则化。模型的权重将有更大的自由度，可能导致更复杂的模型，从而出现过拟合的现象。

故选B。

6. (4分) 单选：现在假设每个数据点的加性噪声 ϵ 是不同的。也就是说，每个 $y^{(i)}$ 在给定 $\mathbf{x}^{(i)}$ 的情况下都有加性噪声 $\epsilon^{(i)} \sim \mathcal{N}(0, \sigma_i^2)$ ，即 $y^{(i)} = \mathbf{w}^T \mathbf{x}^{(i)} + \epsilon^{(i)}$ 。与我们到目前为止使用的标准回归模型不同，现在有一个特定于示例的方差 σ_i^2 。最大化这个新模型的对数似然性等同于最小化加权均方误差，以下哪个是被加的权重？

- A. $1/y^{(i)}$
- B. $1/\sigma_i^2$
- C. $1/\|\mathbf{x}^{(i)}\|_2^2$

答：

首先，写出该模型的似然函数如下：

$$P(y^{(i)} | \mathbf{x}^{(i)}, \mathbf{w}, \sigma_i^2) = \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp \left(-\frac{(y^{(i)} - \mathbf{w}^T \mathbf{x}^{(i)})^2}{2\sigma_i^2} \right)$$

其对数似然形式为：

$$\log P(y^{(i)}|\mathbf{x}^{(i)}, \mathbf{w}, \sigma_i^2) = -\frac{1}{2\sigma_i^2}(y^{(i)} - \boldsymbol{\omega}^T \mathbf{x}^{(i)})^2 - \log(\sqrt{2\pi\sigma_i^2})$$

我们能明显看出来其中的均方误差部分就是 $(y^{(i)} - \boldsymbol{\omega}^T \mathbf{x}^{(i)})^2$ ，后面只是加上了一个常数。均方误差前面的权重是 $1/\sigma_i^2$ 。

故选B。

7. (4分) 单选：与哪种先验的MAP估计相当于 ℓ_1 正则化？请在下面展示你的解答过程。

注意：

- 在 $[a, b]$ 上的均匀分布的概率密度函数为 $f(x) = \frac{1}{b-a}$ ，如果 $x \in [a, b]$ ，否则为0。
- 具有比率参数 a 的指数分布的概率密度函数为 $f(x) = a \exp(-ax)$ ，对于 $x > 0$ 。
- 具有位置参数 a 和尺度参数 b 的拉普拉斯分布的概率密度函数为 $f(x) = \frac{1}{2b} \exp\left(-\frac{|x-a|}{b}\right)$ ，对于所有 $x \in \mathbb{R}$ 。

待选项如下：

- A. $[-1, 1]$ 上的均匀分布
- B. $[-\mathbf{w}^T \mathbf{x}^{(i)}, \mathbf{w}^T \mathbf{x}^{(i)}]$ 上的均匀分布
- C. 具有比率参数 $a = \frac{1}{2}$ 的指数分布
- D. 具有比率参数 $a = \mathbf{w}^T \mathbf{x}^{(i)}$ 的指数分布
- E. 具有位置参数 $a = 0$ 的拉普拉斯分布
- F. 具有位置参数 $a = \mathbf{w}^T \mathbf{x}^{(i)}$ 的拉普拉斯分布

答：

ℓ_1 正则化是线性回归中的一种正则化方法，它鼓励模型参数的稀疏性。它的正则化项为 $\|\mathbf{w}\|_1 = \sum_i |w_i|$ 。

MAP的概率公式如下所示：

$$P(\omega | D) = \frac{P(D | \mathbf{w})P(\mathbf{w})}{P(D)}$$

将其对数化后，可知其中的 $\log P(\omega)$ 就是我们的正则化部分。

首先考虑均匀分布：

其概率密度函数 (pdf) 是一个常数。因此，其负对数概率是一个常数，这与 ℓ_1 正则化不相符。故可排除A和B选项。

再考虑指数分布：

其对数概率为 $-\log(a \exp(-ax)) = -\log(a) + ax$ 。这是一个线性项，与 ℓ_1 正则化不相符。故也可排除C和D选项。

最后再考虑拉普拉斯分布：

其负对数概率为 $-\log\left(\frac{1}{2b} \exp\left(-\frac{|x-a|}{b}\right)\right) = \log(2b) + \frac{|x-a|}{b}$ 。注意到这里有一个绝对值项 $|x-a|$ ，这与 ℓ_1 正则化的形式相似。当 $a=0$ 时，才与其形式相似。故排除F，选E。

故选E。

4. 朴素贝叶斯(24分)

1. (4分) 假设所有人中有0.3%的人患有癌症。如果某人接受癌症检测，检测结果可以是阳性（癌症）或阴性（无癌症）。这项测试并不完美——在患有癌症的人中，测试结果为阳性的概率为97%。在没有癌症的人中，测试结果为阳性的概率为4%。对于这个问题，您应该假设测试结果彼此独立，给定真实状态（有或无癌症）。如果受试者的测试结果是阳性，那么受试者患有癌症的概率是多少？答案请保留四位小数，例如0.1234。

答：

为了解决这个问题，我们可以使用贝叶斯定理。贝叶斯定理是一个在给定某些相关信息的情况下，计算某个事件概率的公式。我们需要找到在测试结果为阳性的情况下，受试者实际患有癌症的概率。我们可以用下面的符号来表示这些概率：

患有癌症的概率：

$$P(C) = 0.003$$

未患癌的概率：

$$P(-C) = 1 - P(C) = 0.997$$

患癌的话，阳性率为：

$$P(Pos|C) = 0.97$$

未患癌的话，阳性率为：

$$P(Pos|-C) = 0.04$$

待求量为阳性情况下患癌的概率，也即：

$$P(C|Pos) = \frac{P(Pos|C) \cdot P(C)}{P(Pos|C) \cdot P(C) + P(Pos|\neg C) \cdot P(\neg C)} = 0.0680$$

故为**0.0680**。

2. 下面的数据集描述了一只独角兽的几个特征，用于说明它是否成年。


颜色	体型	是否成年
彩虹色	小	否
青色	小	否
青色	小	是
青色	中	是
彩虹色	中	否
紫红色	中	是
紫红色	大	是
青色	大	是

有一只独角兽叫做小壮，它是青色的，体型中等。我们想要确定它是否成年，使用朴素贝叶斯假设来估算以下概率。

(a) (2分) 一个青色、中等大小的独角鲸已经成年了的概率是多少？答案请保留四位小数，例如0.1234。

答：

首先画出本题的概率图模型如下：



根据上述概率图模型，我们可以计算如下：

$$\begin{aligned} &P(\text{成年}|\text{青色, 中等大小}) \\ &= \frac{P(\text{青色}|\text{成年}) \times P(\text{中等大小}|\text{成年}) \times P(\text{成年})}{P(\text{青色, 中等大小})} \\ &= 0.7826 \end{aligned}$$

故为**0.7826**。

(b) (2分) 一个青色、中等大小的独角鲸没有成年概率是多少？答案请保留四位小数，例如0.1234。

答：

$$P(\text{未成年}|\text{青色, 中等大小}) = 1 - P(\text{成年}|\text{青色, 中等大小}) = 0.2174$$

故为**0.2174**。

(c) (2分) 判断：小壮这只独角兽成年了吗？

- True
- False

答：

$$P(\text{成年}|\text{青色, 中等大小}) = 0.7826 > 0.2174 = P(\text{未成年}|\text{青色, 中等大小})$$

故选True。

3. (4分) 多选：高斯朴素贝叶斯通常可以学习非线性决策边界。考虑一个简单情况，我们只有一个实值特征 $X_1 \in \mathbb{R}$ ，我们希望从中推断标签 $Y \in \{0, 1\}$ 的值。相应的生成概率是：

$$\begin{aligned} Y &\sim \text{Bernoulli}(\phi) \\ X_1 &\sim \text{Gaussian}(\mu_y, \sigma_y^2) \end{aligned}$$

其中参数是Bernoulli参数 ϕ 和与 $Y = 0$ 和 $Y = 1$ 分别对应的类条件高斯参数 μ_0, σ_0^2 和 μ_1, σ_1^2 。

在一维中，线性决策边界可以由以下形式的规则描述：

$$\text{if } X_1 > c \text{ then } Y = k, \text{ else } Y = 1 - k$$

其中 c 是实值阈值， $k \in \{0, 1\}$ 。注意，这里的 $X_1 > c$ 表示一个通用的线性不等式。也就是说，我们可以使用 $X_1 > c$ 来代替 $X_1 > c, X_1 \geq c, X_1 < c$ 和 $X_1 \leq c$ 中的任何一个。

在这个简单的一维情况下，是否可能构建一个高斯朴素贝叶斯分类器，其决策边界不能用上述形式的规则表示？

- A. 如果高斯分布的均值相等且方差不等，那么可以发生这种情况。
- B. 如果高斯分布的均值不等且方差相等，那么可以发生这种情况。
- C. 如果高斯分布的均值和方差都不相等，那么可以发生这种情况。
- D. 上述都不是。

答：

首先写出 $P(Y)$ 的形式如下：

$$\begin{aligned} P(Y = 1) &= \phi \\ P(Y = 0) &= 1 - \phi \end{aligned}$$

还有 $P(X_1)$ 的形式如下：

$$P(X_1 = x|Y = k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x - \mu_k)^2}{2\sigma_k^2}\right)$$

我们的目标是得到 $Y = k$ 的后验概率：

$$P(Y = k|X_1 = x) = \frac{P(X_1 = x|Y = k) \times P(Y = k)}{P(X_1 = x)}$$

代入后验概率的公式，我们得到：

$$P(Y = k|X_1 = x) = \frac{\frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x - \mu_k)^2}{2\sigma_k^2}\right) \times P(Y = k)}{P(X_1 = x)}$$

由于我们的目标是得到决策边界，所以可以列出方程为：


$$P(Y = 0|X_1 = x) = P(Y = 1|X_1 = x)$$

化简如下：


$$\begin{aligned} &[(\sigma_0 + \sigma_1)x - (\sigma_1\mu_0 + \sigma_0\mu_1)][(\sigma_1 - \sigma_0)x - (\sigma_1\mu_0 - \sigma_0\mu_1)] \\ &= -2\sigma_0^2\sigma_1^2 \log\left(\frac{\sigma_0}{\sigma_1} \times \frac{\phi}{1-\phi}\right) \end{aligned}$$

可以直观看到，是否线性，只与方差是否相等有关系。只要方差不等，那么 x 就会有两个解；只有方差相等，才是线性的，只有一个解。


- i. 均值相等且方差不等



ii. 均值不等且方差相等



iii. 均值和方差都不相等



故选**A**和**C**。

4. 现在我们将扩展到2D，并推导2D高斯朴素贝叶斯的决策边界。

(a) (4分) 显示2D高斯朴素贝叶斯分类器的决策边界是二次的。也就是说，显示 $P(Y = 1|X_1, X_2) = P(Y = 0|X_1, X_2)$ 可以写成 X_1 和 X_2 的多项式函数，其中每个变量的度数最多为2。你可以将不重要的常数折叠成诸如 C, C', C'', C''' 的项，只要你清楚地显示每一步。

答：

由于是高斯朴素贝叶斯分类器，所以有这个条件就知道了特征 X_1 和 X_2 之间是相互独立的，于是将其概率分别设置为：

$$\begin{aligned} Y &\sim \text{Bernoulli}(\phi) \\ X_1|Y = k &\sim \text{Gaussian}(\mu_{1k}, \sigma_{1k}^2) \\ X_2|Y = k &\sim \text{Gaussian}(\mu_{2k}, \sigma_{2k}^2) \end{aligned}$$

其中 $k \in \{0, 1\}$ 。

由贝叶斯公式，我们有：

$$P(Y = k|X_1, X_2) = \frac{P(X_1, X_2|Y = k)P(Y = k)}{P(X_1, X_2)}$$

且其中：

$$P(X_1, X_2|Y = k) = P(X_1|Y = k)P(X_2|Y = k)$$

为了找到决策边界，我们令：

$$P(Y = 1|X_1, X_2) = P(Y = 0|X_1, X_2)$$

代入公式后，得到一个与 X_1 和 X_2 的二次函数相关的等式：

$$\frac{X_1^2}{\sigma_{10}^2} - \frac{X_1^2}{\sigma_{11}^2} + \frac{X_2^2}{\sigma_{20}^2} - \frac{X_2^2}{\sigma_{21}^2} + C'X_1 + C''X_2 + C = 0$$

其中， C' , C'' 和 C 是由均值、方差和先验概率组成的常数项。从而证明了2D高斯贝叶斯分布的决策边界是二次的。

(b) (3分) 多选：选择由高斯朴素贝叶斯分类器产生的所有可能的决策边界。阴影区域被指定为类1，未阴影区域被指定为类0。




Figure 1: Decision Boundaries


- A. (a)
- B. (b)
- C. (c)
- D. (d)
- E. 以上都不是

答：

在上一问中已知了，其决策边界是二次曲线，那么就可能是(a)中的椭圆，(b)中的抛物线，或是(d)中的退化的一次线。而不可能是(c)中的方形。

故选 **A, B和D**。

5. (3分) 单选：小明使用2D高斯朴素贝叶斯模型进行了二分类任务，并得到了给定的条件下的密度 $f(x_1, x_2|y = +)$ 的轮廓图。你立刻注意到他犯了一个错误。为什么他的结果从理论上是不可能从高斯朴素贝叶斯模型获得的？



- A. 分布的均值应该是所有点的均值，而不仅仅是正点（+）的均值
- B. 对于离散标签（+和-）应该使用伯努利朴素贝叶斯模型
- C. 分布的协方差矩阵不是对角矩阵
- D. 以上都不是

答：

A错。因为我们本来要求的也就是 $y = +$ 情况下的分布，所以的确只用考虑(+)正点的均值。

B错。伯努利朴素贝叶斯模型只适用于特征是离散的情况，而本题中的特征是连续的。

C对。显然该轮廓图中两个特征是相关的（因为该高斯分布是倾斜的），但高斯朴素贝叶斯分布有一个默认的假设，就是所有特征都是无关的，也即协方差矩阵必须要是对角矩阵。所以C是对的。

故选C。

5. 提交格式

将答案，整理成PDF格式，命名为 学号_姓名_HW6_Answer.pdf，直接提交即可。