

学号：_____ 姓名：_____ 分数：_____

1-编程题: 多数投票分类器[30 分]

目的

- [1] 熟悉编程作业的流程
- [2] 熟悉 Python 的 I/O

算法描述

多数投票分类器(Majority Vote Classifier)在训练时计算数据集中最常见的标签，并将该标签存储下来用于测试时使用；在测试时，分类器输出的预测标签是最常出现在训练集中的标签。若各个类别的出现次数一样，则可以不进行预测或者随机输出预测结果。

MajorityVoteClassifier 根据数据集中最常见的标签来预测输入实例的类标签,是一个深度 $\text{depth} = 0$ 的决策树，也叫决策树桩（decision stump）。该算法是决策树的组成部分，在下次作业中也会使用到 MajorityVoteClassifier。

数据集

下载数据。

data 目录下包含 education_train.tsv, education_test.tsv, heart_train.tsv 和 heart_test.tsv。数据已经分为训练数据和测试数据。为简单起见，所有属性被离散为两类。每个 tsv 文件的第一行包含每个属性的名称，并且类别标签总是最后一列。

data\example_output 还包含来自 MajorityVoteClassifier 的预测结果和性能指标。你可以对照这些结果检查自己的输出，看看你的实现是否正确。

心脏病数据集

训练数据在 heart_train.tsv 中，测试数据在 heart_test.tsv 中。第一个任务是根据可用的患者信息预测患者是否会被诊断为心脏病。各属性的说明如下：

属性名称	含义
sex	性别：患者的性别——1 表示患者是男性，0 表示患者是女性。
chest_pain	胸痛：如果患者胸痛，则为 1，否则为 0。
high_blood_sugar	高血糖：如果患者有高血糖(空腹 > 120 mg/dl)，则为 1，否则为 0
abnormal_ecg	心电图异常：运动诱发心绞痛为 1，其他为 0。
angina	心绞痛是一种严重的胸痛
flat_ST	ST 段是否为平：如果患者的 ST 段(心电图的一部分)在运动时是平的，则为 1，如果有斜率则为 0
fluoroscopy	荧光透视法：如果医生使用透视检查，则为 1，否则为 0。透视是一种用来观察心脏血流的成像技术
thalassemia	地中海贫血：如果患者已知患有地中海贫血，则为 1，否则为 0。地中海贫血是一种血液疾病，可能会损害患者红细胞的携氧能力
heart_disease	心脏病：如果患者被诊断患有心脏病，则为 1，否则为 0。这是你需要预测的类标签。

教育数据集

训练数据在 education_train.tsv 中，测试数据在 education_test.tsv 中。

第二个任务是预测高中生的最终成绩。 这些属性分别是 5 个选择题 M1 到 M5, 4 个编程作业 P1 到 P4 和期末考试 F 的得分。最终成绩的取值为 1 则表示该学生得到 A；最终的成绩取值为 0 则表示该学生没有得到 A。

命令行参数

使用以下命令运行 majority_vote.py 文件:

```
$ python majority_vote.py [args...]
```

其中, [args...]是五个命令行参数 <train input> <test input> <train out> <test out> <metrics out> 的占位符。这些参数详细描述如下:

- <train input>: 训练集的文件路径
- <test input>: 测试集的文件路径
- <train out>: 训练结果的输出文件 (.txt) 的路径
- <test out>: 测试结果的输出文件 (.txt) 的路径
- <metrics out>: 度量指标 (.txt) 的输出文件的路径

作为示例, 下面的命令行将在心脏数据集上运行 majority_vote.py 文件。训练集的预测将写入 heart_train_labels.txt, 测试集的预测将写入 heart_test_labels.txt, 度量指标(错误率)将写入 heart_metrics.txt。

```
$ python majority_vote.py heart_train.tsv heart_test.tsv \
    heart_train_labels.txt heart_test_labels.txt heart_metrics.txt
```

输出: 标签文件

你的程序应该输出两个 txt 标签文件, 包含你的模型对训练数据(<train out>)和测试数据(<test out>)的预测。每个样本的预测结果输出到对应的行, 使用 '\n' 创建新行。你的标签应该与多数投票分类器预测的标签完全一致。下面给出了心脏数据集的示例输出文件的前几行:

```
0
0
0
0
0
0
...
```

输出: 度量指标文件

<metrics out> 中包含训练集错误率和测试集错误率。你的结果应该和参考答案的误差在 0.0001 以内, 不需要对你的结果进行四舍五入!

文件格式如下:

```
error(train): 0.490000
error(test): 0.402062
```

命令行参数

在本次编程作业和之后的编程作业中,我们将使用命令行参数来运行带有不同参数的程序。假设你的程序接受两个参数:一个输入文件和一个输出文件,参考下面提供的示例学习如何在 Python 中完成此操作。

Python:

```
import sys

if __name__ == '__main__':
    infile = sys.argv[1]
    outfile = sys.argv[2]
    print("The_input_file_is:_%s" % (infile))
    print("The_output_file_is:_%s" % (outfile))
```

代码提交

提交一个名为 majority_vote.py 的文件。

2-概率与统计[25 分]

使用以下数据回答问题 1-2。考虑投掷硬币 5 次所产生的数据 $S = [1,1,0,1,1]$ ，其中，1 表示正面，0 表示反面。

1. (3 分)单选。假设投掷一枚硬币 X ，得到其为正面和为反面的概率分别为 $P(X = 1) = 0.75, P(X = 0) = 0.25$ 。观察到这些数据(4 个正面和 1 个反面)的任何组合的概率是多少？

A. $\frac{405}{1024}$ B. $\frac{1}{32}$ C. $\frac{324}{1024}$ D. $\frac{81}{1024}$

2. (1 分)如果 $P(X = 1)$ 的值不是 0.75，而是其他值，则观察到该数据样本 S 的概率会更大。求使样本 S 的概率最大化的 $P(X = 1)$ 值是多少？以分数形式给出答案。

3. (1 分)单选。对于事件 A 和事件 B ，其中 $A \cap B$ 表示 A 和 B ， $A \cup B$ 表示 A 或 B ；则 $P(A \cap B) = P(A) + P(B) - P(A \cup B)$ 为？

A. True B. False

4. (1 分)单选。对于事件 A 和 B ， $P(A_1 \cap A_2 \cap A_3) = P(A_3 | A_2 \cap A_1)P(A_2 | A_1)P(A_1)$ 为？

A. True B. False

5. (2 分)单选:早上你的车是否是处于湿(W)的状态取决于昨晚(R)是否下雨，但其他因素也可能会导致你的车是处于湿(W)的状态。

以下是此类事件发生的概率：

$$P(R) = 0.4, P(W | R) = 0.8, P(W | \neg R) = 0.2$$

则明天早上你的车是处于湿的状态的概率是多大？

A.0.64 B.0.56 C.0.44 D.0.4

用以下信息回答问题 6-7。

考虑下面的联合概率表，其中 X 和 Y 都是二元变量：

X	Y	Probability
0	0	0.1
0	1	0.4
1	0	0.2
1	1	0.3

6. (1 分)单选： $P(X = 1 | Y = 1) = ?$

A. $\frac{2}{3}$ B. $\frac{3}{7}$ C. $\frac{4}{5}$ D. $\frac{3}{5}$

7. (1 分)单选： $P(Y = 0) = ?$

A.0.2 B.0.6 C.0.5 D.0.3

用以下信息回答问题 8-10。

设 X 为随机变量，期望值 $E[X] = 1$ ，方差 $\text{Var}[X] = 2$ 。

8. (1 分) 单选: $E[6X] = ?$

- A. 1 B. 3 C. 6 D. 36

9. (1 分) 单选: $\text{Var}[2X] = ?$

- A. 1 B. 4 C. 8 D. 16

10. (1 分) 单选: $\text{Var}[2X - 3] = ?$

- A. 3 B. 4 C. 5 D. 8

设 A , B 和 C 为离散概率分布的随机变量。考虑以下两个联合概率表: 一个关于 A 和 B ，另一个关于 B 和 C 。

$A \setminus B$	b_1	b_2	b_3
a_1	0.1	0.05	0.15
a_2	0.1	0.05	0.3
a_3	0.05	0.15	0.05

$B \setminus C$	c_1	c_2	c_3	c_4
b_1	0.02	0.14	0.06	0.03
b_2	0.03	0.05	0	0.17
b_3	0.35	0.04	0	0.11

11. (1 分) 多选: 以下哪个陈述必然是错误的? $X \perp\!\!\!\perp Y$ 表示随机变量 X 独立于随机变量 Y 。

- A. $A \perp\!\!\!\perp B$ B. $B \perp\!\!\!\perp C$ C. $A \perp\!\!\!\perp C$ D. 以上都不对

12. (2 分) $P(B = b_1 | A = a_2, C = c_4)$ 是什么? 如果无法计算, 则写 N/A。对于这个问题, 如果有 $P(A = a_2, C = c_4) = 0$, 请忽略这种情况。

13. (2 分) $P(B = b_2 | A = a_3, C = c_3)$ 是什么? 如果无法计算, 则写 N/A。对于这个问题, 如果有 $P(A = a_3, C = c_3) = 0$, 请忽略这种情况。

14. (2 分) 单选: True or False: $\sum_{i=1}^3 P(B = b_i | C = c_1) = \sum_{j=1}^4 P(C = c_j | B = b_1)$

- A. True B. False

15. (2 分) 单选: (2 分) 选择一个: 考虑两个随机变量 X, Y 。假设我们有 $P(X = x) = \frac{1}{2^x}$ 对于 $x \in \mathbb{Z}_{\geq 1}$

(大于等于 1 的整数)和 $P(Y = y | X = x) = \frac{1}{n}$ 对于 $y \in \{1, 2, \dots, n\}$ 。假设 n 是一个固定的正整数常数。 $E[Y]$ (对 Y 求期望)是什么?

- A. $\sum_{y=1}^n y \frac{1}{2^y}$ B. $\sum_{y=1}^n y \frac{5}{3^y}$ C. $\sum_{y=1}^n \frac{y}{n}$ D. $\sum_{y=1}^n y$

16. (1 分) 单选: 伯努利(p)的随机变量的均值、方差和熵是什么?

- A. p , $p(1-p)$, $-(1-p)\log(1-p) - p\log(p)$
 B. $p(1-p)$, p , $-(1-p)\log(1-p) - p\log(p)$
 C. p , $p(1-p)$, $\log(1-p) - p\log(p)$

D. 伯努利随机变量的熵未定义

17. (2 分) 请将随机变量 X 的概率密度函数与其对应的分布名称进行匹配。

A. $\text{prob}(X = x) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$

B. $\text{prob}(X = x) = \lambda e^{-\lambda x}$ when $x \geq 0$; 0 otherwise

C. $\text{prob}(X = x) = \binom{n}{x} p^x (1-p)^{n-x}$

D. $\text{prob}(X = x) = \frac{1}{b-a}$ when $a \leq x \leq b$; 0 otherwise

E. $\text{prob}(X = x) = p^x (1-p)^{1-x}$

Multivariate Gaussian:

Exponential:

Uniform:

Bernoulli:

Binomial:

3-微积分[8 分]

1. (2 分) 在 $x = 1$ 处, 对 y 求关于 x 的导数, 其中 $y = \ln\left(\frac{4}{x^3} - x^2\right)$ 。

2. (2 分) 单选: 求 y 对 x 的偏导数, 其中 $y = 3x^2 \sin(z) e^{-x}$

A. $x \sin(z) e^{-x} (2 + x)$

B. $-6x \sin(z) e^{-x}$

C. $x \sin(z) e^{-x} (2 - x)$

D. $6x \cos(z) e^{-x}$

3. (2 分) 单选: 对于函数 $f(x) = 4x^3 - 5x^2 - 2x$, 当 $x = -\frac{1}{6}$ 时, $f(x)$ 对 x 的导数为 0。另外,

$f(x)$ 在 $x = -\frac{1}{6}$ 处的二阶导数是负的。对于 $f(x)$ 在 $x = -\frac{1}{6}$ 处的含义是什么呢?

A. 局部最小值

B. 局部最大值

C. 局部最小值或者局部最大值

D. 以上都不对

4. (2 分) 单选: 假设 $f(\mathbf{x} | \boldsymbol{\theta}) = \mathbf{x}^T \boldsymbol{\theta}$, 其中 $\mathbf{x}, \boldsymbol{\theta} \in \mathbb{R}^n$ 。函数 $g(\boldsymbol{\theta})$ 的定义为: $g(\boldsymbol{\theta}) = (f(\mathbf{x}^{(1)} | \boldsymbol{\theta}) - y^{(1)})^2$, 其中 $\mathbf{x}^{(1)} \in \mathbb{R}^n$, $y^{(1)} \in \mathbb{R}$, 那 $g(\boldsymbol{\theta})$ 的函数类型是:

A. $g: \mathbb{R}^n \rightarrow \mathbb{R}$

B. $g: \mathbb{R} \rightarrow \mathbb{R}$

C. $g: \mathbb{R} \rightarrow \mathbb{R}^n$

D. $g: (\mathbb{R}^n \times \mathbb{R}^n) \rightarrow \mathbb{R}$

4-矩阵论[15 分]

1. (2 分)单选:考虑矩阵 $\mathbf{X}$ 和下面的向量 $\mathbf{y}$ 和 $\mathbf{z}$:

$$\mathbf{X} = \begin{bmatrix} 1 & 4 \\ 2 & 6 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{z} = \begin{bmatrix} 4 \\ 3 \end{bmatrix}$$

向量 $\mathbf{y}$ 和 $\mathbf{z}$ 的内积是多少(也称为点积)?

- A. $\begin{bmatrix} 8 & 6 \\ 4 & 3 \end{bmatrix}$ B. 10 C. $\begin{bmatrix} 8 \\ 3 \end{bmatrix}$ D. 11

2. (2 分)单选:使用与上面相同的 $\mathbf{X}$, $\mathbf{y}$ 和 $\mathbf{z}$ 值, $\mathbf{Xy}$ 是多少?

- A. $\begin{bmatrix} 10 \\ 2 \end{bmatrix}$ B. $\begin{bmatrix} 6 \\ 10 \end{bmatrix}$ C. $\begin{bmatrix} 7 \\ 11 \end{bmatrix}$ D. $\begin{bmatrix} 14 \\ 22 \end{bmatrix}$

3. (2 分)多选:考虑 $\mathbf{u} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$, $\mathbf{v} = \begin{bmatrix} 0 & 7 \\ 4 & 5 \\ -1 & 0 \end{bmatrix}$, 哪些是有效的操作?

- A. $\mathbf{u}^T \mathbf{V}$ B. $\mathbf{V}^T \mathbf{u}$ C. $\mathbf{uV}$ D. $\mathbf{VV}$ E. 以上均为无效操作

4. (2 分) 单选: 对于矩阵 $\mathbf{A} = \begin{bmatrix} 2 & 1 & 4 \\ -3 & 2 & 0 \\ 1 & 3 & -2 \end{bmatrix}$ 和 $\mathbf{B} = \begin{bmatrix} 3 & 4 & 5 \\ 3 & -1 & 3 \\ 1 & 3 & -2 \end{bmatrix}$, $\mathbf{AB}=?$

A. $\begin{bmatrix} 13 & 19 & 5 \\ -3 & -14 & -9 \\ 4 & -4 & 18 \end{bmatrix}$

B. $\begin{bmatrix} 13 & 19 & 28 \\ 19 & 9 & -7 \\ -10 & -2 & 13 \end{bmatrix}$

C. $\begin{bmatrix} 20 & -20 & -28 \\ 3 & -14 & 9 \\ 3 & 2 & 13 \end{bmatrix}$

D. $\begin{bmatrix} 13 & 19 & 5 \\ -3 & -14 & -9 \\ 10 & -5 & 18 \end{bmatrix}$

5. (1 分) True or False: 上题中的 $\mathbf{A}$ 有逆矩阵。

- A.True B.False

6. (2 分)单选: 现有两个向量 $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$ 和 $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$, 令 $z = \mathbf{x}^T \mathbf{y}$, 则 $\frac{\partial z}{\partial y_2}=?$

- A. y_2 B. x_2 C. $\mathbf{x}$ D. y

7. (2 分) 单选: 给定矩阵 $\mathbf{X} = \begin{bmatrix} 3 & 4 & 2 \\ 1 & 6 & 2 \\ 1 & 4 & 4 \end{bmatrix}$ 和列向量 $\mathbf{y} = \begin{bmatrix} -6 \\ 1 \\ 1 \end{bmatrix}$, 则 $\mathbf{X}$ 关于 $\mathbf{y}$ 的特征值是多少?

(回想一下矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 的特征向量是非零向量 $\mathbf{v} \in \mathbb{R}^n$, 则有 $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ 其中我们称标量 λ 为 $\mathbf{v}$ 的相关特征值)

- A. -5 B. -3 C. 2 D. 1.5

8. (2 分) 单选: Joe 为他的线性代数期末考试做准备, Joe 在寻找不同矩阵的特征向量和特征

值。Joe 发现某个矩阵 $\mathbf{A}$ (未给定) 具有特征值 4 和 5。他还注意到 $\begin{bmatrix} 3 \\ 11 \\ 7 \end{bmatrix}$ 和 $\begin{bmatrix} 1 \\ 39 \\ 3 \end{bmatrix}$ 是方程 $\mathbf{A}\mathbf{v} =$

$4\mathbf{v}$ 的解, 然后他得出来的结论是这两向量都是特征向量, 且他们对应于特征值都是 4。关于他的结论哪个陈述是正确的?

- A. 肯定是错的, 因为不可能有多个特征向量对应于一个特征值。
 B. 肯定是错的, 因为特征向量是线性相关的, 因此不可能有两个特征向量同时是 $\mathbf{A}\mathbf{v} = 4\mathbf{v}$ 的解。
 C. 是正确的, 因为可能有多个特征向量对应于一个特征值, 而一个矩阵的特征向量是线性相关的。
 D. 是正确的, 因为两个向量都是 $\mathbf{A}\mathbf{v} = 4\mathbf{v}$ 的解。

5-几何[6 分]

1. (2 分) 单选: 向量 $\mathbf{w}$ 与直线 $\mathbf{w}^T \mathbf{x} + b = 0$ 有什么关系?(假设 $\mathbf{x}$ 和 $\mathbf{w}$ 都是二维列向量, $\mathbf{w}^T$ 表示列向量 $\mathbf{w}$ 的转置。)

- A. 平行 B. 正交 C. 取决于 b 的值

2. (2 分) 单选: 参考上题, 解释为什么 $\mathbf{w}$ 和 $\mathbf{w}^T \mathbf{x} + b = 0$ 会有上述关系?

- A. 因为 $\mathbf{w}^T(\mathbf{x}' - \mathbf{x}'')$ 的内积为 0, 其中 $\mathbf{x}'$ 和 $\mathbf{x}''$ 是直线 $\mathbf{w}^T \mathbf{x} + b = 0$ 上的两个点
 B. 因为 $\mathbf{w}^T(\mathbf{x}' - \mathbf{x}'')$ 的内积为 1, 其中 $\mathbf{x}'$ 和 $\mathbf{x}''$ 是直线 $\mathbf{w}^T \mathbf{x} + b = 0$ 上的两个点
 C. 因为 $\mathbf{w}^T(\mathbf{x}' - \mathbf{x}'')$ 的内积为 b , 其中 $\mathbf{x}'$ 和 $\mathbf{x}''$ 是直线 $\mathbf{w}^T \mathbf{x} + b = 0$ 上的两个点

3. (2 分) 单选: 原点到直线 $\mathbf{w}^T \mathbf{x} + b = 0$ 的距离是多少?(在以下答案中, " λ " 是某个常量)

- A. $\frac{|b|}{\|\mathbf{w}\|}$ B. $\frac{|b|}{\mathbf{w}^T \mathbf{w}}$ C. $\frac{2\lambda}{wb}$ D. $\frac{\|\mathbf{w}\|}{|b|}$

6-CS 基础[16 分]

1. (2 分) 单选: 如果 $f(n) = \ln(n)$ 且 $g(n) = \log_3(n)$, 下列哪个是对的?

- A. $f(n) \in O(g(n))$ B. $g(n) \in O(f(n))$ C. AB 都对 D. AB 都不对

2. (2 分) 单选: 如果 $f(n) = n^{10}$ 且 $g(n) = 10^n$, 下面哪个是对的?

- A. $f(n) \in O(g(n))$ B. $g(n) \in O(f(n))$ C. AB 都对 D. AB 都不对

Britain's Royal Family
Review the royal family's line of succession to the throne.




图 1: 英国皇室家族

3. (2 分) 单选: 使用图 1 所示的树, 深度优先搜索在寻找 Mia Tindall(包括她的节点)时会访问多少个节点?假设我们按照从左到右和自顶向下的顺序进行搜索。

A.3 B.12 C.15 D.18




图 2. 带有索引节点的二叉树

4. (2 分) 图 2 是一个带有索引节点的二叉树。假设根节点为节点 1。上述二叉树的 DFS 和 BFS 的节点访问顺序是什么? 二叉树的深度优先搜索(DFS)遍历是先从访问根节点开始, 并在搜索右子树(即以右节点为根的树)之前, 先递归地向下搜索左子树(即以左节点为根的树), 直到遍历完成。注意: 虽然也可以先看右子树, 再在左子树, 对于本问题, 请考虑从左到右的顺序, 即先看左子树, 后看右子树。二叉树的宽度优先搜索(BFS)遍历访问同一层的每个节点(假设从左到右的顺序)(与根的距离相同), 然后再到下一层, 直到遍历完成。

DFS 的节点访问顺序为(数值之间用逗号分隔, 如 1,2,3,4)?

BFS 的节点访问顺序为(数值之间用逗号分隔, 如 1,2,3,4)?

5. (2 分)使用递归深度优先搜索(DFS)遍历，用伪代码填充(1)(2)(3)(4)。

```
class TreeNode:
    def __init__(self, val):
        self.val = val
        self.leftNode = None
        self.rightNode = None

#(a) the left/right node is denoted as
#   node.leftNode/node.rightNode
#(b) left/right node are of type TreeNode
#(c) the value of the node is denoted as node.val
#(d) recursive DFS to search for the node
#   with value key in a binary tree
#(e) the left node is assumed to be searched
#   before the right node

def find_val(node, key):
    if node is None:
        return None
    if (1):
        return node
    else:
        result = (2)
        if result is None:
            result = (3)
        return (4)
```

你的伪代码(1):

你的伪代码(2):

你的伪代码(3):

你的伪代码(4):

6. (2 分)单选: $L_{32} = ?$

其中，Lucas numbers 定义如下：

$$L_n = \begin{cases} 2 & \text{if } n = 0 \\ 1 & \text{if } n = 1 \\ L_{n-1} + L_{n-2} & \text{if } n > 1 \end{cases}$$

A.3010349

B.3524578

C.4870847

D.7881196

考虑以下信息来回答问题 7-8:

给定计算斐波那契数的函数:

```
def fib_1(n):
    if n == 0 or n == 1:
        return 1
    return fib_1(n-1) + fib_1(n-2)
```

```
d = {}
d[0] = 1
d[1] = 1
def fib_2(n):
    if n in d.keys():
        return d[n]
    d[n] = fib_2(n-1) + fib_2(n-2)
    return d[n]
```

7. (2 分) 单选: fib_1 (n)的时间复杂度的最小上界是?
 A. $O(n)$ B. $O(n \log n)$ C. $O(2^n)$ D. $O(n!)$
8. (2 分) 单选: fib_2 (n)的时间复杂度的最小上界是?
 A. $O(n)$ B. $O(n \log n)$ C. $O(2^n)$ D. $O(n!)$