

学号: _____ 姓名: _____ 分数: _____

1-决策树回顾[22 分]

1.下面是一个的 4×4 的棋盘, 假设我们的目标是对棋盘内的范围进行分类: 即将所有黑色区域分类为+1, 所有白色区域分类为-1。让横轴表示特征 x_1 , 纵轴表示特征 x_2 。

注意:如果一个点位于区域的边界或角落, 则这个点与它的上面或者右边的区域具有相同的标签。例如, $(1,0)$ 点的分类标签为+1, $(1,1)$ 点的标签为-1, $(1,1.5)$ 点的标签为-1。




图 1. 4×4 棋盘

- (a)(3 分)只使用 x_1 或只使用 x_2 而不是同时使用 x_1 和 x_2 的特征, 对图 1 中的区域进行分类的二叉决策树的最小深度是多少?你可以自由发挥, 使用 x_1 和 x_2 的特征来对二叉决策树进行分支。一些特征示例: $\text{ceil}(x_1)$, $\text{floor}(x_2)\%4$, $2 < x_1 < 4$, $x_2 < 1$ or $x_2 > 3$
- (b)(3 分)对于不同的常数 c , 仅使用 $x_1 < c$ 作为特征或使用 $x_2 < c$ 作为特征, 对图 1 中的区域进行分类的二叉决策树的最小深度是多少?
- (c)(3 分)使用任何关于 x_1, x_2 的特征或者同时使用 x_1 和 x_2 的特征, 对图 1 中的区域进行完美分类的二叉决策树的最小深度是多少?

2.下面的图表, 展示了树的大小与被修剪回垂直线(红色)的决策树的准确性的关系。假设此任务的所有有标签的数据被随机分为训练数据集 D_{train} , 验证数据集 D_{val} 和测试数据集 D_{test} 。只在 D_{train} 上训练整棵树, 然后使用 D_{val} 对训练后的树进行剪枝, 以减少误差。




图 2. 决策树剪枝

(a)(2 分)单选:参见图 2。请注意, D_{test} 并没有用于训练或修剪。当修剪后的树的大小为 25 个节点时, 它在 D_{test} 上的准确率可能是多少?

- A. 略高于修剪后的树在 D_{val} 上的精度
- B. 与修剪后的树在 D_{val} 上的精度相同
- C. 略低于修剪后的树在 D_{val} 上的精度

(b)(2 分)单选:以下哪一项最接近真实误差?

- A. 在训练集 D_{train} 上的误差
- B. 在验证集 D_{val} 上的误差
- C. 在测试集 D_{val} 上的误差

3.(2 分)多选:以下哪些是避免过拟合的有效方法?

- A. 减小训练集的大小
- B. 在内部节点上分裂所需的最小样本数上设置一个阈值
- C. 对树进行剪枝, 使交叉验证误差最小化
- D. 增加树的深度
- E. 以上都不对

4. 考虑一个使用欧几里得距离度量的 1 最近邻的二元分类问题。我们有 N 个一维训练点 $x^{(1)}, x^{(2)}, \dots, x^{(N)}$ 和相应的标签 $y^{(1)}, y^{(2)}, \dots, y^{(N)}$, 其中 $x^{(i)} \in \mathbb{R}$, $y^{(i)} \in \{0, 1\}$ 。

假设点 $x^{(1)}, x^{(2)}, \dots, x^{(N)}$ 按升序排列, 如果在 1-NN 算法中存在平衡状态 (即出现 $x^{(i)} = x^{(j)}, i < j$), 我们通过选择序列号较低的 $x^{(i)}$ 对应的标签来处理这种情况。

(a)(4 分)单选:是否有可能建立一个决策结果和 1 最近邻分类器完全相同的决策树?假设每个节点的决策采用 " $x \leq t$ " 或 " $x > t$ ", 其中 $t \in \mathbb{R}$ 。

- A. 有可能
- B. 没有可能

如果你的答案是有可能, 请详细描述你将如何构建决策树。如果你的答案是否定的, 解释为什么这是不可能的。

解释:

(b)(3 分)多选:对数据添加一个维度, 即数据点变为二维的, 即 $\mathbf{x}^{(i)} = (x_1^{(i)}, x_2^{(i)}) \in \mathbb{R}^2$ 。下面哪个训练集, 可以得到一个决策结果与 1-近邻分类器完全相同的决策树?假设每个节点的决策采用 " $x_j \leq t$ " 或 " $x_j > t$ " 的形式, 其中 $t \in \mathbb{R}, j \in \{1, 2\}$ 。

- A. 点: $\{(-5, 5), (5, 5)\}$, 标签: $\{0, 1\}$
- B. 点: $\{(0, -9), (0, 10)\}$, 标签: $\{0, 1\}$
- C. 点: $\{(3, 4), (-3, -4)\}$, 标签: $\{0, 1\}$
- D. 点: $\{(0, 0), (0, 1), (1, 0)\}$, 标签: $\{0, 0, 1\}$
- E. 点: $\{(0, 0), (0, 1), (1, 0)\}$, 标签: $\{0, 1, 1\}$
- F. 点: $\{(1, 2), (3, 4), (5, 6)\}$, 标签: $\{0, 1, 1\}$
- G. 以上都不可以

2-k 近邻 [27 分]




图 3. k-NN 数据集

1. 考虑一个 k 近邻(k -NN)的二分类器, 它根据欧几里得距离度量将样本点的 k 近邻的大多数类别作为此样本点的类别。如果最近邻的类别分布出现了平局(即 k 近邻中的两个类别的数量相等), 则分类器将均匀随机地选择一个类别作为此样本点的类别。

(a) (2 分)使用图 3 展示的数据集作为训练集来训练分类器, 选择 $k = 6$, 则在训练集上的分类误差是多少?误差结果四舍五入到小数点后 4 位。

(b) (3 分)多选:假设我们有一个新的样本点(不存在于训练集中) $\mathbf{x}^{\text{new}} = [3, 9]^T$, 用 k -NN 分类器对这个新的样本点进行分类, 如图 4 所示。




图 4:带有测试点的 k-NN 数据集

哪个 k 值的 k -NN 算法可以对样本点进行正确分类?

- A. $k = 1$
- B. $k = 5$
- C. $k = 9$
- D. $k = 12$
- E. 以上皆非

2. 单选: 假设我们有一个大的有标签的数据集, 将其随机分为训练集和测试集, 我们想使用 k -NN 分类器对测试集中的样本点进行分类。

(a). (2 分)判断: 为了使这个测试集上的分类误差最小, 应始终选择使训练集误差最小的 k 值。

- A. True B. False

(b). (2 分)单选: 我们不是仅仅通过最小化训练集误差来选择超参数, 而是考虑将训练集中的数据再分成训练数据集和验证数据集, 并选择使得验证集误差较小的超参数。根据验证集的误差来选择超参数会比根据训练集的误差来选择超参数更好吗?


- A. 是的, 选择使得验证集误差小的超参数比选择使得训练集误差小的超参数更好, 因为降低训练集的误差对于模型泛化没什么帮助, 而且还可能导致过拟合。
 B. 是的, 选择使得验证集误差小的超参数对模型更好, 因为交叉验证可以使得测试集上误差更小。
 C. 不是, 选择使得训练集误差小的超参数更好, 因为降低验证集的误差对模型泛化没什么帮助, 而且还可能导致过拟合。
 D. 不是, 选择使得训练集误差小的超参数更好, 因为必须要尽可能地学习训练集, 这样可以确保测试误差最小。

(c)(4 分)单选: 你的朋友建议我们不要将原始训练集分成单独的训练集和验证集, 而是使用测试集作为选择超参数的验证数据。这是个好的方法吗? 用不超过 3 句话来证明你的观点。

- A. Yes B. No

你的观点:

3.(2 分)多选: 考虑一个二元 k -NN 分类器, 其中 $k = 4$, 两个标签是“三角形”和“正方形”。考虑对一个新点 $\mathbf{x} = (1, 1)$ 进行分类, 其中, $\mathbf{x}$ 上方的两个最近邻的类别标签为“三角形”, 下方的两个最近邻的类别标签为“正方形”, 如下所示。



以下哪一种方法可以用来解决或避免这个平局的局面?

- A. 将 x 最近邻的标签作为 x 的标签
 B. 从 x 最近的 4 个邻居的标签中, 掷硬币给 x 随机分配一个标签
 C. 取 $k = 3$
 D. 取 $k = 5$
 E. 以上都不能解决

4. (4 分)多选:以下关于 k -NN 模型的陈述哪些是正确的?

- A. k 越大, 决策边界越平滑。
- B. 为了减少数据中噪声或异常值的影响, 应该增加 k 的值。
- C. 如果让 k 太大, 最终可能会过度拟合数据。
- D. 可以使用交叉验证来帮助选择 k 的值。
- E. 不应该选择验证数据集上误差最小的 k 。
- F. 以上都不正确。

5. 考虑以下关于学习成绩与毕业后工资之间关系的数据。高中 GPA 和大学 GPA 是两个数值特征, 工资是数值目标。请注意, 这里的工资是以每年千美元计算的。

Student ID	High School GPA	University GPA	Salary
1	2.5	3.8	45
2	3.3	3.5	90
3	4.0	4.0	142
4	3.0	2.0	163
5	3.8	3.0	2600
6	3.3	2.8	67
7	3.9	3.8	unknown

(a)(2 分)在 ID 为 1 到 6 的学生中, 用欧氏距离计算, 谁离学生 7 最近?只回答学生号即可。

(b)(4 分)现在, 我们的任务是预测学生 7 毕业后的薪水。用 k -NN 来解决这个回归问题:对数值目标(在本题中是工资)的预测值等于前 k 名最近邻的平均工资。如果 $k = 3$, 我们预测学生 7 的工资是多少?请使用和上面表格相同的度量单位(每年数千美元)。将答案四舍五入到整数。

(c)(2 分)多选:假设上面显示的前 6 名学生只是完整训练数据集中的子集, 完整的训练数据集由 10,000 名学生组成。我们使用欧几里得距离对这个问题进行 k -NN 回归, 并将这个完整数据集的训练损失定义为工资的均方误差(MSE)。

现在考虑以各种方式对数据进行修改后的可能后果。以下哪一项变化会对整个数据集的训练损失产生影响, 其中损失函数定义为工资的均方误差(MSE)?

- A. 将“高中 GPA”重新调整为 4.0 的百分比
- B. 将“大学 GPA”重新调整为 4.0 的百分比
- C. 将“高中和大学的 GPA”都重新调整为 4.0 的百分比
- D. 以上都不会产生影响。

注意: GPA 通常采用 0 到 4.0 的标准化比例, 其中 4.0 代表最高分。如果一个学生的 GPA 是 3.0, 那么按照这个标准, 他的 GPA 可以说是 4.0 的 75%。如果你需要将 GPA 转换为百分比, 可以使用公式 $(\text{GPA} / 4.0) * 100\%$ 进行百分比的转换

例如, 如果一个学生的 GPA 是 3.0, 那么他的 GPA 的百分比就是: $(3.0 / 4.0) * 100\% = 75\%$

3-感知机(26 分)

1. (2 分)单选:考虑在一些样本序列 S 上运行在线感知器算法(一个样本包含一个数据点和它对应的标签)。设 S' 是与 S 内容相同的一组例子, 但内部的样本顺序不同。

判断题: 在线感知器算法在 S' 上和 S 上对样本分类错误的数量相同。

- A.True B. False

2.(3 分)多选:假设我们有一个感知机, 其输入是二维向量, 每个特征向量的值为-1 或 1, 即 $x_i \in \{-1, 1\}$ 。预测函数为 $y = \text{sign}(w_1x_1 + w_2x_2 + b)$, 且 sign 函数表达式如下所示。

下面哪个函数可以实现上面的感知器?即对于下列各个函数, 是否存在一组参数 w, b 来正确地定义该函数。

$$\text{sign}(z) = \begin{cases} 1, & \text{if } z \geq 0 \\ -1, & \text{otherwise.} \end{cases}$$

- A. AND 函数, 即当且仅当所有输入均为 1 时, 该函数值为 1, 否则为-1。
 B. OR 函数, 即当且仅当至少有一个输入为1时, 该函数值为 1, 否则为-1。
 C. XOR 函数, 即当且仅当输入不完全相同时函数值为 1。例如 $\text{XOR}(1, -1) = 1$, $\text{XOR}(1, 1) = -1$ 。
 D. 以上都不可以

3. (2 分)单选:假设我们有一个数据集 $\{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(N)}, y^{(N)})\}$, 其中 $\mathbf{x}^{(i)} \in \mathbb{R}^M, y^{(i)} \in \{+1, -1\}$ 。在这个数据集上应用感知机算法, 假设没有截距项, 则感知机算法要学习多少个参数?

- A. N
 B. $N \times M$
 C. M

4.(2 分)单选:下表显示了一个数据集以及感知器算法在运行过程中对每个点的分类错误的次数。假设初始权重都是 0, 则感知机算法找到的分离平面 θ 是什么, 即 $\theta = [b, \theta_1, \theta_2, \theta_3]$ 的值为多少?

x_1	x_2	x_3	y	Times Misclassified
2	1	5	1	10
5	3	3	1	5
1	6	2	1	8
7	2	1	-1	2
3	2	6	-1	3

- A. [18, 25, 14, 34]
 B. [18, 30, 63, 61]
 C. [16, 56, 18, 47]
 D. [18, 52, 19, 47]

5.(2 分)单选: 关于感知器算法错误界限的陈述, 以下哪些是正确的?


- A. 如果任何数据点到分离超平面的最小距离增加，而数据点没有任何其他变化，则错误界限也会增加。
- B. 如果整个数据集偏离原点，那么错误界限也会增加。
- C. 如果数据点之间的成对距离增加，即数据被按某个常数值缩放，那么错误界限也会增加。
- D. 错误界限与任何数据点到数据的分离超平面的最小距离成线性反比。
- E. 以上都不正确。

6.(2 分)单选:假设我们有数据，其样本形式为 $[x_1, x_2]$ ，其中 $x_1 - x_2 = 0$ ，我们不知道每个元素的标签。假设感知器算法从 $\theta = [3, 5]$ 开始，在对数据运行感知机算法的过程中，以下哪个值的 θ 永远不会出现？

- A. $[-1, 1]$
- B. $[4, 6]$
- C. $[-3, 0]$
- D. $[-6, -4]$

7.(3 分)多选:根据下面的线性决策边界和展示的数据集，选择以下哪些是有效的权重 θ 及其对应的错误率?(假设决策边界是固定的，在计算误差时不会改变。)

- A. $\theta = [-2, 1]$, error=5/13
- B. $\theta = [2, -1]$, error=8/13
- C. $\theta = [2, -1]$, error=5/13
- D. $\theta = [-2, 1]$, error=8/13
- E. 以上都不是。



8.下面将通过一个应用示例，帮助你理解感知机错误界限。下表显示了一个线性可分的数据集，你的任务是确定该数据集的错误界限。

注意: 感知机错误界限的证明要求最优的线性分割器通过原点。为了使线性分割器通过原点，我们将偏置也放到权重中，并在每个训练样本的属性前面添加 x_0 ，并赋值 $x_0 = 1$ 。原始数据在左边，而添加属性 x_0 后的结果显示在右边。在你的计算中，请使用右边的修改后的数据集。

x_1	x_2	y
-2	2	1
-1	-3	-1
-2	-3	-1
0	1	1
2	-1	1

x_0	x_1	x_2	y
1	-2	2	1
1	-1	-3	-1
1	-2	-3	-1
1	0	1	1
1	2	-1	1

(a)(4 分)以原点为中心，计算出将数据点包围起来的"圆圈"的半径 R 。请将结果四舍五入到小数点后四位。

(b)(4 分) 假设最大边距的线性分隔器有下面的关系：

$$\theta^{*T} \begin{bmatrix} 1 \\ x_1 \\ x_2 \end{bmatrix} = 0, \text{ where } \theta^* = \begin{bmatrix} 6 \\ 3 \\ 4 \end{bmatrix}$$

现在，计算数据集的边距。请将结果四舍五入到小数点后四位。

(c)(2 分) 基于以上值，给出这个数据集在这个线性分隔器下的理论感知机错误界限是多少？请将结果四舍五入到小数点后四位。

4-线性回归(25 分)

1.考虑以下数据集:

x	9.0	2.0	6.0	1.0	8.0
y	1.0	0.0	3.0	0.0	1.0

设 $\mathbf{x}$ 是表示样本点， $\mathbf{y}$ 是标签。这里使用梯度下降法来拟合数据，损失函数是 $\frac{1}{N} \sum_{i=1}^N (w x_i + b - y_i)^2$ ，其中 N 为样本数，这里 $N = 5$ ， w 为权值， b 为截距。请写出详细的解答过程。

(a)(4 分)如果初始化权重为 3.0，截距为 0.0，那么在梯度下降更新的第一步中，在所有数据点上计算的损失函数相对于权重 w 的梯度。请将结果四舍五入到小数点后 4 位。

(b)(3 分)在梯度下降更新的第一步中，在所有数据点上计算的损失函数相对于截距 b 的梯度。

(c)(3 分)设学习率为 0.01，对数据执行一步梯度下降。求用此步骤更新后的权重值和截距值。请将结果四舍五入到小数点后 4 位。

2.考虑一个数据集 $\mathcal{D}_1 = \{(x^{(1)}, y^{(1)}), \dots, (x^{(N)}, y^{(N)})\}$ ，假设在 $\mathcal{D}_1$ 上的均方误差最小的线性回归模型为 $y = w_1 x + b_1$ 。

(a)(2 分)单选:现在，假设我们有数据集 $\mathcal{D}_2 = \{(x^{(1)} + \alpha, y^{(1)} + \beta), \dots, (x^{(N)} + \alpha, y^{(N)} + \beta)\}$ ，其中 $\alpha > 0, \beta > 0, w_1 \alpha \neq \beta$ 。假设在 $\mathcal{D}_2$ 上均方误差最小的线性回归模型为 $y = w_2 x + b_2$ 。选

择下面关于 w_1, w_2, b_1, b_2 的正确表述。注意，无论 α, β 在指定约束内取何值，你选择的表述都应成立。

- A. $w_1 = w_2, b_1 = b_2$
- B. $w_1 \neq w_2, b_1 = b_2$
- C. $w_1 = w_2, b_1 \neq b_2$
- D. $w_1 \neq w_2, b_1 \neq b_2$

(b)(2 分)我们决定请朋友分析 $\mathcal{D}_1$ ，但他在复制了 $\mathcal{D}_1$ 的部分行时犯了一个错误，得到了数据集 $\mathcal{D}_2$ 。请解释为什么在 $\mathcal{D}_2$ 上最小化均方误差的线性回归参数可能与在 $\mathcal{D}_1$ 上学习到的参数不同（即 w_1, b_1 可能和 w_2, b_2 不同）。

3.在数据集 $\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(N)}, y^{(N)})\}$ 上学习线性回归模型，其中 $\mathbf{x} \in \mathbb{R}^k$ 。对于这个问题，定义 log-cosh 损失为：

$$\ell(\hat{y}, y) = \log(\cosh(\hat{y} - y))$$

特别地，对于给定点 $\mathbf{x}^{(i)}$ ，参数为 $\boldsymbol{\theta}$ 的模型的 log-cosh 损失为：

$$J^{(i)}(\boldsymbol{\theta}) = \log(\cosh(\boldsymbol{\theta}^T \mathbf{x}^{(i)} - y^{(i)}))$$

为最小化训练数据上的损失，所以需要最小化 $\mathcal{D}$ 中所有点的平均 log-cosh 损失。

(a)(2 分)在这种情况下，目标 $J(\boldsymbol{\theta})$ 是什么？

(b)(3 分) $J^{(i)}(\boldsymbol{\theta})$ 对第 j 个参数 θ_j 的偏导数是多少？提示： $\frac{d}{dx} \cosh(x) = \sinh(x)$

(c)(2 分) $J^{(i)}(\boldsymbol{\theta})$ 对整个参数向量 $\boldsymbol{\theta}$ 的梯度是多少？

(d)(4 分)为了找到最小化 $J(\boldsymbol{\theta})$ 的最优参数向量 $\boldsymbol{\theta}^*$ ，使用梯度下降法，编写伪代码，在一次迭代中执行梯度下降。设学习率 $\alpha = 0.1$ ，初始化 $\boldsymbol{\theta}$ 为零向量。可以使用 `gradient []`作为变量，该变量包含(c)中的部分答案。请将你的伪代码限制在 10 行以内。

提交要求：

书面部分需要提交的文件：

回答所有问题后，请提交 PDF 格式的文件。具体命名规则：HW3_张三_22920202209999.pdf
标清题号，只写解题过程和答案即可，不要带题目！