

补充作业1答案

- [问题背景](#)
- [补充知识](#)
 - [矩阵求导的布局](#)
 - [第一种：分子布局——Jacobian矩阵形式](#)
 - [第二种：分母布局——梯度矩阵形式](#)
 - [牛顿法](#)
 - [一元函数的情况](#)
 - [求零点](#)
 - [求极值点](#)
 - [多元函数的情况](#)
 - [二乘法](#)
 - [最小二乘法](#)
 - [加权最小二乘法](#)
 - [迭代加权最小二乘法](#)
- [问题](#)
- [提交格式](#)

问题背景

对于数据集 $\{< \mathbf{x}_i, y_i >\}_{i=1}^n$ ，其中 $\mathbf{x}_i \in R^{d \times 1}$, $y_i \in \{0, 1\}$ 。在给定特征的条件下，标签服从伯努利分布：

$$y_i \mid \mathbf{x}_i; \theta \sim B(\sigma_i)$$

其中 $\sigma_i = \sigma(\mathbf{x}_i; \theta) = \frac{1}{1 + e^{-\theta^T \mathbf{x}_i}}$

目标函数：

$$\mathcal{L}_D(\theta) = -\log \prod_{i=1}^n P(y_i \mid \mathbf{x}_i; \theta) = -\sum_{i=1}^n y_i \log \sigma_i + (1 - y_i) \log (1 - \sigma_i)$$

对其求一阶导的结果是：

$$\nabla_{\theta} \mathcal{L}_D(\theta) = \sum_{i=1}^n (\sigma_i - y_i) \mathbf{x}_i$$

注意此处得到的结果是 $d \times 1$ 维。

补充知识

矩阵求导的布局

给定 $\mathbf{F}$ ，其中 $\mathbf{X}_{m \times n} = (x_{ij})_{i=1, j=1}^{m, n}$, $\mathbf{F}_{p \times q} = (f_{ij})_{i=1, j=1}^{p, q}$ 。

因为向量本质上就是一种特殊的矩阵，只用讨论下面这种最复杂的情况即可。矩阵函数下自变量为矩阵的矩阵布局有两种。

矩阵函数求导，且自变量也为矩阵的情况下，必须要将矩阵函数和矩阵自变量都进行列向量化：

将矩阵自变量列向量化如下：

$$\text{vec}(\mathbf{X}) = [x_{11}, x_{21}, \dots, x_{m1}, x_{12}, x_{22}, \dots, x_{m2}, \dots, x_{1n}, x_{2n}, \dots, x_{mn}]^T$$

将矩阵函数 $\mathbf{F}$ 列向量化如下：

$$\text{vec}(\mathbf{F}(\mathbf{X})) = [f_{11}(\mathbf{X}), f_{21}(\mathbf{X}), \dots, f_{p1}(\mathbf{X}), f_{12}(\mathbf{X}), f_{22}(\mathbf{X}), \dots, f_{p2}(\mathbf{X}), \dots, f_{1q}(\mathbf{X}), f_{2q}(\mathbf{X}), \dots, f_{pq}(\mathbf{X})]^T$$

第一种：分子布局——Jacobian矩阵形式

$$\begin{aligned}
 D_{\mathbf{X}} \mathbf{F}(\mathbf{X}) &= \frac{\partial \text{vec}_{pq \times 1}(\mathbf{F}(\mathbf{X}))}{\partial \text{vec}_{mn \times 1}^T \mathbf{X}} \\
 &= \begin{bmatrix} \frac{\partial f_{11}}{\partial x_{11}} & \frac{\partial f_{11}}{\partial x_{21}} & \cdots & \frac{\partial f_{11}}{\partial x_{mn}} \\ \frac{\partial f_{21}}{\partial x_{11}} & \frac{\partial f_{21}}{\partial x_{21}} & \cdots & \frac{\partial f_{21}}{\partial x_{mn}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_{pq}}{\partial x_{11}} & \frac{\partial f_{pq}}{\partial x_{21}} & \cdots & \frac{\partial f_{pq}}{\partial x_{mn}} \end{bmatrix}_{pq \times mn}
 \end{aligned}$$

上面这种形式，可以类比为普通矩阵乘法，分子布局，分子在前，分母转置：

$$(pq \times 1) \cdot (1 \times mn) \rightarrow pq \times mn$$

第二种：分母布局——梯度矩阵形式

$$\begin{aligned}
 \nabla_{\mathbf{X}} \mathbf{F}(\mathbf{X}) &= \frac{\partial \text{vec}_{pq \times 1}^T(\mathbf{F}(\mathbf{X}))}{\partial \text{vec}_{mn \times 1} \mathbf{X}} \\
 &= \begin{bmatrix} \frac{\partial f_{11}}{\partial x_{11}} & \frac{\partial f_{21}}{\partial x_{11}} & \cdots & \frac{\partial f_{pq}}{\partial x_{11}} \\ \frac{\partial f_{11}}{\partial x_{21}} & \frac{\partial f_{21}}{\partial x_{21}} & \cdots & \frac{\partial f_{pq}}{\partial x_{21}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_{11}}{\partial x_{mn}} & \frac{\partial f_{21}}{\partial x_{mn}} & \cdots & \frac{\partial f_{pq}}{\partial x_{mn}} \end{bmatrix}_{mn \times pq}
 \end{aligned}$$

上面这种形式，可以类比为普通矩阵乘法，分母布局，分母在前，分子转置：

$$(mn \times 1) \cdot (1 \times pq) \rightarrow mn \times pq$$

牛顿法

牛顿法是利用泰勒公式的前面几项，快速迭代从而求出函数根的方法。

一元函数的情况

一元函数的泰勒公式为：


$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2} f''(x_0)(x - x_0)^2 + o((x - x_0)^2)$$

求零点

去掉泰勒公式的二次及以上的项，令 $f(x) = 0$ ，可以将公式化简为：

$$x = x_0 - \frac{f(x_0)}{f'(x_0)}$$

从而我们能够得到下一个迭代点的位置。其本质上就是重复得作切线，从而接近零点。如下图所示。



求极值点

去掉二次以上的项，我们需要令一阶导数为0，可以令 $f'(x) = 0$ ，可得如下公式：

$$f'(x) = f'(x_0) + f''(x_0)(x - x_0) = 0$$

进一步化简为：

$$x = x_0 - \frac{f'(x_0)}{f''(x_0)}$$

于是我们继续进行迭代，就能获得一阶导数为0点的估计值。

多元函数的情况

多元函数的泰勒公式为：

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0) \cdot (\mathbf{x} - \mathbf{x}_0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^T \cdot \nabla^2 f(\mathbf{x}_0) \cdot (\mathbf{x} - \mathbf{x}_0) + o(\|\mathbf{x} - \mathbf{x}_0\|^2)$$

此时若要用牛顿迭代法，求极值点的值，可以先去掉二阶以上的部分。并对上式两边同时求导数，最终可得：

$$x = x_0 - \left(\nabla^2 f(\mathbf{x}_0)\right)^{-1} \nabla f(\mathbf{x}_0)$$

继续迭代，即可获得该多元函数的极值点的估计值。

二乘法

最小二乘法

最小二乘法（Least Squares, LS）主要目的是通过最小化误差的平方和来找到数据的最佳函数匹配。

- X ：数据矩阵，每一列代表一种特征，每一行代表一个样本。

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots \\ x_{21} & x_{22} & \dots \\ x_{31} & x_{32} & \dots \\ \dots & \dots & x_{mn} \end{bmatrix}$$

- Y ：标签向量。

$$Y = \begin{bmatrix} y_1 \\ \dots \\ y_m \end{bmatrix}$$

- θ ：参数向量。

$$\theta = \begin{bmatrix} \theta_1 \\ \dots \\ \theta_n \end{bmatrix}$$

目标是最小化下面的损失函数 $f(\theta)$ ：

$$f(\theta) = \frac{1}{2} \|X\theta - Y\|^2$$

损失函数可以进一步展开为：

$$f(\theta) = \frac{1}{2} (\theta^T X^T X \theta - \theta^T X^T Y - Y^T X \theta + Y^T Y)$$

对损失函数 $f(\theta)$ 关于参数 θ 求偏导数，使偏导数等于零，可以得到最优解的闭式表达式：

$$\frac{\partial f(\theta)}{\partial \theta} = X^T X \theta - X^T Y = 0$$

从而得到参数 θ 的解析解为：

$$\theta = (X^T X)^{-1} X^T Y$$

通过最小二乘法的求解过程，我们可以得到参数 θ 的值，从而找到数据的最佳函数匹配。

加权最小二乘法

加权最小二乘法（Weighted Least Squares, WLS）是在普通最小二乘的基础上，对每个样本引入权重，以调整不同样本误差对损失函数的贡献。通过加权，WLS 使得模型能够处理异方差性问题，然后再通过普通最小二乘法估计参数。

- W ：权重矩阵，为一个对角矩阵，每个对角线元素 w_{ii} 代表第 i 个样本的权重。

$$W = \begin{bmatrix} w_{11} & \dots & 0 & 0 \\ 0 & w_{22} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & w_{mm} \end{bmatrix}$$

目标是最小化下面的损失函数 $f(\theta)$ ：

$$f(\theta) = \frac{1}{2} \|W(X\theta - Y)\|^2$$

损失函数可以进一步展开为：

$$f(\theta) = \frac{1}{2} (W\theta^T X^T A \theta - W\theta^T A^T Y - WY^T A \theta + WY^T Y)$$

对损失函数 $f(\theta)$ 关于参数 θ 求偏导数，使偏导数等于零，可以得到最优解的闭式表达式：

$$\frac{\partial f(\theta)}{\partial \theta} = -X^T W^T W Y + X^T W^T W X \theta = 0$$

从而得到参数 θ 的解析解为：

$$\theta = (X^T W^T W X)^{-1} X^T W^T W Y$$

通过加权最小二乘法的求解过程，我们可以得到参数 θ 的值，从而找到数据的最佳函数匹配，同时处理了异方差性问题。

迭代加权最小二乘法

迭代重加权最小二乘法（Iterative Reweighted Least Squares, IRLS）是一类方法，是一种思想。它的本质在于将复杂的非线性优化问题通过迭代的方式，转化为一系列更容易处理的线性优化问题。在每次迭代中，它通过在当前点附近线性化目标函数，然后解决这个线性问题来更新参数。这个过程会不断重复，直到找到满足某些停止准则的解。

我们以求解带有 p 范数的函数拟合问题为例来介绍这种方法。通过迭代过程，IRLS 将 p 范数问题转化为一系列的二范数问题，并逐步逼近最优解。

- p 范数定义为：

$$\|X\|_p = (x_1^p + x_2^p + \dots + x_m^p)^{\frac{1}{p}}$$

原始的目标函数是：

$$f(\theta) = \|AX - Y\|_p^p = \sum_{i=1}^m (x_i \theta - y_i)^p$$

将 p 范数问题转化为二范数问题，目标函数变为：

$$f(\theta) = \sum_{i=1}^m w_i^2 (x_i \theta - y_i)^2$$

其中，权重 w_i 的计算公式为：

$$w_i = |x_i \theta - y_i|^{\frac{p-2}{2}}$$

写成矩阵形式，目标函数变为：

$$f(\theta) = \frac{1}{2} \|W(X\theta - Y)\|_2^2 = \frac{1}{2} W^2 \|X\theta - Y\|_2^2$$

- 初始化 θ 为某个值（例如零向量）。
- 在每次迭代中，根据当前的 θ 值计算权重矩阵 W ：

$$W_{new} = |X\theta_{old} - Y|^{\frac{p-2}{2}}$$

- 使用新的权重矩阵 W_{new} 更新 θ ：

$$\theta_{new} = (X^T W_{new}^T W_{new} X)^{-1} X^T W_{new}^T W_{new} Y$$

4. 重复步骤 2 和 3，直到 θ 收敛。

通过这个迭代过程，IRLS 方法能够逐步逼近 p 范数优化问题的最优解。

问题

1. (10分)请求出目标函数的Hessian矩阵(二阶导):

$$H \triangleq \nabla_{\theta}^2 \mathcal{L}_D(\theta)$$

注意：本题请使用分母布局的格式。

答：

求Hessian矩阵如下：

$$H = \frac{\partial(\nabla_{\theta} \mathcal{L}_D(\theta))^T}{\partial \theta}$$

已知其中：

$$\nabla_{\theta} \mathcal{L}_D(\theta) = \sum_{k=1}^n (\sigma_k - y_k) \mathbf{x}_k$$

那么每一个Hessian矩阵的元素 H_{ij} 为：

$$H_{ij} = \frac{\partial \left(\sum_{k=1}^n (\sigma_k - y_k) x_{ki} \right)^T}{\partial \theta_j} = \sum_{k=1}^n x_{ki} \sigma_k (1 - \sigma_k) x_{kj}$$

故可整理得完整的Hessian矩阵的形式为：

$$H = \sum_{k=1}^n \sigma_k (1 - \sigma_k) \mathbf{x}_k \mathbf{x}_k^T$$

其维度为 $d \times d$ 。（写到这一步均可给分）

继续整理，我们可以将 $\{\mathbf{x}_k\}_{k=1}^n$ 给叠成一个 $X_{n \times d}$ 形式的矩阵，并继续写成如下形式：

$$H = X_{d \times n}^T B_{n \times n} X_{n \times d}$$

其中：

$$B_{n \times n} = \begin{bmatrix} \sigma_1(1 - \sigma_1) & 0 & \cdots & 0 \\ 0 & \sigma_2(1 - \sigma_2) & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n(1 - \sigma_n) \end{bmatrix}$$

$B_{n \times n}$ 矩阵中的 $\sigma_i(1 - \sigma_i)$ 是取值范围为0-1的分布的方差。作为权重，用于控制有些样本特征无用，有些权重更高则特征更有用。

这里的Hessian矩阵还是描述特征之间的相关性的矩阵，只是中间的 $B_{n \times n}$ 矩阵给不同的特征加上了权重。

2. (10分)写出上述逻辑斯蒂回归(Logistics Regression)的牛顿法(Newton)实现算法。

答：

Algorithm 1 牛顿法实现逻辑斯蒂回归

```
1: 初始化参数  $\theta^{(0)}$ 
2: 选择停止准则, 例如最大迭代次数  $T$  和容忍度  $\epsilon$ 
3: for  $t = 0, 1, \dots, T$  do
4:   计算梯度  $\nabla \mathcal{L}_D(\theta^{(t)})$ 
5:   计算 Hessian 矩阵  $H = \nabla^2 \mathcal{L}_D(\theta^{(t)})$ 
6:   更新参数:  $\theta^{(t+1)} = \theta^{(t)} - H^{-1} \nabla \mathcal{L}_D(\theta^{(t)})$ 
7:   if  $\|\theta^{(t+1)} - \theta^{(t)}\| < \epsilon$  then
8:     停止迭代
9:   end if
10: end for
11: 输出最终参数  $\theta^{(T)}$ 
```

有理即给分。

3. (10分)详细阐述迭代加权最小二乘法(Iterative Reweighted Least Square)和问题2中牛顿法的关系。

答:

若采用一般的梯度下降法求解, 迭代公式为:

$$\theta^{\text{new}} = \theta^{\text{old}} - \eta \nabla \mathcal{L}_D(\theta)$$

我们可以用牛顿法, 将逻辑回归这个非线性问题, 给转换为局部的线性问题, 然后再来不停更新参数进行求解。

$$\theta^{\text{new}} = \theta^{\text{old}} - H^{-1} \nabla \mathcal{L}_D(\theta^{\text{old}}) = \theta^{\text{old}} - (X^T B X)^{-1} X^T (\sigma - y)$$

由此可见, 牛顿法可以算是迭代加权最小二乘法的一种, 两者是等价的。

提交格式

将答案, 整理成PDF格式, 命名为 学号_姓名_补充1_Answer.pdf, 直接提交即可。