

补充作业3

- [问题背景](#)
 - [混合伯努利模型](#)
 - [推广的EM算法](#)
 - [混合高斯模型](#)
- [问题](#)
- [提交格式](#)

问题背景

混合伯努利模型

伯努利混合模型是指具有如下形式的概率分布模型:

$$P(y \mid \theta) = \sum_{k=1}^K \alpha_k \phi(y \mid \theta_k)$$

其中, $\theta = (\theta_1, \theta_2, \dots, \theta_K)$, α_k 是权重, $\alpha_k \geq 0, \sum_{k=1}^K \alpha_k = 1$; $\phi(y \mid \theta_k)$ 是伯努利分布,

$$\phi(y \mid \theta_k) = \theta_k^y (1 - \theta_k)^{1-y}$$

称为第 k 个分模型。

伯努利混合模型参数估计的EM算法:

假设观测数据 $y_1, y_2, \dots, y_N$ 由伯努利混合模型生成:

$$P(y \mid \theta) = \sum_{k=1}^K \alpha_k \phi(y \mid \theta_k)$$


其中, $\theta = (\theta_1, \theta_2, \dots, \theta_K)$.

接下来我们详细叙述, 使用EM算法估计伯努利混合模型的参数 θ 的过程:

我们先来对EM算法的一般形式进行推导。我们还是使用的MLE的思想, 想求出能够将 $P(Y \mid \{\alpha, \theta\})$ 最大化的参数 $\{\alpha, \theta\}$, 按照流程先写出公式如下:

$$P(\mathbf{Y} \mid \{\alpha, \theta\}) = \prod_{n=1}^N \sum_{k=1}^K \alpha_k P(y_n \mid \theta_k)$$
$$\log P(\mathbf{Y} \mid \{\alpha, \theta\}) = \sum_{n=1}^N \log \sum_{k=1}^K \alpha_k P(y_n \mid \theta_k)$$

可是显然上述公式存在很大的问题, 因为我们发现求和符号在对数函数里面, 于是我们必须要考虑一个更完整的模型, 加入隐藏变量 $Z = \{z_{nk}\}$, 这个更完整的模型的概率图模型如下:



其中的 z_{nk} 是一个隐含变量，表示数据点 y_n 来自第 k 个贝努利分布。当我们加入这个隐藏变量之后，非常直观得，在后面的混合伯努利模型中就可以将log函数内部的求和符号去掉，并替换成指数符号。

我们首先通过一般的MLE方法来尝试求 θ_k 和 α_k 的导数。先对 θ_k 求导并置为0，可得：

$$0 = \sum_{n=1}^N \frac{\alpha_k}{\sum_{j=1}^K \alpha_j P(y_n | \theta_j)} \cdot \frac{\partial P(y_n | \theta_k)}{\partial \theta_k}$$

其中：

$$\frac{\partial P(y_n | \theta_k)}{\partial \theta_k} \triangleq f(\theta_k; y_n) P(y_n | \theta_k)$$

其中 $P(y_n | \theta_k)$ 对应的是伯努利分布的概率密度函数；而 $f(\theta_k; y_n)$ 对应的是针对参数 θ_k 的导数部分。

因此我们有：

$$0 = \sum_{n=1}^N \frac{\alpha_k P(y_n | \theta_k)}{\sum_{j=1}^K \alpha_j P(y_n | \theta_j)} \cdot f(\theta_k; y_n)$$

上面是用MLE的方法来做本题，接下来要将上式的一部分用新引入的变量 z_{nk} 来进行替换。这里我们引入不变的 $q(Z)$ 分布，在 z_{nk} 各点不变的前提下，计算出新参数。对新参数的计算，本质上是在优化后面出现的完全数据的对数似然的期望 Q 函数。具体的解释见推广的EM算法部分。

我们来分析 z_{nk} 的性质，它应该是一个二维数组，在确定 n 的前提下，在 k 方向是一个one-hot的向量，而我们需要研究的，也正是这个概率 $P(z_{nk} = 1 | y_n, \{\alpha, \theta\})$ ，将这个概率记为 $\gamma(z_{nk})$ ：

$$\gamma(z_{nk}) = P(z_{nk} = 1 | y_n, \{\alpha, \theta\}) = \frac{P(y_n | z_{nk} = 1, \{\alpha, \theta\}) P(z_{nk} = 1 | \{\alpha, \theta\})}{P(y_n | \{\alpha, \theta\})}$$

其中：

$$\begin{cases} P(y_n | z_{nk} = 1, \{\alpha, \theta\}) = P(y_n | \theta_k) \\ P(z_{nk} = 1 | \{\alpha, \theta\}) = \alpha_k \\ P(y_n | \{\alpha, \theta\}) = \sum_{j=1}^K P(y_n, z_{nj} | \{\alpha, \theta\}) = \sum_{j=1}^K \alpha_j P(y_n | \theta_j) \end{cases}$$

代入上式中得：

$$\gamma(z_{nk}) = \sum_{n=1}^N \frac{\alpha_k P(y_n | \theta_k)}{\sum_{j=1}^K \alpha_j P(y_n | \theta_j)}$$

也即可知对 q_k 进行求导的话，结果是：

$$0 = \sum_{n=1}^N \gamma(z_{nk}) \cdot f(\theta_k; y_k)$$

对于有的模型，我们可以求出 $f(\theta_k; y_k)$ ，随后就可通过此式对 θ_k 进行迭代求解。

而对于参数 α_k 来说，有两种方法求解，我们在此不介绍使用Langrange乘子法的复杂方法，而是用定义法，定义 $\sum_{n=1}^N \gamma(z_{nk}) = N_k$ ，其中 N_k 可以解释为来自组件 k 的数据点的“期望”数量。因此：

$$\alpha_k = \frac{N_k}{N} = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$

接下来介绍EM算法的步骤，分别是E步骤和M步骤：

(1) E步骤：固定参数不变，更新分布 $q(Z)$

首先利用先验知识，或者随机初始化获得参数 $\{\alpha^{old}, \theta^{old}\}$ ：

$$\gamma(z_{nk}) = P(z_{nk} = 1 | y_n, \{\alpha, \theta\}) = \frac{\alpha_k^{old} P(y_n | \theta_k^{old})}{\sum_{j=1}^K \alpha_j^{old} P(y_n | \theta_j^{old})}$$

其中 $\gamma(z_{nk})$ 组合起来，就是分布 $q(Z)$ 了

(2) M步骤：更新参数 $\{\alpha, \theta\}$ ：

$$\alpha_k^{new} = \frac{N_k}{N} = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$

解如下方程求解 θ_k^{new} :

$$0 = \sum_{n=1}^N \gamma(z_{nk}) \cdot f(\theta_k^{new}; y_n)$$

$$\{\alpha_k^{new}, \theta_k^{new}\} \rightarrow \{\alpha_k^{old}, \theta_k^{old}\}$$

我们先对混合伯努利模型进行定义：

假设我们一共有 N 个样本 $Y = \langle y_n \rangle_{n=1}^N$ ，每个数据点都是从 K 个参数为 θ_k 的伯努利分布中的一个中抽取出来的。因此若第 n 个数据点是从第 k 个分布中抽取出来的话，就有其抽样概率为：

$$P(y_n | \theta_k) = \theta_k^{y_n} (1 - \theta_k)^{1-y_n}$$

对于此分布来说,

$$f(\theta_k; y_n) = \frac{y_n}{\theta_k} - \frac{1 - y_n}{1 - \theta_k}$$

于是我们解方程 $0 = \sum_{n=1}^N \gamma(z_{nk}) \cdot f(\theta_k; y_n)$ 有：

$$\theta_k = \frac{\sum_{n=1}^N \gamma(z_{nk}) y_n}{\sum_{n=1}^N \gamma(z_{nk})}$$

代入上面的通用EM步骤迭代足够的次数，即可求得参数的解。

参考资料：

<https://dawenl.github.io/files/em.pdf>

推广的EM算法

我们对EM算法还是没一个深刻的认识。比如，为什么这样做，就能够调整参数，让原概率最大化呢。于是我们必须要将MLE要最大化的原概率式拿出来，进一步进行分析：

$$\begin{aligned} \log P(\mathbf{Y} | \{\alpha, \theta\}) &= \log \sum_{\mathbf{Z}} P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\}) \\ &= \log \left(\sum_{\mathbf{Z}} \frac{P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\})}{q(\mathbf{Z})} q(\mathbf{Z}) \right) \\ &\geq \sum_{\mathbf{Z}} q(\mathbf{Z}) \log \left(\frac{P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\})}{q(\mathbf{Z})} \right) \end{aligned}$$

我们来解释一下上式中的变量的意义：

$P(Y, Z | \{\alpha, \theta\})$ 是一个联合概率分布，它表示在给定参数 $\{\alpha, \theta\}$ 的条件下，观察到数据 X 和隐变量 Z 的概率。

$q(Z)$ 是一个人为创造的，用来逼近 $P(Z|Y, \{\alpha, \theta\})$ 的变分分布，单个的点 $\gamma(z_{nk})$ 组合起来就形成了 $q(Z)$ 。这种思路属于是变分观点（Variational Perspective）。这是一种理解和处理统计问题的方法，尤其在处理含有隐变量或者无法直接解析求解的问题时。在这种观点中，我们通过寻找一种替代的分布来近似我们的目标分布，然后优化这个替代分布来近似解决原问题。

而且上式中使用的是Jessen不等式：对于一个凸函数 f ，和一个随机变量 X ，有此关系 $f(E[X]) \leq E[f(X)]$ ，也即，函数在期望值处的值小于等于函数值的期望。


在我们的表达式中， $\log \left(\frac{P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\})}{q(\mathbf{Z})} \right)$ 可以看作是对应于随机变量 $\mathbf{Z}$ 的函数。而 $q(\mathbf{Z})$ 是随机变量 $\mathbf{Z}$ 的概率分布。所以，这个表达式实际上是在计算这个函数 $\log \left(\frac{P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\})}{q(\mathbf{Z})} \right)$ 在分布 $q(\mathbf{Z})$ 下的期望值。

另外，对随机变量 $\mathbf{Z}$ 的函数 $\frac{P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\})}{q(\mathbf{Z})}$ 计算 $q(\mathbf{Z})$ 下的期望值 $\sum_{\mathbf{Z}} \frac{P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\})}{q(\mathbf{Z})} q(\mathbf{Z})$ ，然后将函数 $\log$ 应用于这个期望值。

于是就有了上述可以使用Jessen不等式的基础了。

再然后，我们来考察一下这个不等式左右两边的差，争取能将其写成一个等式：

$$\log P(\mathbf{Y}|\{\alpha, \theta\}) = \underbrace{\sum_{\mathbf{Z}} q(\mathbf{Z}) \log \left(\frac{P(\mathbf{Y}, \mathbf{Z}|\{\alpha, \theta\})}{q(\mathbf{Z})} \right)}_{ELBO = \mathcal{L}(q, \{\alpha, \theta\})} + \underbrace{\sum_{\mathbf{Z}} q(\mathbf{Z}) \log \left(\frac{q(\mathbf{Z})}{P(\mathbf{Z}|\mathbf{Y}, \{\alpha, \theta\})} \right)}_{\Delta = KL(q||p) \geq 0}$$




如图所示，我们的目标是调整参数，使 $P(Y|\{\alpha, \theta\})$ 尽可能最大，也即使其对数尽可能大是等价的。而又知KL距离必然大于等于0。故ELBO是我们待优化目标概率式的一个下界。

还可以进一步将ELBO部分写作如下形式：

$$\mathcal{L}(q, \{\alpha, \theta\}) = \sum_{\mathbf{Z}} q(\mathbf{Z}) \log P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\}) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \log q(\mathbf{Z})$$

现在我们来开始分析EM算法的两个步骤，对于最大化目标概率式有何意义：

(1) 首先是进行E步骤时，我们的主要工作，就是在维持参数不变的前提下，对 $q(Z)$ 分布进行了优化，使得 $q(Z) = P(Z|Y, \{\alpha, \theta\}^{old})$ ，也即让 $KL(q||p) = 0$ 。




此时由于参数未变，故 $\ln P(Y|\{\alpha, \theta\})$ 也不变，而KL散度变为了0。故ELBO与 $\ln P(Y|\{\alpha, \theta\})$ 相等了。

(2) 随后进行了参数更新，而维持 $q(Z)$ 分布不变。

此时是进行了E步骤之后，我们可以将 $q(Z) = P(Z|Y, \{\alpha, \theta\}^{old})$ 代入ELBO式中，用来研究其新形式：

$$\begin{aligned} \mathcal{L}(q, \{\alpha, \theta\}) &= \underbrace{\sum_{\mathbf{Z}} P(Z|Y, \{\alpha, \theta\}^{old}) \log P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\})}_{Q(\{\alpha, \theta\}, \{\alpha, \theta\}^{old})} \\ &\quad - \underbrace{\sum_{\mathbf{Z}} P(Z|Y, \{\alpha, \theta\}^{old}) \log P(Z|Y, \{\alpha, \theta\}^{old})}_{\text{Negative entropy of } P(Z|Y, \{\alpha, \theta\}^{old})} \\ &= Q(\{\alpha, \theta\}, \{\alpha, \theta\}^{old}) + \text{const} \end{aligned}$$

本质上，我们更新参数时优化的是完整数据的对数似然函数的期望 $Q(\{\alpha, \theta\}, \{\alpha, \theta\}^{old})$ ，如上式所示，在代入固定的分布 $q(Z)$ 之后，可以将其写成完整数据的对数似然函数的期望 Q 函数和固定分布 $q(Z)$ 的负熵，后者在 $q(Z)$ 分布不变的前提下，是一个常数。我们只要更新参数，以使 Q 函数的值变大，即可让ELBO的值变大，如下图所示。这时新参数下的 $P(Z|Y, \{\alpha, \theta\}^{new})$ 与之前固定的 $q(Z)$ 分布不再完全相等了，于是两者之间的 $KL(q||p) > 0$ ，如下图所示，也即我们需要优化的概率函数的上界就此提高了。



接下来，正式对优化 Q 函数，计算新参数的过程进行推导：

首先，我们定义一下什么是完全数据：存在隐变量时，完全数据就是指观测数据和隐变量的和。

完全数据的似然函数如下：

$$L(Y, Z | \{\alpha, \theta\}) = \prod_{n=1}^N \prod_{k=1}^K (\alpha_k P(y_n | \theta_k))^{z_{nk}}$$

其中， $\{\alpha, \theta\}$ 是参数集，包括 α_k 和 θ_k ， Y 是观测数据， Z 是隐变量， $P(y_n | \theta_k)$ 是从第 k 类中抽样的分布。

完全数据的对数似然函数如下：

$$\log L(Y, Z | \{\alpha, \theta\}) = \sum_{n=1}^N \sum_{k=1}^K z_{nk} (\log \alpha_k + \log P(y_n | \theta_k))$$

然而，在存在隐变量的情况下，我们通常无法直接最大化这个对数似然函数，因为 z_{nk} 是未知的。

于是采用EM算法的策略，其中E步骤就是计算在当前参数下隐变量的期望值，即计算 $\gamma(z_{nk})$ 。然后，我们就可以固定 z_{nk} 不变，将其替换为它的期望值 $\gamma(z_{nk})$ ，得到期望的对数似然函数：

$$\begin{aligned} Q(\{\alpha, \theta\}^{old}, \{\alpha, \theta\}^{new}) &= E_q[\log L(Y, Z | \{\alpha, \theta\}^{new})] \\ &= \sum_{\mathbf{Z}} P(\mathbf{Z} | Y, \{\alpha, \theta\}^{old}) \log P(\mathbf{Y}, \mathbf{Z} | \{\alpha, \theta\}^{new}) \end{aligned}$$

通过这个概率函数对参数求导，就能得到混合伯努利模型部分中的结论。

总结来看，上面的三张图已经完整表述了在E步骤和M步骤中，调整参数，都只会让目标的对数似然函数增加，所以能够保证EM算法是有效的。

参考资料：

PRML第九章

混合高斯模型

高斯混合模型：

高斯混合模型是指具有如下形式的概率分布模型：

$$P(\mathbf{y} | \theta) = \sum_{k=1}^K \alpha_k \phi(\mathbf{y} | \mu_k, \Sigma_k)$$

其中， α_k 是权重， $\alpha_k \geq 0, \sum_{k=1}^K \alpha_k = 1$ ； $\phi(\mathbf{y} | \mu_k, \Sigma_k)$ 是高斯分布密度，

$$\phi(\mathbf{y} | \mu_k, \Sigma_k) = (2\pi)^{-\frac{d}{2}} \det(\Sigma_k)^{-\frac{1}{2}} \cdot \exp \left\{ -\frac{1}{2} (\mathbf{y} - \mu_k)^T \Sigma_k^{-1} (\mathbf{y} - \mu_k) \right\}$$

称为第 k 个分模型。

高斯混合模型参数估计的EM算法

对于男生女生身高模型，随机变量 Y 是由两个高斯分布混合而成(男性的高斯分布和女性的 高斯分布)。

为了通用性，假设一共有 K 个高斯分布，于是随机变量 Y 是有 K 个高斯分布混合而成，取 各个高斯分布的概率为 $\alpha_1, \alpha_2, \dots, \alpha_K$ ，第 k 个高斯分布的均值为 μ_k ，方差为 Σ_k 。

而目标也就变成: 若观测到随机变量 Y 的一系列样本 $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N$ ，由高斯混合模型生成,

$$P(\mathbf{y} \mid \theta) = \sum_{k=1}^K \alpha_k \phi(\mathbf{y} \mid \mu_k, \Sigma_k)$$

其中， $\theta = (\alpha_1, \alpha_2, \dots, \alpha_K; \mu_1, \mu_2, \dots, \mu_K; \Sigma_1, \Sigma_2, \dots, \Sigma_K)$ 。

记 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_K), \mu = (\mu_1, \mu_2, \dots, \mu_K), \Sigma = (\Sigma_1, \Sigma_2, \dots, \Sigma_K)$

问题

- （30分）请用EM算法估计高斯混合模型的参数 θ , 也即求解 α, μ, Σ （给出M步骤公式即可）。

提交格式

将答案，整理成PDF格式，命名为 学号_姓名_补充3_Answer.pdf，直接提交即可。