

认知计算

- 认知模型
- 机器学习
- 听觉信息认知计算
- 视觉信息认知计算

- **认识计算**源自模拟人脑的计算机系统的人工智能。
- 90年代后，研究人员开始用**认知计算**一词，以表明该学科用于教计算机像人脑一样思考，而不只是开发一种人工系统。
- **人工智能**重在研制一种能够实现人类认知功能的人工机器，而**认识计算**则重在研究可以模拟人类的认知功能的计算原理和方法。
- 传统的计算技术是**定量的**，并着重于**精度**和**序列等级**，而认知计算则试图解决生物系统中的**不精确**、**不确定**和**部分真实的**问题，以实现易于处理、强劲和低价的工程问题解决方案。
- 认知计算是一种**自上至下的**、**全局性的**统一理论研究，旨在解释观察到的认知现象(思维)，符合已知的自下而上的神经生物学事实(大脑)，可以进行计算，也可以用数学原理解释。
- **认知计算**寻求一种符合已知的有着大脑神经生物学事实的计算机科学类的软件元件，并用于处理感知、记忆、语言、智力和意识等心智过程。

1 认知模型

- 人类认知过程的计算机模型即为**认知模型**。**认知建模**即为建立认知模型的技术，其目的是为了从某些方面研究和探索人的思维机制，特别是人的信息处理机制，同时也为设计相应的人工智能系统提供新的体系结构和技术方法。
- 一般人们将认识分成**感性认识**和**理性认识**两个阶段，包括了**感知过程**、**表象过程**、**记忆过程**、**思维过程**等人的认知过程。如果把这些认知过程结合起来构成一个完整的控制系统，并采用信息的输入、存储、检索、加工、输出等概念，就能揭示出认知的实质和相互之间的内在联系，并说明人从感觉经过表象、记忆思维而做出反应的全过程。
- 若把人看成一个**信息加工系统**，那么认知科学的研究主要**采用信息观点和加工理论研究如何注意和选择信息，对信息的认识、记忆，利用信息制定决策、指导外部行为等**。认知科学不同于传统的心理科学，必须寻找神经生物学和脑科学的证据，以便为认知问题提供确定性基础。由于认知问题是一个非常复杂的**非线性问题**，因此我们必须借助现代科学的方法来研究心智世界。

- 若在两个对象之间存在着某种相似性，那么可以把这两个对象之一看作**原型**，另一个看作**模型**，即在这两个对象之间存在着**原型——模型关系**。这里**对象之间的相似性**为模型概念的基础，应作最广义的理解。一般来说，相似性可以有**功能相似**、**结构相似**、**动力相似**、**几何相似**等。从控制论观点看来，在两个系统之间导致原型——模型关系最重要的相似性是**行为上的相似**。建立行为模型的基础是，在一定条件下，在形式、结构和工作过程的物理性质上完全不同的若干系统中，可以观察到同样的行为。相似性概念适用于非常广泛的对象，包括自然界的生物和无生命对象等。

1. 物理符号系统模型

- 一个信息加工系统，常称作**物理符号系统**。例如，认知是一个物理符号系统，计算机也是一个物理符号系统。很明显不同的英文字母、纸上的文字即是不同的符号。符号既可以是物理的符号，也可以是头脑中的抽象的符号，可以是计算机中的电子运动模式，或可以是头脑中的神经元的某种运动方式。实际上所谓“符号”就是**模式**；任何一个模式，只要它能和其它模式相区别，它就是一个符号。而物理符号系统的基本任务和功能就是**辨认相同的符号和区分不同的符号**。简单来讲即对符号进行操作就是对符号进行比较，即找出哪个是相同的符号，哪几个是不同的符号。用物理符号系统则主要是强调所研究的对象是一个具体的物质系统，如计算机的构造系统，人的神经系统、大脑神经元等。


- 既然认知与计算机均是物理符号系统，那么我们就能够**用计算机来模拟认知活动**。
- 根据“物理符号系统的第3个推论”，心理学和人工智能之间有一种互相依靠的密切关系。**符号主义**为认知科学的基本范式。
- 符号主义的模型的共同特点是**产生式规则**。虽然纸上的文字是物理符号系统，但并不是一个完善的物理符号系统，因为它的功能只是存储符号，即把字保留在纸上。一个完善的符号系统还应该有更多的功能。产生式规则是对符号串进行的**替换运算**，其实是一种抽象的符号，就类似于数学公式和数字的关系，数学公式是数字的替换。
- 产生式规则被描述成“**条件——动作**”的形式，每一产生式系统依次评价规则的每一条件，当每一条件都满足时，相应的动作才能执行。产生式规则可以有效的用来描述人类在推理和问题解决中的信息加工过程，较好的解释了人在不同领域问题解决活动中的操作行为。目前符号主义范式发展的主要认知模型有：**通用问题求解程序(GPS)**、**机遇问题求解**、**EPRM**、**奎联的语义记忆系统**、**HAM**、**ACT**、**MEMOD**以及“**信念系统**”和**SOAR**。

- 一个物理符号系统的输出是输入的函数，即对输入的客体进行**修改或建立**。一般输出客体会变成后面的输入客体，或者影响后面的输入客体，从而使整个物理符号系统变成一个封闭系统。此系统的外部行为即由**系统输出**组成，内部行为是由它的**记忆和控制的状态全部变化**构成。其中记忆是由一组符号结构 $\{E_1, E_2, \dots, E_m\}$ 组成。每种符号结构都具有给定的类型和一些不同的作用 $\{R_1, R_2, \dots\}$ ，为了定义符号结构给出一组抽象符号 $\{S_1, S_2, \dots, S_n\}$ ，每种作用包括一个符号。采用显式表示可以写成 $(\text{Type: } T \ R_1: S_1 \ R_2: S_2, \dots, R_n: S_n)$ ，若用隐式表示，则写成： $(S_1, S_2, \dots, S_n)$ 。其中符号结构的内部改变称作**表达**。

① ACT模型

- ACT系统是美国心理学家安德森(J.A. Anderson)于1976年继人类联想记忆模型(HAM)以后提出的系统的整合理论与人脑如何进行信息加工活动的理论模型，原意为“思维的适应性控制”，简称**ACT (adaptive control of thought)**。
- ACT为用户提供了一种**语言**建立心理学过程的计算机模型，可以通过程序来完成许多种认知课题，这是因为除了有**长期记忆**以外，ACT还有关于活动概念的**短期工作记忆**以及一个可编程的“**产生式系统**”，它使工作记忆，长期记忆产生变化。将HAM与产生式系统的结构相结合，模拟人类高级认知过程的产生式系统,在人工智能的研究中有重要意义。

- ACT产生式系统的一般框架由**陈述性记忆**、**过程性记忆**、**工作记忆**三个记忆部分组成。**工作记忆**包括从陈述性记忆中提取的信息、传入信息的编码和产生式活动所执行的信息；外部世界的信息经过编码暂时存储在工作记忆中，将要长时保持的信息存储到陈述性记忆中；匹配过程是把工作记忆中的材料与产生式的条件相对应，执行过程是把产生式匹配成功所引起的行动送到工作记忆中。在执行前的全部产生式匹配活动也称为**产生式应用**，在应用中还可以学习到新的产生式，这表明依据ACT理论，程序性学习是“**做中学**”的。最后的操作由工作记忆完成。



- ACT理论试图将认知过程表达成一种**模式**。
- 人们获得新知识有3个阶段，分别是：**陈述性阶段**，人们获得有关现实的陈述性知识，并且运用一般可行的程序来处理或理解知识；**知识编辑阶段**，学习者通过形成新的产生式规则或用新规则代替旧规则使得新旧知识产生联系；**程序性阶段**，学习者形成与任务相适应的产生式规律：产生式被扩展(概括)，具体化(辨别)及根据使用程度不同得到强化或削弱。




图2 ACT中的信息结构

- 系统的模块包含：用来辨别视野中的物体的**视觉模块**；控制手的运动的手**动模块**；获得记忆中信息的**声明/描述模块**；明了目前目标和意图的**目标模块**。**中心成果系统**实现模块间行为的调节和信息处理。中心成果系统对大部分模块中的活动不敏感，而是仅仅对存储在**模块缓冲区**中的信息做出响应。这模仿人的反应过程，人们不会关注到视野中的所有信息，而仅仅在意需注意的信息。接受缓冲区保存长期描述记忆所获得信息；手动的缓冲区控制和调节手的运动；视觉缓冲保存物体的位置，辨别物体特点；还有初步的声音和听觉系统。基本的神经中枢和相关的连接实施ACT-R中的**成果规则**，成果规则一个重要的功能是**分辨和更新ACT-R结构的缓冲区**。这样，在ACT-R中的循环是：**缓冲区保存外部世界和内部模块的描述，模块在缓冲区中被确认，成果开火(即成果为当前状态建议算子)，然后缓冲区被更新，执行下一个循环；这个结构是一个并行和串行的混合。**

② SOAR模型

- SOAR由AllonNewell等人于1986年开发的，被称为“通用智能的一种框架”。AllonNewell相信存在着认知和智能的通用性理论。SOAR主要讨论了知识、思考、智力和记忆，是一个应用范围非常广的认知结构。概念+事实+规则构成了人类的知识，并存放在人的大脑中，因此大脑实际上就相当于一个存放大量知识的“知识库”。Baddeley认为工作记忆指的是一种系统，它为复杂的任务，比如言语理解、学习和推理等提供临时的储存空间和加工时所必需的信息，工作记忆系统能同时储存和加工信息，这和短时记忆概念仅强调储存功能是不同的。

- **SOAR模型**就是在以上面的概念为基础上开发研制出来的，它实现了短时记忆的功能，并且很好的使概念、事实、规则有机结合在一起。虽然SOAR的成果是按照**if-then**的形式，但是它的思想并不是按照一般程序那样的具体执行步骤都写得很清楚，而是对问题的状态进行描述，然后针对不同的状态执行动作，具体应该选择那个动作则是**不确定的**(一个状态可以有几个动作可以选择)，这些类似于人的处理问题的方法(对于一个问题，人可以有几种不同的解决方法)，SOAR的处理机制就像人的大脑一样选择应该应用那个方法。






图3 SOAR的高层结构

- 右边是潜在的**结构过程**，包括**选择算子**、**创造状态**、**学习新成果**等。他们都是用**一般程序语言**实现的，用户不必改变他们的代码。左上方是**成果记忆区**，它包括所有的成果。用户可以创造成果来完成具体的功能。左下方是**工作记忆区**，工作记忆区是短期记忆单元存放的地方，以**表结构**来表示。SOAR在工作记忆中表示目前问题的解决的状态，工作记忆保存着**目前状态**和**算子**(还有因为**困境**而产生的**子状态**和**算子**)，算子可以对状态进行操作。

- SOAR把长期知识表示为**成果**，成果存储在成果记忆中。每一个成果都有一套状态和一套行为，当状态与工作记忆中的对象相符合时，行为就执行。**目前算子**是被选择并做出相应决定的算子；**建议的候选算子**被放在工作记忆区中；**参数选择过程**对这些候选算子进行比较，选择一个作为目前算子；然后目前算子中的成果改变工作记忆中的元素，进而改变状态；这个过程的循环就是**SOAR的执行过程**。目前算子的优先选择并不是一帆风顺的，当决定过程用来评价优先和决定状态的算子论证时，优先或者是不完全的或者是矛盾时，**困境**就会发生。优先不完全一般发生在：没有可接受的算子；可接受的算子很多，没有充足的优先决定应选择哪个算子。优先矛盾发生在：例如，算子A比算子B更好，算子B比算子A更好。因为优先是由不同的实例化成果独立的创造的，他们很有可能互相矛盾。
- 困境发生后，SOAR结构会创造出新的**子状态**来解决它。

2. 联结主义认知模型

- 联结主义认知模型即**人工神经网络**。**人工神经网络**是基于模仿生物神经网络的结构和功能而构成的一种信息处理系统。人工神经网络的一般结构有5种：
- ①**前馈式网络**：前馈网络的神经元是分层排列的，每个神经元只与前一层的神经元相连；
- ②**输入输出有反馈的前馈网络**：它是指输出层上存在一个反馈回路到输入层，而网络本身还是前馈的网络；
- ③**前馈内层互联网络**：这种网络是指在同一层内互相联接，它们可以形成互相制约，而从外部看还是一个前向网络；
- ④**反馈型全互连网络**：在这种网络中，每个神经元的输出都与其他神经元相连；
- ⑤**反馈型局部联接网络**：每个神经元的输出只与其周围的神经元相连，形成反馈的网络。

2 机器学习

2.1 机器学习概述及方法分类

- **机器学习**是研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已有的知识结构，使之不断改善自身的性能，是人工智能的一个研究领域。
- **机器学习**是人工智能的核心，是使计算机具有智能的根本途径。机器学习的应用遍及人工智能的各个领域，如**专家系统**、**自动推理**、**自然语言理解**、**模式识别**、**计算机视觉**、**智能机器人**等。
- 机器学习依从简单到复杂，从少到多的次序分为以下六种基本类型：（1）**机械学习**(Rote learning)（2）**示教学习**(Learning from instruction 或 Learning by being told)（3）**演绎学习**(Learning by deduction)（4）**类比学习**(Learning by analogy)（5）**基于解释的学习**(Explanation-based learning, EBL)（6）**归纳学习**(Learning from induction)。




图4 机器学习系统的基本结构

- **机器学习**是让计算机模拟和实现人类的学习的过程，目的是**获取知识**。
- 机器学习中的知识是人类知识的一个很小的子集，而且与人类知识的表示也区别。无论这种知识是**概念**、**规则**、**定理**等等，要使用在机器学习中必须要求**知识的表示**能够被机器所接受、应用。
- 系统的学习部分从环境中获得相关信息，并根据这些信息和执行部分反馈回来的信息修改知识库，提高系统执行部分完成任务的效能；执行部分根据知识库完成任务，同时把获得的信息反馈给学习部分。
- 机器学习系统实际上一个能自动处理数据信息，并能根据数据信息的变化或者对不确定的数据信息自动完善自己的数据信息处理方式。这里面包含两个含义：1、**能够处理数据信息**。2、**能够改变处理数据信息的方式**。

- 机器学习中的知识和它所要处理的数据信息分不开。数据来源于环境，而环境中的数据信息很多，如何去识别有用信息需要知识库中的知识。这时的知识是**有用数据信息知识**，也可以称为**样本特征知识**，它应该包括有用数据信息的基本特征。这时特征应该是指对数据集中数据分类的那些依据，它也就是经常所说的机器学习中的知识。
- 当机器具备了这些知识之后要求它能够处理数据信息。处理数据一种是**对数据信息分类**，另一种是**对给出的数据信息做出决策**。这是依据数据信息的特征推理出来的，也就是机器学习系统中的**执行过程**。因此，在机器学习系统中还要一类知识--**操作性知识**，它的功能是处理数据信息，由一系列**推理规则**构成。同时当环境变化后，数据信息发生了变化或者数据信息不确定的时候，对人类给定的原来给定的知识去处理这些数据信息可能得到错误的决定。因此要求机器应该具有**学习能力**，也就是**能自我完善知识的能力**。

- 机器学习中的知识还需要一种知识--**推理性知识**，这种知识有两个功能：
 - 1、获取新的数据信息特征；
 - 2、修改并完善操作性知识以及推理性知识自身。
- 对于操作性知识和推理性知识，它们是人类总结出来的定理或定义，然后按照某种具体的数学表示形式提供给机器使用。
- 在机器学习系统中的知识库包括三个方面的知识：**样本特征知识、操作性知识、推理性知识**。

2.2 机器学习应用现状

- **机器学习**是机器具有智能的重要标志，同时也是机器获取知识的根本途径。
- **机器学习**主要研究如何使计算机能够模拟或实现人类的学习功能。
- **机器学习**是一个难度较大的研究领域，它与**认知科学**、**神经心理学**、**逻辑学**等学科都有着密切的联系，并对人工智能的其它分支，也起到重要的推动作用。
- 许多新的学习方法相继问世并获得了成功的应用，机器学习的研究取得长足的发展。如**增强学习算法**、**Reinforcement learning** 等。
- 近年来，国内对有关机器学习的研究发展较快，主要在**泛化能力的研究**、**监督学习算法向多示例学习算法转化的一般准则**、**机器学习技术在工作流模型设定中的应用**、**机器学习技术在数据挖掘中的商业应用**、**基于机器学习的入侵检测技术**、**人工智能原理在人类学习中的应用**等领域中得到了广泛的应用并且得以发展。

- 在国外的机器学习发展同样很迅速，主要体现在对于搜索引擎和**汽车自动驾驶**的支持。
- 在搜索引擎方面，Google 的成功使得Internet 搜索引擎成为新兴产业，机器学习技术正在支撑着各类搜索引擎。
- 在汽车自动驾驶方面，机器学习算法的核心是决定车辆继续前进，还是左转、右转。主要任务是从立体视觉中学习如何在高速公路上行驶，要根据观察人类的驾驶行为记录各种图像和操纵指令，并且要将各种图像和指令进行正确分类等。当汽车在路况复杂的道路上行驶时，由计算机控制车辆自动行驶可以大大减少交通事故的发生。
- 在学习**对天文物体进行分类**、**生物技术**（可折叠的蛋白质预测，遗传因子的微型排列表示）、计算机系统性能的预测、银行业信用卡盗用检测、**美国邮政服务属性识别**、**互联网文档自动分类**等方面人工智能同样也在不同的层面和角度上快速发展壮大。

3 听觉信息认知计算

3.1 听觉信息的中枢处理

1. 耳的结构

- 耳由**外耳**、**中耳**、**内耳**三部分组成。**外耳**包括耳廓和外耳道，主要起**集声作用**。**中耳**主要由鼓膜、鼓室和听小骨组成，主要起**传声作用**。**内耳**由前庭器官（它与听觉无关）和耳蜗组成。耳蜗形似蜗牛壳，内部充满着淋巴细胞，是一个绕蜗轮盘旋两圈半的骨管。骨管内部被骨质螺旋板和基底膜分隔成上、下两半，在基底膜上排列着**毛细胞（即听觉的感觉细胞）**，毛细胞的适宜刺激是声波。听觉过程概括地说包括**机械→电→化学→神经冲动→中枢信息加工**等环节。声波从外耳至内耳基底膜的运动是**机械过程**，毛细胞受刺激后引起**电变化**，**化学介质的释放**，**神经冲动的产生**等活动，冲动传至中枢后则是一连串复杂的信息加工过程。





图 人耳的构造


2. 频率分析机理

- 听觉系统是如何对声音频率进行编码的？对这个问题的解释，有**地点说**和**频率说**两种主要的理论。**地点说（place theory）**的基本假设是基底膜由不同地点感受不同频率的声音刺激，所产生的神经冲动传达到脑便产生不同的音高感觉。地点说又分为**共鸣说**和**行波说**。在1863年亥姆霍兹提出**共鸣说（resonance theory）**，认为基底膜的横纤维是感音的共鸣要素。亥姆霍兹在考察内耳结构时，观察到基底膜底部的横纤维短，顶部的横纤维长，当声波的振动作用于卵圆窗时，卵圆窗将振动迅速传遍前庭阶，但基底膜的横纤维只是有选择地对一定的频率发生共鸣，就像竖琴的琴弦对不同频率的声波发生共鸣那样：**短纤维对高频率发生反应，长纤维对低频率发生反应，且一条纤维只对一种声波频率发生反应。**由于横纤维的振动转化为神经兴奋，传到听觉中枢便产生不同音高的听觉。

- 贝克西（Békésy, 1960）否定了这一理论，他通过对新鲜尸体的耳蜗进行直接观察，没有发现基底膜的横纤维有足够的共振张力（而这对于共鸣说是必不可少的）。他发现，基底膜受到运动液体振动时是以行波的形式发生振动的，基底膜横纤维很少是孤立起作用的，于是提出了**行波说（traveling wave theory）**，认为基底膜对不同频率的声音的分析，决定于最大振幅所在的位置：声波的振动作用于卵圆窗时，基底膜便产生相应的振动，而振动的幅度随着振动从蜗底向蜗顶推行的过程逐渐加大，当到达基底膜的某一个部位振幅达到最大时振动停止前进而消失。其中基底膜最大振幅的所在部位与外来声波频率的有关：**声波频率越低，最大振幅部位越靠近蜗顶；频率越高，最大振幅部位越接近蜗底**。耳蜗底部的基底膜对高、低音都能发生振动，顶端只对低音刺激发生振动，当中按频率高低次序排列，因此基底膜就成为一个初级的频率分析器。



- **频率说（frequency theory）**是由拉瑟福德（W.Rutherford）在1886年提出的。他认为**声音的频率是由听神经中神经元发放的速率来编码的**。例如，听到一个频率为2000赫兹的声音，听神经的第一级神经元每秒钟必须发放2000个动作电位。但生理学的研究表明，听觉通路中的单一神经元冲动发放速率根本不能快于1000赫兹，也就是说，单一的听觉神经纤维是不能传递人类听觉范围的所有频率的。
- 为此，温弗尔（E.G.Weaver）在1949年提出了**齐射说（volley theory）**。他认为，声音频率在400赫兹以内时，单一神经纤维以符合频率的发放速率发放冲动。但当频率增高时，由于神经纤维之间存在着合作和相互联系，就产生神经齐射现象。这样，神经纤维发放冲动的总效应就能体现声波的频率。如图显示，每条纤维对每种声波作出反应，反应的汇集代表声波的全部频率。



- 对声波频率的听觉编码很可能像色觉理论一样，**既包括地点说也包括频率说**。听觉信息在基底膜上依**行波说**编码，在神经传导路上依**频率说**编码。然后神经冲动传到大脑皮质听区就产生音高听觉。现在已有一些研究结果证明了这种猜想。

3. 强度及声源定位技术

- **响度**，又称为**声强**或**音量**，它表示的是声音能量的强弱，主要取决于声波振幅的大小。在物理上，客观测量声音信号强弱的单位是：**Pa(声压)**或**W/cm³(声强)**。它与基本声压比值的对数值称为**声压级**，单位是**db(分贝)**。
- 响度是听觉的基础。正常人听觉的强度范围是**0db-140db**(也有人认为是**5db-130db**)。固然，超出人耳的可听频率范围（即频域）的声音，即使响度再大，人耳也是听不出来的（即响度为零）。但在人耳的可听频域内，若声音弱到或强到一定程度，人耳同样听不到。
- 按照一般的规律，感受细胞和神经单元的兴奋阈值有高有低，刺激强时被兴奋的感受细胞和神经单元便多，每一神经单元兴奋后发放神经冲动的数目也大。**被兴奋的单元是高阈值的还是低阈值的，兴奋单元的总数是多是少，发放的神经冲动是多是少**，这三者都可以成为强度分析的依据。
- 有资料表明，听皮层及其他听觉中枢与声音的强度间还有一定的区域分布关系，即不同的区域分别对不同的刺激强度敏感，似乎**部位原则**也在起作用。

- **声源定位**指听觉系统对声源方位的判断，以**双耳听觉**为基础，利用当声音由声源传到入耳时所具有的**强度差（声级差）、时间差（相位差）、音色差**来区别。这些差别作用于人的中枢神经系统，使中枢神经系统对声音传来的方向做出心理判断，这就是我们所说的“**听觉定位**”。由于从声源到两耳的距离不同及声音传播途中屏障条件的不同所产生的强度差，时间差，音色差与声源的方位有关，是声音定位的三个主要要素。当一个声源发声时，由于聆听者自身头部的屏蔽作用，声源到两耳的距离一般来说并不相等。因此到达两耳的声音也就不完全相同，而是具有了一定的时间差和强度差。一般近似的把人头当做一个球体来处理，对于一般人来说两耳间距为**15cm**左右。对于纯音来说，声音到达双耳时存在时间差。声音绕过聆听者的头部以后，在双耳产生的声音响度差不仅与入射角有关，而且还是频率的函数。在频率低于**300赫兹**，由于波长很长，声波可以不受阻挡的绕过头部，在左耳和右耳产生相等的声压，这样双耳感觉到的声波强度差几乎为零。

- 总的来说, 在声音为低频时, 双耳强度差并不明显, 因此对声源方位的判断主要依赖于**双耳时间差**的信息; 在声音为高频时, 到达双耳时的相位差不明显, 对声源方位的判断主要依赖于**双耳强度差**的信息。实际上, 一般声源发出声波绕过聆听者的头部后既会产生强度差又会产生时间差。
- **声源定位技术**是通过声学传感装置接收声波, 再利用电子装置将声信号进行转化处理, 以此实现对声源位置进行探测、识别并对目标进行定位及跟踪的一门技术。现有的声源定位技术有3类基本方法: (1)**基于最大输出功率的可控波束形成技术**; (2)**基于高分辨率谱估计技术**; (3)**基于声达时间差 (TDOA) 的定位技术**。前两种方法为**直接定位法**, 计算量较大、效率低。第3种方法是一种**间接定位法**, 相对前两种方法而言计算量小, 定位精度高, 目前得到广泛的应用。

- 除了声源定位这一重要功能外，和单耳听觉相比，**双耳听觉有明显的优点**。由于双耳综合的结果，声音的响度可以增加，相当于单耳时提高3—6分贝，双耳听觉的辨别能力比单耳好；特别是在有噪声干扰的情况下，双耳听觉对语言的识别能力明显地比单耳高。在双耳听觉的条件下，**右耳**对语言信号的感受似占较重要的地位，**左耳**则似对非语言信号的感受较重要，这可能和大脑两半球的分工有关。
- 关于听觉系统如何辨别复杂的问题，目前存在着两种截然不同的观点：**(1)** 复杂声的感受以听觉系统对其**简单组成成分的感受**为基础，复杂声在听觉中枢引起的神经活动过程，是各组成成分引起的神经活动过程的总和；**(2)** 听觉系统有分工检测各种复杂声音或声音某种特征的专门结构单元，称为**探测器**或**特征探测器**，它们只对特定的声音或特定的声音特征敏感，对其他声音或声音特征则无反应。

3.2 语音编码

- 现代通信的重要标志是**实现数字化**,而要实现数字化首先得把模拟信号转变为数字信号,这种变换对语音信号来说就是**语音编码**。为了提高语音编码和语音信号数字传输的有效性,通常还要进行**语音压缩编码**。语音压缩编码技术有多种,归纳起来大致可分为三类,即**波形编码**、**参量编码**和**混合编码**。另外,根据编码速率的高低还可分为**中速率**和**低速率**两大类。
- **波形编码**是将时间域信号直接变换为数字代码进行传输,也就是说这种编码是将语音信号作为一般的波形信号来处理,力图保持重建的语音波形与原语音信号波形一样。这种编码方式的特点是适应能力强、重建语音的质量高,例如**PCM**、**M**、**ADPCM**和**自适应预测编码 (APC)**、**子带编码(SBC)**及**自适应变换编码(ATC)**等均属于这一种。但这种方式所需的编码速率较高,在**16kbit/s-64 kbit/s**速率范围能得到较高的重建质量,而当速率进一步降低时,语音重建质量就会急剧下降。

- **参量编码**,又叫**声码化编码**,是在信源信号频率域或其它正交域提取特征参量并将其变换为数,以及在接收端从数字代码中恢复特征参量,并由特征参量重建语音信号的一种编码方式。这种方式在提取语音特征参量时,往往会利用某种**语音生成模型**在幅度谱上逼近原语音,以使重建语音信号有尽可能高的可懂性,即力图保持语音,但重建语音的波形与原语音信号的波形却有相当大的区别。这种方式的特点是编码速率低 (1.2 kbit/s - 2.4 kbit/s 或更低),但只能达到合成语音的质量(即自然度、讲话者的可识别性都较差的语音),并当码率提高到与波形编码相当时,语音质量也不如波形编码。利用参量编码实现语音通信的设备通常称为**声码器**,例如**通道声码器**、**共振峰声码器**、**同态声码器**以及广泛应用的**线性预测(LPC)声码器**等都是典型的语音参量编码器。

- 当前,由参量编码与波形编码相结合的混合编码的编码器正在得到人们较大的关注。这种编码器既具备了声码器的特点(利用语音生成模型提取语音参数),又具备了波形编码的特点(优化激励信号,使其与输入语音波形相匹配),同时还可利用感知加权最小均方误差的准则使编码器成为一个闭环优化的系统,从而在较低的比特率上能获得较高的语音质量。例如,多脉冲激励线性预测(MPLPC 或 MPC)编码,正规脉冲激励线性预测(RPE_LPC)编码和码激励线性预测(CELP)编码都属于这一种,这种编码方式能在4kbit/s-16kbit/s中低编码的速率上得到高质量的重建语音。

- 在全欧洲数字蜂窝标准GSM语音编码器中,采用规则脉冲激励长期预测编解码技术(RPE-LTP),比特率为13kbps,该编解码器在与各种编码器一起进行主观测试后被选中。RPE-LTP编解码器结合了早期法国提出的基带RELTP的优点与德国提出的多路脉冲激励长期预测MTP-LTP编码的优点。
- 编码器包括4个主要处理模块,语音序列首先预加重,排列成20ms的分段,然后加窗,短期预测(STP)滤波分析,即计算反射系数 $r_n(k)$ 的对数面积比LAR,8个LAR参数有不同的动态范围和概率分布函数,这样它们不用同样的比特数进行编码,为了误差 e_n 最小化,LAR参数也同样用LPC反滤波器解码。LTP分析包括寻找基音周期 p_n 、增益因子 g_n ,使得LPC差值 r_n 最小化,LTP通过判决时延D,提取基音。D使当前STP误差抽样 e_n 和前一个误差抽样 e_{n-1} 之间的互相关性最大化。以3.6kbps速率对提取的基音 p_n 增益 g_n 编码。LTP差值 r_n ,经过加权和分解,成为3个候选激励序列。分析这些序列的能量,选择其中能量最高的一个来表示差值,激励序列中的脉冲用最大值归一化、量化,然后用9.6kbps传输。





图 GSM 语音编码方框图

- 解码包括4个框图, 执行与编码互补的操作, 接收的激励参数通过RPE解码, 再通过LTP合成滤波器,LTP合成滤波器使用基音和增益参数来合成长期信号, 运用接收的反射系数执行短期合成来再生语音信号。



3.3 语音识别

- 近些年来随着计算机、通讯技术的发展，语音识别技术的重要性进一步得以体现。**语音识别技术**指计算机能根据人类说话的语句或命令做出相应的反应。当声音通过一个转换装置输入计算机内部并以数字方式存储后，语音识别程序便开始以所输入的声音样本与事先储存好的声音样本进行对比。对比完成后计算机会算出数个最匹配、最接近的声音样本序号，这样就可以知道所输入的声音是什么意思进而执行此命令了。
- 用计算机进行语音识别主要有三个阶段，**孤立语音的识别**，**连续语音识别**及**语言理解**。孤立语音识别已经进入实用阶段，目前国内外正在进行连续语音识别的研究，有些已经有商品出售，如，卡里奇-梅隆大学Harpy连续语音识别系统，RTSRS通用语音识别系统，DP-100、DP-200连续语音识别系统等。语言理解,这个课题目前世界上正在研究阶段。

- 一个完整的语音识别系统如图所示，可大致分为以下三个部分：**语音特征提取**，其目的是从语音波形中提取出随时间变化的语音特征序列；**声学模型与模式匹配（识别算法）**，声学模型通常将获取的语音特征通过学习算法产生，在识别时将输入的语音特征同声学模型（模式）进行匹配和比较，得到较佳的识别效果；**语言模型与语言处理**，语言模型包括由识别语音命令构成的语法网络或由统计方法构成的语音模型，语言处理可以进行语法、语义分析。
- 话筒把语音信号变成毫伏级电信号，经过线性放大后为了使后面识别工作进行得顺利准确，要进行**高频提补**，即辅音部分频率高能量小，为了使系统得到足够的辅音信息对高频加权。再经过**16个带通滤波器**，**A / D变换器**，变成数字量可以送到计算机中。




图 语音识别系统基本构成

- 从数字化信号中抽取特征的一种方法是进行**傅里叶变换**。傅立叶变换可以用来识别组成声波时影响最大的频率，抽取出的频率集合称作**频谱**。在语音识别中，常用另一种称作**线性预测（LPC）编码的技术**来抽取特征。傅立叶变换可用来在下一阶段中提取附加信息。LPC把信号的每个采样表示为前面采样的线性组合,预测需要对系数进行估计，系数估计可以通过使预测信号和附加真实信号之间的均方误差最小来实现。第三种方法是**倒频谱分析**。语音信号 $S(n)$ 的傅里叶变换，得到声道函数和激励源傅里叶变换的乘积，激励源的傅里叶变换是高频部分的函数，声道是低频部分，取对数后使乘积变成加法运算，很容易把激励源和声道函数分开。实验结果抽取这个特征进行匹配，效果很好。第四种方法是**修正相位谱**。1843年欧姆(G. S. Ohm)提出声学定律：“听觉对发音的理解，仅取决于振幅谱，而与各谱串成分相位无关。用**短时傅立叶谱分析语音(带通滤波器级法)**时，只包括了幅度谱信息，而语音信号是非最小相位系统，短时谱可能丢失一些语音信息，可以想象相位谱包含了某些有用的东西。相位有利于区别两语音特征，利用相位来识别就是可取的。

- 早期的语音识别模型多是建立在**模板匹配**基础上的，它们大多是按照简单的模板匹配的**特定人、小词汇量、独立词识别系统**。这一阶段的重要研究成果是**动态时间伸缩算法**。**概率语法分析法**适用于大长度范围的连续语音识别，它主要是针对“语言区别性特征”，对不同层次的知识，用若干不同的知识规则来描述和区分。这种方法的困难在于很难建立一个普遍有效的实用知识系统。**随机模型法**是目前语音识别研究的主流途径。随机模型法的主流代表算法是**基于参数模型的隐马尔可夫模型（HMM）方法**和**基于非参数模型的矢量量化（VQ）的方法**。基于HMM的算法主要用于大量词汇的语音识别系统，在语音识别性能上优于VQ算法。在一般应用的语音识别系统，都采用基于HMM的识别方法作为基本算法。

- 要完成语音识别程序的设计，首先我们要熟悉语音识别的工作模式，包括**识别模式**和**命令模式**。在识别工作模式下，语音识别引擎将提供一个巨大的**语音单词库**和**识别模板库**。任何语音识别程序都不需要在对识别语法进行设置和编程，只需要编制识别主程序就可以进行语音识别应用了。而在命令方式下，用户需要为应用程序提供的语音编写**语音字典**，并编译形成**语音模板**，然后再编写语音识别主程序，对应用程序提供的语音字典内的语音进行识别和处理。语音字典的设置包括**识别语法设置**、**语音规则设定**、**语音模板制作**、**字典编译**等。
- 语音程序环境的设置包括**CTI** 服务器的设置，语音采集系统的初始化和**引擎端口设置**等几个部分。为了实现语音识别，必须为计算机主程序添加必要的代码，以最终完成语音识别功能。根据语音平台提供的应用程序开发向导，可以设置各个端口的调用，并在**Windows**的**GUI** 界面下，方便地完成程序开发过程, 实现语音识别功能。

3.4 语音合成

- **语音合成**概括地讲就是可以让计算机像人一样将要表达的信息以普通人可以听懂的声音播放出来的技术，是一门典型的交叉学科。它涉及到**声学、语音学、语言学、语义学、信息论、信号处理、计算机、模式识别、人工智能、心理学**以及**人类的大脑神经活动**等众多学科的理论和技术。根据人类语言功能的不同层次，语音合成可以分成三类层次：(1)**按规则从文字到语音的合成**(Text-To-Speech)。(2)**按规则从概念到语音的合成**(Concept-To-Speech)。(3)**按规则从意向到语音的合成**(Intention-To-Speech)。
- 从现有的语音合成的水平来说，可以解决的还是从文字到语音的合成这个阶段，也就是**文语转换**(TTS)，后面所说的语音合成都是指文语转换。




图 文-语转换系统框图

- 将语音的合成过程看成是一个**层次化的分析过程**，从文本信息到语音信息的文语转换过程可以看成**不同的层次信息在不同的层面上进行分析处理的过程**。
- 在文本的层面上，先要在语言层、语法层和语义层上进行分析，得到**文本的层次信息**(包括词组、短语、句子等信息)。然后在层次化信息的基础上在语音层的基础上进行韵律分析，得出**语音层面上的韵律信息**(针对汉语来说就是超音段特征的生成，包括基频、时长、能量的综合韵律曲线)，然后根据生成的韵律特征，利用合成器生成或者从语音库中挑选单元来完成**语音数据的最后生成**。
- 在语言层、语法层、语义层的工作可以归结为**前端的文本分析**，而语音层面上的韵律生成和声学层面上的按韵律合成语音单元或在音库中挑选单元可以说**后端的韵律合成**。

- 对于语音合成系统来说，前端的文本分析部分都是相同的，只是由于要求的不同而有不同信息表达方式。而后端的韵律合成方面也可以层次化的分为两个部分，一个就是**按照前端给出的层次化文本信息生成合适的韵律**，而另一个就是**按照生成的韵律来产生最后的合成语音**，在产生韵律和合成语音的方法上，各种方法不尽相同，甚至两个部分成为一个不可分割的整体，但是从思想上来说，每个合成系统都包含这样两个方面。
- 从整个语音合成研究的发展历史来看，早期的**机械式语音合成器**反应了人们对语音产生机理了解得比较粗略，**现代语音合成的方法**基本上都是采用一种**语音模型**来合成语音。总的说来，近期语音合成的方法可以归结为四种：**1) 物理机理语音合成；2)源-滤波器语音合成；3)基于波形拼接技术的语音合成；4)可训练的语音合成；**
- 其中基于波形拼接技术的合成包括**基于小样本的波形拼接调整合成**以及**基于大语料库的波形拼接合成方法**。

- **物理机理语音合成**是通过对人产生语音的物理结构进行建模，从而产生语音，比如，对发音过程中嘴唇、牙齿、下巴等运动进行建模。**Tizte**曾经研究过一个数学模型，这个模型是对声带振动的过程进行建模。但是也有另外一些研究是对通过声带的气流来建立模型。
- 近来，物理机理语音合成的研究受到了制约，因为难以将它现阶段推向实用。其原因主要在于两个方面:一是**对语音产生过程中发声器官的运动和变化进行度量非常困难**，比如说如何精确记录舌位运动和口腔的变化。第二个原因是**和源-滤波器的语音合成模型相比，对通过声道气流特征和运动轨迹的数学建模也非常复杂，以及这种模型的计算量非常大**。但是目前，随着高性能计算机的出现和对发音机理的深入了解，很多学者在推动这方面的研究。

- **源-滤波器的语音合成**基于这样一种声学理论，这种理论认为**声音由激励和相应的滤波器形成**。
- 其中激励主要分为两种:一种是**类似噪声的激励**，主要形成**非浊音语音信号**;另外一种**是周期性的激励**，主要产生**浊音信号**。这两种激励有时也会共同使用，如产生某些**浊辅音信号**。在该方式里，音库中预先存放各种语音合成单元的声道参数，这些参数根据控制规则的要求进行修正，以合成出各种语言环境下的语音。




图 源-滤波器合成方式结构框图

- 在基于源-滤波器的参数合成中，合成器的工作流程主要可分为三步：
- 1)首先根据待合成音节的声调特性构造出相应的**声门波激励源**；
- 2)然后再根据协同发音、速度变换(时长参数)等音变信息在原始声道的基础上构造出新的**声道参数模型**；
- 3)最后将声门波激励源送入新的声道模型中，其输出就是符合给定韵律特性的合成语音。**共振峰合成**和**LPC(线性预测分析)合成**是上述源/滤波器型结构的参数合成器中最常用的两种方法。它们实现原理基本上类似，只是所用声道模型不同。同时，针对声道模型的特性，在源的选取上略有差别。

- 由于在模型的精确度方面的原因，以前的合成器都难以有效的合成高自然度的语音，而**基于原始语音库的波形拼接合成**在实现高自然度的合成系统上，取得了很大的进展。
- **波形拼接合成方法**的基本原理就是根据输入文本分析得到的信息，从预先录制和标注好的语音库中挑选合适的单元，进行少量的调整(也可以不进行调整)，然后拼接得到最终的合成语音，其中用来进行单元挑选的信息可以是前端分析得到的**韵律文本**，也可以是生成的**声学参数**(比如基频、时长和谱参数)，或者**两者兼有**。由于最终合成语音中的单元都是直接从音库中复制过来的，其最大的优势就是在于保持了原始发音人的音质。

- 在单元拼接合成方法最初提出时由于受音库容量以及单元调整算法的限制，其优势并不是很明显，主要是合成语音不连续，自然度不高，而且单元调整过大时导致语音音质急剧下降。一般我们把这种原始音库比较小(即拼接样本数比较少)的合成系统，称之为**基于小样本的波形拼接合成**。
- 与此对应的就是现在比较流行的**基于大语料库的单元拼接合成**。这种方法的演变主要得益于近年来计算机的运算和存储能力的飞速增长，其音库由以前的1MB变为100MB，甚至超过1GB，相应的单元挑选策略也越来越精细，使得挑选出来的单元基本不需要调整，不仅保持了原始语音的音质，而且不连续现象也得到很大的改善，自然度得到极大的提高。因此，**基于大语料库的单元拼接合成系统**得到越来越广泛的应用。

- 在构建一个大语料库合成系统时，主要包括以下几个重要环节:
- 1)**单元尺度的选择**:可以是音素、双音素、音节、词甚至短语等，对于中文语音合成系统，比较常用的基本单元是**声韵母**和**音节**;
- 2)**语料库构建**:首先是在保证单元覆盖率的前提下，根据特定的搜索策略从原始文本语料中挑选出合适大小的语料;然后进行音库录制并对音库进行标注，包括**音段切分**和**韵律标注**等;
- 3)**单元挑选算法设计和优化**:大语料库合成系统的单元挑选算法一般分为两步:首先是**基于决策树或者其他索引方式的快速预选算法，得到一定数目候选单元序列**;然后再考虑候选单元的自身代价和连接代价进行精细的**单元打分，从而得到最优的拼接单元序列**;
- 4)**单元拼接算法**:主要包括**韵律调整**和**单元平滑**;虽然大语料库合成系统的合成语音的音质和自然度都相当不错，尤其针对一些特定领域的应用，包括新闻播报和信息查询等。但是，它也存在一些内在的缺陷和不足，下面我们将一一介绍。

- 一般而言，**大语料库合成系统的合成效果都不是很稳定**，对有些语句可以合成的很好，而对有些语句则合成效果比较差，主要体现在虽然每个单元的音质都很好，但是有些拼接单元之间有比较大的不连续，如果一个句子中出现多个不连续的拼接点，整个句子听起来效果比较差。因此，大语料库合成系统更适合**在受限领域的应用**，比如数字串合成、新闻合成、旅游信息合成等。而对于任意文本合成，其合成效果还有待提高。
- 在大语料库合成系统中，一个非常重要的环节就是**语料库的构建**，具体包括**语料设计**、**音库录制**以及**音库制作**，其中音库制作包括**韵律和音段标注**。由于现在的音库越来越来(超过1GB)，使得音库制作的工作量非常大，而且周期也很长，虽然可以采用一些自动标注的技术来替代人工的方法，但是效果并不是很稳定，所以现有的系统一般只构建少数几个发音人(比如只有一个男声和一个女声)的音库，导致合成系统的合成语音比较单一。

- 此外，现在很多大语料库合成系统的单元挑选算法都是通过经验总结，并在具体环境(包括语种、发音人、语料等)下针对合成效果进行调试和优化得到的，其**鲁棒性不高**。如果环境有一定的变动，比如换一个发音人甚至换一个语种，则需要对单元挑选算法重新设计和优化。
- 由上面的分析可以看出，虽然现在大语料库合成系统的效果不错，但是也存在不少缺陷，比如：**合成语音的效果不稳定，音库构建周期太长以及合成系统的可扩展性太差**等。这些缺陷明显限制了大语料库合成系统在多样化语音合成方面的应用，因此，近年来**可训练的语音合成(Trainable TTS)**的概念被提出来并逐渐得到越来越广泛的应用。

- **Trainable TTS**的基本思想就是基于一套自动化的流程，根据输入的语音数据进行训练，并形成一個相应的合成系统。一般而言，训练是针对**模型**或者**参数**进行的。在语音信号处理中，最普遍有效的建模方法就是**隐马尔可夫模型(HMM)**，它在语音识别中已经有非常成熟的应用，目前的Trainable TTS技术也都是基于HMM进行参数建模。
- 根据HMM的应用层次和方式的不同，不同的研究机构，包括**NIT**，**Microsoft** 和**IBM**，对Trainable TTS提出了几种不同的实现技术和方法，对于它们的相同点和各自的技术特点，我们将会在后面作详细介绍。由于本论文的一系列关键技术研究都是围绕着NIT的Trainable TTS技术展开的，所以后面所称的Trainable TTS一般都是指在NIT的技术基础上构建的Trainable TTS。

- 在最初提出Trainable TTS方法时，由于受模型训练算法的不匹配以及参数合成器合成音质的限制，其合成效果与大语料库合成系统有比较大的差距，因此并没有得到研究人员的重视。不过，经过对**模型训练算法的改进**以及**STRAIGHT分析合成器的提出**，其合成效果有明显的提高。总体而言，Trainable TTS相对于现在大语料库系统的优势就在于，**可以在短时间内，基本不需要人工干预的情况下自动构建一个新的系统**，因此对于不同发音人、不同发音风格、甚至不同语种的依赖性非常小。
- 它的不足之处在于，由于采用**模型**来生成目标参数并基于**参数合成器**来合成最终的语音，其合成效果与原始语音相比还是有不小的差距。考虑到Trainable TTS在合成时所需的存储和运算资源非常有限，因此特别适合在**嵌入式环境下的应用**。

- 由于现在大语料库合成系统的合成音质和自然度都不错，大家对合成系统提出了更多的**需求多样化的语音合成**，包括多个发音人、多种发音风格、多种情感以及多语种等。而现有的语音合成系统大多是单一化的，一个合成系统一般只包括一到两个说话人，采用朗读或者新闻播报风格，而且针对某个特定的语种。这种单一化的合成语音大大限制了语音合成系统的在实际中的应用。为此，**多样化语音合成方面的研究**逐渐成为近期语音合成研究领域的主流。
- 实现一个多说话人的语音合成系统，最直接的方法就是录制多个人的音库并分别构建各个发音人的合成系统。由于针对每个发音人制作一个单独音库的工作量太大，因此这种方法在实际中并不可行。现在比较实用的方法是基于少量的目标说话人的语音数据，通过**说话人转换技术**对源说话人的语音参数(基频、时长和谱参数)进行转换，来实现多说话人的合成系统。对说话人转换技术的研究已经有近30年，比较经典的几种说话人转换方法有：**基于SATSC的码本影射的方法**、**基于混合高斯模型GMM的转换**以及**基于HMM的线性回归转换**等。虽然很多研究人员对说话人转换技术展开了比较深入的分析，但是到目前为止还没有一种方法可以很好地完成任意说话人声音之间的转换，这已经超越了当前语音科学技术所能达到的高度。

- 虽然目前大语料库合成系统的合成音质和自然度都不错，但是与真人发音相比**缺乏表现力**，主要体现在**发音风格单一**，**基本没有情感**。为了改善语音合成系统在表现力方面的欠缺，近年来，富于表现力的语音合成研究逐渐开展起来，尤其是**情感语音合成方面**。现在比较实用的情感语音合成系统的构建方法有两种:一种是**直接构建法**，即对每种典型的情感(比如高兴、生气、难过等)录制一个单独的音库来构建对应情感的合成系统;二是**采用情感参数控制的方式**，即基于一定情感语音数据对情感参数模型进行训练，从而实现对情感类型和强弱可控的合成系统。
- 针对**多语种语音合成**的研究工作目前还处于初步阶段，而且相对于前面的多说话人、多情感语音合成的难度也更大，这主要是由于语种之间的差异性相当大，甚至可能需要采用截然不同的合成方法来分别处理。目前的多语种合成研究大多还停留在只有两种语种的情况下，比如**中英文混读**，采用的方法一般是**分别录制两种语种的音库以及混读音库**，然后在合成时分别采用各自的合成引擎挑选单元，并拼接得到最后的合成语音。此外，与多语种合成类似还有**方言语音合成方面**的研究，比如汉语中除了普通话以外，还有多种方言，包括粤语、闽南语和东北话等，这方面的研究工作也正在开展。

- 为了合成出高质量的自然语音，除了要考虑**语音基元库的建立**、**语音单元的查找和拼接**、**语音合成**外，还要考虑**自然语言的理解**问题，这又牵涉到**文本的分词**、**正则化**、**注音**和**韵律处理**等问题。




图 基于语音数据库的文语转换过程

- 在语音数据库的设计中，首先要确定合适的**语音基元**。在汉语普通话语音合成中可以选择的基元包括：**词、音节、半音节、声韵母、音素**等。对于汉语普通话语音合成，将词作为合成基元不太合适，因为词条数目非常丰富，这不但会增加存储开销，还将极大地增加搜索的复杂度。而将音素或声韵母作为基元，则由于保留的自然音成分太少，需要后期进行复杂的波形处理，造成自然度下降。而选择**音节**作为语音基元，由于合成的语音基元都是来自自然的原始发音，合成语句的清晰度和自然度都将会非常高。而且，由于普通话本身是基于音节的语言，在普通话中共有**417个无调音节**，如果考虑音调，每个音节可能有五种声调：**阴平、阳平、上声、去声和轻声**，这样普通话所有音节大约是 **$417 \times 5 = 2085$ 个**，而常用的只有**1300个左右**，在数目上也是可以接受的。因此，采用“**带有声调的音节**”作为合成基元，是比较合适的。

- 要获得合适的语音基元，则必须要有好的**语料库**，才能根据需从语料库中切割出相应的基元。对于语料库的选择，可以采用权威部门发布的**标准语料库**，如中科院声学所、社科院语言所等制作的数据库。如果为了突出个性化，也可以自己用麦克风手工录制。有了合适的语料库，接下来就是要进行**基元的切割和存储**。对于基元的切割，可以采用任何一款能处理声音波形的软件，比如GoldWave 等。切割后的语音数据，可以以文件的形式存储在磁盘上，也可以以二进制的形式存储在数据库中。如果以文件形式存储，比如Windows下的Wave 文件，则需要建立数千个波形文件，这对于后续的查找和语音数据提取都比较麻烦。因此，在语音存储设计时最好采用**数据库**的方式来存储语音波形数据。在数据库的选择上，最好选择支持**BLOB(Binary Large Object)二进制大对象数据类型**的数据库，比如可以考虑Oracle 和SQL Server。

- 在对文本进行语音合成之前，必须对文本进行**语音标注**，以便搜索语音库，查找相对应的语音。而要对文本进行语音标注，又必须对所输入的文本作**分词、正则化、自动注音和韵律控制**等相关环节的处理。
- 与绝大多数中文信息处理一样，TTS 系统中的文本处理也是从**分词**开始的。通过分词，才能正确地分析语义，划分语音单元和注音，最终合成出准确的语音来。如例句：“我/长大/以后，我/的/胳膊/也/变长/了”。只有正确的分词，才能依据上下文判定前一个“长”应该读“zhang3”（拼音后面的数字代表音调，0-轻声，1-阴平，2-阳平，3-上声，4-去声），后一个“长”应读“chang2”，否则就无法确定“长”该如何读音。分词往往依靠事先编制好的**词典**，通过**规则或统计计算**作出字词切分的判断。当然，最近几年也出现了一些新的其他分词方法，比如**基于字标注法**等。关于分词的研究，已经非常成熟，目前市场上有大量的自动分词算法和成熟的产品，其分词精度普遍都达到了95%以上。读者可以参阅相关的文献资料 and 选择相关的产品来解决自己的分词问题，例如中科院计算技术研究所研制出的**汉语词法分析系统ICTCLAS**，分词速度单机996KB/s，分词精度高达98.45%。

- 真实文本中含有大量**非标准词**(Non-Standard Words)，这些词在词典中查不到，它们的读音也不能通过正常的拼音规则得到。在中文文本中，**非标准词**是指包含非汉字字符(如阿拉伯数字，标点符号、各种特殊符号等)的词，其中的非汉字字符需要转换成对应的汉字，这个转换过程称为**文本正则化**。比如：“2008-2009 年，我市最低工资水平为¥1200 元/月，同比增长了8.5%”。在这个句子里，“-”要正则化为“至”或“到”，“¥1200 元/月”要正则化为“每月人民币一千二百元”，“8.5%”要正则化为“百分之八点五”。**文本正则化**是文本处理的关键环节，也是语音合成的必要步骤。由于非标准化词的语音无固定规律可寻，要结合特定的语言环境才能确定，再加上非标准词类型多种多样，因此文本正则化也是语音合成的难点。

- TTS系统只对**汉字、英文、数字等发音符号**进行处理，对于**其它不发音字符**则不予标注，如空格、换行标记等。因此在进行语音标注之前，必须先进行**预处理**，过滤掉不发音字符，提取要发音的有效字符。正常情况下，对汉字注音，只需要建立一个汉字的拼音库，查阅该库就可以了。但汉语言是一门非常灵活的语言，存在非常多的特例和不规则的音变。因此对文字进行拼音标注，也是一个非常复杂的问题。造成汉字注音问题复杂的原因是多方面的，但主要体现在以下几个方面：一是**命名实体难以检测**；二是**数字串的读法不唯一**；三是一字多音及连续变调。
- 命名实体的注音关键在于自动分词时能否将这些词或词组检测出来，之后就可以交由正常自动注音模块处理。
- 对于数字串的读法，比如“9.11 事件”，只能标记为“jiu3 yao1 yao1 shi4 jian4”，就不能标记为“jiu3dian3 yi1 yi1 shi4 jian4”。对于这类错误，解决的办法是考数字串的相邻词及其词性，通过设定有限的规则，决定数字串的读法。
- 对于多音字，比如“我在北京出差时，出了一点差错”，要想正确标记“差”的读音，就必须首先正确的分词，将“出差”和“差错”分别分割出来，然后依据邻接关系来套用规则正确的判定。

- 对于**音变**，则通常要依据词性，相邻词及位置信息等综合判定。比如，双音节动词重叠式**ABAB** 的第二音节读轻声，像“考虑考虑”应该读“**kaŋ0 kaŋ0 kaŋ0 kaŋ0**”。再如“敏感”涉及“上上”相连变调，要将第一个上声变为阳平，正确的应标记为“**min2 gan3**”。对于上述这些特殊情况，通常可以根据经验和知识，建立一个**音变的规则库**，解决部分音变问题。
- 如果要让计算机合成的语音，既显得抑扬顿挫，有节奏感，又轻重缓急，富有感情，就必须对语音进行**韵律处理**。否则，合成出来的语音就会显得机械呆板，让人听起来极不自然，甚至会得到相反的信息。比如同样一句“我好怕你哟”，如果以陈述语气读出来，则表示“我真的怕你”，如果语气加重，则意思完全相反，表示“我根本不怕你”。**韵律**是一个听觉感知的概念，表现出的语调、节奏、停顿和重音等特征，它是语言交际的必要手段，能够帮助听者更好的理解语音携带的信息。**韵律处理**主要是对语音的基频、时长、能量和停顿进行预测和控制，属于计算机语音合成技术中比较核心的部分，又是最难控制和把握的，涉及语言学、声学、信息学等多种学科，在当前的学界研究中尚属于探索阶段。

- 语音合成从本质上讲是一种“**时间-波形**”的**编码技术**。语音合成先前比较流行的是**线性预测编码LPC(Linear Prediction Coding)技术**，通过该方法可以有效地估计基本语音参数，如基音、振峰、谱、声道面积函数等，可以对语音的基本模型给出精确的估计，而且计算速度较快。但是，由于自然语流中的语音和孤立状况下的语音有着极大的区别，如果只是简单地把各个孤立的语音生硬地拼接在一起，其整个语流的质量势必不太理想，因此，线性LPC 法对于连续语流的处理效果并不好。九十年代初，**基于基音同步叠加(PSOLA)算法的波形编辑技术**开始用于语音合成。这种方法的核心思想是直接对存储于音库中的语音运用PSOLA 算法进行拼接，从而整合成完整的语音。

- 随着数据库技术的不断发展和数据库性能的提高，当前，广泛使用了**基于数据库的语音合成方法**。基于数据库的语音合成方法采用**基元波形**进行**语音拼接**，然后对拼接后的波形采用各种算法进行**后期处理**，从而模拟出比较接近自然的语音。由于该方法比较简单和实用，特别是音库中的采样波形保留了原始发音人的语音特征，使合成语音的自然度和清晰度都得到了显著提高，因此受到广泛的欢迎。其不足之处是，要想获得比较理想的语音合成效果，往往要建立庞大的**语音基元库**，要数据库的支持，因此某些硬件配置较低的系统或一般的嵌入式开发平台，其应用就受到限制。
- 通过语音合成后的语音波形数据，将其格式化为特定格式的波形文件，比如Windows 操作系统下最常用的**Wave 格式**的波形文件，然后通过播放软件，调用发声设备进行播放，人们就可以听到合成后的语音了。

3.5 自然语言理解

- 在语言理论的基础上计算机是通过**自然语言理解技术**来对文字信息内容及表达的意义进行分析的。

1. 语言

- **语言**是人类所特有的用来表达意思、交流思想的工具，是一种特殊的社会现象，由**语音、词汇和语法**构成一定的系统。**语言学**是指对语言的科学研究，是研究语言的本质、结构和发展规律的科学。**语音**和**文字**是语言的两个基本属性。




图 语言的构成示意图

- **语言的起源和进化问题**似乎是个难解之谜。两千多年来，哲学家、人类学家、生物学家、心理学家和语言学家就此提出了各种各样的假设，但多属思辨性质，缺乏实证。因而，针对语言起源的研究曾被列为禁区，但是随着科学的不断发展，研究手段的不断更新，研究视野的不断扩大以及关于宇宙的起源、生命的起源、人类的起源等研究累累硕果的涌现，语言起源问题的研究重新被提上议事日程。并在更大的规模、更广阔的领域、更坚实的基础和更多学科的参与中开展起来。由于语言的本质特性是它的**口语性质**，这种口语行为过后留不下任何印迹，因此，现在的研究课题已从语言是怎样产生的转变到人类的祖先在什么时候已经具备了产生语言的必要和充分条件。人的语言能力要受到三个生物学因素的制约：**输入系统**（主要是听觉和视觉，特别是听觉）、**中央处理系统**（神经中枢）和**输出系统**（主要是发音器官），在这其中最重要的就是中央处理系统（神经中枢）。因此，有关语言的研究就主要集中在人类大脑与语言能力的关系上。

- 语言的产生是古人类进化的必然结果，它与大脑功能和人体其他功能的发展是密不可分的。古人类学家Leakey认为，人类最早的语言产生于200万年前的**能人（巧人，直立猿人，是第一种被认为属于人类的生物）**。当时的语言不过是一种简单的原始语。他的证据是，现代人的大脑里存在与语言和工具的使用有关的**布洛卡区(Broca's area)**和**韦尼克区(Wernick's area)**，而且大脑的两个半球不对称，控制语言和右手动作的左脑比右脑略大一些；布洛卡区和脑的偏侧化的痕迹都被Holloway在一个200万年前能人的头骨上找到了。Leakey的结论是，能人使用的语言尽管内容和结构一定都很简单，但确是真正的语言。然而Lieberman指出，根据Damasio等多位神经学家的最新研究，对语言起决定性控制作用的不是布洛卡区或韦尼克区的大脑皮层，也不仅是这两个区大脑皮层下面的部位，而是**多处大脑皮层及下面的神经结构以及将所有这一切联系起来的神经线路**。因此，在古人类头骨化石上发现布洛卡区的痕迹并不能证明什么。Lieberman还指出，脑的偏侧化并不是人类的特征，猴类也有类似的现象。这样，古人类的脑偏侧也不能说明什么问题。**大脑的进化**可以说是人类获得语言能力的一个关键的**必要条件**，但却不是充分条件。

- 产生语言符号的**充分条件**是一种心理和口头的社会行为，这种行为留不下任何印迹或证据供考古学家直接进行考察研究，但他们可以考察与语言相关的文化行为及其后果，揭示这些文化行为所蕴含的语言能力，从而达到对语言起源的认识。**文化活动**是人类的一种有意识的活动，标志着人类意识的产生，也就意味着人类语言的产生，因为**人类意识和语言**差不多是同义词，是区分人类和动物的标志。意识的产生就意味着语言的产生，因为**语言是生成意识的必要条件**。大脑的语言能力和我们的意识、记忆、想象、知识都有密切的关系。
- 原始语言产生后，人类语言又不断的进化和发展。**原始词**的产生，标志着人类的交际系统由以**信号**为基础发展到以**符号**为基础；其次是**词序**的形成，标志着**原始语**的诞生；然后是**虚词**，**屈折变化等其它语法手段**的产生，标志着原始语向**现代语**的过渡。**主语、谓语和宾语**一般被视为句子的三个最基本的成分。这三个成分的排列顺序因语言而异，语言学家根据各语言**基本语序**的不同，区分出“主宾谓”、“主谓宾”、“谓主宾”、“谓宾主”和“宾谓主”等不同的语序。关于语言最初的语序，目前尚无成熟的研究手段，也没有实质性的研究成果，语言学家只是提出了一些假设，其中一个就是**思维定势理论**。

- **思维定势理论**实际上是**Chomsky普遍语法理论**的一个翻版。这种理论认为人的大脑有某种先天的**认知结构**。人类识别人、物、行动、事件之类的大范畴以及以什么方式把这些范畴结合起来，要受到认知结构的制约，从而形成某种思维定式。语言建立在人的认知结构基础之上，由于人的思维定式中有“行事者先”和“行为—受事者比邻”这两条，所以世界上绝大多数语言的基本语序不是“**主谓宾**”就是“**主宾谓**”。
- 但是这种观点受到了人们的怀疑，因为任何一个物种的先天性行为，都不应该在物种内部有变异。所以，关于原始语的语序问题，还需要进一步研究。同时，在语言的进化过程中，为了满足表义的需要，必然会发展出其他语法手段，其中最主要的是**虚词和曲折变化**。虚词中出现比较早的可能是**介词**，因为介词表示的方位和领属关系对人类基本的认知活动至关重要。介词有几个特点：**分布广泛**，似乎没有哪一种语言没有介词；**数目有限**，一种语言里不过二三十个；主要用来连接两个语言成分，表明二者之间的关系；**通常是从动词、名词等实词转化来的**。

- 在**屈折语**里，各类实词都可能曲折变化，其中以动词的曲折变化最为丰富。**Aitchison**通过对皮津语和克里奥尔语的观察和研究发现，这些“动词附加成分”起初也是独立使用的实词，而且常有不只有一个词作为同一个语法标记的候选者。开始时这些成分的使用比较灵活，后来经过词义淡化、词形改变、重新解释等过程，其中一个词淘汰了其他候选者，才演变成完全的语法标记。认为**皮津语**和**克里奥尔语的语法化**是人类祖先语言语法化的重演，只是速度更快一些。
- 无论哪个语种，进化到现在的语言都与**大脑及认知**是密不可分的。因此，研究表明，正常的语言理解过程至少包括两条相竞争的神经处理脉络：**以记忆系统为基础的语义处理机制**和**以词汇符号组合为基础的处理机制**，后者在处理句子结构时基本上以**各种形态的句法规则**为基础，同时兼顾**特定语义词干**的限制问题。当语言实时展开时，单独词汇的意义需结合语句的句法结构，以表达出整体意义。

- 大脑通过接收的语义信息与存储在记忆中的语义信息相联系，将人、物体、行动之间的联系结合起来并建构出新的意义，而它们之间的**平衡协作**则使理解过程既合理又有效率。以前的证据已暗示文法的处理和左额叶皮层间的联系，包括**布洛卡区**，以及**词汇记忆**和**左侧颞叶**和**顶叶皮层**之间的联系。
- 早期的语言处理模式常常包括一些**记忆缓冲器**，一些句子元素为以后把一些短语、从句、句子结合起来被暂时储存，每一单词只有被放在一定的场合下才能被处理，然后再快速融入到句子中。**Boutla**等人的研究结果证明，大脑的语法分析能对在句子理解过程中语言处理的各个方面进行可能的预测。
- 因为，对一个词做语法分析要利用大量的约束因素，一个句子要根据每个词去估计语言所指和上下文的关系并进行分析，可预测类别中的意义特征，或预测目前的各种句法特征。**句法结构**是构成语言基本特性的心理表象，它允许词汇的含意与另一词汇相联系以传达谁在完成或接受一种行为。

2. 自然语言处理

- 在语言起源及进化理路基础上，如何让计算机实现**自动的或人机互助的语言处理功能**？同时，如何让计算机实现海量语言信息的自动处理、知识挖掘和有效利用？这就需要**自然语言处理**及**自然语言理解**。
- **自然语言处理(NLP, Natural Language Processing)** 是使用自然语言同计算机进行通讯的技术，是研究在人与人交际中以及在人与计算机交际中的语言问题的一门学科。
- **自然语言处理**主要研制**表示语言能力和语言应用(linguistic performance)的模型**，建立**计算框架**来实现这样的语言模型，提出相应的方法来不断地**完善这样的语言模型**，根据这样的语言模型设计各种**实用系统**，并探讨这些实用系统的**评测技术**。因为处理自然语言的关键是要让计算机“理解”自然语言，所以自然语言处理又叫做**自然语言理解**。

- **自然语言理解**(NLU,Natural Language Understanding)是人工智能早期的研究领域之一。这其中的自然语言是指人类社会的发展过程中自然产生的语言，而不是人为编造的语言，如程序语言等。从微观上讲，**语言理解**是指从自然语言到机器(计算机系统)内部之间的一种映射。从宏观上讲，**语言理解**是指机器能够执行人类所期望的某些语言功能。这些功能包括**回答有关提问、提取材料摘要、不同词语叙述、不同语言翻译**。
- **计算语言学**(Computational Linguistics) 是语言学的一个研究分支，用**计算技术和概念**来阐述语言学和语音学问题。这其中包括**自然语言处理、语音合成、语音识别、自动翻译、编制语词索引、语法的检测**，以及许多**需要统计分析和领域**。近几年来，自然语言处理技术的迅速发展，并不断与**语音技术**相互渗透和结合形成新的研究分支，因此，很多人在谈到“计算语言学”、“自然语言处理”或“自然语言理解”这些术语时，往往默认为同一个概念。

- 由于不同的研究方向所关注的侧重点不同，因此，很多人愿意将**语音识别**、**语音合成**和**说话人识别**等以语音信号为主要研究对象的语音技术独立出来，而其他以**文本(词汇/句子/篇章等)**为主要处理对象的研究内容作为自然语言处理的主体。




图 语音识别、语音合成、自然语言理解之间的关系

- 1956年以前，人们主要进行**自然语言处理的基础性研究工作**。
- 1948年Shannon把**离散马尔可夫过程的概率模型**应用于描述语言的自动机，同时又把**“熵”(Entropy)**的概念引用到语言处理中。而Kleene在同一时期研究了**有限自动机**和**正则表达式**。
- 1956年，Chomsky又提出了**上下文无关语法**。这些工作导致了**基于规则**和**基于概率**两种不同的自然语言处理方法的诞生，使得该领域的研究分成了**采用规则方法的符号派(Symbolic)**和**采用概率方法的随机派(Stochastic)**两大阵营，进而引发了数十年有关这两种方法孰优孰劣的争执。
- 1956年，人工智能诞生以后，自然语言处理迅速融入了人工智能的研究中。随机派学者在这一时期利用**贝叶斯方法**等统计学原理取得了一定的进步；而以Chomsky为代表的符号派也进行了**形式语言理论、生成句法和形式逻辑系统**的研究。由于这一时期，多数学者注重研究**推理和逻辑问题**，只有少数学者在研究**统计方法和神经网络**，所以符号派的势头明显强于随机派的势头。

- 1967年美国心理学家Neisser提出了**认知心理学**，从而把自然语言处理与人类的认知联系起来。
- 70年代初，由于自然语言处理研究中的一些问题未能在短时间内得到解决，而新的问题又不断地涌现，许多人因此丧失了信心，自然语言处理的研究进入了低谷时期。尽管如此，一些发达国家的学者依旧地研究着。**基于隐马尔可夫模型(Hidden Markov Model, HMM)的统计方法和话语分析(Discourse Analysis)**在这一时期取得了重大进展。
- 80年代，在人们对于过去的工作反思之后，**有限状态模型**和**经验主义**的研究方法开始复苏。
- 90年代以后，随着计算机的速度和存储量大幅增加，自然语言处理的物质基础大幅改善，**语音和语言处理的商品化开发**成为可能；同时，网络技术的发展和1994年Internet商业化使得基于自然语言的信息检索和信息抽取的需求变得更加突出。自然语言处理的应用面不再局限于机器翻译、语音控制等早期研究领域了。

- 从90年代末到21世纪初，人们逐渐认识到，仅用基于规则的方法或仅用基于统计的方法都是无法成功进行自然语言处理的。**基于统计、基于实例和基于规则的语料库技术**在这一时期开始蓬勃发展，各种处理技术开始**融合**，自然语言处理的研究又开始兴旺起来。
- 语言的分析 and 理解过程是一个**层次化**的过程，它主要包括如下四个层次：

① 语音分析

- 声音通过**音素、音节、音词、音句**，这四个层次表达句子的。其中，构成单词发音的独立单元是**音素**。上下文不同而发音不同。**语音分析**就是根据**音位规则**，从语言流中区分出一个个独立的音素，再根据**音位形态规则**找出一个个音节及其对应的词素或词。

② 词法分析

- 语言是以**词**为基本单位的，词又是由**词素**构成的，即**词素**是构成词的最小的有意义的单位。词汇在语法的支配下构成有意义的和可理解的**句子**，从而进一步地按一定的形式再构成**篇章**。**词法分析**是理解单词的基础，因而也是自然语言理解和处理的基础，其主要目的是从句子中切分出单词，找出词汇中的词素，从中获得单词的语言学信息并由此确定单词的词义。
- 词法分析包括两方面的任务：第一，**要能正确地把一串连续的字符切分成一个一个的词**；第二，**要能正确地判断每个词的词性，以便于后续的句法分析的实现**。以上两个方面的处理的正确性和准确度将对后续的句法分析产生决定性的影响，并最终决定语言理解的正确与否。
- 不同的语言对词法分析有不同的要求。英语和汉语在词法分析处理方面就存在着很大的差异。英语语言中，由于单词之间是以**空格**自然分开的，而汉语则不具备英语以空格划分单词的特点，其单词的切分是非常困难的，不仅需要**构词**的知识，还需要解决可能遇到的**切分歧义**。

- **【举例-1】** 中国人为了实现自己的梦想

中国/ 人为/ 了/ 实现/ 自己/ 的/ 梦想

中国人/ 为了/ 实现/ 自己/ 的/ 梦想

中/ 国人/ 为了/ 实现/ 自己/ 的/ 梦想

- **【举例-2】** 门把手弄坏了

门/ 把/ 手/ 弄/ 坏/ 了

门/ 把手/ 弄/ 坏/ 了

- 举例-1和-2说明，在汉语中，不同的分词方法会产生不同的意义。对于词性分析和判断，由于英语单词有**词性、数、时态、派生、变形**等繁杂的变化，再加上英语的单词往往有**多种解释**，词义的判断非常困难，仅仅依靠查词典常常是无法实现的，这就需要进行**形态分析**。

- 【举例6-3】 I'll see prof. Zhang home after the concert.

I/ will/ see/ prof./ Zhang/ home/ after/ the/ concert.

- 举例6-3中' ll和prof.属于形态分析中的特殊形式单词识别，要**写入字典**中。同时，形态分析中的有些情况要进行**形态还原**。有规律变化单词的形态还原，如：**所有格，复数，比较级，时态的变化**等，developing还原为develop，worked还原为work。若是不规律变换的要建立**不规则变化词表**。
- 因此形态分析主要遵循以下三步：**1、查词典，如果词典中有该词，直接确定该词的原形；2、根据不同情况查找相应规则对单词进行还原处理，如果还原后在词典中找到该词，则得到该词的原形；如果找不到相应变换规则或者变换后词典中仍查不到该词，则作为未登录词处理。3、进入未登录词处理模块**。而汉语中的每个字就是一个词素，所以找出词素是相当的容易的。

- 可见，在自然语言理解的词法分析处理中，汉语、日语、韩语等语言的词法分析的难点在于**分词切词**，而英语、法语等语言的难点则是**词素区分**。**汉语自动分词**是汉语语言处理和理解中的关键技术，也是中文信息处理发展的瓶颈，其困难主要在**“词”的概念缺乏清晰的界定、未登录词的识别、歧义切分字段的处理**三个方面。
- 因此，**汉语的自动分词算法**成为研究者们重点研究的内容，而其中，**歧义字段的处理**是各种算法研究的重点。至今专家学者们研究出了一系列的自动分词算法，如：**最大匹配法**（Maximum Matching Method：简称MM）、**基于标记法、约束矩阵法、句模切分法、基于统计语言模型（Statistical Language Models：简称SLM）的中文自动分词算法、神经网络分词算法、专家系统分词算法、基于词典的中文分词算法**等。

- **MM法**是最早出现的自动分词算法，是一种**机械分词方法**。该算法首先建立词库，将所有可能出现的词都事先存放在词库中，对于给定的待分词汉字串，采用某种策略进行匹配分词。策略有两种：一是**最大匹配法**，每次匹配时优先考虑长词；另一种则是**最小匹配法**，每次匹配时优先考虑短词。在机械分词的基础上，利用各种语言信息（如**规则、语法、语义、标点、数字**等）进行**歧义校正**，从而提高其分词的正确性。前面提到的**基于标记法、约束矩阵法、句模切分法**等就属于**机械匹配与切分歧义处理方法相结合的算法**。
- **基于SLM的中文自动分词方法**又称为**无词表分词算法**。所谓**无词表**是指分词匹配的词表并不是事先建立的，而是利用**机器学习**手段从语料库中直接获取分词所需要的某些适用知识作为分词依据的重要补充手段。

- 该算法的核心思想是：词是稳定的汉字的组合，上下文中汉字与汉字相邻出现的概率能够较好地反映成词的可信度，因此，将相邻共现的汉字组合的频率进行统计并将其统计信息作为分词的依据。
- 神经网络分词算法和专家系统分词算法都属于基于人工智能技术的自动分词方法。该类方法应用人工智能中的神经网络和专家系统来进行中文自动分词。

③ 句法分析

- 句法分析是从单词串得到句法结构的过程。为了实现句法分析的功能，必须赋予计算机两项内容：第一个是语法。通常语言学教材中的语法是面向人的，为了让机器分析句子，需要让机器知道这些语法，这种面向机器处理的语法也称为形式语法，它是规定语言中允许出现的结构的形式化说明。其中很重要的是如何表示形式语法，即形式语法的表示方式。

- 第二个是**句法分析算法**。在计算机自然语言处理中，我们更多地关心**句法分析器的算法**，因为句法分析器比识别器具有更强的能力，能够提供更多的信息。句法分析算法还应包括其中采用的**数据结构**的构造，在分析之后如何表示句子的**句法结构**等各个方面。在通常的人类自然语言中，未经分析的句子是**线性的符号串表示**。
- 在语法方面，**乔姆斯基的形式语法理论**是现代计算机科学的基础之一，同时也为语言学的研究打开了一个崭新的局面。**乔姆斯基理论的层次体系** (Chomsky Hierarchy)，指的是乔姆斯基定义的四种形式语法：**短语结构语法，上下文有关语法，上下文无关语法，正则语法**。四种语法的具体说明，如表6-1所示。这四种语法所产生的语言依据包含关系构成了严格的层次体系，可统一定义形式如下：一个**四元组**， **$G = (T, N, S, P)$** 其中，T为**终结符集合**，N为**非终结符集合**，S为**起始符**，P为**产生式规则集**。

- 举例-4中，定义了终结符集合T，非终结符集合N，这样就可以由起始符S根据产生式规则P来进行形式语法分析。

- **【举例-4】**

T = (the, man, killed, a, deer, likes)

N = (S, NP, VP, N, ART, V, Prep, PP)

S = S

P: (1) $S \rightarrow NP + VP$ (2) $NP \rightarrow N$ (3) $NP \rightarrow ART + N$


(4) $VP \rightarrow V$ (5) $VP \rightarrow V + NP$ (6) $ART \rightarrow the / a$

(7) $N \rightarrow man / deer$ (8) $V \rightarrow killed / likes$

表-1 乔姆斯基四种形式语法

层次	语法	识别自动机	产生式规则形式
0 型	短语结构语法	图灵机	$\alpha \rightarrow \beta$
1 型	上下文有关语法	线性有界自动机	$\alpha A \beta \rightarrow \alpha \gamma \beta$
2 型	上下文无关语法	下推自动机	$A \rightarrow \gamma$
3 型	正则语法	有限状态机	$A \rightarrow aB$ $A \rightarrow a$


- 从0型语法到3型语法是逐层强化的包含关系：



- 除了乔姆斯基的形式语法理论外，**句法分析树**也是一种常见的形式语法。在对一个句子进行分析的过程中，如果把分析句子各成分间关系的推导过程用**树形图**表示出来，那么这种图称为**句法分析树**。
- 【举例】

The man killed a deer.

利用句法分析树分析此句，得：



- 分析过程如下：

$S \rightarrow NP + VP$

$\rightarrow ART + N + VP$

$\rightarrow \text{The man} + VP$

$\rightarrow \text{The man} + V + NP$

$\rightarrow \text{The man killed} + NP$

$\rightarrow \text{The man killed} + ART + N$

$\rightarrow \text{The man killed a deer}$

- **转移网络及扩充转移网络**也是一种语言自动分析方法，是通过**状态**及其**网络图**进行分析的。

- 语法规律是否已经涵含在人类的头脑当中，并且可以通过内省的方式总结出来，目前还不清楚，而能够体现语法规则的语言现象却随处可见。同时，自然语言处理的任务开始从**小规模受限语言处理**走向**大规模真实文本处理**。在这种情况下，利用**统计**的方法，从观察到的句法分析样本出发，对未知的句子进行分析是句法分析研究中的另一类方法。**利用统计方法建立语言模型**是用**概率统计的方法**来揭示语言单位内在的统计规律，它不是简单地判断该句子是否符合文法，而是估计出句子在语言中出现的可能性。**统计句法分析模型**的目的是评价若干个可能的句法分析结果是当前句子的正确语法解释的概率或在这若干个可能的分析结果中直接选一个最可能的结果。
- 上下文无关语法的统计模型**为：对于一个字符串 $S = w_1, w_2 \cdots w_n$ ，其中，每一个 w_i 为词典中的一个词，则句子的概率为 $p(S) = \sum_t p(S, t)$ 。这样，在此模型下，就可以利用**机器学习算法**进行句法分析了。

④ 语义分析

- **语义分析**的主要任务是解释自然语言句子各个部分（词、词组及句子）的意义。由于在自然语言句子中存在大量的歧义，同时，同一句子不同人有不同的理解，所以仅仅靠句法分析是远远不够的，必须借助**语义知识**。语义分析主要有如下几种方法：
- **概念从属理论**是美国语言学家香克(Schank)在七十年代初提出的描述句义和语义的方法。他认为，人在理解自然语言时依赖的是潜在的**概念表述**，而不是具体的词或句子。人们总是用以前遇到的更简单、更基本的事来理解现在所遇到的事情。因此，当计算机理解自然语言时，也要依赖**事件的概念表述**而不是特定的词或句。**概念**是指动作或在某一方向上对一物体做些什么，所有概念都可以由少量作用于物体的原语动作来描述，这是概念从属理论的基本思想。**原语**可以表达大量动词潜在的意义，是描述事件的基础，其它动作都可由这些动作原语组合而成。因此，合适的**原语概念表述体系**对自然语言理解是必需的，原语的能力越强，理解系统的能力就越强。

- **语义场理论**(The Theory of Field)是德国学者特雷尔最先提出来的研究语言词汇的语义结构。他说：“**语义场**是介于单个词和整体词汇之间的一种活的现实。作为整体的一部分，它们与词一样具有被并入一个更大的系统中去的特征，而又和词汇一样，具有被分成较小单位的特性”。由此可见，语义场具有**层次性**。根据语义场理论可以对语言词汇进行分类。
- **格语法**(Case Grammar)是美国语言学家菲尔默(Fillmore)提出的一种语法分析模式。此语法承认**语义**在句法中的主导作用。格语法的基本思想是：**动词**在句中起中心作用，参与动作的个体称为“**语义格**”，且“格”的数量是有限的。针对每个动词的义项，由可能的“语义格”子集构成**格框架**，这一子集分为**必要的**和**可选的**两个集合。

- 菲尔默提出了六种格：“**施事**”格(Agentive), 表示动作的主体；“**工具**”格(Instrumental), 表示事件中使用的力量或工具；“**与**”格(Dative), 表示动作的受益者；“**使成**”格(Factitive), 表结果；“**处所**”格(Locative), 表地点；“**受事**”格(Objective), 表示动作的对象。后来又陆续加了“**经验者**”格(Experiencer)、“**来源**”格(Source)、“**目标**”格(Goal)、“**时间**”格(Time)和“**途径**”格(Path)。
- **格语法**给出了各格成分之间的深层语义，即句子的深层结构。这样，有不同表层形式的、含义相同的句子有同样的格框架。例如, I gave him the book. I gave the book to him. The book was given to him by I.这三个句子有相同的格框架。格语法适应于**汉语**的分析。格语法最大的特点是承认**语义**在句法中的主导作用，由格语法分析可以得到句子的深层语义结构，给出各成分的语义角色，对于确定正确的句法结构有很大帮助。

- **语义网络**(semantic network)由美国心理学家M. R. Quilian于1968年在研究人类联想记忆时提出。1977年美国AI学者G. Hendrix提出了**分块语义网络**的思想，把语义的逻辑表示与“格语法”结合起来，把复杂问题分解为几个较为简单的子问题，每个子问题用一个语义网络表示，把自然语言理解的研究向前推进了一步。
- 自然语言理解有很广泛的应用，主要有**机器翻译**、**信息检索**、**问答系统**和**文档分类**。
- **机器翻译**产生于20世纪30年代初，实现一种语言到另一种语言的自动翻译，代表系统有Google。

信息系统检索出现于20世纪50年代，是指将信息按一定的方式组织和存储起来，并根据信息用户的需要找出有关的信息的过程和技术，如图书馆中的文献检索就是其最主要的应用。

问答系统能够用准确、简洁的自然语言回答用户用自然语言提出的问题，直接用语言进行检索满足人们快速、准确地获取信息的需求。

文档分类也叫**文本自动分类**或**信息分类**，其目的就是利用计算机系统对大量的文档按照一定的分类标准（例如，根据主题或内容划分等）实现自动归类。主要应用于图书管理、情报获取、网络内容监控等。

4 视觉信息的认知计算

- **视觉**是人类与外部世界的一种交互方式，人类所获取的信息有**80%以上**是通过视觉接收得到的，利用视觉系统人类能够从客观世界的杂乱场景中抽取**像素**及**空间信息**，分析感兴趣的目标或区域，形成对场景内容的理解和认识，因而视觉在人类所有知觉方式（包括**视觉、听觉、嗅觉、味觉和触觉**等）中以其信息量大、利用率高占据着主导地位。

- 近些年来关于视觉认知计算的研究蓬勃发展，各国科学家从**解剖学、计算神经科学、认知心理学**等多方面对视觉系统展开了深入的探讨，无论是在**低层视觉表达**还是**高层视觉认知**方面，都大大增进了对视觉感知系统的结构和功能之间关系的理解，为视觉计算模型的建立奠定了坚实基础。
- 2008年，国家自然科学基金委员会启动“视听觉信息的认知计算”重大研究计划。在2009年“视听觉信息的认知计算”重大研究计划项目指南中指出：“与人类视听觉感知密切相关的图像、语音和文本（语言）信息在社会、经济和国家安全等领域中扮演着重要角色，并在今后一段时间内仍将迅猛增长。这类信息可被人类直接感知和理解，也可用计算机进行处理，但计算机的处理能力远逊于人类且处理效率远不能满足当今社会的发展需求。如何借鉴人类的认知机理和相关数学的最新研究成果，建立新的计算模型和方法，从而大幅度提高计算机对这类信息的**理解能力与处理效率**，不仅可有力推动信息科学的快速发展，也将为国民经济和社会发展做出重大贡献。”

4.1 视觉的生理机制

- 神经生理学提供了视觉神经系统的**解剖学构造**（如图所示），说明了视觉信号由**视网膜**到**脑皮层**的生物组织结构，它们在视觉过程中所起到的作用以及各种神经细胞的活动规律等。这种视觉组织结构是由**光电信号**到**主观意识**的复杂信息处理过程的生理学和心理学基础，组成了视觉信息处理的**硬件载体**。
- **视觉皮层**则是一个由大量简单神经元高度耦合的**巨型非线性动力学系统**，不同部位的神经元形态不同，响应特性迥异，但所有的视神经活动都遵循一定的共性规律，并具有相同的基本处理过程。下面简要介绍生物视觉感知系统中视网膜、初级视皮层、纹外皮层和高级视皮层的生理结构。




图-18 视觉神经系统的主要结构

① **视网膜**，也称为**外周脑**。视网膜分为三层，最内层**光感受器细胞**，接受光信号；最外层的**神经节细胞**，通过视神经，将信息传递到大脑。不同的节细胞，它的感受野不一样，有的对**深度**敏感，有的对**形状**敏感，有的对**颜色**敏感，从而形成了各种**并行的滤波器**，对输入的信息进行**层次化的特征提取过程**。

- **感受野**（Receptive Field）是指生物神经元在受到刺激时产生的神经冲动所能达到的范围。视觉系统在处理图像信息时采用的基本方式之一，就是通过不同形式的感受野**逐级**进行抽取，也就是说，在每一水平上抛弃某些不太重要的信息，抽取更有用的信息。





图-19 神经节细胞的感受野示意图

- ② **初级视皮层（V1区）**，是被科学家研究的最为深入和详尽的功能区域。它通过外侧膝状体核的中继，接收来自眼的视觉信息，是人类和灵长类动物视皮层的主要入口。初级视皮层中的典型视神经细胞（如**简单细胞**、**复杂细胞**等），都有与之相应的典型计算模型（如**简单细胞响应模型**、**复杂细胞相应模型**等）。
- ③ **纹外皮层（V2~V5区）**，V2区是纹外皮层的第一个皮层区域，它主要接收V1区的传入，它的输出传入纹外皮层的高级区域，如V3、V4和V5区。同时，它也有少数的反馈连接指向V1区。科学家对V2区采用**细胞色素氧化酶染色法**发现，V2区包含一些粗细条纹，同时，粗细条纹彼此间被一些轻度染色的中间条纹分开。对**波长（颜色）**有选择性的细胞集中在细条纹中，对**运动方向**有选择性的细胞则存在于粗条纹中，对**形状敏感**的细胞则在粗条纹和中间条纹中都有所分布。另外，在V2区，研究者已经描绘出几种具有高级感受野的V2细胞。

④ 高级视皮层，如颞下皮层（inferotemporal, IT）、颞中回皮层（middle temporal, MT），直至更高的一些视皮层区域，视神经细胞加工的特征明显复杂化。IT区的单细胞记录发现，某些细胞能对复杂形状进行反应。例如，在对面孔产生特异反应的细胞中，一些是对整个面孔反应，而一些是对面孔的部分反应，这种特异反应也显示了很强的不变性，如不受尺寸、位置、方位、颜色变化的影响。MT区被广泛认为是参与运动加工的主要视觉皮层，它接收V1区的投射，形成精细的运动加工信息。

6.4.2 视觉信息处理

- 人类的视觉信息处理过程已经进化到高度完美的阶段。**神经生理学和解剖学**的研究表明，视觉信息在大脑中按照一定的通路进行传递。视觉神经系统对视觉信息的处理存在着**串行**和**并行**两种方式。就串行处理方式而言，视觉通道中不同层次的神经细胞其感受野范围从低到高逐渐增大，编码特征复杂度增加。就并行处理方式而言，视觉通路的各个层次上存在着基本相互独立的并行通道，视皮层对物体的**形状、颜色、运动、深度**等信息进行并行处理。




图-20 视觉信息处理示意图

- **视网膜细胞接收外界信息的信号**。其中，**柱状细胞**主要感应光照条件的变化，**锥状细胞**则主要感应信号的颜色变化。视网膜有五类神经节细胞，不同的节细胞，它的感受野不一样，有的对**深度**敏感，有的对**形状**敏感，有的对**颜色**敏感等等，形成了各种**并行的滤波器**，进行了**层次化的特征提取过程**。
- 视网膜上的神经节细胞将接收到的信号通过**视神经交叉**和**视束**传到中枢的**侧膝体**。最后，信息到达大脑的皮层细胞。在大脑主皮层内，视觉信息是按照视皮层**简单细胞、复杂细胞、超复杂细胞、更高级的超复杂细胞**这样一个序列，由简单到复杂，由低级到高级分级进行处理的。
- 从神经处理信息的过程可以看到，视觉信息处理过程是一个既有**信息的横向流动**，又有**信息的纵向流动**的**极为复杂的动力学过程**。

- 视觉系统具有非常复杂的**层次结构**，主要体现在处理视觉信息的两条通路——**what通路**和**where通路**，如图所示。




图-23 视觉系统中的两条通路——what通路和where通路

- **what通路**从视网膜开始，沿腹部经过侧膝体（LGN）、初级视皮层区域（V1，V2，V4）、下颞叶皮层（IT），最终到达腹外侧额叶前部皮层（VLPFC）。
- **where通路**从视网膜开始，沿背部流经侧膝体（LGN）、初级视皮层区域（V1，V2）、中颞叶区（MT）、后顶叶皮层（PPC），最后到达背外侧额叶前部皮层（DLPFC）。
- 视觉通路上各层次神经细胞，**由简单到复杂**，所处理的信息分别对应于视网膜上的一个局部区域，**层次越深，该区域就越大**。而在各层次内部，信息则是**并行处理的**，在同一个层次内的神经元往往具有相似的感受野形状和反应特性，并完成相似的功能。

- 大脑对外界信息并不一视同仁，而是表现出**特异性**。这是由于大脑所能存储信息的容量远低于感受系统提供的信息总量，特别在视觉系统中尤为突出（据估计，人的视网膜提供的信息量大约是**每秒 $10^8 \sim 10^9$ 比特**，而大脑皮层细胞的总数仅为 **$10^8 \sim 10^9$ 个**），这就是通常所说的信息处理中的**瓶颈效应**。在此情况下，要实时地处理全部信息是不可能的，为此视觉系统只是有所选择地对一部分信息进行处理。另一个原因，对于观察者来说，并不是全部的外界环境信息都是重要的，所以大脑只需要对部分重要的信息做出响应，并进行控制。这种特异性称为**神经系统的注意机制**。

4.3 Marr视觉计算理论

- 在认知科学领域，“视知觉从哪里开始”是本源性问题。目前，国际上在视知觉研究领域占主导地位的理论是**以Marr为代表的视觉计算理论**。
- 20世纪80年代初，Marr首次从信息处理的角度综合了**图像处理、心理物理学、神经生理学**等学科的研究成果，提出了第一个较为完善的**视觉系统框架**，如图所示。虽然它在细节甚至主导思想方面尚存在大量不完备的方面，甚至有许多争议，但至今仍是广大计算机视觉工作者接受的基本框架。
- 从信息处理系统的角度出发，Marr认为对视觉系统的研究应分为三个层次，即**计算理论层次、表达与算法层次**和**硬件实现层次**。

3D模型表象
以物体本身为中心
坐标系

**3D Model
Representation
(Object based)**

通过立体视觉、运动分析、由灰度
复表面形状等不同的处理单元，得
完整的三维信息

2.5 维图
以环境（或观察者）为
中心的坐标系

**2.5D Sketch
(View based)**

形状、深度、位置及运动信息

2D “要素图”或“基元图”

**Primal Sketch
(Image based)**

边缘点、直线段、曲线、顶点、
理等基本几何元素或特征

Images

每一点的亮度值

图-22 Marr的视觉计算理论框架

- ① **计算理论层次**，主要回答计算的目的是计算的策略，即说明输入输出是什么，它们之间的关系是通过什么变换而得，或者是具有什么约束条件；它的总的目标即实现：输入是**二维图像**，输出是由二维图像“重建”的**三维物体**。
- ② **表达与算法层次**，主要回答各个模块的输入和输出、内部的信息表达，以及实现计算理论的目标算法。算法与表达有关，完成同一计算，不同的表达方式会有不同的算法。
- ③ **硬件实现层次**，主要解释如何用硬件来实现以上的算法。
- 从视觉计算理论出发，Marr将视觉系统分为**自下而上**的三个阶段，即**二维“要素图”**、**2.5维描述**和**三维模型表象**。

- ① **“要素图”**（Primary Sketch），也称**“基元图”**，是基于图像的，主要是二维视觉信息，由二维图像中的**边缘点、直线段、曲线、顶点、纹理**等基本几何元素或特征组成。
- ② **2.5维描述**，是基于对环境的描述，这一阶段主要重建三维物体在以观察者为中心坐标系下的三维形状与位置，称之为**部分的、不完整的三维信息**。这是因为，我们可能只观察到物体的一部分，另一部分有可能是物体的背面或被其他物体遮挡，所以是部分的、不完整的三维信息。这一阶段中存在许多并行的相对独立的模块，如**立体视觉、运动分析、由灰度恢复表面形状**等不同处理单元。只有通过不同的角度去观察物体，进一步处理才能得到以物体本身为中心坐标系下的完整的三维描述。
- ③ **三维模型表象**，是以物体本身为中心，这一阶段主要通过**立体视觉、运动分析、由灰度恢复表面形状**等不同的处理单元，得到完整的三维信息。其中，**“表象”**是指外部客观事物在神经系统内部建立的一种信息上的对应关系。

- 以Marr的思想为指导，20世纪80年代人们对这些特征提取的计算理论和实现算法进行了大量研究，例如，各种边缘检测理论、图像分割、基于概率统计的特征提取、基于信息熵的特征提取等。但是，这些算法大都面临着鲁棒性不够好的问题，往往只适用于某一类特定的条件，对于一般的、变化多样的条件只表现出有限的能力，而且对噪声和离散化引起的误差极其敏感。对于这些问题，许多专家提出了不同的意见，例如：特征提取不应只限于空间域，应充分考虑时域和频域特性；发展主动视觉，利用知识自上而下地指导初级信息处理的特征提取等。

4.4 计算机视觉

- **计算机视觉**（Computer Vision）就是研究用计算机来模拟人类视觉或灵长类动物视觉的一门科学，由图像数据来产生视野环境内有用符号描述的过程，主要研究内容包括**图像的获取、图像处理、图像分析、图像识别**。图像包括**静态图像**和**动态图像（视频）**，包括**二维图像**和**立体图像**。计算机视觉的输入是**数据**，输出也是**数据**，是**结构化或半结构化数据和符号**。**识别**是传统计算机视觉的目的，即要得到图像中有什么这一结论。
- **图像理解**和**计算机视觉的模型**依赖于实际应用背景，而采用的算法应该不同程度地接近视神经信息处理的基本原理。因而**生物视觉的神经机制及其感知机理**应成为视觉信息处理的软件载体。将**视觉认知**与**图像理解**相结合，从**生理学**和**神经科学**的角度，为计算机视觉提供基础。




图-23 计算机视觉与人类视觉认知过程

- 整个人类视觉认知过程包含三层结构：**感知过程**、**思维过程**和**认知过程**，如图-25所示。在人类视觉中，感知过程是**信息获取阶段**，完成将视觉转换为图像的任务，属于计算机视觉中对应的**图像处理过程**；思维过程是信息处理阶段，完成将图像转换为符号（数据）的任务，属于计算机视觉中对应的**图像分析过程**；认知过程是**信息再生和存储阶段**，完成将符号转换为**知识**的任务，属于计算机视觉中对应的**图像理解过程**。
- 计算机视觉模拟人类视觉认知过程，也具有**层次结构**特点，按照低层的**图像处理**、中层的**图像分析**以及高层的**图像理解**三部分进行划分，层次间形成了**自下而上的数据驱动**和**自上而下的知识（模型）驱动**，其目的是识别图像中的目标，标记目标间的关系，最终解释图像场景。因此，**视觉信息的表示**、**目标识别**和**场景分析**就成为了主要的研究内容。

- **低层的数据特征获取**，一方面可以采用不同的**边缘检测算子**得到线的起始位置、长度以及曲率等特征；另一方面可以通过**图像分割方法**将场景分成若干统一的区域，计算区域的颜色、方差、区域大小以及各种矩形形状特征实现区域的特征向量描述；或是通过**视觉选择性注意机制**提取场景中显著性区域作为特征向量。目前存在的主要方法有**曲线片段方法**、**高斯差分方法**、**多尺度Harris方法**、**边缘检测方法**和**SIFT描述方法**。低层的信息和**特征**是最基本处理和分析对象，**信息表示和特征提取**是完成上层图像理解中广义目标识别、场景分类以及分析推理的先决条件。

- **目标识别**，主要解决场景中“目标”或“物体”的判断、定位以及分类问题，即“**what-where**”问题，它是对场景中目标进行**特征分析**和**概念理解**的过程。其中，对目标识别的研究涉及以下问题：**多方位的目标变化、多视角的目标变化、光照变化、背景干扰、目标遮挡、类内的个体变化**等。目前目标识别已由**手写字符、人脸**等几类**有限目标识别**扩展到了**复杂场景下的多类目标识别**。现实世界中，目标的出现都不是相互孤立的，与其周围环境、场景有着密切的关系。近年来，**场景中的目标识别**成为研究的热点，尤其是复杂场景中目标所表现的各种变化形式更是为目标识别提出了新的挑战。

- **场景分析与理解**，属于计算机视觉中图像理解的高层任务，其主要目标是通过一组**语义类别**自动地对图像场景进行标记，实现场景分类并为目标识别等其他过程提供上下文信息。场景分类的实现取决于**场景建模过程**，目前对场景建模研究主要集中在两方面：（1）从图像中直接提取颜色、纹理和形状特征，结合有监督的学习方法将图像分成若干语义类别（如室内，室外，城市，风景等），形成**低层场景建模方法**；（2）通过**语义中层描述**对场景进行建模，从而减小低层特征与高层语义表达之间的“语义鸿沟”，建立与人类场景感知过程相一致的模型。对场景描述与理解的研究是近两年来的研究热点。2006年在MIT首次召开了**场景理解研讨会**，会上明确了场景描述与理解以及与目标识别、低层视觉信息表示之间的紧密关系，特别指出**场景分类**将会是计算机图像理解一个新的有前途的基础研究方向。