

1.描述下列正规表达式定义的语言：

(1) $a(a|b)^*a$ ：由 a 和 b 构成的且以 a 开头，以 a 结尾，长度至少为 2 的所有串集

(2) $((\epsilon|a)b^*)^*$ ：由 a 和 b 构成的所有串集

(3) $(a|b)^*a(a|b)(a|b)$ ：由 a 和 b 构成的且倒数第三位是 a ，长度至少为 3 的所有串集

(4) $a^*b a^*b a^*b a^*$ ：由 a 和 b 构成的含有且仅含有 3 个 b 的所有串集

(5) $(aa|bb)^*((ab|ba)(aa|bb)^*(ab|ba)(aa|bb)^*)^*$ ：由 a 和 b 构成的含有偶数个 a 和偶数个 b 的所有串集

2.试说明在一个长度为 n 的字符串中，分别有多少个前缀、后缀、真前缀、子串、子序列

答：

(1) 前缀： $n+1$ 个。从空串到长度为 n 的字符串本身，共 $n+1$ 个。

(2) 后缀： $n+1$ 个。同理。

(3) 真前缀： n 个。不包括长度为 n 的字符串本身的前缀。

(4) 子串： $\frac{n^2+n+2}{2}$ 个。空串是一个。不考虑空串，以第 1 个字符开头的子串

有 n 个，第 2 个字符开头的子串有 $n-1$ 个，依次类推，以第 n 个字符开头的子串

有 1 个，所以，一共有子串 $1+n+(n-1)+\cdots+1=1+\frac{n(n+1)}{2}=\frac{n^2+n+2}{2}$ 个。

(5) 子序列： 2^n 个。字符串中的每一个字符都可以出现或者不出现在子序列中，

又因为字符顺序不能调整，所以共有子序列 2^n 个。

3.写出下列语言的正规表达式：

(1) 包含 5 个元音的所有小写字母串，且元音按 $aeiou$ 顺序出现：

$d_1 \rightarrow b | \cdots | z$ (不含 a 、 e 、 i 、 o 、 u)

$d_1^* a d_1^* e d_1^* i d_1^* o d_1^* u d_1^*$

(2) 所有按词典递增序排列的小写字母串：

$a^* b^* c^* \cdots y^* z^*$

(3) C 语言的注释：

$d_1 \rightarrow$ 换行符

$d_2 \rightarrow \{\text{所有符号 (包括空符号)}\}$

$d_3 \rightarrow \{\text{换行符外的所有符号 (包括空符号)}\}$

$d_4 \rightarrow *$ (符号*, 而不是正则表达式中用来表示*运算的*)

$//d_3^* d_1 //d_4 d_2^* d_4 /$

(4) 数字串, 其中每个数字皆不重复:

$d_i \rightarrow i \mid \varepsilon \quad (i=0, 1, 2 \dots 9)$

$A = \{\text{由 0-9 组成的所有全排列}\}$

记 $\sum_{i \in U} D_i = D_{i1} \mid D_{i2} \mid \dots \mid D_{in}$

$\sum_{i0i1 \dots i9 \in A} d_{i0} d_{i1} \dots d_{i9}$

(5) 偶数个 a 和奇数个 b 组成的串:

$E \rightarrow (aa \mid bb)^*((ab \mid ba)(aa \mid bb)^*(ab \mid ba)(aa \mid bb)^*)^*$
 $E1E \mid E0E1E0E$

(6) 所有 a 和 b 组成的且不含有子串 abb 的串

$b^*(a^* \mid (ba)^*)^*$

(7) 所有 a 和 b 组成的且不含有子序列 abb 的串

$b^*a^*(b \mid \varepsilon)a^*$

(8) Email 地址:

(假设名称允许汉字, 域名只能为英文域名)

$d_1 \rightarrow a \mid b \mid \dots \mid z \mid A \mid B \mid \dots \mid Z \mid 0 \mid 1 \mid \dots \mid 9 \mid - \mid _$


$d_2 \rightarrow a \mid b \mid \dots \mid z \mid A \mid B \mid \dots \mid Z \mid 0 \mid 1 \mid \dots \mid 9 \mid - \mid _ \mid \text{啊} \mid \dots$ (所有汉字)

$d_2 d_2^* @ d_1 d_1^* (. d_1 d_1^* \mid \varepsilon)^*$

4.将下列正规表达式转成 DFA:


(1) $(a \mid b)^*$:

状态	输入符号	
	a	b
◎0	0	0




(2) $(a^*|b^*)^*$:

状态	输入符号	
	a	b
◎0	0	0



(3) $((\epsilon|a)b^*)^*$:


状态	输入符号	
	a	b
◎0	0	0



(4) $(a|b)^*abb(a|b)^*$:

状态	输入符号	
	a	b
0	1	0
1	1	2
2	1	3


◎3	3	3
----	---	---



5. 为下列正规表达式构造最小状态的 DFA

(1) $(a|b)^*a(a|b)$

[1] 画 NFA:




[2] 用“子集构造法”转化成 DFA

I	I_a	I_a
$\{0,1,2\}$	$\{1,2,3\}$	$\{1,2\}$
$\{1,2,3\}$	$\{1,2,3,4\}$	$\{1,2,4\}$
$\odot\{1,2,3,4\}$	$\{1,2,3,4\}$	$\{1,2,4\}$
$\odot\{1,2,4\}$	$\{1,2,3\}$	$\{1,2\}$
$\{1,2\}$	$\{1,2,3\}$	$\{1,2\}$

得：

状态	输入符号	
	a	b
0	1	4
1	2	3
⊙2	2	3
⊙3	1	4
4	1	4



[3]通过“分割法”进行最小化


a.先分为 $k_1=\{0,1,4\}$ （非接受状态）和 $k_2=\{2,3\}$ （接受状态）

b.考察 $\{2,3\}$ 是否可分。因为 2 经过 a 到达 2，属于 k_2 , 3 经过 a 到达 1，属于 k_1 ，所以可划分为 $\{2\}$ 和 $\{3\}$

c.考察 $\{0,1,4\}$ 是否可分。0,4 经过 a 到达 1，属于 k_1 , 1 经过 a 到达 2，属于 k_2 ，所以可以划分为 $\{0,4\}$ 和 $\{1\}$


d.考察 $\{0,4\}$ 是否可分。因为 0,4 经过 a 都到达 1，经过 b 都到达 4，所以不可再分
不可再分，用 0 表示 $\{0,4\}$ ，1 表示 $\{1\}$ ，2 表示 $\{2\}$ ，3 表示 $\{3\}$ 。于是有最小状态的 DFA:

状态	输入符号	
	a	b
0	1	0
1	2	3
⊙2	2	3
⊙3	1	0



(2) $(a|b)^*a(a|b)(a|b)$:

[1]画 NFA:




[2]用“子集构造法”转化成 DFA

I	I_a	I_b
$\{0,1,2\}$	$\{1,2,3\}$	$\{1,2\}$
$\{1,2,3\}$	$\{1,2,3,4\}$	$\{1,2,4\}$
$\{1,2\}$	$\{1,2,3\}$	$\{1,2\}$
$\{1,2,3,4\}$	$\{1,2,3,4,5\}$	$\{1,2,4,5\}$
$\{1,2,4\}$	$\{1,2,3,5\}$	$\{1,2,5\}$
$\{1,2,3,4,5\}$	$\{1,2,3,4,5\}$	$\{1,2,4,5\}$
$\{1,2,4,5\}$	$\{1,2,3,5\}$	$\{1,2,5\}$
$\{1,2,3,5\}$	$\{1,2,3,4\}$	$\{1,2,4\}$
$\{1,2,5\}$	$\{1,2,3\}$	$\{1,2\}$

得:

状态	输入符号	
	a	b
0	1	2
1	3	4
2	1	2
3	5	6
4	7	8
⊙5	5	6
⊙6	7	8
⊙7	3	4
⊙8	1	2



[3]通过“分割法”进行最小化

先分为 $G1=\{0,1,2,3,4\}$ (非接受状态) 和 $G2=\{5,6,7,8\}$ (接受状态)


G1	⊙G2
0,1,2,3,4	5,6,7,8
a→G1 G2 {0,1,2}{3,4}	a→G1 G2 {5,6}{7,8}

G1	G2	⊙G3	⊙G4
0,1,2	3,4	5,6	7,8
a→G1 G2 {0,2}{1}	a→G3 G4 {3}{4}	a→G3 G4 {5}{6}	a→G2 G1 {7}{8}

G1	G2	G3	G4	G5	G6	G7	G8
0,2	1	3	4	5	6	7	8
No Change	No Change	No Change	No Change	No Change	No Change	No Change	No Change


DFA:

状态	输入符号	
	a	b
0	1	0
1	2	3
2	4	5
3	6	7
⊙4	4	5
⊙5	6	7
⊙6	2	3
⊙7	1	0



(3) $(a|b)^*a(a|b)(a|b)(a|b):$

[1]画 NFA:




[2]用“子集构造法”转化成 DFA

I	I_a	I_a
$\{0,1,2\}$	$\{1,2,3\}$	$\{1,2\}$
$\{1,2,3\}$	$\{1,2,3,4\}$	$\{1,2,4\}$
$\{1,2\}$	$\{1,2,3\}$	$\{1,2\}$
$\{1,2,3,4\}$	$\{1,2,3,4,5\}$	$\{1,2,4,5\}$
$\{1,2,4\}$	$\{1,2,3,5\}$	$\{1,2,5\}$
$\{1,2,3,4,5\}$	$\{1,2,3,4,5,6\}$	$\{1,2,4,5,6\}$
$\{1,2,4,5\}$	$\{1,2,3,5,6\}$	$\{1,2,5,6\}$
$\{1,2,3,5\}$	$\{1,2,3,4,6\}$	$\{1,2,4,6\}$
$\{1,2,5\}$	$\{1,2,3,6\}$	$\{1,2,6\}$
$\odot\{1,2,3,4,5,6\}$	$\{1,2,3,4,5,6\}$	$\{1,2,4,5,6\}$

◎{1,2,4,5,6}	{1,2,3,5,6}	{1,2,5,6}
◎{1,2,3,5,6}	{1,2,3,4,6}	{1,2,4,6}
◎{1,2,5,6}	{1,2,3,6}	{1,2,6}
◎{1,2,3,4,6}	{1,2,3,4,5}	{1,2,4,5}
◎{1,2,4,6}	{1,2,3,5}	{1,2,5}
◎{1,2,3,6}	{1,2,3,4}	{1,2,4}
◎{1,2,6}	{1,2,3}	{1,2}

得:

状态	输入符号	
	a	b
0	1	2
1	3	4
2	1	2
3	5	6
4	7	8
5	9	10
6	11	12
7	13	14
8	15	16
◎9	9	10
◎10	11	12
◎11	13	14
◎12	15	16
◎13	5	6
◎14	7	8
◎15	3	4
◎16	1	2



[3]通过“分割法”进行最小化

先分为 $G1=\{0,1,2,3,4,5,6,7,8\}$ （非接受状态）和 $G2=\{9,10,11,12,13,14,15,16\}$ （接受状态）

G1	G2
0,1,2,3,4,5,6,7,8	9,10,11,12,13,14,15,16
a->G1 G2 {0,1,2,3,4}{5,6,7,8}	a->G1 G2 {9,10,11,12}{13,14,15,16}

G1	G2	G3	G4
0,1,2,3,4	5,6,7,8	9,10,11,12	13,14,15,16
a->G1 G2 {0,1,2}{3,4}	a->G3 G4 {5,6}{7,8}	a->G3 G4 {9,10}{11,12}	a->G1 G2 {13,14}{15,16}


G1	G2	G3	G4
0,1,2	3,4	5,6	7,8
a->G1 G2 {0,2}{1}	a->G3 G4 {3}{4}	a->G5 G6 {5}{6}	a->G7 G8 {7}{8}
G5	G6	G7	G8
9,10	11,12	13,14	15,16
a->G5 G6 {9}{10}	a->G7 G8 {11}{12}	a->G3 G4 {13}{14}	a->G1 G2 {15}{16}

G1	G2	G3	G4	G5	G6	G7	G8
0,2	1	3	4	5	6	7	8
No Change	No Change	No Change	No Change	No Change	No Change	No Change	No Change
G9	G10	G11	G12	G13	G14	G15	G16
9	10	11	12	13	14	15	16
No Change	No Change	No Change	No Change	No Change	No Change	No Change	No Change

DFA:

状态	输入符号	
	a	b
0	1	0
1	2	3
2	4	5
3	6	7
4	8	9
5	10	11
6	12	13
7	14	15

◎8	8	9
◎9	10	11
◎10	12	13
◎11	14	15
◎12	4	5
◎13	6	7
◎14	2	3
◎15	1	0



(4) 你有没有看出什么规律？

这些正则表达式都是表示由 **a** 和 **b** 组成的，倒数第 **n** 位为 **a** 的所有串集，不考虑字符串长度比 **n** 小的情况，其最小状态的 DFA 都有 2^n 个状态，分别对应字符串最后 **n** 位的所有可能的情况，并且，其中一半是接收状态（表示倒数第 **n** 位是 **a**），另一半是非接收状态（表示倒数第 **n** 位是 **b**），随着对字符串的扫描，实际上 DFA 状态的变化即为当前已经扫描过的子串的最后 **n** 位随着扫描过程的相互转换情况，所以，要从其他状态到达某一特定的状态，需要的字符都是一样的，要么都是 **a**，要么都是 **b**，且每一个状态节点的入度都是 2。

6. 什么是正则表达式匹配的贪心模式？

正则表达式匹配的贪心模式即是说，正则表达式一般趋向于最大长度匹配。例如对一个字符串进行贪心模式下的正则表达式匹配，得到的结果是从开始匹配的位置开始，到字符串结束所能匹配的最长的串，这个过程中可能多次会达到接收状态，而非贪心模式是只要匹配到第一次达到接收状态就停止。

7.写一段 python 程序，找出一个文本文件中的所有数字。

```
import re
f=open(r"./hello.txt","r",encoding='utf-8') #文件名在这里更改
text=f.read()
f.close();
p=re.compile("\d+(?:\.\d+)?")#允许出现 001 这样的数字
#p=re.compile('0(?:\.\d+)?|(?:1|2|3|4|5|6|7|8|9)\d*(?:\.\d+)?')
#不允许出现 001 这样的数字，会将其拆分成 0、0、1
list1=p.findall(text)
print(list1)
```