

文件说明：

- (1) **train_new2.py**: 训练代码，主要是提取特征，使用时需要改一下训练集和测试集的目录（目录之后会做出介绍），如果需要重新训练则需要运行此程序
- (2) **KNN1_com.py**: 使用欧氏距离作为衡量文档向量相似性的使用 KNN 算法的简体与繁体文本识别程序
- (3) **KNN2_com.py**: 使用归一化距离作为衡量文档向量相似性的使用 KNN 算法的简体与繁体文本识别程序
- (4) **xinhua_j.txt** 和 **msn_f.txt**: 分别表示简繁体训练语料
- (5) **sim.txt** 和 **tra.txt**: 测试文件，分别为简体和繁体
- (6) 其他文件: 运行 **train_new2.py** 后生成的存放各种变量的文本文件

使用说明：

程序有两种调用方式，如图所示：

```
PS D:\my_world\class\大三\大三下\主修课\语言分析技术\作业\7\代码> python KNN2_com.py -s 今天的天气很好啊
简体
PS D:\my_world\class\大三\大三下\主修课\语言分析技术\作业\7\代码> python KNN2_com.py tra.txt
繁体
PS D:\my_world\class\大三\大三下\主修课\语言分析技术\作业\7\代码> python KNN2_com.py sim.txt
简体
```

多余的参数会被抛弃，参数不足会报错
过程中可能出现编码错误而无法读入文件的情况。

算法说明：

- (1) 代码使用词袋模型，并且每个词都是单个汉字（只保留汉字，去除标点这样的存在），使用 **tf*idf** 作为权重来构造文档向量。
- (2) 使用的 KNN 方法，其中 K 可以在文件中更改值。
- (3) 有两个版本：直接使用欧氏距离衡量文档向量相似度的程序和使用归一化距离衡量文档向量相似度的程序。
- (4) 程序中将 **idf** 太小的词删除掉，阈值可以通过 **del_range** 调整