

文件说明：

(1) **train.py**: 训练代码，主要是提取特征，使用时需要改一下训练集和测试集的目录（目录之后会做出介绍），如果需要重新训练则需要运行此程序

(2) **KNN_dis.py**: 使用欧氏距离作为衡量文档向量相似性的使用 KNN 算法的简体与繁体文本识别程序

(3) **KNN_sim.py**: 使用归一化距离作为衡量文档向量相似性的使用 KNN 算法的简体与繁体文本识别程序

(4) **data** 文件夹: 存放训练和测试文件。**test** 文件夹存放测试文件（其中的 **sim.txt** 是简体，**tra.txt** 是繁体）。**train** 文件夹存放训练文件（其中的 **sim** 子文件夹存放简体训练文件，**tra** 子文件夹存放繁体训练文件）

(5) 其他文件: 运行 **train.py** 后生成的存放各种变量的文本文件

使用说明：

为了使得上传的文件不至于过大，训练集只有 20 个，真实情况下应该是多放入一些训练集，并且使用 **train.py** 重新进行特征提取，使得效果更好。

使用 **KNN_dis.py** 或者 **KNN_sim.py** 时也要先设定测试文件路径。

过程中可能出现编码错误而无法读入文件的情况。

算法说明：

(1) 代码使用词袋模型，并且每个词都是单个汉字（只保留汉字，去除标点这样的存在），使用 **tf*idf** 作为权重来构造文档向量。

(2) 使用的 KNN 方法，其中 K 可以在文件中更改值。

(3) 有两个版本：直接使用欧氏距离衡量文档向量相似度的程序和使用归一化距离衡量文档向量相似度的程序。

(4) 程序中暂时没有使用停用词，因为简体和繁体的区分还是很明显的，但是也可以根据停用词表和 **tf*idf** 信息整合。