



语言分析技术实验报告

实验 1：C—语言的词法分析器

姓 名：田佳铭
学 号：22920172204211
院 系：信息学院人工智能系
专 业：智能科学与技术
年 级：2017 级
指导教师：史晓东

2020 年 3 月 20 日

目录

一、实验目的.....	3
二、实验环境及工具.....	3
三、实验与附件说明.....	3
四、设计思想.....	4
1.总体设计思路.....	4
2.输入与输出.....	4
3.声明部分.....	5
4.规则部分.....	6
5.其他备用功能.....	6
6.实验结果.....	6
7.现存的一些问题与可能的改进方案.....	8
五、遇到的问题与解决.....	8

一、实验目的

1. 实现 C--语言的词法分析器。将一个 C--语言程序分割成 token 串的序列。处理 C--语言的所有 token 类型。
2. 程序要做成命令程序，带两个参数，分别表示输入和输出文件名。
3. 实例输入输出文件为 y.c y.out, z.c z.out，提交前保证你的分析器能够正确处理这些文件。

二、实验环境及工具

本实验使用 flex 工具来编写。

先编写(*)l 格式的文件，之后通过 flex 工具转变成 c 的代码，之后通过 GNU GCC 编译器生成可执行文件。

三、实验与附件说明

本次实验独立完成，参考了网上的一些资料，没有和同学进行内容上的讨论。
实验所花时间约为 6 个小时。

附件中文件说明：

- (1) y.c 和 z.c: 实验文件夹中的文件
- (2) y-old.out 和 z-old.out: 实验文件夹中的文件 y.out 和 z.out
- (3) y.out 和 z.out: 使用自己的可执行文件对 y.c 和 z.c 处理后的结果
- (4) test.c: 自己另加的测试输入文件，主要在 z.c 的基础上增添了指针类型
- (6) test.out: test.c 的输出文件
- (7) project1.l: 实验 1 的最终(*)l 格式的文件
- (8) project1.c: 由 project1.l 生成的 c 文件

(9) project1.o 和 project1.exe: 由 project1.c 编译生成的目标文件和可执行文件

四、设计思想

1.总体设计思路

要进行实验，首先要对 C++ 语言有所了解，这里主要参考网站上《基于 C++ 语言的编译原理实验教程》中对 C++ 语言的描述，并且针对给出的示例文件进行调整。

详情请看 project1.1 文件，下面对关键部分进行说明。

2.输入与输出

实验要求命令行输入参数，于是输入输出的关键代码如下：

```
void main(int argc, char **argv)
{
    ++argv;
    --argc;
    if (argc > 0)
    {
        yyin = fopen(argv[0], "r");
        if (argc > 1)
        {
            fp = fopen(argv[1], "w");
        }
        else
        {
            fp = fopen("aout.out", "w");
        }
    }
    else
    {
        yyin = stdin;
    }
    yylex();
    fclose(fp);
}
```

图 4-2-1 输入输出部分关键代码

根据输入参数数量和方式的不同，可以有以下方式来执行 project1.exe（这里不考虑第一个参数，即“project1.exe”或“路径\project1.exe”）：

- (1) 没有参数的情况，采用标准输入，即 yyin=stdin，此时输出文件默认为“aout.out”；
- (2) 一个参数的情况，输入文件名从命令行参数获取，输出文件默认为“aout.out”；

(3) 两个及两个以上参数的情况，输入文件名为从命令行参数获取的第一个参数，输出文件名为从命令行参数获取的第二个参数。

3.声明部分

声明部分如下：

[illegible]

图 4-3-1 正规表达式定义

除了一些辅助的正则表达式，比较重要的正则表达式有：

- (1) **ws**: 空串
- (2) **id**: 变量, 以字母开头, 由字母和数字组成
- (3) **number**: 数字, 包括整数与小数, 也包括正数与负数 (认为 001 这样的数字合法, 且认为只有 10 进制数)
- (4) **comment**: 注释
- (5) **string**: 字符串
- (6) **char**: 字符常量
- (7) **keyword**: 保留字, 包括变量类型 (根据文档说明, C++ 不包括浮点数类型, 所以不包含浮点数; 指针类型单独分一类; 数组类型因为涉及到表达式的正则表达式等比较麻烦的问题, 这里没有涉及, 所以现有的变量类型为: `void`、`int`、`char`、`long`、`short`) 和其他的一些保留字 (查阅文档发现 C++ 并没有 `do-while`、`switch` 和 `goto` 这样的语法, 目前有 `if`、`else`、`while`、`return` 四种)。
- (8) **pointer**: 指针变量类型, 包括 **keyword** 中定义的变量类型的指针及指针的指针
- (9) **pun**: 标点符号。
- (10) **rel**: 关系符号。

4.规则部分

规则部分如下：

```
"\n"      { /*nline++ */}
{comment} { /*fprintf(fp,"COMMOM %s\n",yytext); */}
{ws}      { /*fprintf(fp,"BLANK %s\n",yytext); */}
{number}   {fprintf(fp,"NUM %s\n",yytext);}
"_stdcall" {fprintf(fp,"STDSCALL %s\n",yytext);}
"_cdecl"   {fprintf(fp,"CDECL %s\n",yytext);}
{keyword}  {fprintf(fp,"KEYWORD %s\n",yytext);}
{pointer}  {fprintf(fp,"POINTER %s\n",yytext);}
{id}       {fprintf(fp,"ID %s\n",yytext);}
{string}   {fprintf(fp,"STRING %s\n",yytext);}
{chartype} {fprintf(fp,"CHAR_CONST %s\n",yytext);}
{rel}      {fprintf(fp,"REL_OP %s\n",yytext);}
{pun}      {fprintf(fp,"PUN %s\n",yytext);}
....
```

图 4-4-1 规则部分

除了几个特殊的，格式都大体相同。特殊的几条规则：

- (1) 换行、空串、注释不做处理（但准备了相关的代码）
- (2) 除了上面定义过的正则表达式，还增加了”_stdcall”和”_cdecl”两种调用方式。

5.其他备用功能

有些代码是注释掉的，需要时也可以解除注释，可以做以下的事情：

- (1) 统计每个 token 出现的行
- (2) 输出空串、注释等

6.实验结果

如图，可见可执行文件的执行是成功的且符合要求：



```
PS D:\my_world\class\大三\大三下\主修课\语言分析技术\实验\1\project1> .\project1.exe y.c y.out
PS D:\my_world\class\大三\大三下\主修课\语言分析技术\实验\1\project1> .\project1.exe z.c z.out
PS D:\my_world\class\大三\大三下\主修课\语言分析技术\实验\1\project1> .\project1.exe test.c test.out
PS D:\my_world\class\大三\大三下\主修课\语言分析技术\实验\1\project1>
```

图 4-6-1 文件执行情况

比较 y-old.out 和 y.out 的信息，如图，发现是一样的（也可以用命令行来比较，不过这样比较直观）：




图 4-6-2 y-old.out 和 y.out 的信息比较

比较 z-old.out 和 z.out 的信息，如图，发现是一样的：



图 4-6-3 z-old.out 和 z.out 的信息比较（一）



图 4-6-4 z-old.out 和 z.out 的信息比较（二）

打开 test.out 文件，发现指针类型又被正确的识别：




图 4-6-5 test.out 内容

可见，实验是比较成功的。

7.现存的一些问题与可能的改进方案

- (1) 有些正则表达式可能会存在问题
- (2) 正则表达式有更简便的写法，例如可以用 `type` 来取代 `keyword` 中一段式子（因为 `type` 是后来添加的所以没有回去修改 `keyword` 的定义）
- (3) 可能有不使用 `fprintf` 的输出方式。在学习 `flex` 的过程中，认识了 `yyin`，那么也应该存在 `yyout` 这样的变量，可能会使文件更加简洁清晰。
- (4) 之后可以想办法增加数组这种数据类型。

五、遇到的问题与解决

实验中主要碰到的问题是对 `flex` 还有点不太熟悉，经过多次尝试最终没有搞懂像书中的例子，规则中的 `return` 语句的作用，按照书上写会编译错误，所以最终采用直接输出的格式。